



浙江电力
Zhejiang Electric Power
ISSN 1007-1881,CN 33-1080/TM

《浙江电力》网络首发论文

题目：变电站监测数据质量提升技术研究及展望
作者：郑翔，陈韶昱，吴佳毅，张一康，张敏，于逸廷，薛安成
收稿日期：2025-09-03
网络首发日期：2026-01-28
引用格式：郑翔，陈韶昱，吴佳毅，张一康，张敏，于逸廷，薛安成. 变电站监测数据质量提升技术研究及展望[J/OL]. 浙江电力.
<https://link.cnki.net/urlid/33.1080.TM.20260128.0912.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

变电站监测数据质量提升技术研究及展望

郑翔¹, 陈韶昱¹, 吴佳毅², 张一康³, 张敏⁴, 于逸廷³, 薛安成³

1. 国网浙江省电力有限公司衢州供电公司, 浙江 衢州 324100;
2. 国网浙江省电力有限公司, 杭州 310007;
3. 新能源电力系统全国重点实验室(华北电力大学), 北京 102206;
4. 国网电力科学研究院有限公司, 南京 211106)

摘要: 随着变电站保护监控系统数字化、智能化的推进, 二次系统产生的多源异构数据规模急剧增长、维度持续攀升, 并出现异常频发、存储与计算成本增加等问题。因此, 清洗监测数据, 归并冗余信息, 构建高效的数据质量提升体系, 成为支撑新型电力系统发展的关键。有鉴于此, 系统梳理变电站监测数据清洗研究进展, 并结合 LLMs(大语言模型)技术发展趋势, 探讨 MLLMs(多模态大语言模型)在数据质量提升中的应用潜力。首先, 分析了变电站监测数据的基本特征及其质量提升的迫切需求; 其次, 围绕异常数据检测、异常类型辨识和数据修复 3 个关键环节, 分析总结了现有数据清洗技术的原理、优缺点及适用场景, 进一步探讨了 MLLMs 在相关任务中的应用路径; 最后, 展望了未来发展方向, 特别分析 LLM 技术应用需解决的关键问题。

关键词: 变电站二次系统; 数据质量提升; 数据清洗; 大语言模型

DOI:

Research and outlook on techniques for improving the quality of substation monitoring data

ZHENG Xiang¹, CHEN Shaoyu¹, WU Jiayi², ZHANG Yikang³, ZHANG Min⁴, YU Yiting³, XUE Ancheng³

- (1. State Grid Quzhou Power Supply Company, Quzhou, Zhejiang 324100, China;
2. State Grid Zhejiang Electric Power Co., Ltd., Hangzhou 310007, China;
3. State Key Laboratory of Alternate Electrical Power System with Renewable Energy Source (North China Electric Power University), Beijing 102206, China;
4. State Grid Electric Power Research Institute, Nanjing 211106, China)

Abstract: With the advancement of digitalization and intelligence in substation protection and monitoring systems, the volume of multi-source heterogeneous data generated by secondary systems has increased sharply, with continuously rising dimensionality. This has led to issues such as frequent anomalies, increased storage and computational costs. Therefore, cleaning monitoring data, consolidating redundant information, and establishing an efficient framework for data quality improvement have become critical to supporting the development of modern power systems. In light of this, this paper reviews the research progress in substation monitoring data cleaning and, in combination with the development trends in large language models (LLMs), explores the application potential of multi-modal large language models (MLLMs) for data quality improvement. First, the fundamental characteristics of substation monitoring data and the urgent need for improving data quality are analyzed. Then, it examines the principles, advantages, disadvantages, and applicable scenarios of existing data cleaning techniques around three key aspects: anomaly data detection, anomaly type identification, and data restoration. Further, it discusses the potential application pathways of MLLMs for these tasks. Finally, it outlines future development directions, with particular emphasis on the key issues that must be addressed in applying LLM technologies.

Keywords: substation secondary system; data quality improvement; data cleaning; LLMs

0 引言

变电站二次系统是变电站的核心基础设施，承担着变电站运行监视、操作控制和生产管理等功能^[1]。二次系统直接监测电网运行状态，监测数据是电力系统态势感知、调度控制的基础。同时，监测数据也蕴含重要设备状态信息和故障演变规律，潜在反映设备或系统的故障情况，对设备状态评估和故障诊断具有重要意义^[2-3]。

伴随着变电站数智化进程推进，传感器等智能组件在变电站中大量应用，监测数据维度持续攀升，多源异构数据规模爆炸式增长^[4-6]。同时，因电磁干扰、网络堵塞等原因导致的数据异常和质量下降问题也频繁发生^[7-8]，严重威胁电网监视和安全运行。因此，如何提升已采集数据的质量以支撑电网监控，受到越来越多的关注。

数据清洗直接检测和修复数据中的异常值、缺失值等问题，是提升数据质量的主要方法，已在同步向量异常数据检测与修复^[9-10]、设备状态评估^[11]、电量数据异常检测^[12]等诸多领域应用。文献[9]从本地、区域、系统3个层级归纳了同步相量异常数据检测和修复的研究现状。文献[11]对变压器油中溶解气体分析进行监测分析，基于孤立森林和神经网络模型实现了监测数据离群点的识别剔除与重构。文献[12]从系统状态、数据驱动和博弈论3个技术角度对现有的异常用电检测方法进行了系统性梳理，总结了不同方法的优缺点。文献[13]介绍了配电系统的不良数据类型，并分析相应的检测技术和修正方法。

值得注意的是，对于海量的多源异构数据，传统清洗方法面临着效率与智能化的双重挑战，大模型技术的发展或可为数据处理领域注入新的活力。当前，以LLMs(大语言模型)为代表的新一轮人工智能技术正在快速发展，ChatGPT、DeepSeek等标志性大模型更带动了AI技术的全民化浪潮。特别地，MLLMs(多模态大语言模型)具有强大的跨模态语义理解能力和生成式学习机制^[14-16]，文献[14]探讨了MLLMs在电力设备故障诊断等运维场景的赋能应用，并指出数据问题制约着LLMs的应用效果。文献[15]指出，LLMs凭借泛化和迁移学习能力，在数据处理阶段可实现自动

化标注，从而解决传统AI模型面临的数据标注难题。文献[16]探讨了LLMs在电力系统中的应用，通过实验展示了其在电力系统辅助运行中的能力和潜力。MLLMs能够实现多模态数据处理的自动化与智能化，或可推动数据质量提升技术进一步发展。

本文从变电站二次系统出发，首先分析了监测数据特征及质量提升需求；然后从异常检测、异常类型辨识和数据修复角度介绍了数据清洗技术的研究现状，比较了各方法的优缺点和适用场景；最后探讨了MLLMs在数据质量提升的应用路径及面临的问题，以期后续研究提供参考。

1 变电站二次系统及数据特征

1.1 变电站二次系统概述

变电站二次系统直接采集站内电网运行信息和保护、测控等二次设备状态信息，通过系统集成优化和信息共享，实现全站信息的统一接入、存储和管理^[17]。二次系统具有运行监视、操作控制、综合信息分析、智能告警等功能，通过网关机与主站相连，为调度、生产等主站系统提供统一的变电站操作和访问服务^[18]，其结构及信息交互关系如图1所示^[19]。

1.2 二次系统数据监测场景及类型

变电站二次系统有诸多数据监测场景，其数据类型各不相同，如表1所示。按功能用途，二次系统监测数据可分为运行信息、动作信息、告警信息、监测信息、诊断维护信息和控制命令6类。具体类型划分如图2所示。

表1 二次系统数据监测场景

Table 1 Data monitoring scenarios of the secondary system

数据监测场景	数据类型	示例
设备状态监测	时序数据、结构化数据	温度、油色谱数据、局部放电波形数据等
故障诊断与预警	多模态混合数据、非结构化数据	红外热成像图、设备噪声频谱、断路器动作日志等
负荷预测与调度	时序数据、空间关联数据	母线负荷曲线、电源出力数据、电网拓扑结构数据等
安全防护、环境监控	视频流数据、空间定位数据	站内视频监控、SF ₆ 气体浓度、安防传感器状态等
能效优化控制	多源异构数据、高维关联数据	无功补偿装置参数、电容器组投切记录等

1.3 监测数据特点

监测数据具有数据维度高、规模量级大、耦合性强^[20]、安全要求高等特点, 具体表现如下。

1) 维度高。监测数据包含多种变量特征, 如电压、电流等电气参数; 温度、湿度等设备状态参数; 事件和报警信息等。每个参数均可视为一个维度, 高维数据可全面反映变电站运行情况。

2) 规模量级大。传感器等智能组件在变电站中的大量应用使得监测信息更加全面, 但随之产生的数据规模也逐渐庞大。常规 SCADA(数据采集与监视控制)系统 10 000 个遥测点每年将产生约 1 TB 数据, 广域相量测量系统将产生 495 TB 数据^[4]。

3) 数据耦合性强。监测数据在机理、时间和空间上存在复杂的耦合关系。如电气量变化受 KCL、KVL 等物理规律的约束。

4) 安全性要求高。变电站监测数据包含电力设备实时运行参数、故障诊断记录及调控指令等核心信息, 其安全性直接关系到电力系统稳定运行与电网关键基础设施防护^[21]。

2 数据质量提升需求

高质量监测数据是电力系统态势感知、风险预警和调度控制的重要基础^[9]。数据质量不仅影响监控系统数据的准确性和完整性, 还会对系统



图2 监测数据类型

Fig.2 Types of monitoring data

的运行、决策和安全性产生影响。对监测数据质量提升需求进行总结。

1) “脏”数据清洗需求。受电磁干扰、通信异常等因素影响, 监测数据中存在缺失、跳变、重复等“脏”数据类型, 直接影响数据完整性与可信度。“脏”数据异常可能引发系统误报警, 威胁变电站的运行安全。通过统计分析和机器学习等方法, 结合数据特征以识别异常数据并进行修复, 提高数据质量以满足应用要求。

2) 异常类型辨识需求。设备/系统发生故障




图1 变电站二次系统结构及信息交互

Fig.1 Structure and information interaction of substation secondary system

时, 监测数据往往呈现出一定的变化趋势^[22]。这类有效异常数据是故障诊断与预警的重要依据。需建立数据变化规律分析机制, 区分由故障引发的有效异常类型与“脏”数据异常, 清洗时保留有效异常特征, 实现故障隐患的早期识别预警。

值得注意的是, 数据特点提高了需求的满足难度, 同时也提供了解决途径, 如图3所示。




图3 监测数据特点与质量提升需求关系

Fig.3 Relationship between characteristics of monitored data and quality improvement requirements

3)对于“脏”数据清洗需求, 数据高维、规模大的特点增加了“脏”数据数量和清洗难度, 对数据安全也有更高要求。而数据的高维度和强耦合性也为清洗工作提供了更多突破点, 通过挖掘监测量间的时空关联规律, 建立多参量耦合模型, 可有效提升异常检测精度, 提高清洗准确率。

4)对于异常类型辨识需求, 高维、庞大的监测数据完整记录了设备状态的演变过程, 其内在的强耦合性与时序连续性为故障特征提取建立了天然优势。解析数据间的关联模式, 结合设备运行机理, 能够有效捕捉故障引发的有效异常数据, 避免传统单维度分析的误判风险。

3 监测数据清洗技术

数据清洗技术主要包括: 异常检测、异常类型辨识与数据修复, 3个环节形成递进式技术链条。本节将针对这3个主要环节进行系统梳理。

3.1 异常检测方法

部分异常数据可通过数据筛查发现, 如记录为None、N/A、null等特殊字符或空白的缺失数据、完全相同的冗余数据等。但数据筛查的异常检测效果有限, 仍需借助相关性分析、统计分析和机器学习等方法进一步检测。

3.1.1 基于相关性分析

监测数据的相关性对提升异常检测精度具有重要作用, 可归纳为机理相关性与时空关联性两类^[24-27]。机理相关性源于物理化学规律的作用, 如光伏系统中光照强度与输出功率间的函数关系; 时空关联性则表现为数据在时间和空间维度上的耦合特征。文献[27]提出一种基于时空相关性的数据修复方法, 利用缺失时间最接近、空间位置最近传感器的数据进行修复。数据相关性分析需采用专业方法进行挖掘, 常用方法如表2所示。

1)相关系数法。Pearson、Spearman、Kendall均为相关系数。其中, Pearson用于衡量两组数据间的线性相关程度, 但适用于符合正态分布的数据。文献[28]将Pearson和线性回归结合, 恢复缺失的负荷数据; Spearman和Kendall均基于秩次, 适用于单调关系。文献[29]结合Kendall和Copula函数理论, 多维度分析了风电机组间的风速相关度; 文献[30]利用Spearman分析区域负荷间的时空相关性。

2)灰关联分析法。灰关联分析法基于灰色系统理论, 根据监测序列曲线几何形状的相似程度评估监测数据间的相关性。文献[31-32]通过灰关联算法分析各监测序列间的关联程度, 对数据的异常模式进行区分。

3)Apriori算法。用于寻找数据集中的频繁项集, 通过支持度与置信度衡量相关关系。Apriori算法原理简单, 但需多次遍历数据集, 处理效率较低^[33]。文献[34]使用Apriori算法挖掘待清洗序列的强关联参数组合, 结合关联参数同步检测结果有效区分有效异常数据和“脏”数据。

4)FP-growth算法。同样用来寻找数据集中的频繁项集, 比Apriori算法效率更高。文献[35]利用FP-growth算法挖掘变电站历史数据库中异常信号的频繁项集和强关联关系, 有效发现了二次设备的频发异常, 并找到了诱发异常的缺陷。

3.1.2 基于统计分析

常用于异常检测的统计分析方法有 3σ 准则、四分位法、统计量分析法、Grubbs检验法与置信边界法等, 如表3所示。

1) 3σ 准则。若数据服从正态分布, 分布在 $(\mu - 3\sigma, \mu + 3\sigma)$ 外的数据占比不足0.3%, 是极小

表 2 相关性分析方法

Table 2 Correlation analysis methods

相关性分析方法	优点	局限性	适用数据	文献
Pearson 相关系数	计算简单, 易于解释	异常值敏感, 数据要求高	连续数据, 正态分布	[28]
Spearman 相关系数	范围广, 数据要求低	计算效率低, 重复值效果差	等级数据	[29]
Kendall 相关系数	要求低, 异常值稳健	计算复杂, 样本大时耗时长	等级数据, 小样本	[30]
灰关联分析法	计算简单, 易于解释	主观性强, 无法检验	连续、离散数据均可	[31-32]
Apriori 算法	算法简单, 易解释	数据库扫描次数过多	标称型数据 ^①	[33-34]
FP-growth 算法	运算速度快, 效率高	内存开销大, 实现困难	标称型数据	[35]

注: ①标称型数据仅代表不同的类别或标签, 不涉及数值大小或顺序。

概率事件, 可视为异常值。 3σ 准则的适应性强, 计算复杂度低, 但基于平均值和标准差, 对极端异常值很敏感^[36]。另外, 3σ 准则仅适用于平稳序列, 对存在趋势变动的非平稳序列准确性较差, 这限制了其处理的数据类型是近似正态分布^[31]。

2) 四分位法。根据四分位数和四分位间距确定阈值, 超出阈值则视为异常数据。四分位法便于实施, 异常数据占比小时可以有效识别, 具有一定客观性。但处理高维数据时会忽略属性间的相互影响, 效果不佳^[37]。四分位法要求数据是完整的, 对于样本量较少或分布不均匀的数据集, 识别结果不够准确^[38]。

3) 统计量分析法。系统异常时, 监测数据的均值、方差和方差变化率等数据特征会发生变化, 选择合适的变点指标识别异常数据。此方法不依赖正常数据集, 实现简单, 通用性强, 但需要人为设定阈值, 结合其他方法时需注意使用顺序^[39]。文献[38-40]分别基于方差变化率、滑动标准差、方差变点和均值对比法识别异常数据, 均取得了不错的异常识别效果。

4) Grubbs 检验法^[41]。它假设数据服从正态分布, 找出数据中与平均值偏差最大的可疑点, 计算残差与标准差的比值, 若大于 Grubbs 表值, 则判定为异常数据。其灵敏度高、适用性广, 但每次只能检测一个离群值。Grubbs 检验在小样本中的表现性能更好, 当数据具有一定趋势时, 两端

数据易被误判, 误差较大^[42]。文献[43]对其进行改进, 可用于标准差未知时的离群值检测。文献[44]采用 Grubbs 检验法滤除短时突变点, 从而抑制畸变对区间斜率曲线的干扰。

5) 置信边界法。计算在某一置信度(如 95%)下的置信区间, 在置信区间外的数据被认为是异常数据。置信边界法具有结果可信度高、可解释性强的优点, 但异常数据较多、分布不均时会影响置信区间的求解, 需要引入置信区间不对称度。文献[28]采用置信边界法来检测负荷曲线的异常数据。

表 3 基于统计分析的数据异常检测方法

Table 3 Data anomaly detection methods based on statistical analysis

统计分析方法	优点	局限性	文献
3σ 准则	适应性强, 计算复杂度低	对极端异常值敏感	[31, 36]
四分位法	原理简单, 便于实施	高维或异常数据占比高时, 效果不佳	[37-38]
统计量分析法	实现简单, 通用性强	需人为设定阈值	[38-40]
Grubbs 检验法	灵敏度高、适用性广	效率低, 不适用大样本和趋势性数据	[41-44]
置信边界法	结果可信度高, 可解释性强	异常数据较多时效果差, 不适用	[28]

3.1.3 基于机器学习

表 4 汇总了基于机器学习的异常检测方法。

1) KNN(K 最近邻)法。依次计算每个样本点与它最近的 K 个样本的平均距离, 若距离大于设定阈值, 则认为是异常数据。KNN 算法原理简单, 便于理解, 无需假设数据分布。但每次计算需要遍历数据集, 工作量大, 耗时长, 且模型泛化能力较差^[45], 只能找出异常点, 无法找出异常簇; 此方法对参数敏感程度高, 需多次试验获得最优参数^[46]。

2) K -means 聚类法。将数据分为 K 个簇, 同一簇中的数据尽可能相似, 不同簇中的数据尽可能不同。若数据到所属簇中心的距离超过设定阈值, 则认为是异常数据。算法的可解释性强, 处理大数据集时效率高, 但对簇的数量和簇中心的选择较为敏感。文献[47-49]对 K -means 算法进行不同形式的改进, 提高了异常检测性能。

3) DBSCAN(基于密度空间聚类)。DBSCAN

表4 基于机器学习的数据异常检测方法

Table 4 Data anomaly detection methods based on machine learning

异常检测方法	优点	局限性	文献
KNN	原理简单, 不需要假设数据分布	不适合高维、大样本数据, 无法找出异常簇, 计算量大, 耗时长, 对参数敏感	[45-46]
K-means	可解释性强, 大数据集效率高	对簇的数量和簇中心选择敏感, 假设簇是圆形, 对非凸形状数据聚类效果不佳	[47-49]
DBSCAN	无需指定簇的数量, 可发现任意形状的簇	参数选择较为困难, 算法时间复杂度高	[50-51]
LOF	简单直观, 检测精度高, 搜索能力强	数据量大时时间复杂度高, 参数选取敏感	[52-54]
IF	效率高, 可快速处理高维、大规模数据	对分布特征复杂的数据识别能力下降	[55]
RF	泛化能力和鲁棒性好	可解释性不足, 内存占用较大, 训练时间长	[56-57]
LSTM	检测精度高, 可处理多维、非线性数据	数据较长时不适用, 受参数影响较大	[58-59]
AE	方法高效, 适用范围广	对参数选择敏感	[60-61]
GNN	快速处理图结构数据, 捕捉复杂关系	计算资源要求高, 可解释性不足	[62-63]

将簇定义为密度相连的点的最大集合, 通过点的密度来识别聚类集群, 而异常值通常位于低密度区域。其可以发现任意形状的簇, 不需要事先指定聚类数。但无法准确识别聚集型异常数据, 且对参数较为敏感, 需要调优。文献[50-51]对DBSCAN进行改进, 实现了参数的自适应选择, 提高了异常检测性能。

4)LOF(局部异常因子)。同一簇中数据周围的密度与其邻域周围的密度相似, 通过比较数据点与邻近点的密度来检测异常。LOF算法简单直观, 检测精度高, 搜索能力强, 但对堆积型数据的检测效果不佳, 数据量大时, 时间复杂度, 且对参数敏感。LOF的阈值选取有一定的难度, 需要多次尝试选出最佳效果^[52]。文献[53-54]将LOF算法分别应用于配电网和PMU(同步相量测量装置)数据中, 均有较好的异常识别效果。

5)IF(孤立森林)。通过递归构建二叉树对数据空间进行切割, 直到每个子空间仅含单个数据, 异常数据因分布稀疏更易被早期切割分离。IF算法具有较高准确率, 但对局部稀疏点和高维数据的适用性较差^[55]。

6)RF(随机森林)。RF由多个决策树组成, 每个决策树单独训练, 最终结果由所有决策树集成。模型具有更好的泛化能力和鲁棒性, 但可解释性较差。文献[56]用有标签数据训练RF模型以解决不平衡数据的长尾分布特性, 构建的集成模型可显著提高异常检测准确率。文献[57]采用改良的RF算法进行异常检测, 解决了模型复杂、训练时间过长的问题。

传统机器学习模型以浅层结构和低参数量为特征, 具备计算效率高、可解释性强的优势, 但在处理高维数据时面临显著局限: 对复杂非线性关系的建模能力不足, 特征工程依赖人工设计, 面对海量数据时效果不佳。

深度学习模型凭借自动特征提取、多模态数据融合、非线性建模和高维数据处理能力等优点, 有效弥补了传统机器学习的不足, 尽管存在计算资源和解释性挑战, 但其数据处理能力仍然突出。

1)LSTM(长短期记忆网络)。LSTM模型处理多维、非线性时序数据的优势明显, 但模型受参数影响较大, 时序数据较长时, 难以确定阈值, 且特征提取能力下降。文献[58]引入注意力机制解决此问题, 并结合梯度提升机检测异常数据。文献[59]利用无监督双向LSTM构建时序数据预测模型, 通过对比预测值和实际值的误差检测异常数据。

2)AE(自编码器)。AE提取输入数据隐藏特征, 并重构输出使其尽可能接近输入。通过AE重构误差检测高维数据, 从而区分异常数据。文献[60]将KNN与AE结合, 在解决高维数据处理问题的同时也保留了数据的近邻关系。文献[61]提出一种主动自编码器, 显著提高了对大规模高维数据集的检测准确性。

3)GNN(图卷积网络)。GNN是一种能够处理图结构数据的深度学习模型, 通过聚合节点的邻域信息来更新节点的特征表示。文献[62]利用图论将电量数据转换为二维图结构, 通过GNN挖掘

数据特征,有效提高了异常电量数据检测精度。文献[63]将现有异常检测方法与GNN结合,提出一种统一框架,表明了GNN在异常检测领域的发展潜力。

3.2 异常类型辨识

异常数据既可能是由设备或系统的故障造成的有效异常数据;也可能是受电磁、工况等因素影响造成的“脏”数据。对异常类型进行区分,辨识并保留有效异常数据,清洗“脏”数据。

传统异常类型辨识方法主要基于监测数据的趋势性特征与数据关联性分析。在设备正常运行状态下,监测数据通常围绕稳定值小幅波动;当发生故障时,监测数据则呈现持续性趋势变化^[22],如变压器故障引发的油中溶解气体含量持续波动。通过多参量关联分析可提高判断准确性:若多个关联监测序列在相近时段出现同步异常^[28](如突增、突减或趋势改变),可判定为有效异常数据;若仅单一序列异常则视为“脏”数据,需进行清洗。研究显示,输变电设备故障常伴随监测数据水平迁移和快速趋势变化,其残差序列会出现显著跳变^[64]。文献[65]通过监测数据的关联性分析及预测偏差评估,判断变压器的异常类型。

传统辨识方法取得了不错的应用效果,但仍存在两方面局限:其一,设备故障可能破坏测量间的固有相关性,导致误判风险;其二,不同监测对象的参数关联模式存在差异,异常识别仍需依赖专业人员的经验判断,制约了自动化处理效率。因此,尝试探索大模型等前沿技术在异常类型辨识中的应用可能性。

3.3 数据修复方法

数据修复的主要任务为异常值修正和缺失值填补。异常值修正通常采用“识别-剔除-填补”的处理流程,其实质可归入缺失值处理范畴,而冗余数据则直接删除。本节将重点探讨缺失数据填补方法,汇总如表5所示。

3.3.1 基于统计分析方法

1)统计分析 with 插值方法。统计分析方法利用缺失数据邻近值、众数、均值等进行填补。其优势在于原理直观且可解释性强,但会改变原始数据分布特性,不适用于大范围缺失场景^[66]。各类插值方法也经常用于数据填补,但对长时序缺失

表 5 数据修复方法

Table 5 Data restoration methods			
数据修复方法	优势	局限性	文献
统计分析与插值法	原理简单,可解释性强,效率高	人为改变原始数据分布	[66-67]
回归模型	充分挖掘历史数据,修复精度稳定	非线性时序的处理效果不佳	[28,32,68]
随机森林	准确性和泛化性较好,抗噪能力强	训练复杂,成本高,参数需调优	[53]
自编码器	方法高效,范围广	对参数敏感	[22,69]
长短期记忆网络	能处理含非线性时序关系的数据	数据要求高,有信息丢失风险	[31,70]
生成对抗网络	框架灵活,扩展性好,缺失多也适用	训练数据质量要求高,难度大	[71-73]

的修复效果有限。文献[67]改进插值方法,匹配相似特征的数据块进行插补,可有效提升大段缺失的填补质量。

2)回归模型。基于历史数据建立回归模型进行预测式填补,在线性条件下具有稳定的填补精度^[68]。文献[28]结合Pearson系数与线性回归,实现对长缺失数据的插补。文献[32]采用ARIMA模型清洗变压器监测数据,修复了缺失值和噪声。

3.3.2 基于机器学习

1)RF。文献[53]将RF与最小二乘回归结合,自适应辨别缺失类型并选择合适的修复算法,在保证精准度的同时也降低了运行时间。

2)AE。为提高模型鲁棒性,避免过拟合,Vincent^[69]等人提出DAE(降噪自编码器);文献[22]采用改进DAE对设备监测数据进行修复,实现了孤立点修复和空缺值填补。

3)LSTM。LSTM能处理含非线性时序关系的监测序列,通过门结构规避了梯度消失和梯度爆炸的问题^[70]。文献[31]在关联分析基础上,采用LSTM对异常数据进行预测式修复。

4)GAN(生成对抗网络)。GAN由生成器和判别器组成,通过不断博弈,提高模型的数据生成能力^[71],通过生成数据来修复缺失。文献[72]基于GAN模型清洗光伏异常数据,效果优于LSTM模型。文献[73]改进GAN模型修复负荷数据,取得了较好的插补精度。

3.3.3 其他修复方法

文献[74]提出一种稳健矩阵完备方法,即使随机缺失数据占比高达50%,仍能实现缺失数据

的准确填补。文献[75]利用组合式的数据修复策略,提高了数据修复的准确率。

对于PMU数据异常问题,文献[76-77]提出一种基于奇异值分解的PMU数据恢复方法,可快速准确地恢复系统动静态信号中的缺失数据。文献[78-79]基于线路物理模型,结合两端PMU数据对互感器误差进行修正。文献[80]借助线路对侧正常数据,对缺失数据进行修复。

4 MLLMs在数据质量提升中的应用分析

4.1 异常检测方面

MLLMs整合了多层自注意力机制和知识图谱,能够捕捉监测数据间的关联关系,解析数据变化过程,自动提取数据异常特征,实现对监测数据的全面解析。

目前已有专家学者将MLLM技术用于异常检测领域。文献[81-82]将视觉信息和文本描述结合输入,使大模型更好地理解数据异常特征,在少量样本情况下实现有效的异常检测,展示了大模型技术在数据异常检测中的应用潜力,尤其在处理复杂多模态数据时具有显著优势。

国家铁路集团提出一种高铁列控系统多模态异常检测方法^[83],对系统故障进行预测,从而缩小故障的影响。哈工大团队^[84]提出一种利用视觉专家进行工业异常检测的MLLMs,实现了数据的异常检测及异常高质量描述。但实验表明当前大模型的异常检测准确率仍低于人类专家^[85],还需进一步提升。

LLMs可以融合多模态数据,从多个维度理解分析数据,实现信息互补和交叉验证,为监测数据提供更为全面的异常检测。推动LLM技术和数据异常检测工作的高度结合,或是AI时代下的一个重要研究方向。

4.2 异常类型辨识方面

MLLMs具有强大的多模态数据融合能力,可以融合文本、时序数据、图像等多模态信息,通过交叉验证提升异常辨识的全面性。如设备的振动数据异常,同时红外图像显示局部过热,LLMs可综合判断为有效异常情况。

另外,MLLMs通过预训练学习电力设备通用知识,在新型设备或罕见故障场景下,仅需少量

标注数据即可微调模型,快速辨识异常数据。如针对新型变压器的故障诊断,大模型可基于历史相似设备的故障案例库生成推理路径,减少对新数据量的依赖。

LLMs通过多模态融合、小样本学习与知识迁移,有望突破传统方法在复杂场景下的局限性,实现有效异常与“脏”数据的高效区分。未来可结合电力行业需求,推动LLMs与领域知识的深度融合,以期为异常类型的辨识提供可靠支撑。

4.3 数据修复方面

传统数据修复方法依赖规则引擎或统计模型,但规则本身可能从错误数据推导,模型存在一定局限性。LLM技术凭借其优秀的上下文理解和生成能力、多模态融合能力和通用性强等特点,为数据修复提供了新的可能。

针对地址文本数据存在的表述不规范问题,文献[86]构建了LLMs+GeoTools的技术框架,利用LLMs的语义理解 and 外调工具能力,实现了地址文本数据的清洗和规范化修复。文献[87]提出的Cocoon系统利用LLMs的语义推理能力识别和修复数据问题,在5个基准测试集中进行清洗实验,效果优于其他系统。文献[88]介绍了利用LLMs和数据湖进行检索式数据清洗的RetClean系统,并在3种典型应用场景下进行清洗实验。结果表明,系统减少了人工干预,提高了数据清洗的准确性和可解释性。

LLM技术在数据修复方面具有巨大潜力,有望为数据修复带来范式变革,使其从传统规则驱动转向为认知智能驱动。

4.4 MLLMs应用框架探索

MLLMs输出结果具有一定的概率生成特性,存在随机风险,难以满足电力系统可靠性要求,这也导致其应用受限于辅助决策或设备运维场景。探索MLLMs用于数据质量提升的应用框架,具体如图4所示。

多模态数据采集阶段,选取海量的电压、电流等电力系统运行、设备监测等时序类数据,国家和企业标准、行业相关数据等文本类数据,可见光图像、红外线等图像数据,可听声和超声等音频数据,作为MLLMs的基础数据库,用于后续LLMs的训练测试。

模型构建与训练环节, 选取基础 MLLMs 作为系统底座, 应用 Transformer 注意力机制、多模态对齐和集成外部工具等技术进行模型设计与预训练。基于注意力机制, 模型处理信息时“聚焦”与当前任务最相关的部分。多模态对齐技术将不同来源的信息映射至同一向量空间, 进而理解不同模态信息间的关联性。基于已获取的海量多模态数据, 进行模型预训练, 赋予其通用知识和基础能力(机构完成)。在此基础上, 结合电力领域特定数据集, 对预训练模型进行额外训练, 完成模型微调。RLHF(人类反馈强化学习)将人类偏好作为指导信号, 通过强化学习优化大模型, 使其结果生成更符合人类的需求。RAG(检索增强生成)将大模型的生成过程与外部知识库的检索相结合, 模型首先从外部知识源检索与问题最相关的文档片段, 将此文档片段和原始问题一起作为新的、增强了的提示词, 输入至 LLMs, 模型基于此生成输出结果。

模型应用与更新环节, 凭借 MLLMs 的多模态融合能力、分类能力和出色的语义理解与生成能力, 基于 MLLMs 的数据质量提升系统可实现异常数据检测、异常类型辨识和数据修复等功能, 将 MLLMs 与监测数据质量提升工作深入结合,

可为运维人员提供可靠的辅助工具。

5 展望

数据清洗方法在异常检测、数据修复和信息完整性平衡等方面仍面临着诸多挑战, 时代发展也对其提出了更高要求。结合现有研究, 对数据清洗进行展望, 并探索 MLLM 技术的应用路径。

5.1 基于机理方法

数据清洗过程中, 结合电力系统的动、静态特性, 利用监测量间的耦合关系, 构建多约束联合清洗模型, 从而减少误差对数据清洗的影响, 提高模型性能。另外, 可以整合 PMU、SCADA 等多源信息, 通过时空对齐和置信度加权等方式进行交叉验证, 提高模型准确性。

其他领域的机理思想, 亦可对清洗工作提供新思路和新方法。信息熵是信息无序程度的度量, 用于衡量数据的不确定性和混乱程度。而数据清洗的目标之一即减少不确定性, 使数据有序一致, 这与信息熵的目标“量化和最小化信息的不确定性和损失”是一致的。因此, 未来可以从信息熵角度研究数据清洗技术。

5.2 基于单一类型的数据驱动方法

探索新兴 AI 技术在数据清洗的应用可能性。




图4 基于MLLMs的数据质量提升应用框架

Fig.4 Application framework for data quality improvement based on MLLMs

如图神经网络在面对图结构数据时具有明显优势,图结构数据的清洗可基于图神经网络完成;扩散模型具有高质量的图像生成能力,能够填补图像缺失区域、提高图像分辨率等。将其应用于图像修复领域,可显著提高图像数据质量。生成对抗网络能够合成高质量数据,有望解决小概率异常样本不足的问题,进而提升模型检测能力。

5.3 基于机理-数据双驱动模型

针对数据驱动模型鲁棒性要求高、可解释性弱、训练成本高等问题,将监测数据间的耦合关系和数据发展规律等机理知识与神经网络相结合,在数据驱动框架中融入先验知识,构建具备机理知识的数据驱动模型。未来考虑将机理-数据双驱动模型用于数据清洗,以期获得更好的处理效果。

5.4 基于MLLMs

MLLMs能够融合多模态数据,筛选冗余信息,准确捕捉电力系统运行机理和规律,在数据清洗方面有着巨大优势和发展潜力。然而,LLMs应用仍存在如下关键问题。

1)如何准备微调数据集并进行针对性训练。模型微调可细分为指令微调和对齐微调。其中,指令微调旨在使模型理解和执行用户任务指令;而对齐微调根据人类反馈调整,以确保输出符合伦理和安全要求。准备指令微调数据集时,首先考虑将现有的高质量数据集转化为指令格式,也可以通过少量人工标注的示例引导LLMs生成指令数据。

在数据清洗中,考虑将已有的未处理数据集、相应清洗方法和处理后的数据集作为高质量数据转换为指令格式,进行指令微调。对齐微调的数据集可基于少量高质量的人类反馈数据或使用强大的LLMs生成的人工反馈数据。这些数据需要准确表示使用何种方法的清洗效果最优,并尽可能涵盖多个应用场景,如设备监测数据、故障录播数据和日志数据等。

2)如何通过微调构建适配数据清洗的MLLMs。LLMs微调通过在特定任务或领域的数据上进一步训练预先训练好的LLMs,使其在该任务或领域上表现得更准确有效。考虑基于适配器对模型进行微调,此方法仅训练适配器层,不改变模型本体参数,从而以较低训练成本满足特定

任务场景的需求。

3)如何应对LLMs产生的幻觉数据。LLMs幻觉指模型生成的内容与现实世界事实或用户输入不一致的现象。幻觉现象是LLMs的通病,会严重影响LLMs的公信度。在模型建立过程中,可以考虑从数据、多模态数据编码器、模态对齐和强化学习等角度缓解幻觉现象,如引入负面指令样本、提高视觉分辨率等。另外,可开发针对幻觉数据的自动分析技术,并建立信息溯源机制,为用户提供验证工具,帮助用户分辨输出结果。同时,用户也应辩证地看待LLMs输出,提高自身分辨能力。

4)如何减少LLMs的过度思考。LLMs将更多计算资源应用在“推理”过程,这显著提高了模型的推理能力和复杂任务的准确率,但也带来了简单任务过度思考的问题。考虑在思考决策过程中,引入选择性强化学习算法以优化决策过程,选择最优方案。另外,用户在使用时,也可以通过输入指令,直接阻止LLMs的过度思考,如“不进行深度思考,直接给出答案”等。未来应探索更加科学的方法,力求做到推理复杂度与任务难度相匹配,合理利用推理资源,提高模型效率及准确性。

5)如何构建高效的提示词框架。提示词工程是指通过精心设计和调整输入提示词来优化LLMs的输出,使其更符合用户的需求和期望。提示词设计的关键在于:明确意图、结构化提示、提供上下文及约束条件、减少歧义等。如在数据清洗中,需要识别异常值,提示词要说明具体的数据格式、可能的异常类型。可以考虑建立提示词综合评价体系,预先测试不同提示词框架的应用效果,探索效果更好的提示词框架。

MLLMs可为监测数据提供高效、安全、智能的辅助处理,但其在数据质量提升中的应用尚处于积极探索和深化认识阶段,相关技术暂不成熟,仍需进一步完善。

6 结论

本文介绍了变电站监测数据特征,明确了监测数据的质量提升需求,详细介绍了现有的数据清洗方法,对比了其优缺点,并分析了MLLMs应用需要解决的问题,主要结论如下:

1)变电站监测数据类型多样,具有维度高、规模量级大、耦合性强、安全要求高等特点。

2)监测数据的质量提升需求主要概括为:随机误差和干扰带来的“脏”数据清洗需求;故障引发的监测数据规律性变化辨识需求。

3)采用LLMs实现数据质量提升时,需要重点解决微调数据集准备、模型微调、幻觉数据、过度思考和提示词工程等问题。

上述探索了AI时代变电站数据提升的可能技术发展路线,可为后期技术研发提供指导。

参考文献

- [1] 李明节,刘宇,舒治淮,等.中国变电站二次系统技术发展趋势分析[J].电网技术,2024,48(1):1-12.
LI Mingjie, LIU Yu, SHU Zhihui, et al. Development trend of secondary system technology in China's substations[J]. Power System Technology, 2024, 48(1): 1-12.
- [2] 刘云鹏,许自强,李刚,等.人工智能驱动的数据分析技术在电力变压器状态检修中的应用综述[J].高电压技术,2019,45(2):337-348.
LIU Yunpeng, XU Ziqiang, LI Gang, et al. Review on applications of artificial intelligence driven data analysis technology in condition based maintenance of power transformers[J]. High Voltage Engineering, 2019, 45(2): 337-348.
- [3] 郑一鸣,孙翔.基于多源监测数据挖掘的电力设备状态诊断[J].浙江电力,2016,35(5):1-6.
ZHENG Yiming, SUN Xiang. State diagnosis of power devices based on multi-source monitoring data mining[J]. Zhejiang Electric Power, 2016, 35(5): 1-6.
- [4] 薛禹胜,赖业宁.大能源思维与大数据思维的融合(一)大数据与电力大数据[J].电力系统自动化,2016,40(1):1-8.
XUE Yusheng, LAI Yening. Integration of macro energy thinking and big data thinking part one big data and power big data[J]. Automation of Electric Power Systems, 2016, 40(1): 1-8.
- [5] 彭小圣,邓迪元,程时杰,等.面向智能电网应用的电力大数据关键技术[J].中国电机工程学报,2015,35(3):503-511.
PENG Xiaosheng, DENG Diyu, CHENG Shijie, et al. Key technologies of power big data for smart grid applications[J]. Proceedings of the CSEE, 2015, 35(3): 503-511.
- [6] WANG Y, CHEN Q X, HONG T, et al. Review of smart meter data analytics: applications, methodologies, and challenges [J]. IEEE Transactions on Smart Grid, 2019, 10(3): 3125-3148.
- [7] GENES C, ESNAOLA I, PERLAZA S M, et al. Robust recovery of missing data in electricity distribution systems [J]. IEEE Transactions on Smart Grid, 2019, 10(4): 4057-4067.
- [8] HUANG Y T, CHENG F T. Automatic data quality evaluation for the AVM system [J]. IEEE Transactions on Semiconductor Manufacturing, 2011, 24(3): 445-454.
- [9] 徐飞阳,薛安成,常乃超,等.电力系统同步相量异常数据检测与修复研究现状与展望[J].中国电机工程学报,2021,41(20):6869-6886.
XU Feiyang, XUE Ancheng, CHANG Naichao, et al. Research status and prospects of detection, correction and recovery for abnormal synchrophasor data in power system [J]. Proceedings of the CSEE, 2021, 41(20): 6869-6886.
- [10] 李子康,刘灏,毕天姝,等.考虑PMU数据质量问题的电力系统扰动检测方法[J].中国电机工程学报,2024,44(2):451-464.
LI Zikang, LIU Hao, BI Tianshu, et al. Power system disturbance detection method considering PMU data quality problems [J]. Proceedings of the CSEE, 2024, 44(2): 451-464.
- [11] 江军,张文乾,李波,等.电力变压器油中溶解气体离群值识别和数据重构[J].电工技术学报,2024,39(17):5521-5533.
JIANG Jun, ZHANG Wenqian, LI Bo, et al. Outlier detection and data reconstruction of dissolved gas in oil for power transformers [J]. Transactions of China Electrotechnical Society, 2024, 39(17): 5521-5533.
- [12] 陈启鑫,郑可迪,康重庆,等.异常用电的检测方法:评述与展望[J].电力系统自动化,2018,42(17):189-199.
CHEN Qixin, ZHENG Kedi, KANG Chongqing, et al. Detection methods of abnormal electricity consumption behaviors: review and prospect [J]. Automation of Electric Power Systems, 2018, 42(17): 189-199.
- [13] 韩寅峰,戴晓红,徐重西,等.配电自动化系统不良数据检测与修正[J].浙江电力,2018,37(3):37-41.
HAN Yinfeng, DAI Xiaohong, XU Chongyou, et al. Bad data supervision and correction in power distribution automation system [J]. Zhejiang Electric Power, 2018, 37(3): 37-41.
- [14] 陈晓红,傅文润,刘朝明,等.人工智能大模型在电力设备运维场景中的应用探讨[J].中国工程科学,2025,27(1):180-192.
CHEN Xiaohong, FU Wenrun, LIU Chaoming, et al. Application of artificial intelligence large language model in power equipment operation and maintenance [J]. Strategic Study of CAE, 2025, 27(1): 180-192.
- [15] 李刚,方鸿,刘云鹏,等.新型电力系统中的大模型驱动技术:现状、机遇与挑战[J].高电压技术,2024,50(7):2864-2878.

- LI Gang, FANG Hong, LIU Yunpeng, et al. Large-model drive technology in new power system: status, challenges and prospects[J]. High Voltage Engineering, 2024, 50(7): 2864-2878.
- [16] 牛泽原, 李嘉媚, 艾芊. 大语言模型在电力系统中的应用初探[J]. 电网技术, 2025, 49(4): 1327-1336.
- NIU Zeyuan, LI Jiamei, AI Qian. Preliminary exploration of the application of large language models in power systems[J]. Power System Technology, 2025, 49(4): 1327-1336.
- [17] 樊陈, 倪益民, 窦仁晖, 等. 智能变电站一体化监控系统有关规范解读[J]. 电力系统自动化, 2012, 36(19): 1-5.
- FAN Chen, NI Yimin, DOU Renhui, et al. Interpretation of relevant specifications of integrated supervision and control systems in smart substations[J]. Automation of Electric Power Systems, 2012, 36(19): 1-5.
- [18] 国家能源局. 智能变电站监控系统技术规范: DL/T 1403—2015[S]. 北京: 中国电力出版社, 2015.
- [19] 自主可控新一代变电站二次系统技术规范通用类系列规范 1 变电站二次系统数据(试行): DL/T xxxx—2021[S]. 北京: 国家电网有限公司, 2021.
- General series specifications for autonomous and controllable new generation secondary system technology of substations-part 1: substation secondary system data (trial): DL/T xxxx—2021[S]. Beijing: State Grid Corporation of China, 2021.
- [20] 王臻, 刘东, 徐重酉, 等. 新型电力系统多源异构数据融合技术研究现状及展望[J]. 中国电力, 2023, 56(4): 1-15.
- WANG Zhen, LIU Dong, XU Chongyou, et al. Status quo and prospect of multi-source heterogeneous data fusion technology for new power system[J]. Electric Power, 2023, 56(4): 1-15.
- [21] 汤奕, 陈倩, 李梦雅, 等. 电力信息物理融合系统环境中的网络攻击研究综述[J]. 电力系统自动化, 2016, 40(17): 59-69.
- TANG Yi, CHEN Qian, LI Mengya, et al. Overview on cyber-attacks against cyber physical power system[J]. Automation of Electric Power Systems, 2016, 40(17): 59-69.
- [22] 计蓉, 侯慧娟, 盛戈皞, 等. 基于粒子群优化堆叠降噪自编码器的电力设备状态数据质量提升[J]. 上海交通大学学报, 2025, 59(6): 780-788.
- JI Rong, HOU Huijuan, SHENG Gehao, et al. Data quality improvement method for power equipment condition based on stacked denoising autoencoders improved by particle swarm optimization[J]. Journal of Shanghai Jiao Tong University, 2025, 59(6): 780-788.
- [23] 李子珏. 基于相关性的高维时间序列清洗技术研究[D]. 哈尔滨: 哈尔滨工业大学, 2020.
- LI Zijue. Research on correlation-based high-dimensional time series cleaning[D]. Harbin: Harbin Institute of Technology, 2020.
- [24] 赵洪山, 孙承妍, 温开云, 等. 无气象信息条件下基于AGCRN的分布式光伏出力超短期预测方法[J]. 高电压技术, 2024, 50(1): 65-73.
- ZHAO Hongshan, SUN Chengyan, WEN Kaiyun, et al. Ultra-short-term prediction of distributed photovoltaic power method based on AGCRN in the absence of meteorological information[J]. High Voltage Engineering, 2024, 50(1): 65-73.
- [25] 李宏仲, 刘国栋, 米阳. 利用时空相关性的海岛长期风速序列估计方法[J]. 高电压技术, 2023, 49(8): 3185-3198.
- LI Hongzhong, LIU Guodong, MI Yang. Long-term wind speed series estimation method for islands using spatio-temporal correlation[J]. High Voltage Engineering, 2023, 49(8): 3185-3198.
- [26] 周文俊, 李泽, 丁波, 等. 新能源高占比电力系统并行恢复分区划分[J]. 浙江电力, 2024, 43(11): 74-89.
- ZHOU Wenjun, LI Ze, DING Bo, et al. Partitioning of high-penetration renewable energy power systems for parallel restoration[J]. Zhejiang Electric Power, 2024, 43(11): 74-89.
- [27] ATWA W, BAHGAT A, REFAIE M. Simple missing data estimation algorithm in wsn based on spatial and temporal correlation[J]. IJCI. International Journal of Computers and Information, 2020.
- [28] 刘沅昆, 栾文鹏, 徐岩, 等. 针对配电变压器的数据清洗方法[J]. 电网技术, 2017, 41(3): 1008-1014.
- LIU Yuankun, LUAN Wenpeng, XU Yan, et al. Data cleaning method for distribution transformer[J]. Power System Technology, 2017, 41(3): 1008-1014.
- [29] 沈小军, 周冲成, 吕洪. 基于运行数据的风电机组间风速相关性统计分析[J]. 电工技术学报, 2017, 32(16): 265-274.
- SHEN Xiaojun, ZHOU Chongcheng, LÜ Hong. Statistical analysis of wind speed correlation between wind turbines based on operational data[J]. Transactions of China Electrotechnical Society, 2017, 32(16): 265-274.
- [30] 吴军英, 路欣, 刘宏, 等. 基于Spearman-GCN-GRU模型的超短期多区域电力负荷预测[J]. 中国电力, 2024, 57(6): 131-140.
- WU Junying, LU Xin, LIU Hong, et al. Ultra-short-term multi-region power load forecasting based on spearman-GCN-GRU model[J]. Electric Power, 2024, 57(6): 131-140.
- [31] 刘云鹏, 王权, 许自强, 等. 基于多层架构的油中溶解气体数据清洗与异常识别方法研究[J]. 华北电力大学学报(自然科学版), 2022, 49(1): 81-89.
- LIU Yunpeng, WANG Quan, XU Ziqiang, et al. Research

- on data cleaning and abnormal recognition method of dissolved gas in oil based on multi-layer architecture[J].Journal of North China Electric Power University (Natural Science Edition), 2022, 49(1): 81-89.
- [32] 钱宇骋,甄超,季坤,等.变压器在线监测数据异常值检测与清洗[J].哈尔滨理工大学学报, 2020, 25(5): 15-22.
QIAN Yucheng, ZHEN Chao, JI Kun, et al. Transformer online monitoring data abnormal value detection and cleaning[J].Journal of Harbin University of Science and Technology, 2020, 25(5): 15-22.
- [33] XING Y H, MENG C H, LI C H, et al. Lean operation and maintenance evaluation technology of power grid equipment based on improved big data cleaning method [C]//2020 IEEE 4th Conference on Energy Internet and Energy System Integration (EI2). October 30-November 1, 2020. Wuhan, China. IEEE, 2020: 2749-2752.
- [34] 徐搏超.基于参数关联性的电站参数异常点清洗方法[J].电力系统自动化, 2020, 44(20): 142-147.
XU Bochao. Parameter correlation based parameter abnormal point cleaning method for power station[J].Automation of Electric Power Systems, 2020, 44(20): 142-147.
- [35] 方晓洁,黄伟琼,叶东华,等.分布式并行FP-growth算法在二次设备缺陷监测中的应用[J].电力系统保护与控制, 2021, 49(8): 160-167.
FANG Xiaojie, HUANG Weiqiong, YE Donghua, et al. Application of a distributed parallel FP-growth algorithm in secondary device defects monitoring[J].Power System Protection and Control, 2021, 49(8): 160-167.
- [36] 槐克亮,王胜辉,于小森,等.基于SinGAN与LSTM-FCN的电力变压器单指标在线监测数据扩充与噪声清洗方法[J/OL].华北电力大学学报(自然科学版), 2024: 1-10. (2024-08-07). <https://kns.cnki.net/kcms/detail/13.1212.tm.20240806.1621.002.html>.
HUAI Keliang, WANG Shenghui, YU Xiaosen, et al. Method for enhancing and noise cleaning of power transformer online monitoring data for single indicators based on SinGAN and LSTM-FCN [J/OL]. Journal of North China Electric Power University (Natural Science Edition), 2024: 1-10. (2024-08-07). <https://kns.cnki.net/kcms/detail/13.1212.tm.20240806.1621.002.html>.
- [37] 魏泰,贺少雄,胡子武,等.基于改进孤立森林算法的风电机组异常数据清洗[J].科学技术与工程, 2024, 24(9): 3691-3699.
WEI Tai, HE Shaoxiong, HU Ziwu, et al. Wind turbine abnormal data cleaning based on an improved isolation forest algorithm[J].Science Technology and Engineering, 2024, 24(9): 3691-3699.
- [38] SHEN X J, FU X J, ZHOU C C. A combined algorithm for cleaning abnormal data of wind turbine power curve based on change point grouping algorithm and quartile algorithm [J]. IEEE Transactions on Sustainable Energy, 2019, 10(1): 46-54.
- [39] 时珉,尹瑞,胡傲宇,等.基于滑动标准差计算的光伏阵列异常数据清洗办法[J].电力系统保护与控制, 2020, 48(6): 108-114.
SHI Min, YIN Rui, HU Aoyu, et al. A novel photovoltaic array outlier cleaning algorithm based on moving standard deviation[J].Power System Protection and Control, 2020, 48(6): 108-114.
- [40] 叶林,崔宝丹,李卓,等.光伏电站高比例异常运行数据组合识别方法[J].电力系统自动化, 2022, 46(20): 74-82.
YE Lin, CUI Baodan, LI Zhuo, et al. Combined identification method for high proportion of abnormal operation data in photovoltaic power station [J]. Automation of Electric Power Systems, 2022, 46(20): 74-82.
- [41] ADIKARAM K K L B, HUSSEIN M A, EFFENBERGER M, et al. Data transformation technique to improve the outlier detection power of Grubbs' test for data expected to follow linear relation [J]. Journal of Applied Mathematics, 2015, 2015: 708948.
- [42] 江军,张文乾,李波,等.电力变压器油中溶解气体离群值识别和数据重构[J].电工技术学报, 2024, 39(17): 5521-5533.
JIANG Jun, ZHANG Wenqian, LI Bo, et al. Outlier detection and data reconstruction of dissolved gas in oil for power transformers [J]. Transactions of China Electrotechnical Society, 2024, 39(17): 5521-5533.
- [43] DING K, ZHANG J W, DING H X, et al. Fault detection of photovoltaic array based on Grubbs criterion and local outlier factor [J]. IET Renewable Power Generation, 2020, 14(4): 551-559.
- [44] 韦明杰,石访,张恒旭,等.基于零序电流波形区间斜率曲线的配电网高阻接地故障检测[J].电力系统自动化, 2020, 44(14): 164-171.
WEI Mingjie, SHI Fang, ZHANG Hengxu, et al. Detection of high impedance grounding fault in distribution network based on interval slope curves of zero-sequence current [J]. Automation of Electric Power Systems, 2020, 44(14): 164-171.
- [45] KUSIAK A, ZHENG H Y, SONG Z. Models for monitoring wind farm power [J]. Renewable Energy, 2009, 34(3): 583-590.
- [46] 任家东,刘新倩,王倩,等.基于KNN离群点检测和随机森林的多层入侵检测方法[J].计算机研究与发展, 2019, 56(3): 566-575.
REN Jiadong, LIU Xinqian, WANG Qian, et al. An multi-level intrusion detection method based on KNN outlier detection and random forests [J]. Journal of Computer Re-

- search and Development, 2019, 56(3):566-575.
- [47] 常荣, 徐敏. 基于改进 K-means 和 DNN 算法的电力数据异常检测[J]. 南京理工大学学报, 2023, 47(6):790-796.
CHANG Rong, XU Min. Power data anomaly detection based on improved K-means and DNN algorithm[J]. Journal of Nanjing University of Science and Technology, 2023, 47(6):790-796.
- [48] 孟令雯, 张锐锋, 汪明媚, 等. 基于改进 DBN 和 K-means 的变压器数据异常检测[J]. 电力信息与通信技术, 2023, 21(10):48-55.
MENG Lingwen, ZHANG Ruifeng, WANG Mingmei, et al. Abnormal detection of transformer data based on improved DBN and K-means[J]. Electric Power Information and Communication Technology, 2023, 21(10):48-55.
- [49] 彭勃, 李耀东, 龚贤夫. 基于自编码的改进 K-means 光伏能源数据清洗方法[J]. 计算机科学, 2024, 51(增刊 1):725-729.
PENG Bo, LI Yaodong, GONG Xianfu. Improved K-means photovoltaic energy data cleaning method based on self-coding[J]. Computer Science, 2024, 51(S1):725-729.
- [50] ZHANG X P, LIN R J, XU H T. An adaptive parameters density cluster algorithm for data cleaning in big data [M]//Artificial Intelligence and Security. Cham: Springer International Publishing, 2020:543-553.
- [51] 李特, 王荣喜, 高建民. 风电机组数据采集与监控系统异常数据识别方法[J]. 西安交通大学学报, 2024, 58(3):106-116.
LI Te, WANG Rongxi, GAO Jianmin. A method for abnormal data recognition of wind turbine supervisory control and data acquisition systems[J]. Journal of Xi'an Jiaotong University, 2024, 58(3):106-116.
- [52] SUN Z X, SUN H X. Stacked denoising autoencoder with density-grid based clustering method for detecting outlier of wind turbine components [J]. IEEE Access, 2019, 7:13078-13091.
- [53] 梅玉杰, 李勇, 周王峰, 等. 基于机器学习的配电网异常缺失数据动态清洗方法[J]. 电力系统保护与控制, 2023, 51(7):158-169.
MEI Yujie, LI Yong, ZHOU Wangfeng, et al. Dynamic data cleaning method of abnormal and missing data in a distribution network based on machine learning[J]. Power System Protection and Control, 2023, 51(7):158-169.
- [54] LIU S Y, ZHAO Y X, LIN Z Z, et al. Data-driven event detection of power systems based on unequal-interval reduction of PMU data and local outlier factor [J]. IEEE Transactions on Smart Grid, 2020, 11(2):1630-1643.
- [55] LV Z N, HU Z H, NING B F, et al. The data cleaning of electric industrial control terminal based on the iForest and genetic BP neural network algorithms [C]//2019 IEEE 2nd International Conference on Information Communication and Signal Processing (ICICSP). September 28-30, 2019, Weihai, China. IEEE, 2020:490-494.
- [56] 陈宇轩, 张耀, 徐杨, 等. 基于 Boosting 集成框架的新能源发电功率异常值检测方法[J]. 电网技术, 2023, 47(8):3261-3268.
CHEN Yuxuan, ZHANG Yao, XU Yang, et al. Outlier detection method of new energy power based on boosting integration framework [J]. Power System Technology, 2023, 47(8):3261-3268.
- [57] 黄润. 电力系统异常检测与分类研究[D]. 成都: 电子科技大学, 2020.
HUANG Run. Research on abnormal detection and classification of power system [D]. Chengdu: University of Electronic Science and Technology of China, 2020.
- [58] 吴海荣, 李振华, 程紫熠, 等. 基于注意力机制和 LSTM-LightGBM 的特高压直流输电线路可听噪声无效数据清洗方法[J]. 南方电网技术, 2024, 18(8):115-123.
WU Hairong, LI Zhenhua, CHENG Ziyi, et al. Invalid data cleaning method of audible noise for UHV HVDC transmission lines based on attention mechanism and LSTM-LightGBM [J]. Southern Power System Technology, 2024, 18(8):115-123.
- [59] 况华, 何鑫, 何觅, 等. 基于双向长短期记忆神经网络的配网电压异常数据检测[J]. 科学技术与工程, 2021, 21(24):10291-10297.
KUANG Hua, HE Xin, HE Mi, et al. Abnormal voltage data detection of distribution network based on bidirectional long short-term memory neural network [J]. Science Technology and Engineering, 2021, 21(24):10291-10297.
- [60] LIU S Z, MA S, CHEN H Q, et al. Combining KNN with AutoEncoder for outlier detection [J]. Journal of Computer Science and Technology, 2024, 39(5):1153-1166.
- [61] NING J, CHEN L T, ZHOU C, et al. Deep active autoencoders for outlier detection [J]. Neural Processing Letters, 2022, 54(2):1399-1411.
- [62] 张杰, 方浪森, 姚立明, 等. 基于图论及混合卷积神经网络的电力结算电量数据异常检测方法[J/OL]. 南方电网技术, 2024:1-12. (2024-10-28). <https://kns.cnki.net/kcms/detail/44.1643.tk.20241025.1656.012.html>.
ZHANG Jie, FANG Langsen, YAO Liming, et al. Abnormal detection method of electric power settlement data based on graph theory and mixed convolutional neural network [J/OL]. Southern Power System Technology, 2024:1-12. (2024-10-28). <https://kns.cnki.net/kcms/detail/44.1643.tk.20241025.1656.012.html>.
- [63] GOODGE A, HOOI B, NG S K, et al. LUNAR: unifying local outlier detection methods via graph neural networks [J]. Proceedings of the AAAI Conference on Artificial In-

- telligence, 2022, 36(6):6737-6745.
- [64] 严英杰, 盛戈皞, 陈玉峰, 等. 基于时间序列分析的输变电设备状态大数据清洗方法[J]. 电力系统自动化, 2015, 39(7):138-144.
YAN Yingjie, SHENG Gehao, CHEN Yufeng, et al. Cleaning method for big data of power transmission and transformation equipment state based on time sequence analysis[J]. Automation of Electric Power Systems, 2015, 39(7):138-144.
- [65] 林峻, 严英杰, 盛戈皞, 等. 考虑时间序列关联的变压器在线监测数据清洗[J]. 电网技术, 2017, 41(11):3733-3740.
LIN Jun, YAN Yingjie, SHENG Gehao, et al. Online monitoring data cleaning of transformer considering time series correlation[J]. Power System Technology, 2017, 41(11):3733-3740.
- [66] 闫亚男, 陈小松, 范慧敏, 等. 水电设备运行状态数据清洗方法研究[J]. 水电站机电技术, 2021, 44(10):14-16.
YAN Yanan, CHEN Xiaosong, FAN Huimin, et al. Study on data cleaning method for running state of hydropower equipment[J]. Mechanical & Electrical Technique of Hydropower Station, 2021, 44(10):14-16.
- [67] WEBER M, TUROWSKI M, ÇAKMAK H K, et al. Data-driven copy-paste imputation for energy time series[J]. IEEE Transactions on Smart Grid, 2021, 12(6):5409-5419.
- [68] 董晓翀, 张姝, 李焯, 等. 电力系统中时序场景生成和约简方法研究综述[J]. 电网技术, 2023, 47(2):709-721.
DONG Xiaochong, ZHANG Shu, LI Ye, et al. Review of power system temporal scenario generation and reduction methods[J]. Power System Technology, 2023, 47(2):709-721.
- [69] VINCENT P, LAROCHELLE H, BENGIO Y, et al. Extracting and composing robust features with denoising autoencoders [C]//Proceedings of the 25th International Conference on Machine Learning. July 5-9, 2008, Helsinki, Finland. ACM, 2008:1096-1103.
- [70] JIANG L, YAN C K, ZHANG X S, et al. Temperature prediction of battery energy storage plant based on EGA-BiLSTM[J]. Energy Reports, 2022, 8:1009-1018.
- [71] 邵振国, 张承圣, 陈飞雄, 等. 生成对抗网络及其在电力系统中的应用综述[J]. 中国电机工程学报, 2023, 43(3):987-1004.
SHAO Zhenguo, ZHANG Chengsheng, CHEN Feixiong, et al. A review on generative adversarial networks for power system applications[J]. Proceedings of the CSEE, 2023, 43(3):987-1004.
- [72] 李泽光. 基于生成式对抗网络的光伏出力数据修复研究[D]. 西安: 西安理工大学, 2023.
LI Zeguang. Research on photovoltaic output data restoration based on generative adversarial network[D]. Xi'an: Xi'an University of Technology, 2023.
- [73] 赵厚翔, 沈晓东, 吕林, 等. 基于GAN的负荷数据修复及其在EV短期负荷预测中的应用[J]. 电力系统自动化, 2021, 45(16):143-151.
ZHAO Houxiang, SHEN Xiaodong, LYU Lin, et al. Load data restoration based on generative adversarial network and its application in short-term load forecasting of electric vehicle[J]. Automation of Electric Power Systems, 2021, 45(16):143-151.
- [74] 刘清蝉, 钟尧, 林聪, 等. 基于稳健非负矩阵分解的用电数据清洗和插补[J]. 电网技术, 2024, 48(5):2103-2112.
LIU Qingchan, ZHONG Yao, LIN Cong, et al. Electricity consumption data cleansing and imputation based on robust nonnegative matrix factorization [J]. Power System Technology, 2024, 48(5):2103-2112.
- [75] 何宁辉, 吴旭涛, 沙伟燕, 等. 电力变压器油中溶解气体在线监测数据修复方法[J]. 高压电器, 2024, 60(11):37-48.
HE Ninghui, WU Xutao, SHA Weiyang, et al. On-line monitoring data repair method for dissolved gas in power transformer oil [J]. High Voltage Apparatus, 2024, 60(11):37-48.
- [76] YANG Z W, LIU H, BI T S, et al. An adaptive PMU missing data recovery method [J]. International Journal of Electrical Power & Energy Systems, 2020, 116:105577.
- [77] 杨智伟, 刘灏, 毕天姝, 等. 基于奇异值分解的PMU数据恢复法[J]. 中国电机工程学报, 2020, 40(3):812-821.
YANG Zhiwei, LIU Hao, BI Tianshu, et al. A PMU data recovery method based on singular value decomposition [J]. Proceedings of the CSEE, 2020, 40(3):812-821.
- [78] PAL A, CHATTERJEE P, THORP J S, et al. Online calibration of voltage transformers using synchrophasor measurements[J]. IEEE Transactions on Power Delivery, 2016, 31(1):370-380.
- [79] SHI D, TYLAVSKY D J, LOGIC N. An adaptive method for detection and correction of errors in PMU measurements[J]. IEEE Transactions on Smart Grid, 2012, 3(4):1575-1583.
- [80] XUE A C, KONG H, LAO Y Z, et al. Method of amplitude data recovery in PMU measurements that considers synchronisation errors [J]. IET Generation, Transmission & Distribution, 2020, 14(24):5746-5755.
- [81] CHEN Z L, CHEN H N, IMANI M, et al. Can multi-modal large language models be guided to improve industrial anomaly detection? [C]//Volume 2B: 45th Computers and Information in Engineering Conference (CIE). August 17-20, 2025. Anaheim, California, USA. American Society of Mechanical Engineers, 2025:V02BT02A051.
- [82] LU M C, CHAI Y, XU K X, et al. Multimodal fusion and

- knowledge distillation for improved anomaly detection[J]. The Visual Computer, 2025, 41(8): 5311-5322.
- [83] 康仁伟, 卢楠, 程剑锋, 等. 一种高铁列控系统多模态异常检测方法: CN118915692A[P]. 2024-11-08.
- [84] LI Y Z, WANG H L, YUAN S H, et al. Myriad: large multimodal model by applying vision experts for industrial anomaly detection [EB/OL]. 2023; arXiv: 2310.19070. <https://arxiv.org/abs/2310.19070>.
- [85] JIANG X, LI J, DENG H, et al. MMAD: The first-ever comprehensive benchmark for multimodal large language models in industrial anomaly detection [J]. ArXiv, 2024, abs/2410.09453.
- [86] HUANG C H, CHEN S S, LI Z X, et al. GeoAgent: to empower LLMs using geospatial tools for address standardization[C]//Findings of the Association for Computational Linguistics ACL 2024. Bangkok, Thailand and virtual meeting. Stroudsburg, PA, USA: ACL, 2024: 6048-6063.
- [87] ZHANG S, HUANG Z, WU E. Data cleaning using large language models[J]. ArXiv, 2024, abs/2410.15547.
- [88] AHMAD NAEEM Z, AHMAD M S, ELTABAKH M, et al. RetClean: retrieval-based data cleaning using LLMs and data lakes[J]. Proceedings of the VLDB Endowment, 2024, 17(12): 4421-4424.

收稿日期: 2025-09-03; 修回日期: 2025-10-23

作者简介:

郑翔(1972), 男, 工学学士, 高级工程师, 从事电力系统自动化相关工作。

薛安成(1979), 男, 教授, 博士生导师, 主要研究方向为模型和数据驱动的新型电力系统稳定性分析及安全防护、二次设备评估等。(通信作者)

(本文编辑: 孙文文)