

计算机集成制造系统
Computer Integrated Manufacturing Systems
ISSN 1006-5911, CN 11-5946/TP

《计算机集成制造系统》网络首发论文

题目：大模型指令微调驱动的电力故障抢修方案智能生成
作者：邓养吾，刘梦琪，李荣生，杨阳，孙玮璠，程培强
DOI：10.13196/j.cims.2026.BPM06
收稿日期：2025-08-30
网络首发日期：2026-03-02
引用格式：邓养吾，刘梦琪，李荣生，杨阳，孙玮璠，程培强. 大模型指令微调驱动的电力故障抢修方案智能生成[J/OL]. 计算机集成制造系统.
<https://doi.org/10.13196/j.cims.2026.BPM06>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.13196/j.cims.2026.BPM06

大模型指令微调驱动的电力故障抢修方案智能生成

邓养吾¹⁺, 刘梦琪², 李荣生¹, 杨阳¹, 孙玮璠¹, 程培强³

(1. 国网山东省电力公司 烟台供电公司, 山东 烟台 264000; 2. 国网山东省电力公司 莱州供电公司, 山东 烟台 261000; 3. 国网山东省电力公司 福山供电公司, 山东 烟台 265500)

摘要: 针对电力故障抢修方案制定过程中依赖人工经验、效率低下且准确性难以保障的问题, 本文提出了一种基于大模型指令微调驱动的智能生成方法。该方法首先构建多源数据融合与预处理框架, 对结构化遥测数据和非结构化文本数据进行归一化、语义消歧与跨模态特征对齐, 形成统一语义表示; 在此基础上, 设计融合领域知识的指令模板, 并采用双阶段微调策略——通过领域知识预微调注入电力专业术语、物理规律与安全规程, 再基于多模态任务指令进行 LoRA 参数高效微调, 结合引入物理约束与安全规则的加权混合损失函数, 显著增强模型对故障特征的语义理解与安全合规生成能力。实验结果表明, 所提方法在故障类型准确率、关键步骤召回率等多项指标上均优于 GPT-3.5、BERT-GRU 及基础微调模型, 有效降低安全违规次数, 生成的抢修方案在文本质量、专业准确性与安全性方面更接近专家水准, 为电力系统故障处置的智能化决策提供了可靠支持。

关键词: 大模型; 电力故障; 微调; 智能方案生成

中图分类号: TP315

文献标识码: A

Intelligent generation of power fault repair scheme driven by fine tuning of large model instructions

DENG Yangwu¹⁺, LIU Mengqi², LI Rongsheng¹, YANG Yang¹, SUN Weifan¹, CHENG Peiqiang³,

(1. State Grid Yantai Power Supply Company, Yantai 264000, China; 2. State Grid Yantai Laizhou Power Supply Company, Yantai 261000, China; 3. State Grid Yantai Fushan Power Supply Company, Yantai 265500, China)

Abstract: In order to solve the problems of relying on manual experience, low efficiency and difficult to guarantee the accuracy in the process of making the power fault repair plan, this paper proposes an intelligent generation method based on large model instruction fine-tuning drive. Firstly, the multi-source data fusion and preprocessing framework is constructed, and the structured telemetry data and unstructured text data are normalized, semantic disambiguated and cross modal feature aligned to form a unified semantic representation; On this basis, the instruction template integrated with domain knowledge is designed, and a two-stage fine-tuning strategy is adopted. The power terminology, physical laws and safety regulations are injected through the pre fine-tuning of domain knowledge, and the Lora parameters are effectively fine tuned based on the multimodal task instructions. Combined with the weighted mixed loss function of physical constraints and safety rules, the semantic understanding of fault features and the generation of safety compliance of the model are significantly enhanced. The experimental results show that the proposed method is superior to gpt-3.5, bert-gru and basic fine-tuning model in terms of the accuracy of fault types and the recall rate of key steps, effectively reducing the

收稿日期: 2025-08-30; 修订日期: 2025-12-30. Received 30 Aug. 2025; accepted 30 Dec. 2025.

基金项目: 国网山东省电力公司科技项目 (2025A-054)。Foundation item: Project supported by the State Grid Shandong Electric Power Company, China (No. 2025A-054).

number of safety violations, and the generated emergency repair scheme is closer to the expert level in terms of text quality, professional accuracy and safety, providing reliable support for the intelligent decision-making of power system fault disposal.

Keywords: large model; power failure; fine tuning; intelligent solution generation

0 引言

当前, 电力故障抢修方案的制定仍以“数据采集 - 人工分析 - 经验决策”的传统模式为主, 辅以局部自动化系统。然而, 该模式在技术层面面临显著瓶颈: 多模态故障数据(如结构化遥测数据、非结构化文本记录、半结构化设备台账)存在割裂与关联失效问题, 传统模型泛化能力与电力领域适配性不足, 通用大语言模型亦因专业知识鸿沟难以直接应用。这些缺陷导致抢修方案生成效率低、精准度不足, 难以满足现代配电网对“快速、精准、安全”的运维需求。




图 1 传统模式与基于智能体故障抢修方案生成模式示意图

如图 1 所示, 传统故障抢修模式依赖专家、调度员与检修人员通过电话沟通传递信息, 需手动编写方案并多次调整, 流程中充斥着“故障现象询问”“资料查找”等低效环节。与之对比, 智能故障抢修方案生成模式通过大模型驱动的智能体自动获取告警信息、故障历史记录及设备台账, 结合 RAG (检索增强生成) 技术实现抢修方案的智能化生成, 大幅简化了人工干预流程, 凸显了数据驱动与自动化决策的优势^{[1][2]}。

尽管大模型指令微调技术为电力故障抢修方案的智能生成提供了新路径, 但其实际应用仍存在以下关键问题。

首先, 多模态数据融合深度不足。传统方法对电力故障多模态数据的处理停留在“拼接式集成”阶段, 如将遥测数据的特征向量与文本词向量简单拼接, 未建立数值特征与语义特征的深层因果关联^[3]。例如, 结构化数据中“b 相电流为 0”的特征无法与文本中“绝缘击穿”“导线碰触”等语义原因有效关联, 导致故障诊断依赖人工主观判断, 难以实现跨模态信息的协同推理。

其次, 传统模型领域适配能力薄弱。现有故障诊断模型中, 基于规则的专家系统存在规则库维护成本高、覆盖范围有限的缺陷, 无法处理罕见故障^[5]; 数据驱动的机器学习模型则依赖人工特征工程, 在小样本场景下泛化能力弱, 且输出结果缺乏可解释性, 难以满足电力行业对决策可追溯性的要求^[7]。两类模型均难以适应电网拓扑与设备类型动态更新的需求。

最后, 通用大模型的领域知识缺失^{[8][9]}。以 GPT、LLaMA 为代表的通用大模型在电力领域应用时, 存在专业术语理解偏差(如误判“环网箱”功能)、数值特征处理能力缺失(无法关联时序数据逻辑)及安全规程适配不足(生成方案遗漏“验电”等关键步骤)等问题^{[8][10]}。其通用知识与电力专业知识的鸿沟, 导致直接应用时方案生成的准确性与安全性难以保障。

为解决传统模式与现有技术的痛点, 本文提出基于大模型指令微调驱动的电力故障抢修方案智能生成方法。通过设计多模态指令模板实现结构化数值与文本语义的跨模态融合, 并采用领域知识增强的指令微调策略,

将电力专业术语、物理规律与安全规程注入大模型，使其具备“数值特征解读 - 语义理解 - 方案生成”的一体化能力。

具体来说，本文贡献如下：

(1) 提出了一种大模型指令微调驱动的电力故障抢修方案智能生成方案。该方法突破了传统“数据采集-人工分析-经验决策”模式的效率瓶颈，构建了端到端的自动化方案生成框架，为实现电力系统运维决策的智能化提供了新路径。

(2) 设计了一种面向电力多模态数据的深度融合与预处理框架。针对结构化数值数据与非结构化文本数据间的“模态割裂”问题，提出了包含改进的滑动窗口归一化、领域语义标准化及跨模态特征对齐网络的协同处理流程，有效实现了数值特征与语义特征的深层关联与统一表示。

(3) 提出了一种领域知识增强的双阶段指令微调策略。该策略通过“领域知识预微调”系统性地注入专业术语、物理规律与安全规程知识，再通过“多模态任务微调”结合 LoRA 参数高效微调技术与加权混合损失函数，精准优化模型的方案生成能力，解决了通用大模型在专业领域存在的知识鸿沟与安全性不足问题。

(4) 构建了基于真实电力故障场景的数据集并进行了全面实验验证。通过设计多维度评估指标体系与详尽的对比、消融实验，实证了所提方法在生成方案的文本质量、专业准确性和安全性方面均优于现有基线模型，并通过案例研究直观展示了其在实际应用中的有效性与优越性。

1 相关工作

电力系统的故障诊断与抢修决策作为保障供电可靠性的关键环节，长期以来主要依赖领域专家的经验判断，存在效率低下和主观性强的问题^[1]。随着人工智能技术的发展和电力行业数字化转型的推进，越来越多的研究开始探索如何将数据驱动的方法应用于这一领域。这些研究大致可归纳为以下几个方向：基于传统机器学习与深度学习的故障诊断方法、多模态信息融合技术、大语言模型在专业领域的适配与优化，以及面向任务泛化的指令微调技术。

1.1 基于机器学习和深度学习的故障诊断方法

早期的自动化故障诊断研究主要集中于利用传统机器学习模型对结构化遥测数据进行分析。例如，支持向量机（SVM）、决策树和随机森林等模型被广泛应用于故障分类和定位任务^[11]。这类方法的有效性高度依赖于人工设计的特征，且难以捕捉复杂故障模式下特征间的非线性关系。随后，深度学习模型展现了更强的表示学习能力。卷积神经网络（CNN）被用于处理电气量时序数据或故障录波图像，长短期记忆网络（LSTM）则擅长捕捉时间序列中的长期依赖关系，从而实现对故障暂态过程的更精准建模^{[12][13]}。然而，这些方法大多仅局限于处理数值型数据，无法有效利用现场巡检报告、调度日志等丰富的文本信息，形成了“数据孤岛”，限制了其决策的上限。

1.2 电力系统中的多模态信息融合技术

电力系统的运维数据本质上是多模态的^[14]。为了综合利用结构化数据（电压、电流等）、非结构化文本（故障描述、操作日志）以及图像数据（红外测温、设备外观），研究人员提出了多种信息融合框架^[15]。早期的融合策略多为特征级拼接或决策级投票，方法简单但融合层次较浅，未能实现模态间的深层语义交互^[16]。近年来，受到视觉-语言研究领域的启发，基于神经网络的跨模态学习方法被引入电力领域。例如，有研究尝试采用双流网络分别编码数值序列和文本描述，再通过注意力机制实现模态间的信息交互^{[17][18]}。然而，现有方法在融合时往往忽视了电力领域知识的引导作用，导致融合特征缺乏可解释性，有时甚至会得出违反电工学基本原理的结论。

1.3 大语言模型在垂直领域的适配与应用

以 GPT、LLaMA、T5 等为代表的大语言模型在通用自然语言处理任务上取得了革命性成功，但其在电力等高专业门槛领域的直接应用面临显著挑战^[19]。核心问题在于“领域知识鸿沟”，包括：对专业术语的理解偏差、对数值推理和物理规律的忽视、以及对行业安全规范与标准操作流程的陌生。为缓解这些问题，主流适配方法可分为三类：一是在领域语料上继续进行预训练^[20]，以增强模型的语言表示；二是利用检索增强生成技术，在推理时引入外部知识库，提高事实准确性^[21]；三是进行指令微调，将任务构建成指令-回复对，激发

模型的任务跟随与推理能力^[22]。目前，如何系统性地将领域知识，而不仅仅是领域语料注入模型，并保证其输出在技术和安全上的可靠性，仍是研究的难点。

1.4 指令微调与参数高效微调技术

指令微调通过将多种任务统一格式化为遵循自然语言指令的形式，极大地提升了大模型的任务泛化能力和零样本/小样本性能。在数据稀缺的垂直领域，如何高效地进行指令微调至关重要。全参数微调虽然有效，但成本高昂且易导致过拟合。参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）技术应运而生，其核心思想是冻结预训练模型的大部分参数，仅训练少量引入的额外参数。具有代表性的方法包括：LoRA（通过低秩分解注入可训练矩阵）^[23]、Adapte^[24]（在模型中插入小型神经网络模块）以及 Prefix-Tuning（为模型添加可训练的软提示前缀）^[25]。这些方法能以极低的参数量达到与全微调相近的性能，显著降低了计算门槛和部署成本，为大模型在电力等工业场景的落地提供了技术可行性。

2 大模型指令微调驱动的电力故障抢修方案智能生成

2.1 系统架构

本文的系统架构如图 2 所示。聚焦多源数据融合与领域知识增强的指令微调策略，以实现电力故障抢修方案的智能生成。在多源数据融合与预处理方面，针对结构化数据，采用改进的 Z-score 归一化方法并引入滑动窗口动态调整机制，消除量纲差异后转换为标准键值对形式；对于非结构化文本数据，基于 BERT 预训练模型进行领域自适应微调，构建语义知识库实现实体识别与关系抽取，同时引入注意力机制的语义消歧模型确保文本语义准确；跨模态特征对齐通过模态独立编码模块、跨模态交互模块与联合特征对齐模块，实现结构化数值与文本语义的特征融合与对齐。在领域知识增强的指令微调策略上，分两阶段进行：领域知识预微调阶段，构建术语对齐、物理规律、安全规程三类样本，采用全参数微调结合知识蒸馏的方式，让模型掌握电力领域基础知识；多模态任务微调阶段，基于真实故障案例构建多模态指令模板样本，运用 LoRA 轻量化微调技术，并设计包含语义损失、物理约束损失和安全损失的加权混合损失函数，使模型能生成符合专业要求和安全规范的抢修方案。




图 2 大模型指令微调驱动的电力故障抢修方案智能生成

2.2 多源数据融合与预处理

多源数据的有效融合是突破诊断精度瓶颈的核心前提。然而，电力故障场景下，结构化数值特征（如遥测电流、电压序列）与非结构化语义信息（如故障工单文本、运维日志描述）天然存在“模态割裂”——数值数据聚焦量化指标的精确性，却缺失语义关联；文本信息蕴含故障场景的逻辑描述，却难以与数值特征直接映射。这种语义裂痕导致多模态数据无法协同支撑智能诊断模型，成为系统架构落地的阻碍。因此，需要构建数据协同预处理框架，通过结构化数据归一化消除量纲差异、统一数值特征分布，文本语义标准化挖掘文本语义并转化为可计算表示，最终依托跨模态特征对齐技术打破模态壁垒，构建统一特征空间。

2.2.1 结构化数据归一化

结构化遥测数据的归一化是消除量纲差异、统一数据分布的关键步骤。本研究采用改进的 Z-score 归一化方法，针对电力数据的时序特性与异常波动，引入滑动窗口动态调整机制。设原始数据序列为 $X = \{x_1, x_2, \dots, x_n\}$ ，在长度为 m 的滑动窗口内，归一化公式为：

$$x_{norm}^i = \frac{x^i - \mu_{w(i)}}{\sigma_{w(i)}} \quad (1)$$

其中， $\mu_{w(i)}$ 与 $\sigma_{w(i)}$ 分别为第 i 个窗口内数据的均值与标准差。归一化后的数据通过维度对齐处理，转换为“特征名称 = 数值 + 单位”的标准键值对形式，为后续跨模态融合提供统一格式。

2.2.2 非结构化数据标准化

非结构化文本数据的语义标准化旨在消除自然语言表达的模糊性，构建电力领域的标准化语义表示。基于 BERT 预训练模型，采用领域自适应微调策略，在电力故障案例数据集上进行针对性训练，提升模型对专业术语的理解能力。通过构建电力领域语义知识库，对输入文本进行实体识别与关系抽取，将口语化描述转换为结构化语义表达。例如，将“线路出问题了”解析为“电力线路发生故障”，并补充故障类型、位置等关键信息。

为解决文本语义的歧义问题，引入基于注意力机制的语义消歧模型。该模型在 Transformer 架构基础上，通过计算文本中各词汇与电力领域关键概念的注意力权重，动态调整语义表示。设输入文本的词向量序列为 $T = \{t_1, t_2, \dots, t_k\}$ ，关键概念向量为 $C = \{c_1, c_2, \dots, c_l\}$ ，注意力权重计算如下：

$$\alpha_{ij} = \frac{\exp(\text{score}(t_i, c_j))}{\sum_{j=1}^l \exp(\text{score}(t_i, c_j))} \quad (2)$$

其中， $\text{score}(t_i, c_j)$ 采用点积计算词汇与概念的相似度。最终标准化后的文本语义通过加权求和得到，确保表达的准确性与专业性。

2.2.3 跨模态特征对齐

跨模态特征对齐致力于打破结构化数值数据与非结构化文本数据之间的模态壁垒，构建统一的特征空间。该网络包含三个核心模块：模态独立编码模块、跨模态交互模块与联合特征对齐模块。

在模态独立编码模块中，结构化数据通过多层感知机（MLP）映射到高维特征空间，

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2) \quad (3)$$

σ 为 ReLU 等激活函数），映射到高维特征空间。目的是将简单数值转化为富含抽象语义的高维向量，让数值特征具备与文本特征“对话”的基础。文本数据则通过 BERT 模型提取语义特征，利用 Transformer 的自注意力机制，挖掘文本中词汇间的语义关联。

跨模态交互模块采用双向注意力机制，计算两种模态特征之间的交互权重，实现信息互补。设数值特征矩阵为 $X \in R^{d \times n}$ （ d 是特征维度， n 是数值样本数），文本特征矩阵为 $T \in R^{d \times m}$ （ m 是文本样本数），双向注意力权重 A 可通过点积计算：

$$A_{ij} = \text{softmax} \left(\frac{x^T w T}{\sqrt{d}} \right) \quad (4)$$

其中， W 是可学习参数，softmax 归一化权重。通过权重加权求和，实现两种模态特征的信息互补。

联合特征对齐模块基于对比学习框架，通过最小化同一故障场景下不同模态特征的距离，最大化不同场景特征的距离，实现特征对齐。损失函数定义为：

$$L_{align} = \sum_{(x,t) \in S} [1 - \cos(MFA - Net(x), MFA - Net(t))] + \sum_{(x,t') \in S'} \max(0, m - \cos(MFA - Net(x), MFA - Net(t'))) \quad (5)$$

其中， $(x,t) \in S$ 为同一故障场景的结构化 - 文本数据对集合， $(x,t') \in S'$ 为不同场景的数据对集合， m 为预设的距离阈值。通过该机制，实现多模态数据在特征空间的有效对齐，为后续模型推理提供融合特征。

2.3 领域知识增强的指令微调策略

通用大语言模型（如 Flan-T5、LLaMA）虽具备强语义理解能力，但在电力故障场景中存在显著局限性：对专业术语理解偏差、对故障物理规律认知不足、对安全规程遵守性差。为此，本创新提出双阶段领域增强微调策略，通过“知识注入-规则约束-小样本强化”的组合手段，将电力领域知识定向注入模型，实现从通用能力到专业适配的跨越。

2.3.1 领域知识预微调

该阶段目标是让模型掌握电力行业的基础知识体系，包括术语定义、故障物理规律、安全操作规范，为后续任务微调奠定基础。

微调数据集构建：基于《电力安全工作规程》及历史故障案例，构建三类核心样本。1. 术语对齐样本：解决术语误解问题。样本格式为“输入：什么是[术语]？输出：[术语定义+功能+应用场景]”。例如：“输入：什么是环网箱？输出：环网箱是配电网中用于电缆线路分接、联络的配电设备，包含 1-4 个开关单元，可实现故障区段隔离与负荷转移，广泛应用于城市电缆网”。2. 物理规律样本：解决“特征关联缺失”问题，样本格式为“输入：[电压/电流特征]属于什么故障？输出：[故障类型+特征匹配逻辑]”。例如：“输入：a 相电流 0A，b 相电流 70A，ab 线电压 0V，属于什么故障？输出：B 相接地故障。逻辑：故障相（B 相）电流正常，非故障相（A

相)电流中断且电压骤降,符合单相接地特征”3。安全规程样本:解决“操作违规”问题,样本格式为“输入:[操作场景]需执行哪些步骤?输出:[步骤+安全依据]”。例如:“输入:抢修前需执行哪些步骤?输出:1.停电(依据《安规》3.2.1);2.验电(使用合格验电器,依据3.3.2);3.挂接地线(先接接地端,后接导体端,依据3.4.5);4.设置安全围栏(依据4.2.3)”。数据集规模控制在5000-10000条,确保覆盖核心知识且避免冗余。

微调方法:采用“全参数微调+知识蒸馏”组合策略。全参数微调使用上述数据集对基础模型(如Flan-T5-base)进行训练,采用分层学习率策略,公式为:

$$n_l = n_0 \cdot \gamma^{L-1} \quad (6)$$

其中 l 为当前网络层编号, L 为总层数, $\gamma=0.95$ 为衰减系数,使顶层(语义输出层)学习率比底层(特征提取层)高,强化领域知识的表达能力。学习率设为 $5e-5$,迭代3-5轮,确保模型深度内化领域知识。知识蒸馏将微调后的模型知识蒸馏至轻量级模型(如Flan-T5-small),通过“教师-学生”损失函数(KL散度)保留核心知识,兼顾性能与部署效率。知识蒸馏过程采用温度系数修正的KL散度损失,设教师模型输出概率分布为 P_t (Flan-T5-base),学生模型输出为 P_s (Flan-T5-small),则蒸馏损失为:

$$L_{\text{distill}} = \frac{1}{T^2} \sum_c P_t(c) \log \frac{P_t(c)}{P_s(c)} \quad (7)$$

其中 T 为温度系数,通过平滑概率分布增强学生模型对边缘知识(如罕见故障类型)的学习能力。

2.3.2 多模态任务微调

该阶段基于第一阶段的知识基础,针对多模态指令到抢修方案的具体任务进行定向优化,使模型能结合结构化数据与文本描述输出精准方案。

微调数据集构建:以真实故障案例为基础,按多模态指令模板格式构建样本,每条样本包含“多模态输入+标准输出”,如下表1所示。

表1 微调数据集指令模板格式

输入:
物理提示: 接地故障时故障相电流趋近于0, 非故障相电压升高; 表格数据: a相电流=72.49A, b相电流=0.0A, c相电流=69.94A, ab线电压=0V, 总无功=0kVar; 故障描述: 029开关至101环网箱01开关间电缆中间接头异响, 跳闸后遥测数据持续不变; 任务指令: 输出故障类型、特征关联、抢修步骤、验证指标。
输出:
故障类型: B相绝缘击穿(接地故障); 特征关联: b相电流为0A、ab线电压0V(符合故障相特征), a/c相电流升高(非故障相分流), 与“电缆中间接头异响”匹配, 排除设备误动; 抢修步骤: ① 拉开101环网箱01开关及029开关; ② 验电、挂接地线; ③ 剥除接头外护套, 检测绝缘损坏范围; ④ 更换中间接头, 用2500V摇表测绝缘($\geq 100M\Omega$); 验证指标: 送电后三相电流差值 $<5\%$, 线电压稳定在 $10kV \pm 5\%$, 持续监测30分钟无异常。

轻量化微调技术:采用LoRA(Low-Rank Adaptation)参数高效微调方法,仅更新模型注意力层的低秩矩阵参数。低秩矩阵分解满足

$$W=W_0+BA \quad (8)$$

其中, W_0 为预训练权重, $B \in R^{d \times r}$ 、 $A \in R^{d \times r}$ 为低秩矩阵(秩 $r=16$),参数规模从 d^2 降至 $2dr$ 。其优势在于,首先降低计算成本,相比全参数微调,训练所需GPU显存减少90%,单GPU即可完成。其次避免过拟合,小样本场景下,仅微调关键层可保留模型的通用能力,防止对有限样本的过度记忆。最后便于模型融合,微调后的LoRA权重可与基础模型灵活分离,支持快速切换不同场景的微调版本。

损失函数设计:传统微调仅采用交叉熵损失,关注文本输出准确性,本创新设计加权混合损失函数,同时约束模型对物理规律的遵守和安全规程的执行。

语义损失(L_{sem}):采用交叉熵损失,计算模型输出与标准方案的文本差异,权重系数 ω_{sem} ;

物理约束损失 (L_{phy})：针对电压、电流特征设计硬性约束，如“若故障类型为 B 相接地，则模型输出中必须包含‘b 相电流 $\approx 0A$ ’的关联分析”，否则施加惩罚，权重系数 ω_{phy} 。惩罚采用特征匹配惩罚机制，设模型输出的特征关联集合为 S ，标准特征集合为 S^* ，则：

$$L_{phy} = \lambda \cdot \|\text{OneHot}(S) - \text{OneHot}(S^*)\|_2^2 \quad (9)$$

其中 $\lambda=10$ 为惩罚系数，当模型遗漏 “b 相电流 $\approx 0A$ ” 等关键特征时，该损失会急剧增大。

安全损失 (L_{safe})：对违反安全规程的步骤施加高权重惩罚，引入风险等级加权因子，设步骤风险等级为 $r_i \in [1,5]$ ，违规指示变量为 $v_i \in \{0,1\}$ ，则：

$$L_{safe} = \sum_{i=1}^n r_i \cdot v_i \cdot \log(1 + \exp(r_i)) \quad (10)$$

确保 “未验电即操作” 等高危步骤 ($r_i=5$) 的惩罚力度是低危步骤的 10 倍以上。 L_{safe} 权重系数 ω_{safe} ，惩罚值随步骤风险等级递增。

总损失函数为：

$$L_{total} = \omega_{sem} L_{sem} + \omega_{phy} L_{phy} + \omega_{safe} L_{safe} \quad (11)$$

该微调策略通过知识分层注入+损失函数定制，突破通用大模型领域适配的技术瓶颈。双阶段设计先夯实基础再聚焦任务，避免“术语学习”与“决策能力”的相互干扰，解决传统微调中“知识碎片化”问题；LoRA 技术与混合损失函数结合，使模型在小样本场景下仍能达到较高准确率，降低对标注数据的依赖；物理约束与安全损失确保模型输出不仅语义通顺，更符合电气规律、遵守安全规范，解决通用模型看似合理实则违规的缺陷。

3 实验

本章节通过设计对比实验与消融实验，对所提出的“大模型指令微调驱动的电力故障抢修方案智能生成”模型（以下简称 PowerRepair）进行全面评估。实验旨在回答以下三个核心问题。首先是有效性，PowerRepair 模型在抢修方案生成任务上的整体性能如何？与基线模型相比有何优势？其次是贡献分析，方法中的关键组件，各自发挥了多大作用？最后是实用性，模型生成的方案是否具备技术准确性、安全性和实用性？

3.1 实验设置

3.1.1 数据集

实验采用国内某大型电网公司真实的历史故障数据构建数据集 PowerFaultDataset。数据来源为 SCADA/EMS 系统、生产管理系统、配电自动化系统及现场移动应用上报的文本。数据规模方面，共包含 847 个有效故障案例，涵盖接地故障、短路故障、设备老化等 8 种主要故障类型。每个案例包含多模态输入（遥测数据、文本描述、设备元数据）及对应的、由专家评审确认的标准抢修方案输出。数据按 7:2:1 的比例随机划分训练集、验证集和测试集。

3.1.2 评估指标

为全面、多维度评估大模型生成的电力故障抢修方案质量，结合电力领域的专业性与安全性需求，构建涵盖文本生成质量、专业准确性及安全性的三层评估指标体系。在文本生成质量维度，采用 BLEU-4 与 ROUGE-L 两项经典指标。其中 BLEU-4 通过衡量生成文本与参考文本在 4-gram 层次上的重叠程度，量化生成内容与标准方案在专业表述逻辑上的精确性；ROUGE-L 则基于最长公共子序列计算，不严格限制词序，重点评估生成文本对参考文本中核心信息的覆盖完整性，避免因词序差异误判信息缺失情况。在专业准确性维度，设计故障类型准确率与关键步骤召回率：故障类型准确率用于统计模型判断的故障类型与真实故障类型的一致比例，直接反映模型对故障本质的诊断能力；关键步骤召回率则计算模型生成方案中完整覆盖所有必要抢修步骤的案例占比，确保方案在专业流程上的完整性。在安全性维度，引入安全违规次数 (Safety Violations) 指标，通过对照《电力安全工作规程》，统计模型生成方案中出现 “未验电即操作” “先接导体端后接接地端” 等违规

步骤的次数，安全违规次数 = 总违规次数 / 测试案例总数。从合规性角度保障方案的实际可执行性，避免因模型输出违规操作引发安全风险。

3.1.3 基线模型

选取以下具有代表性的基线模型进行对比：

- GPT-3.5-turbo (Zero-shot)^[26]：调用通用大模型 API，直接输入指令和数据进行生成，检验其领域泛化能力。
- Flan-T5-base (Vanilla FT)^[27]：使用本研究的训练数据对基础 Flan-T5 模型进行全参数指令微调，作为微调有效性的基线。
- BERT-GRU^[28]：基于编码器-解码器架构的传统领域模型。使用 BERT 编码多模态输入，GRU 解码生成方案，代表深度学习时代的主流方法。

3.1.4 实施细节

本模型以 Flan-T5-large 为基座模型。训练分两阶段进行。首先是领域知识预微调：使用 5000 条知识对齐样本，学习率 5e-5，训练 4 轮。其次是多模态任务微调：使用 PowerFaultDataset 训练集，采用 LoRA (rank=16) 微调，混合损失权重($\alpha=0.4, \beta=0.3, \gamma=0.3$)，学习率 3e-4，训练 10 轮。

3.2 结果与分析

3.2.1 有效性分析

表 2 模型实验性能

模型	BLEU-4 ↑	ROUGE-L ↑	故障准确率 ↑	关键步骤召回率 ↑	安全违规次数 ↓
GPT-3.5	15.23	2.41	61.35	54.72	2.84
BERT-GRU	22.67	35.19	76.88	70.51	1.57
Flan-T5-base	31.45	42.76	85.91	82.33	0.89
PowerRepair (Ours)	38.92	49.87	93.25	91.06	0.21

如表 2 所示，所提出的 PowerRepair 模型在各评估指标上均显著优于所有基线模型。相较于 GPT-3.5 (Zero-shot)，该模型在各项指标上实现大幅提升，有力证明在高度专业化的电力故障诊断领域，通用且未经专门微调的大模型难以适配需求，凸显领域特定指令微调的关键价值；相较于 BERT-GRU，模型优势显著，体现出基于 Transformer 的现代大语言模型在语义理解与生成能力上，对传统模型形成代差优势；相较于 Flan-T5-base (Vanilla FT)，模型在故障准确率与安全性方面提升明显，这得益于所提出的多模态指令模板、双阶段微调策略及混合损失函数的协同作用，有效强化了模型的专业认知与安全性，而非单纯提升文本流畅度。

3.2.2 消融实验

为验证模型中各个关键组件的贡献，我们进行了系统的消融实验，结果如表 3 所示。

表 3 消融实验

模型变体	BLEU-4	ROUGE-L	故障准确率 (%)	安全违规次数
PowerRepair (完整模型)	38.92	49.87	93.25	0.21
w/o 多源数据融合与预处理	33.15	44.02	86.41	0.75
w/o 领域知识预微调	35.68	46.33	88.97	0.53
w/o 混合损失 (仅用交叉熵损失)	37.04	47.89	90.12	0.82
w/o LoRA (全参数微调)	38.01	48.55	91.84	0.38

对 PowerRepair 模型开展消融实验，去除不同关键组件后，各模型变体性能呈现显著差异。当去除多模态指令模板，模型性能全面下滑，安全违规次数增加，表明标准化数据在引导模型关注跨模态关联、构建清晰输

入逻辑方面作用关键。去除领域知识预微调时，故障准确率明显降低，体现出第一阶段知识注入是模型理解电力领域术语和规律的基础，不可或缺；仅使用交叉熵损失，安全违规次数大幅上升，说明物理约束损失与安全损失能有效约束模型输出，避免看似合理实则错误的问题；采用全参数微调，性能略有下降且训练成本剧增，凸显 LoRA 在保证性能的同时可提升训练效率，是更优的参数高效微调选择。

3.2.3 案例研究

为直观展示各模型性能差异，我们选取一个测试集中典型的 B 相接地故障案例进行深入的定性分析。该案例包含了丰富的多模态信息，能有效检验模型的数据融合、专业推理和安全合规能力。

输入信息

物理提示：接地故障时故障相电流趋近于0，非故障相电压升高。
表格数据：a相电流=6.24A，b相电流=0A，c相电流=18.24A，ab线电压=23108V，总无功=-11.87kVar。
故障描述：#43-#13杆高压导线与拉线接触，伴随火花放电，此前有大风天气记录。
任务指令：输出故障类型、特征关联分析、抢修步骤及送电验证指标

标准输出（专家方案）：

故障类型：B相接地故障。
特征关联分析：b相电流为0A是故障相的直接表现；ab线电压异常升高（23.1kV > 额定10kV）符合中性点非有效接地系统单相接地时非故障相电压升高的规律；总无功为负值可能与线路充电功率或测量点有关；现场“火花放电”描述与“导线与拉线接触”的物理现象高度吻合，大风天气是可能诱因。
抢修步骤：
① 向调度申请拉开#43、#13杆相关开关，并确认停电。
② 在#43杆小号侧、#13杆大号侧分别验电，确认无电压。
③ 在#43杆小号侧、#13杆大号侧挂接地线。
④ 排查并处理#43-#13杆间导线与拉线接触点，消除放电现象。
⑤ 测量线路绝缘电阻（B相对地绝缘应>100M Ω ）。
⑥ 拆除接地线，汇报调度，申请恢复送电。
验证指标：送电后三相电流平衡（差值<5%），线电压恢复至10.0kV $\pm$ 5%，无异常报警，持续监测30分钟。

PowerRepair (Ours)：

故障类型：B相接地故障。
特征关联分析：b相电流为0A明确指示B相为故障相；ab线电压升高至23.1kV印证了非故障相电压升高的理论；总无功为负值需关注线路电容电流分布；现场描述的“导线与拉线接触”及“火花放电”是导致B相直接接地的直接原因，大风是主要诱因。
抢修步骤：
① 断开#43、#13杆联络开关，确认线路停电。
② 使用合格验电器在作业点两侧验电。
③ 在作业点两侧挂设接地线。
④ 使用绝缘操作杆处理导线与拉线金属性连接点，修复外破痕迹。
⑤ 使用2500V摇表测量B相对地绝缘电阻，要求大于100M Ω 。
⑥ 拆除安全措施，逐级恢复送电，并监测电气指标。
验证指标：送电后b相电流恢复至正常范围，三相电流不平衡度<2%，线电压稳定在10.0kV至10.2kV之间。

BERT-GRU：

故障类型：接地故障。
特征关联：b相电流0A故障接地火花放电大风天气导线拉线接触。
抢修步骤：
① 调度停电拉开开关。
② 去现场找到#43杆和#13杆。
③ 看到导线碰到拉线了，用绝缘杆把它拨开。
④ 检查一下导线有没有烧坏。
⑤ 送电。
验证指标：送电后看电流电压正常。

Flan-T5-base：

故障类型：接地故障。
特征关联分析：b相电流为零说明可能发生了接地。ab线电压有变化。文本描述显示有放电现象。
抢修步骤：
① 拉开#43和#13杆的开关。
② 找到导线与拉线接触的地方，把它们分开。
③ 检查一下线路有没有明显损坏。
④ 合上开关送电。
验证指标：送电后看看电流电压是否正常。

GPT-3.5：

故障类型判断：可能是一起B相接地故障。
特征关联分析：B相电流降为零是接地故障最直接的电气特征。现场人员报告的“导线与拉线接触”并伴有“火花放电”是导致B相直接接地的物理原因。
抢修步骤：
① 立即向电力调度中心汇报故障情况。
② 派出抢修队伍前往#43至#13杆塔区段进行巡视。
③ 找到导线与拉线接触的具体位置。
④ 使用绝缘工具将导线与拉线分离。
⑤ 检查导线和拉线是否有熔断或灼伤痕迹。
⑥ 检查完毕后，汇报调度，申请恢复送电。
验证指标：送电后，观察B相电流是否恢复正常，三相电流是否平衡，线路电压是否稳定，并无再次跳闸或异常报警。

本小节围绕典型 B 相接地故障案例展开，整合数值监测数据、文本描述及环境诱因等多模态信息，将标准方案与四种模型生成方案进行对比，检验模型在故障诊断、特征关联、方案生成及安全性维度的综合能力。在综合性能对比中，各模型表现差异显著：PowerRepair 在故障判断准确性、特征关联深度、抢修步骤完整性与安全性上表现最优，最贴近专家方案；GPT-3.5 语义理解能力较强，但专业准确性与安全规程遵守方面存在明显短板；BERT-GRU 输出内容破碎、逻辑连贯性差，缺乏完整方案结构；Flan-T5-base 处于中间水平，虽能生成结构化内容，却在关键安全步骤上存在遗漏。

案例研究进一步揭示关键发现：通用大模型（如 GPT-3.5）虽能生成流畅文本，但因缺乏领域安全知识，可能输出看似合理却存在危险的方案，在电力等高风险行业直接应用风险极大；单纯指令微调（如 Flan-T5-base）虽能提升领域适应性，却难以满足安全性约束，验证本研究安全损失函数与物理约束的必要性；PowerRepair 通过有效融合数值特征与文本描述开展深度关联推理，凸显多模态学习优势；传统方法（如

BERT-GRU) 则因无法处理复杂生成任务, 输出结果实用性极低。

综上, 在电力故障抢修这类专业性强、安全性要求高的场景中, 通用大模型或简单微调方法均无法适配实际需求。本文提出的 PowerRepair 方法, 提升方案的专业性、安全性与实用性, 为大模型在垂直领域的深度应用提供有效路径, 其生成方案已逼近专家水平, 具备实际部署价值。

参考文献:

- [1]. Liu H, Hu W, Yu L, et al. Application and Outlook of Artificial Intelligence Large Models in New Power System Operation Control[C]//2024 3rd International Conference on Energy and Electrical Power Systems (ICEEPS). IEEE, 2024: 1184-1187.
- [2]. Liu Z, Gao Y, Liu B. An artificial intelligence-based electric multiple units using a smart power grid system[J]. Energy Reports, 2022, 8: 13376-13388.
- [3]. Yao Q, Fang F, Chen Y, et al. AI Large Models for Power System: A Survey and Outlook[J]. IET Smart Energy Systems, 2025, 1(1): 3-21.
- [4]. Xu H, Liu W, Guo K. Strategy and implementation of large language model in intelligent guidance of electric power industry training[J]. Journal of Computational Methods in Sciences and Engineering, 2023: 14727978251362694.
- [5]. Vilorio A, Palma H H, Suarez R G, et al. Intelligent Model for Electric Power Management: Patterns[C]//Journal of Physics: Conference Series. IOP Publishing, 2020, 1432(1): 012032.
- [6]. Wang H, Huang Z, Zhang X, et al. Intelligent power grid monitoring and management strategy using 3D model visual computation with deep learning[J]. Energy Reports, 2022, 8: 3636-3648.
- [7]. Sechilariu M. Intelligent energy management of electrical power systems[J]. Applied Sciences, 2020, 10(8): 2951.
- [8]. Khayyam H, Ranjbarzadeh H, Marano V. Intelligent control of vehicle to grid power[J]. Journal of Power Sources, 2012, 201: 1-9.
- [9]. Wu P, Tu H, Mou X, et al. An intelligent energy management method for the manufacturing systems using the knowledge graph and large language model[J]. Journal of Intelligent Manufacturing, 2025: 1-20.
- [10]. Aljarrah E. AI-based model for Prediction of Power consumption in smart grid-smart way towards smart city using blockchain technology[J]. Intelligent Systems with Applications, 2024, 24: 200440.
- [11]. 郑立鑫, 杨楠. 人工智能在电力故障诊断中的应用[J]. 集成电路应用, 2024, 41(11): 156-157. DOI:10.19339/j.issn.1674-2583.2024.11.070.
- [12]. 姜俊秋, 车德敏. 基于人工智能的电力系统故障检测与自动修复方法研究[J]. 电气技术与经济, 2024, (03): 22-24.
- [13]. 方萌, 史可敬. 对于人工智能在电力系统故障诊断中的应用及研究[J]. 中国科技投资, 2021, (22): 63-64.
- [14]. 米加威. 基于大数据的多源信息融合技术在电力系统中的应用研究[D]. 天津理工大学, 2019.
- [15]. He X, Dong H, Yang W, et al. Multi-source information fusion technology and its application in smart distribution power system[J]. Sustainability, 2023, 15(7): 6170.
- [16]. Li D, Zhou P, Li X, et al. Implementation of Multimodal Information Fusion Methods for Intelligent Converter Stations[C]//Proceedings of the 2024 2nd International Conference on Internet of Things and Cloud Computing Technology. 2024: 19-23.
- [17]. Liu J. Multi Modal Data Fusion using Fusion Convolution Network for High Voltage Insulator Condition Monitoring in Power Grid[C]//2024 Second International Conference on Data Science and Information System (ICDSIS). IEEE, 2024: 1-6.
- [18]. Gaw N, Yousefi S, Gahrooei M R. Multimodal data fusion for systems improvement: A review[J]. Handbook of Scholarly Publications from the Air Force Institute of Technology (AFIT), Volume 1, 2000-2020, 2022: 101-136.
- [19]. 李宝亮, 张恒旭, 曹永吉, 等. 基于大语言模型的电力系统潮流自适应调整[J/OL]. 电力系统自动化, 1-14[2025-08-26]. <https://link.cnki.net/urlid/32.1180.TP.20250728.1548.004>.
- [20]. 张建良, 张晓洁, 麻坚, 等. 面向新型电力系统的故障诊断技术研究进展(二): 机器学习和大语言模型技术[J/OL]. 实验技术与管理, 1-23[2025-08-26]. <https://link.cnki.net/urlid/11.2034.T.20250630.1609.006>.
- [21]. 冯磊, 洪晔, 秦永亮, 等. 大语言模型安全评估技术在新型电力系统中的应用思考[C]//《信息安全研究》杂志社. 2025

- 网络安全创新发展大会论文集.国网思极网安科技(北京)有限公司;,2025:5-8.DOI:10.26914/c.cnkihy.2025.017915.
- [22]. Meng Q, Song Y, Mu J, et al. Electric power audit text classification with multi-grained pre-trained language model[J]. IEEE Access, 2023, 11: 13510-13518.
- [23]. Ren M, Cao B, Lin H, et al. Learning or self-aligning rethinking instruction fine-tuning[J]. arXiv preprint arXiv:2402.18243, 2024.
- [24]. Zhao H, Andriushchenko M, Croce F, et al. Long is more for alignment: A simple but tough-to-beat baseline for instruction fine-tuning[J]. arXiv preprint arXiv:2402.04833, 2024.
- [25]. Zhang R, Han J, Liu C, et al. Llama-adapter: Efficient fine-tuning of language models with zero-init attention[J]. arXiv preprint arXiv:2303.16199, 2023.
- [26]. Anand Y, Nussbaum Z, Duderstadt B, et al. Gpt4all: Training an assistant-style chatbot with large scale data distillation from gpt-3.5-turbo[EB/OL].(2023)
- [27]. Oza J, Yadav H. Enhancing Question Prediction with flan t5-a context-aware language model approach[J]. Authorea Preprints, 2023002E
- [28]. Yi R, Hu W. Pre-trained BERT-GRU model for relation extraction[C]//Proceedings of the 2019 8th international conference on computing and pattern recognition. 2019: 453-457.

作者简介:

+邓养吾(1994-), 男, 黑龙江省佳木斯人, 国网烟台供电公司数字化部中级工程师, 硕士, 研究方向: 人机交互与虚拟现实技术, 通讯作者, E-mail: 1049237372@qq.com;

刘梦琪(1996-), 女, 山东济南人, 国网莱州市供电公司运维检修部中级工程师, 研究方向: 无线通信与信号处理等, E-mail: 540682864@qq.com;

李荣生(1986-), 男, 山东临清人, 国网烟台供电公司数字化部高级工程师, 硕士, 研究方向: 电力网络安全管理与技防体系建设、网路安全应急体系建设等, E-mail: 429540684@qq.com;

杨 阳(1989-), 男, 内蒙古杭锦人, 国网烟台供电公司通信调度与运行技术高级工程师, 研究方向: 通信工程, E-mail: 295121316@qq.com;

孙玮璠(1996-), 男, 山东莱州人, 国网烟台供电公司信息建设运检初级工程师, 硕士, 研究方向: 嵌入式及人工智能等, E-mail: 1515283061@qq.com;

程培强(1980-), 男, 山东烟台人, 福山区供电公司调控分中心副主任, 高级技师, 研究方向: 电力系统稳定运行、主配网故障防御及新型电力调度系统的实践与应用等, E-mail: 786965035@qq.com;