

类 DeepSeek 范式在电力装备故障诊断中的应用模式

江秀臣, 臧奕茗, 谢子恒, 琚钰瑶, 刘亚东, 盛戈皞

(上海交通大学电气工程学院, 上海 200240)

摘要: 作为新一代人工智能技术, 类 DeepSeek (DS) 范式具有开源、推理能力强、低算力需求、可本地部署的优势, 符合数字化电力装备故障诊断数据安全、可靠评估、边缘部署的需求。该文首先介绍了类 DS 模型的发展现状与类 DS 范式的基本架构, 分析了其运算效率高、占用缓存少、推理能力优越、开源模型共享、中文优化的模型优势。然后, 针对电力装备故障诊断基础理论, 研究了基于类 DS 范式的电力装备故障参量产生机理挖掘模型、电力装备多状态参量耦合机理理解模型; 针对电力装备故障诊断技术应用, 研究了电力装备多模态联合诊断技术、电力装备故障诊断大模型的轻量化部署技术、大规模多参量传感器性能自校验技术。最后, 提出了类 DS 范式在电力行业中所面临的挑战, 总结了未来类 DS 范式的发展方向。

关键词: 类 DeepSeek 范式; 人工智能; 大模型; 电力装备; 故障诊断

Application Model of DeepSeek-like Paradigm in Fault Diagnosis of Power Equipment

JIANG Xiuchen, ZANG Yiming, XIE Ziheng, JU Yuyao, LIU Yadong, SHENG Gehao

(Department of Electrical Engineering, Shanghai Jiao Tong University, Shanghai 200240, China)

Abstract: As a new generation of artificial intelligence technology, DeepSeek-like (DS-like) paradigm has the advantages of open source, strong reasoning ability, low arithmetic demand, and local deployability, which meet the needs of secure, reliable evaluation and edge deployment of digital power equipment fault diagnosis data. We first introduced the development status of DS-like models and the basic architecture of DS-like paradigm, and analyzed its model advantages of high computing efficiency, low cache occupation, superior reasoning capability, open source model sharing, and Chinese optimization. Then, for the basic theory of power equipment fault diagnosis, we studied the mining model of power equipment fault parameter generation mechanism based on DS-like paradigm and the model of power equipment multi-state parameter coupling mechanism understanding; for the application of power equipment fault diagnosis technology, we investigated the multi-modal joint diagnosis technology of power equipment, the lightweight deployment technology of power equipment fault diagnosis model, and the performance self-checking technology of large-scale multi-parameter sensors. Finally, the challenges faced by the DS-like paradigm in the power industry are proposed, and the future development direction of the DS-like paradigm is summarized.

Key words: DeepSeek-like model; artificial intelligence; large model; power equipment; fault diagnosis

0 引言

当前, 为应对“双碳”目标下新型电力系统带来的高比例新能源接入、源荷互动复杂化等挑战, 电力装备的数字化、智能化转型已成为必然趋势。以智能传感、云边计算和人工智能应用为代表的数字化技术已经在电力系统的“发、输、变、配、用”各环节取得一定进展, 积累了海量的多源异构设备数据, 为提升数字化电力装备的可观、可测、可控水平奠定了基础^[1-2]。

然而, 面对海量爆发式增长的电力装备状态数据、设备故障机理不明确、多参量内在关联挖掘不足等问题, 亟需更智能、更高效的数据处理与分析技术来挖掘数据价值, 以支撑多参量联合检测与诊断^[2-3]。同时, 边缘终端算力有限、算法模型迭代成本高昂, 加剧了对云计算资源的依赖, 且静态独立智能系统难以适应动态演化的数字化电力装备状态感知场景。

近年来, 大语言模型(large language models, LLMs)凭借其自然语言理解能力、小样本学习能力、知识迁移能力、自动生成等优势, 在电力系统的负荷与发电出力检测、电力系统规划、电力系统调度、

基金资助项目: 国家自然科学基金(52407179)。
Project supported by National Natural Science Foundation of China (52407179).

电力系统故障诊断、电力市场问题等方面有着广泛的应用前景^[4]。例如, 2025 年 2 月以来, 国家电投集团能源科学技术研究院成功将人工智能大模型深度融入自主研发的虚拟电厂平台, 打造了国内电力行业首个虚拟电厂智能助手“小易”, 将非结构化政策文本转化为知识图谱, 支撑交易策略生成与负荷预测, 数据召回准确率达 92%; 南方电网人工智能创新平台实现了大数据模型的本地化部署, 基于“大瓦特”模型体系开放技术路线, 实现了自然语言处理(natural language processing, NLP)基础模型快速升级迭代为千亿参数级, 能在内网安全环境下提供更高性能的分布式、高并发推理服务。

除此之外, 国内专家也在积极探索大数据模型在电力行业新的应用方案。例如, 文献[5]通过时序数据重编程和提示工程技术, 将 LLMs 应用于绿电功率预测, 为园区综合能源系统集群的绿电交易和协同优化运行提供精准预测基础。文献[6]通过链式提示法, 利用 LLMs 降低了海上风电场系统拓扑优化问题的维度, 提高了聚类问题的求解速度和效果。文献[7]分析 LLMs 的预测建模、自然语言处理和推理决策能力, 展望了 LLMs 应用于电力调度的多个关键环节, 有望提升调度预测精度、控制智能性、合规管理效率和辅助决策水平的应用前景。文献[8]分析了中等规模城市电力系统诊断案例, 通过 LLMs 的数据处理, 诊断准确率得到显著提升。文献[9]通过使用低秩微调(low-rank adaptation, LoRA)和检索增强生成(retrieval-augmented generation, RAG)技术, 将 LLMs 应用于电力装备缺陷诊断, 构建了智能诊断助手, 达到了提升诊断问答专业性、准确性与可靠性的效果。文献[10]引入微调、提示语、RAG、智能体等先进方法, 将 LLMs 适配并应用于低碳电力市场场景, 为电力系统低碳转型提供了新的数据分析、决策支持和技术创新路径。

然而, 闭源 LLMs 模型存在以下局限^[11]。1) 数据安全问题: 电力装备数据高度敏感, 而闭源 LLMs 数据需要外传处理, 显著增加了泄漏、滥用风险, 难以满足电力行业对数据安全与主权的严格要求。2) 生成内容偏差问题: 闭源 LLMs 知识滞后, 易生成不准确的“幻觉”信息。训练数据或人工反馈引入的偏见会影响输出客观公正性, 威胁故障机理挖掘、多参量耦合关系探究、诊断等决策的准确性与可靠性。3) 硬件算力限制问题: 训练和运行类 ChatGPT 闭源大模型需要庞大算力和高昂能

耗, 导致硬件投入与运营成本极高, 限制了电力企业内训练电力装备专用大模型及常态化更新维护。

4) 大模型封闭性与集成适配问题: 闭源模型的“黑箱”特性及代码不公开, 难以按电力特定需求深度定制优化。缺乏可解释性使得 LLMs 在高风险应用中可信度降低, 其与现有电力装备和传感系统、软件、接口的无缝集成适配亦面临挑战。因此, 国产类 DeepSeek(DS)系列模型凭借其开源的特质和显著的成本优势, 在电力行业具有广阔的应用前景。

目前, 国产类 DS 系列模型指的是与 DeepSeek 技术路线相似的主流大数据模型, 如 Kimi K2、Qwen 3.0、ERNIE 4.5 等。对多种类 DS 模型进行对比分析可以发现, 每种模型都具有其独特的优势。例如, 在架构设计方面, Kimi K2 是国内首个开源的万亿级稀疏混合专家模型(mixture of experts, MoE), 编程表现出色, 支持超长文本输入, 长上下文处理能力强; 在性能表现方面, Qwen 3.0 可实现轻量化部署, 采用卷积代码量化技术, 边缘设备显存占用降低 35%; 在应用适配性方面, ERNIE 4.5 通过对抗训练注入 120 万条安全样本, 实现了有害输出率小于 0.1%, 相比国外大数据模型 Claude 3.5 的有害输出率 0.3%数据结果更小。

类 DS 模型在训练中应用了 FP8 (8 位浮点数)混合精度训练框架, 结合细粒度量化和高精度累积技术, 利用 DualPipe 流水线并行算法高效隐藏了通信开销, 无需昂贵的张量并行即可完成训练^[12], 极大地降低了硬件算力需求和训练成本。这使得在电力企业可以进行内部部署和维护, 有效缓解了“硬件算力限制”的问题。同时, 类 DS 模型的开源特性结合显著降低的部署门槛, 支持本地化或私有化部署, 将敏感数据保留在电力企业内部, 有助于解决“数据安全”的挑战。

类 DS 模型通过强化学习可实现高效推理能力, 并且验证了推理能力的可蒸馏性^[13]: 使用全参数 DS 生成的高质量推理数据, 能够高效地将强大推理能力迁移到开源的小型密集模型(如 Qwen、Llama)上, 使这些小模型性能大幅提升。类 DS 模型及其蒸馏模型的全面开源, 能从根本上克服“大模型封闭性与集成适配”的挑战, 允许电力领域进行不受限制的定制、集成和二次开发。其强大的推理能力, 有助于生成更可靠、逻辑性更强的分析结果, 从而缓解“生成内容偏差”的挑战。推理能力能够被高效蒸馏到算力需求低得多的小模型上, 为

算力有限的电力应用场景部署高级 AI 推理能力提供了经济可行的途径，这进一步缓解了“硬件算力限制”的挑战。

综上所述，以 DeepSeek-V3 和 R1 系列为代表的类 DS 开源大模型，凭借其架构创新、训练效率优化、推理能力提升以及核心的开源特性，为电力系统应对当前数字化电力装备状态检测中的诸多挑战提供了极具潜力的解决方案。在电力装备故障诊断中，类 DS 范式凭借其大参量训练数据模型与轻量化边缘部署技术，与行业高度适配。例如，华能清能院故障诊断与状态检修部将电力设备故障诊断与基于类 DS 模型的检索增强生成(RAG)技术深度融合，开启大模型深度赋能故障诊断的探索之路。通过部署类 DS 模型，电力装备故障诊断向以可靠性为中心的检修平台、以高效性为中心的发电设备分级管控平台、以安全性为中心的机电状态监测系统方向发展，实现电力装备智能化管理、监测与诊断，从根本上转变电力装备故障诊断方式。

1 类 DeepSeek 范式模型

本章通过分析类 DS 系列模型(DeepSeek-V3、DeepSeek-R1-Zero、DeepSeek-R1 等)创新架构与训练方法，详细介绍该系列模型在现有大模型架构上的探索与改进，其中类 DeepSeek 范式模型的基本模型框架如图 1 所示。

1.1 基本架构

类 DS 大语言数据模型是一种基于多层 Transformer 架构的预训练语言模型，通过大规模的

数据预训练来处理自然语言。该模型在预训练过程中所用的数据涵盖了多种语言和多领域的的数据，所用的技术包含了如下多项核心模型^[14]。

1) 混合专家模型(mixture of experts, MoE)

扩展模型参数规模是增强模型容量、提高模型能力最简单、最有效的方式之一，为降低扩展模型带来的巨额参数计算量压力，类 DS 模型使用 MoE 模型，并在 MoE 架构基础上提出共享专家隔离技术和无辅助损耗负载均衡，旨在解决“路由崩溃”和专家冗余问题，以提高模型精度和计算效率^[15]。

MoE 是机器学习领域的一种集成学习技术，该技术使用多个子模块，分别处理复杂问题的不同子集，这些子模块被称为专家。多个子模块并行处理问题，最后由门控网络根据输入数据的特征将其路由到特定专家，并为专家分权重，最后根据专家模型不同的权重输出预测结果。MoE 的输出 y 可用式 (1)表示。

$$y = \sum_{i=1}^n G_i(x) E_i(x)$$

(1)

式中： $E_i(x)$ 为专家 i 对输入 x 的输出； $G_i(x)$ 为门控网络对第 i 个输入 x 的输出。通过门控网络计算权重，从 n 个专家中选择权重最高的前 K 个专家参与计算，softmax 只评估前 K 个专家而其余专家不激活，这种机制称为 Top-K 稀疏激活，输出 $G(x)$ 如式 (2)所示。

$$G(x) = \text{softmax}(\text{TopK}(xW_{\text{gate}}, K))$$

(2)

式中： W_{gate} 为门控网络参数；softmax(·)为机器学习中常用的一种激活函数，主要功能为概率转换，将




图 1 类 DS 范式模型技术架构

Fig.1 Technical architecture based on a DS-like modeling paradigm

1 组实数转换为概率分布, 确保每个元素在 0~1 之间, 且所有元素之和为 1。

由式(2)可以看出, MoE 引入了一个不连续的门控函数。在梯度计算中, 该函数会导致梯度下降, 优化方法训练表现不佳, 可能会出现模型始终为每个词元激活相同少数专家的情况, 导致某些专家被过度使用而剩下专家闲置占用内存, 这一问题被称为“路由崩溃”。解决该问题的传统办法是采用“辅助损失”训练策略, 即让每个专家在大量训练批次中被激活相等的次数。这种强制性的辅助损失虽然能防止“路由崩溃”, 但会导致同领域的专家能力分散到不同专家模型中造成性能损失, 而且会重复复制信息造成专家模型的效率降低。

为了解决这一矛盾, 类 DS 模型创新性地提出了共享专家隔离技术与无辅助损失负载均衡。

(1) 共享专家隔离技术。类 DS 模型将所有专家分为两类: 一是共享专家; 二是路由专家。每个 MoE 层拥有少量共享专家和大量路由专家, 每个词元只会从路由专家中选择最优的几个专家进行处理, 而共享专家始终会被激活, 在词元的训练中确保路由专家的路由均衡, 防止出现某些专家超负荷情况导致的计算资源浪费。同时, 共享专家也处理通用知识, 减少路由专家计算负担, 让路由专家更专注于不同的专业领域, 提高训练效率。

(2) 无辅助损耗负载均衡。为了避免辅助损失, 类 DS 模型将定向于每个专家的偏差项引入路由机制, 在梯度计算中该偏差项会持续监控训练过程, 通过检查某些专家的激活次数是否合理来确保负载均衡, 例如某一专家接收词元任务次数过多, 则减少激活该专家的概率来预防专家超负荷; 某一专家长时间处于待机状态, 则增加激活概率。该偏差项由设计者指定, 在训练过程中不会跟随梯度下降更新, 还可以根据实际训练结果满意度对偏差项动态调整, 改变某些专家的激活次数来实现更优的计算结果。

2) 多头潜在注意力模型(multi-head latent attention, MLA)

注意力机制是大语言数据模型通过捕捉已输入的上下文与生成词的关键信息、并对这些关键词进行权重分配的动态差异化关注机制。MLA 是一种低秩键值联合压缩注意力机制, 其关键技术原理是通过矩阵的低秩近似, 对数据进行有损压缩, 只保留关键细节, 从而快速进行矩阵计算, 可通过以下

数学方法进行理解。

数据的集合存储在任意矩阵 $A(N \times n)$ 中, A 的每一列对应一个 N 维向量, 表示一个数据点。对于高维数据, 想要简化数据, 可用传统的向量表示技术, 用一个低秩矩阵来近似矩阵 A 。数学上, 矩阵 A 的最优的低秩近似被写成如下形式。

对任意秩为 r 的实矩阵 $A \in \mathbf{R}^{N \times n}$ 来说, 可通过 SVD 奇异值 $\sigma_i (i=1, 2, \dots, r)$ 分解得到:

$$A = UDV^T \quad (3)$$

$$D = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0), \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 \quad (4)$$

式中: D 为对角线元素从大到小排序的矩阵, 这些对角线元素称为奇异值; 矩阵 U 与 V 正交。已知 $\|A-B\|_F$ 是 Frobenius 范数, 对 $1 \leq k \leq r$ 有以下误差计算式:

$$\sum_{i=k+1}^r \sigma_i^2 = \|A - B\|_F^2 \quad (5)$$

式中: $B = \text{best}_k(A)$ 为所能实现的最小值, 此时 $\text{best}_k(A) = U_k \text{diag}(\sigma_1, \dots, \sigma_k) V_k^T$; U_k 为 U 的前 k 列矩阵; V_k 为 V 的前 k 列矩阵。由式(5)可知奇异值的平方和等于范数的平方。奇异值分解可将 A 分解为 r 个秩为 1 的矩阵片段的线性组合, 在原始高维空间中矩阵 A , 可被退化到空间中的两列近似表示, 即高维数据点可被退化到降维空间对应的数据点。

基于 Transformer 的模型在推理过程需要根据上下文计算生成词元, 常常需要前向计算过去所有词元的相关内部状态, 主要是注意力机制中的键矩阵和值矩阵, 即键值对。该算法会重复计算上一回合处理过的词元, 从而造成计算资源浪费, 降低模型效率。为避免该问题, 目前方法是进行键值缓存, 而类 DS 模型将低秩近似原理创新性地应用在减少键值缓存的计算上, 提出了 MLA 注意力机制。

MLA 方法是包含大量输入信息的原矩阵通过低秩近似转换为两个较小的潜向量矩阵的乘积, 同时对旋转位置编码(rotary position embedding, RoPE)方式进行改进, 以便于更好地兼容低秩键值的压缩。因此, MLA 缓存的是较小的潜在量, 而不是完整的键值对, 显著减小了推断过程中键值缓存大小, 提升了推理效率, 减少了内存和计算资源的消耗, 获得了相比于多头注意力机制、分组查询注意力机制更好的性能。

3) 群体相对策略优化(group relative policy optimization, GRPO)

大模型的训练通常首先进行预训练, 然后进一

步通过监督微调处理,最后使用强化学习精确调整模型来满足使用者的偏好。类 DS 模型采取了基于 GRPO 框架的纯强化学习算法,跳过了基于人类反馈的强化学习和传统的监督微调过程^[16],以此来节约显存与计算资源、降低训练成本和轻量化模型。

传统强化学习中主要采用价值模型来评估每个响应的质量,而 GRPO 算法通过组内响应的相对比较来评估响应质量,即在同一输入问题下生成多个候选响应,通过正确性、格式等预期指标进行组内响应的排名或归一化奖励计算,见图 2。

首先对一组输出进行采样,对于每一个输入的问题 q , GRPO 基于策略模型的概率分布从当前策略中采样一组动作 $o_1, o_2, \dots, o_G$,然后通过期望得到指标设计奖励函数,对每个采样动作进行评估,得到对应的奖励值 $r_1, r_2, \dots, r_G$ 。最后将每个动作的奖励值进行归一化处理,得到相对优势 $A_1, A_2, \dots, A_G$,可以通过式(6)计算:

$$A_i = \frac{r_i - \mu}{\sigma} \quad (6)$$

式中: A_i 为每个响应的优势值; μ 为组内奖励的均值; σ 为组内奖励的标准差。然后通过最大化目标函数更新策略模型,以增加具有正相对优势动作的概率,同时减少具有负相对优势动作的概率,从而使策略在环境中得到期望回报最大化。在一轮训练结束后,继续进行迭代训练,逐步优化策略模型。为防止策略更新剧烈导致失真,GRPO 还引入了 KL 散度约束这一概念,通过限制新旧策略之间的 KL 散度,确保策略分布的变化在可控范围内。

GRPO 不依赖独立的价值函数模型,而是用组内相对质量比较来替代绝对奖励评估,用多个输出的平均奖励作为基准,简化了训练过程、减少了内存消耗和计算开销,提高了效率,消耗的计算时间和计算开销大大减小,实现了高效低能耗运行。

4) 多词元预测模型(multi-token prediction, MTP)

MTP 的核心在于将传统的单词元预测扩展为多词元预测,采用多输出头并行预测,再由主输出头预测并输出最有可能的结果。其原理如下所述。

模型输入词元序列 $\{x_1, x_2, \dots, x_{t-1}\}$,主模型经过 Transformer 层处理后,处理结果分为两个去向:一边通过共享的线性输出头,映射到词汇表空间得到预测词元 $\{x_2, x_3, \dots, x_t\}$,并使用损失函数得到预测词元分布概率 P_{main} ;另一边输入到下一个 MTP




图 2 GRPO 算法框架

Fig.2 Framework of the group relative policy optimization (GRPO) algorithm

词元预测位置,继续经过 Transformer 层处理,处理结果 $\{x_3, x_4, \dots, x_{t+1}\}$ 仍然一边通过损失函数处理得到 P_{MTP1} , 另一边投入下一预测位置,以此类推得到 $P_{\text{MTP2}}, P_{\text{MTP3}}$ 等。定义损失函数 L 用于量化模型预测值与真实值之间的差异,损失函数值越小模型预测结果越接近真实数据, L 由以下函数计算,其中每个预测位置的词元概率分布用 k 个位置的 CrossEntropy(交叉熵损失)之和来判断:

$$L = \sum_{i=0}^{k-1} \text{CrossEntropy}(x^{t+i}, \text{Logits}^i(x_{t:t-1})) \quad (7)$$

式中: i 为预测的第 i 个相对位置, $i \in \{0, 1, \dots, k-1\}$; $x_{t:t-1}$ 表示从第 i 个位置一直到第 $t-1$ 个位置的词元; t 为当前时间步; $\text{Logits}^i(x_{t:t-1})$ 为模型为第 i 个预测位置生成的未经任何概率归一化处理(如 softmax 等)的数值输出,即未归一化的得分。每个位置的交叉熵独立计算,最终预测值与真实值的误差为所有位置的损失函数之和。通过比较计算误差,最后 MTP 模型输出词汇表空间最高概率的后 k 个词元序列,得到 $\{x_t, x_{t+1}, \dots, x_{t+k-1}\}$ 。

传统自回归模型逐词生成文本,每次仅预测下一个词元,而 MTP 引入主模型与多个 MTP 顺序模块,且每个模块包含共享的嵌入层、Transformer 块和投影矩阵^[17]。主模型负责基础的下一个词元的预测,MTP 模块则并行预测未来多个词元,为每个预测位置分配独立的线性层进行分类并计算每个位置的词元概率分布。模块之间的协同工作为模型提供更丰富的监督信号,能快速掌握语言的结构规律。

5) 知识蒸馏

知识蒸馏为一种可以将复杂网络的特征学习能力迁移到便携式轻量级网络中的技术,可以实现网络模型的压缩。这种将复杂模型知识转移到简单

模型的技术有两个模型概念。教师模型指复杂且性能好的模型; 学生模型指结构简单计算效率高的模型。知识蒸馏过程就是通过训练, 让学生模型模仿教师模型的输出, 从而继承其知识^[18]。

教师模型通常在大规模数据集上训练, 对输入 x , 通过教师模型训练得到未归一化的数据集 z^{teacher} , 对训练数据通过蒸馏温度缩放生成包含类别间关系的概率分布(软标签), 如式(8)所示:

$$p_i^{\text{teacher}} = \frac{\exp(z_i^{\text{teacher}} / T)}{\sum_{j=1}^C \exp(z_j^{\text{teacher}} / T)} \quad (8)$$

式中: p_i^{teacher} 为蒸馏温度参数 T 对 softmax 函数进行缩放后得到的概率分布; j 为类别的索引; C 为类别的总数。softmax 函数具有放大差异功能, 蒸馏温度缩放本质上是在 softmax 函数中引入蒸馏温度参数 T , 用于控制 softmax 概率分布结果的平滑度, 相比不引入 T (硬标签)对误差的容忍度更高。当 $T \rightarrow 0$ 时软标签退化为硬标签; 当 $T=1$ 时相当于没有蒸馏温度; 当 $T>1$ 时概率分布更平滑。

然后将同一原始数据输入学生模型, 得到学生模型训练的未归一化的输出 z^{student} , 同样应用蒸馏温度参数 T 对 softmax 函数进行缩放, 得到 p_i^{student} 。一款好的学生模型既要在蒸馏温度为 T 时与教师模型的结果相接近, 也要保证不使用蒸馏温度时的结果与真实结果相接近。

知识蒸馏通过模仿学习将大模型压缩为小模型, 不仅便于部署, 并且加速了推理速度、提升了模型性能。在数字化电力装备状态检测领域中, 通过知识蒸馏可以在资源有限的设备上部署高效模型, 在电力边缘设备上运行轻量级模型, 有巨大应用潜力。

1.2 模型优势

基于大规模的预训练基础, 类 DS 模型进一步通过创新架构设计和高效训练策略来提升推理性能, 在推理能力、成本效益、中文处理能力以及开源策略等方面表现突出, 展现了更强大的语言理解和生成能力。因此相比于其他大数据模型, 其有以下几种优势。

1) 运算效率提升。类 DS 模型在 MoE 架构中创新性地引入了无辅助损失的负载均衡策略, 同时引入共享专家和路由专家概念^[19], 通过为每个专家引入偏差项, 动态调整路由决策, 有效解决了传统 MoE 架构中因负载不均导致的性能下降问题, 减少

了不必要的计算, 同时支持分布式计算环境下的并行处理, 大大提高了运算的效率。在数字化电力装备状态检测中, 该模型可以提高传感器数据处理速度, 从而提高故障处理的响应速度, 降低故障处理延迟带来的风险。且分布式计算可对电力系统中各种边缘化设备进行统筹规划, 提高工作效率。

2) 占用缓存减少。类 DS 模型通过动态选择 FP8 或 FP32(32 位浮点数)精度进行计算, 构建了混合精度训练框架, 提高了训练速度, 降低了内存占用。同时专家稀疏激活机制保证了模型的计算复杂度随模型规模的扩展而次线性增加, 让硬件芯片计算开销显著降低。在数字化电力装备状态检测中, 计算开销的减小能更好地在边缘设备部署模型进行智能状态监测, 从而提高 AI 设备普及率。传统 Transformer 架构中键值缓存的瓶颈问题被 MLA 机制通过低秩联合压缩解决, 大幅减少了键值缓存的存储需求, 能让数字化电力装备在保持高性能检测的同时降低显存的占用, 进一步降低了对硬件处理器设备的显存要求。

3) 推理能力优越。GRPO 强化学习算法取消了近端策略优化(proximal policy optimization, PPO)算法中需要训练的价值模型, 通过对比不同策略组的得分动态调整模型输出, 不仅显著减少了内存和计算开销^[20]。同时 MTP 技术并行预测提高了模型在大多数评估基准上的性能, 可以整合电力检测设备历史数据、实时信号、环境因素等进行全方位推理, 提前发现潜在故障风险, 让数字化电力装备检测更加精确。模型通过持续推理新的输入数据, 自动更新知识库来进行自我迭代学习, 减少了人工成本在数字化电力装备检测中的投入。这种低精度计算技术显著降低了训练成本, 同时保持了模型性能^[21]。

4) 开源模型共享。开源的模型架构和权重让开发者可以自由查看、修改和优化, 这样的模式吸引了大量技术贡献者, 加速了 AI 技术在数字化电力装备检测领域的迭代。同时开源意味着电气工程师可基于模型构建各类电力装备检测工具, 根据不同的电力业务调整模型来开发电力系统专用模型版本, 推动了 AI 技术专业化。类 DS 模型的开源模式在透明度、成本、生态和创新方面均优于闭源模型, 闭源模型通常只提供固定的功能, 而开源模型可与 Stable Diffusion、Whisper 等模型结合, 实现电力装备检测数据多模态处理, 完成文本-图像-语音交互。

5) 中文优化与国产化。类 DS 模型在深度语义

优化、专业领域适配、长文本逻辑方面优于国际开源模型,更适合中国电力市场低成本部署本地化,并且能更好地理解中文电气专业术语规范,深度理解电力装备检测报告、调度日志等数据,减少由于中文语境表述带来的误判,增强逻辑推理优化。通过与国产芯片及操作系统配合设计,可以满足电力行业对数据不出内网、自主可控的要求。国产化模型架构、国际制裁抗性强等特点使得它成为电力行业在 AI 应用中的优先选择,更适合中国电力系统的定制化使用。

2 类 DS 范式在电力装备故障诊断基础理论中的应用模式

2.1 电力装备故障参量产生理理挖掘模型

开展电力装备故障机理研究具有重要意义,是保障电力系统安全稳定运行和智能运维技术发展的核心。随着新能源及电力电子化设备比例提升,设备运行环境日趋复杂,设备运行涉及多物理场(如电、热、机械等)耦合,设备故障模式多样且难以预测。深入解析故障机理不仅可提升设备状态分析与诊断精度,还为新型电力系统的寿命预测和风险评估提供了理论依据。当前,传统基于物理模型和专家经验的方法难以全面刻画复杂环境下的新型设备故障,庞大异构、新型监测数据的涌现要求对多物理场耦合等方向更深刻的理解。人工智能有潜力进一步推进电力装备故障研究,但还面临诸多困难。首先,真实故障样本稀缺,且多源数据融合、标准化难度高,影响模型训练和泛化能力。其次,深度学习等“黑箱”模型缺乏物理可解释性,难以满足电力系统对可靠性和透明性的要求。最后,电气、材料、热等多学科知识尚难以跨领域有效融合,制

约了复杂工况下的机理建模。

类 DS 模型由于其 128K+窗口、位置编码、KV Cache 和滑窗 Attention 等技术突破,在长上下文理解能力上有显著优势,在通过 RAG 知识库和 LoRA 微调后,相较于其他大模型,更加适合进行电力装备故障机理研究这种数据文本量大、上下文理解记忆能力要求高的任务。

如图 3 所示,以 GIS 故障挖掘为例,首先需要对 GIS 故障知识库进行针对性构建,汇聚 GIS 典型故障案例:用类 DS 模型提取 GIS 的运行场景和运行参数等结构化信息,并将运行参数进行归一化、时域对齐、降噪滤波等处理。同时用类 DS 模型处理非结构性信息,将技术手册、故障报告、运维记录提取为“故障现象-原因-解决方案”的结构性问题,并按照设备类型和故障类别将文本分块,块大小 300 词、重叠 50 词,确保上下文完整^[22]。提取数据时使用向量嵌入模型将这些稀疏的信息生成低维稠密向量,如将气体压力 P 、分解产物浓度 C_{SF_6} 、局放脉冲幅值 V_{PD} 、振动信号 A 等时域信号进行滑动窗口分割后,提取出均值、方差、峰值等信号特征,再使用 sentence-transformers 转换为类 DS 模型可以理解的向量^[23]:

$$S = \text{DeepSeekENC}(P, C_{SF_6}, V_{PD}, A) \quad (9)$$

式中: $\text{DeepSeekENC}(\cdot)$ 为专门针对类 DS 所训练的文本嵌入过程,通过该过程,连续的时域信号将被处理为低维稠密信号,组成电力装备故障知识库。

其次,采用 LoRA 进行高效微调。LoRA 不直接微调大模型的庞大原始权重矩阵 W_{LLM} ,而是通过分析原始权重矩阵 W_{LLM} 的稀疏性、梯度重要性或影响力,识别分析电气参数驱动下的 GIS 故障或正常样本贡献最大的行或者列,分离出 GIS 状态子




图 3 类 DS 模型故障机理挖掘模型框架

Fig.3 Framework of DS-like models failure mechanism mining model

矩阵 $\mathbf{S}_{\text{mat}}$ 进行调整, 低耗高效地让模型快速理解新型号、新工况下 GIS 状态的本质物理逻辑。训练时可以将 float32 形式的数据转换为 FP8 形式的数据, 使之更加适用于类 DS 模型训练:

$$\mathbf{S}_{\text{mat}}^{\text{FP8}} = \text{Quantize}_{\text{FP8}}(\mathbf{S}_{\text{mat}}^{\text{Float32}}) \quad (10)$$

式中: $\text{Quantize}_{\text{FP8}}$ 是将 Float32 数据转为 FP8 数据的过程。LoRA 训练过程如下:

$$\mathbf{S}'_{\text{mat}} = \mathbf{S}_{\text{mat}} + s \cdot \mathbf{L}_{\text{S1}} \mathbf{L}_{\text{S2}} \quad (11)$$

式中: $\mathbf{S}'_{\text{mat}}$ 为类 DS 模型经过训练后的 GIS 状态子矩阵; s 为缩放因子, 用于控制学习率, 在 GIS 故障参量产生机理这个复杂的场景下应当选择 4~8 之间的数值来增加训练后模型的适应性。 $\mathbf{S}_{\text{mat}}$ 的原始权重依然是高维且过度参数化的, 需要针对 GIS 故障产生机理进行参数训练, 并通过低秩分解, 将 $\mathbf{S}_{\text{mat}}$ 的 $h \times o$ 的矩阵规模分解为 $h \times r$ 和 $r \times o$ 规模的小矩阵 $\mathbf{L}_{\text{S1}}$ 和 $\mathbf{L}_{\text{S2}}$, 并以实际故障标注进行微调训练, 令模型聚焦在 GIS 故障机理上, 迅速提升其 GIS 故障机理的推理能力。最后, 使用信息增强生成进行电气设备故障机理的研究, 并进行评估反馈。增强生成过程中, 用户输入 GIS 参量和故障描述, 由模型输出故障机理。

输出得到机理后可遵循 BLEU 规则, 对比标准答案, 由模型自动进行评估。BLEU 规则是通过测量生成输出与标准答案之间的 n -gram 重叠精确度 P_n 来评估生成文本的质量, 生成综合准确率 B_L , 其中 n -gram 是由连续的 n 个单词组成的序列。然后, 使用几何平均值组合得分, 并乘以指数化简洁惩罚因子 f_{BP} , 用以考虑过于简短的翻译。因此, 可得到以下概念表达式:

$$f_{\text{BP}} = \begin{cases} 1, & c > r \\ e^{\frac{1-r}{c}}, & c < r \end{cases} \quad (12)$$

$$B_L = f_{\text{BP}} \cdot \exp\left(\frac{1}{4} \sum_{n=1}^4 \ln P_n(P, C_{\text{SF}_6}, V_{\text{PD}}, A)\right)$$

式中: c 为生成文本长度; r 为参考答案的长度。在过程中, 可通过专家评审介入来帮助模型更正确理解故障机理。

2.2 电力装备多状态参量耦合机制理解模型

电力装备多物理参量联合诊断是当前电网智能运维的重要发展方向。与单一参数监测相比, 联合诊断通过整合设备运行过程中的温度、振动、油中溶解气体等多类型数据, 能够更加全面和准确地

揭示设备健康状况, 大大提升故障诊断的可靠性。此外, 结合数字孪生等前沿技术, 可以基于多物理场参量构建设备运行的动态模型, 实现设备状态的实时评估和预测性维护, 降低突发故障的风险, 提高电网运行的安全性与经济性。在当前设备类型多元化、负载水平波动加剧的背景下, 联合诊断有助于适应复杂工况, 实现更加主动和智能的决策支持。当前技术已实现多参量在线监测, 但关键参量仍依赖间接分析。数据融合模型虽逐步成熟, 但参量相关性分析与多物理场耦合建模仍是难点。

类 DS 模型创新性使用 MoE 结构与多头注意力机制, 能够高效挖掘电力装备多参量间的耦合关联。以局部放电的声光电热等参量为例, 如图 4 所示, 首先, 对多参量特征进行统一处理: 对低采样率信号进行插值重采样, 对高采样率信号滑动窗口降采样统一采样率; 针对非平稳信号, 通过动态时间规整对齐物理事件; 使用最小-最大归一化法和 Z 分数归一化法将数据归一化到相同的范围。其次, 提取多参量物理特征: 通过降噪和时频域分析提取声学信号的频谱特征 A_t ; 利用小波包分解获取光学信号的频域非平稳分布特征 O_t ; 通过短时傅里叶变换提取电信号谐波特性 E_t ; 通过 LSTM(long short-term memory)提取磁信号的时间序列特征 B_t ; 通过前馈神经网络提取红外热数据的局部温升区域特征 T_t 。将处理后的特征输入类 DS 模型记作:

$$\mathbf{x}_t = [A_t, O_t, E_t, B_t, T_t] \quad (13)$$

式中: $\mathbf{x}_t$ 为第 t 时刻的综合输入特征, 结合物理特性优化路由权重分配, 使得每一个专家模块致力于学习不同物理模态及其耦合特性。根据物理特性, 首先为各个专家赋予经验路由权重初值: 声学专家路由权重初值 W_A 、光学专家路由权重初值 W_O 、电信号专家路由权重初值 W_E 、磁性号专家路由权重初值 W_B 、温度专家路由权重初值 W_T , 使其对于自己所擅长的物理量更加关注, 训练过程中通过反向传播, 使用梯度下降法动态调整各专家路由权重 W_i , 使得总体损失函数 L_{total} 最小。计算式为:

$$W_i^{(k+1)} = W_i^{(k)} - \eta \frac{\partial L_{\text{total}}}{\partial W_i} \quad (14)$$

式中: η 为学习率; $W_i^{(k)}$ 为第 k 轮迭代时的权重参数。通过数据驱动的自适应优化过程, 每个专家的路由权重逐步强化对其专长物理模态的关注, 进而实现依据输入内容和训练反馈, 动态更新权重分配, 使

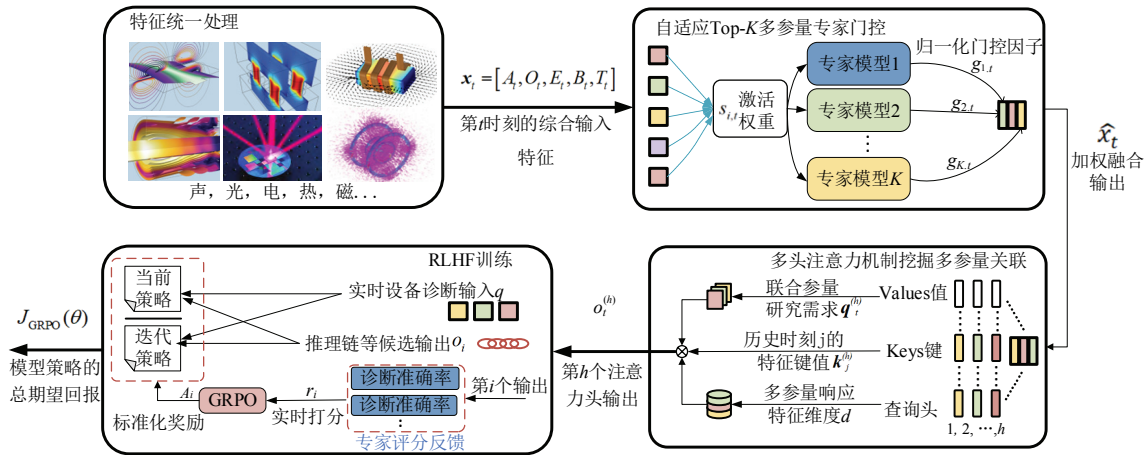


图4 类DS模型多参量耦合机制理解模型框架

Fig.4 Framework of DS-like models multi-parameter coupling mechanism

专家模块逐步专精于其物理特性相关的耦合区域。

模型采用门控机制确定在每一时刻最相关的 K 个专家参与推理, 获得激活权重:

$$S_{i,t} = \sigma(\mathbf{x}_t^T \mathbf{e}_i) \quad (15)$$

式中: $S_{i,t}$ 为第 i 个专家在时刻 t 的激活权重; σ 为 Sigmoid 函数; $\mathbf{e}_i$ 为该专家从局部放电与声信号的强耦合区域中学习获得的参数向量。专家选择与归一化后, 最终输出为:

$$\hat{\mathbf{x}}_t = \mathbf{x}_t + \sum_{i=1}^N g_{i,t} \cdot \text{FFN}_i(\mathbf{x}_t) \quad (16)$$

式中: $\hat{\mathbf{x}}_t$ 为多专家加权后的融合输出; $g_{i,t}$ 为归一化门控因子; $\text{FFN}_i(\cdot)$ 为第 i 个专家针对输入模态特征的前馈神经网络映射, 该结构使得模型能够针对放电信号声光电热等各个感知参量自适应选取最合适的信息分解路径。同时, 多头注意力机制有助于深入挖掘感知参量间的本质耦合, 其主要输出表达为:

$$o_t^{(h)} = \sum_{j=1}^t \text{Softmax}_j \left(\frac{(\mathbf{q}_t^{(h)})^T \mathbf{k}_j^{(h)}}{\sqrt{d}} \right) \cdot \mathbf{v}_j^{(h)} \quad (17)$$

式中: $o_t^{(h)}$ 为第 h 个注意力头的输出; $\mathbf{q}_t^{(h)}$ 为当前时刻联合各参量的研究需求; $\mathbf{k}_j^{(h)}$ 为历史时刻 j 包含多参量信号的特征键值; $\mathbf{v}_j^{(h)}$ 为相应的特征值; d 为特征维度。这意味着, 模型能够融合历史振动、红外、特高频等不同传感器的响应, 关注于局部放电各参量的协同时序演变。在训练方面, 引入人类反馈的强化学习(RLHF)方法, 并采用分组相对策略优化(如 GRPO), θ 为当前策略模型的可学习参数,

通过优化目标函数更新, 目标函数表示为:

$$J_{\text{GRPO}}(\theta) = E_{q, \{o_i\}} \frac{1}{G} \sum_{i=1}^G (\min(\frac{\pi_{\theta}(o_i | q)}{\pi_{\theta_{\text{old}}}(o_i | q)}, 1 \pm \epsilon) A_i - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}})) \quad (18)$$

式中: $J_{\text{GRPO}}(\theta)$ 为模型策略的总期望回报; E 为期望值; D_{KL} 为 KL 散度; q 为实时设备诊断输入, 如一组声光电脉冲信号; o_i 为推理链等候选输出; π_{θ} 为当前策略; $\pi_{\theta_{\text{old}}}$ 为上一次迭代策略; ϵ 为偏差参数; β 为 KL 散度正则系数; A_i 为标准化奖励; π_{ref} 为参考策略; G 为候选样本数。奖励项 A_i 表示为:

$$A_i = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\})} \quad (19)$$

$$r_i = \omega_1 \cdot A_{\text{cc}}(o_i) + \omega_2 \cdot \exp(-\lambda T_{\text{resp}}) \quad (20)$$

式中: r_i 为电气专家对第 i 个输出的实时打分, 包括对诊断准确率、响应速度等指标的量化; $\omega_1 \cdot A_{\text{cc}}(o_i)$ 为准确率奖励; $A_{\text{cc}}(o_i)$ 为加权准确率评估函数, 基于故障分类混淆矩阵, 通过专家标注验证集计算候选输出 o_i 的加权准确率; $\omega_2 \cdot \exp(-\lambda T_{\text{resp}})$ 为时效性奖励, 采用指数衰减形式, 当响应时间 T_{resp} 超过设备安全阈值时产生负向惩罚, λ 由 LSTM 建模设备状态退化曲线自适应调整。 ω_1 、 ω_2 由任务需求确定, 在多状态参量耦合机制理解的任务中, 取较大的 ω_1 来确保结果准确性。实际应用中, 模型输出 “<think>推理过程</think><answer>多物理参量耦合关系” 结构化报告, 并通过专家权重追踪与失效知识库的动态更新不断进化, 逐步优化设备多物理参量耦合关系识别能力。

3 类 DS 模型在电力装备故障诊断中的应用模式

3.1 多模态联合诊断技术

近年来,随着电力装备智能化水平的提升,多模态联合诊断方法逐渐成为提升设备故障检测和健康评估准确性的关键途径。现有研究聚焦于融合声学、振动、温度、电流、红外及局部放电等多源监测数据,结合自适应经验模态分解、孤立森林、深度神经网络等智能算法,实现对异常状态的高效特征提取及可靠识别。多参量融合能够克服单一传感手段的信息盲区,有效应对复杂工况下的误诊和漏检问题。然而,当前方法在数据表征细粒度、特征协同建模、多源信息置信度统一等方面仍面临挑战,以变压器内部高分辨率温度和电流信号、局部放电等多模态数据为例,其异构特征高效联合尚有较大提升空间。

类 DS 模型的 MoE 多专家稀疏激活、细粒度视觉空间建模与动态置信证据融合机制,赋予智能电力装备多模态联合诊断高可移植性、强解释性与实时可信的工程价值^[24]。以智能变压器为例,基于类 DS 模型先进多模态视觉-语言混合专家架构提出一种面向电力装备的高可信多模态故障诊断融合方法。如图 5 所示,首先从设备采集多源数据,包括重点监测套管接头、绕组热点、油箱表面温度场等红外数据 x_{IR} 、悬浮放电、沿面放电的局部放电光谱数据 x_{PD} 、 H_2 、 C_2H_2 、 CH_4 等变压器故障特征气体的油色谱分析参数 x_{DGA} 和变压器历史缺陷记录、油位变化描述等巡检文本 x_{TEXT} 。各项信息经由相对应的预置视觉 Transformer 或文本专家网络 f 分别嵌入为:

$$\begin{cases} z_{IR} = f_{IR}(x_{IR}) \\ z_{PD} = f_{PD}(x_{PD}) \\ z_{DGA} = f_{DGA}(x_{DGA}) \\ z_{TEXT} = f_{TEXT}(x_{TEXT}) \end{cases} \quad (21)$$

式中: f 为预置视觉 Transformer 或文本专家网络的处理过程; z 为处理后的大模型可以理解的词元。在红外及表计影像这类高分辨率数据处理上,类 DS 模型引入动态切片策略,将全图划分为若干 Tile 局部块,通过拼接形成含细粒度空间表征的整体视觉特征,确保绕组热点、局部放电、油液温升等故障征兆不会遗漏。

$$z_{Tile}^{(ij)} = f_{Vision}(Tile_{ij}) \quad (22)$$

式中: $Tile_{ij}$ 为第 i 行第 j 列的局部块; f_{Vision} 为一个共享的视觉编码器(如 SigLIP-SO400M-384 视觉 Transformer),用于对每个 Tile 提取视觉特征; $z_{Tile}^{(ij)}$ 为第 i 行、第 j 列的 Tile 经过视觉编码器后输出的高维特征向量(或特征图),通常包含该 Tile 的语义、纹理、物体等信息。在数据的融合环节,类 DS 模型依据当前场景下各模态特征的重要性,借助 Mixture-of-Experts 机制,仅激活最相关的特征分支,并自适应给出权重 W 进行融合:

$$[\alpha_{IR}, \alpha_{PD}, \alpha_{DGA}, \alpha_{TEXT}] = \text{softmax}(W[z_{IR}; z_{PD}; z_{DGA}; z_{TEXT}] + b) \quad (23)$$

最终综合为:

$$z^* = \sum_i \alpha_i z_i \quad (24)$$

式中: α_i 为明确反映了在特定任务下红外、局放、油色谱、文本等模态对最终诊断推理的贡献度。多模态推理结果通过结构化三元组 (h, r, t, m, Bel) 输




图 5 类 DS 模型多模态联合诊断模型框架

Fig.5 Framework of DS-like models multimodal joint diagnostic model

出, h 为设备, 如绕组、绝缘等; r 为故障关系, 如局部过热导致绝缘老化; t 为异常现象, 如局部过热或局部放电; m 为具体数据模态, 如红外图像或局放谱图; B_{el} 为深度门控与证据理论融合后的置信度。证据置信值通过 Dempster-Shafer 规则归一化^[25]:

$$\begin{cases} (m_1 \oplus m_2)(A) = \frac{1}{K} \sum_{B \cap C = A} m_1(B)m_2(C) \\ K = \sum_{B \cap C \neq \emptyset} m_1(B)m_2(C) \end{cases} \quad (25)$$

式中: $m_i(A)$ 为第 i 模态针对异常 A 的置信赋值; $m_i(B)$ 、 $m_i(C)$ 为模态 B 、 C 诊断产生的可能故障; $i=1, 2$ 。当模态 B 、 C 共同证实异常 A 时, $m_i(B)$ 、 $m_i(C)$ 的置信度累加到 $m_i(A)$ 上。类 DS 模型的推理输出不仅能够按顺序溯源每一项结论涉及的图像 Tile、信号段或文本句, 并且证据链的透明可查, 极大地满足了现代电力装备工程对可解释性与高可信度智能诊断的需求。通过联合端到端训练, 关键参数可根据真实工况自适应迁移优化, 保证在复杂场景下微小异常亦能被充分感知融合。

3.2 故障诊断大模型的轻量化部署技术

在电力装备故障现场诊断场景中, 如何高效、快速地识别并溯源设备异常, 是保障供电可靠性与支持电网智能运维的核心技术难题。大规模预训练诊断模型能够集成各类现场采集的电气参数、故障日志及历史工单案例, 实现对设备多状态、多尺度故障模式的智能感知。类 DS 模型将电力场景中的变压器、开关柜、配电室等主要设备的实时电压 U 、电流 I 、温度 T_{em} 、工作状态 S_{ym} 、负载水平 L_{oad} 等各类关键参数与历史现场诊断文本及专家知识库有机融合, 并结合 RAG 和 LoRA 机制, 支撑复杂工况诊断关联分析与故障因果推理解释。

然而由于电力边缘部署场景下计算资源受限, 难以直接部署超大模型, 所以在有限硬件资源下平衡计算精度、延迟与能耗是实现现场诊断的关键。从算力角度分析, 电力行业设备边缘端一般采用的硬件算力上限低, 需要在有限的算力范围内部署故障诊断大模型。因此, 需要在电力装备上通过减少实现大模型的算力需求来实现轻量化部署, 主要涉及知识蒸馏这一关键技术。

知识蒸馏首先让大模型在全量设备工况和丰富故障实例上开展专家级推理, 该大规模参数专家称为教师模型。参数量指模型中所有需要学习的权重和偏置的总数量。这些存储在计算机的内存或显

卡的显存中的参数决定了模型如何从输入数据计算输出, 因此参数量直接决定了一个模型的硬件需求和计算能力, 一般来说参数越大代表对复杂问题的处理能力越强, 对算力和硬件的要求也越高。以 DeepSeek-R1 为例, 性能最强版本参数量 6 710 亿, 运行需要 1 000 GB 以上的运存, 电力装备芯片往往不足以支撑如此大参数的计算, 需要使用知识蒸馏技术进行模型压缩。

知识蒸馏技术将教师模型的故障判别能力迁移给边缘可部署的小模型, 该小模型称为学生模型, 如 DeepSeek-R1-Distill-Qwen-1.5 B, 仅需 1.5 B 参数量与最低 3.9 GB 显存即可运行, 并且仍然保留推理性能。知识蒸馏后的模型计算量降低, 实现了模型的轻量化, 对算力和硬件的要求降低, 适合部署在资源受限的电力装备上。

知识蒸馏的本质是通过降低数值精度减少计算量和内存占用, 同时尽量保持模型性能, 以实现边缘设备在算力受限、时效性强、响应链路短的情景下, 同样具备智能诊断推理与多场景通用预警能力。

具体而言, 对于电力装备故障现场采集的输入特征数据 $\mathbf{x}_i = [U, I, T_{em}, S_{ym}, L_{oad}, \dots]$; 其中 U 为主要设备的实时电压; I 为进线开关、负载支路等关键节点的三相电流; T_{em} 为变压器绕组、接线端子、输电母排等部位的在线温度监测; S_{ym} 为断路器、隔离开关等设备的运行/分合状态、保护装置动作标志; L_{oad} 为当前有功、无功负载水平。其他如谐波、电能质量、接地电阻、局部放电等参数, 也可扩展用于特殊故障类型识别。

通过对上述多维物理参数和现场工况的语义重组, 预训练的类 DS 大模型输出详细的故障类别、异常特征描述及诊断推理链路, 形成高质量训练数据为小模型蒸馏迁移奠定基础。图 6 所示为提升现场小模型诊断准确性, 知识蒸馏采用多级损失项、系统融合软标签对齐、真实标签监督及特征层联动的策略。在输出层, 对同一现场工况采样 $\mathbf{x}_i$ 数据, 教师大模型和学生小模型分别输出对多个故障类型的预测 Logits(输出层的未归一化分数), 并通过软化系数 τ 调整软标签输出的概率分布平滑程度:

$$\hat{y}_i^t = \text{softmax}\left(\frac{x_i^t}{\tau}\right) \quad (26)$$

$$\hat{y}_i^s = \text{softmax}\left(\frac{x_i^s}{\tau}\right) \quad (27)$$




图6 类 DS 模型轻量化部署模型框架

Fig.6 Lightweight deployment model framework for DS-like models

式中: $\hat{y}_i^t$ 与 $\hat{y}_i^s$ 分别为教师/学生模型对于短路、接地、过载等多类别故障的现场判别概率输出。采用 KL 散度蒸馏大模型丰富判据进行对蒸馏效果细致度进行评估:

$$L_{lgt} = \frac{\tau^2}{N} \sum_{i=1}^N \sum_{j=1}^C \hat{y}_{ij}^t \ln \frac{\hat{y}_{ij}^t}{\hat{y}_{ij}^s} \quad (28)$$

式中: N 为采样工况/时刻数; C 为所有现场诊断故障类型; τ 为软化系数, 用于调整软标签输出。为确保关键故障类型检测精度, 同时引入标准交叉熵损失(L_{ts}), 以人工巡检标注或高置信度报警数据作为真实标签 $y_{ij}^{[26]}$:

$$L_{ts} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{ij} \ln \hat{y}_{ij}^s \quad (29)$$

式中: y_{ij} 为真实标签; $\hat{y}_{ij}^s$ 为学生模型的判别概率输出。考虑到设备故障链路往往跨越多个部件、参数之间的耦合关系复杂, 蒸馏还在模型中间层引入特征对齐约束。假设教师模型第 l_t 层和学生模型第 l_s 层嵌入电力装备多状态参量, 如同时刻某站多设备 $[U, I, T_{em}, S_{ym}, L_{oad}, \dots]$ 分布, 其特征一致性损失定义^[27]为:

$$L_{fa} = \frac{1}{N} \sum_{i=1}^N \sum_{(l_s, l_t) \in S_{ts}} \beta_{l_s, l_t} \|U_{l_s}^s h_{i, l_s}^s - U_{l_t}^t h_{i, l_t}^t\|_2^2 \quad (30)$$

式中: $U_{l_s}^s$ 、 h_{i, l_s}^s 、 $U_{l_t}^t$ 、 h_{i, l_t}^t 为线性投影矩阵; β_{l_s, l_t} 为设备部件或数据通道在实际诊断流程中的相对重要度; 最右侧的 2 为 L_2 范式的平方; S_{ts} 是教师层索引 l_t 与学生层索引 l_s 的对应集合。

为模拟现场巡检专家关注高风险部件或参数的诊断习惯, 还可对关键层的注意力权重分布施加 Frobenius 范数约束:

$$L_{at} = \frac{1}{N} \sum_{i=1}^N \sum_{(l_s, l_t) \in S_{ts}} \gamma_{l_s, l_t} \|A_{l_s, l_t}^s - A_{l_s, l_t}^t\|_F^2 \quad (31)$$

式中: A_{l_s, l_t}^s 、 A_{l_s, l_t}^t 为学生/教师模型在输入 x_i 下对不同设备部件、监测通道的注意力分配; γ_{l_s, l_t} 为可调权重; F 为 Frobenius 范数。

综上, 通过将软标签判别、人工标签监督、中间特征对齐与重点通道关注因素加权融合, 整体蒸馏损失函数^[28]为:

$$L_{total} = \alpha L_{lgt} + (1 - \alpha) L_{ts} + \lambda_1 L_{fa} + \lambda_2 L_{at} \quad (32)$$

式中: 超参数 α 为用于平衡 KL 散度损失和标准交叉熵损失的参数, 其值通常为 0~1。训练初期增大 α 可以使学生模型更多地模仿教师模型的输出分布, 从而继承教师模型的丰富知识, 这对于复杂故障诊断任务尤其有益。训练后期减小 α 则可以增强真实标签的监督作用, 确保学生模型在关键故障类型上的预测准确性。

λ_1 和 λ_2 分别用于控制特征对齐损失和注意力权重约束损失的影响, 针对不同设备的运行特点进行调整。增大 λ_1 可以加强中间特征层的对齐, 帮助学生模型更好地捕捉设备故障特征间的复杂关系。例如, 对于变压器设备, 其内部绝缘故障可能涉及多个状态参量的耦合变化, 故障特征较为复杂, 此时应增大 λ_1 值。 λ_2 的增大则促使学生模型增加对关键部件或参数的注意力权重分布, 例如对于断路器设备, 其触头磨损情况直接关系到其开断性能, 诊断任务更关注关键部件, 此时应增大 λ_2 值。

综上所述, 超参数的调整需根据设备故障的复杂性、数据的质量与数量及诊断任务的具体要求进行综合考虑, 以实现对学生模型学习过程的有效指导, 提升其在实际应用场景中的诊断性能。

考虑到部分现场终端如配电自动化单元、馈线监控器、智能继电保护等计算和存储资源有限, 学生模型微调采用参数高效的 LoRA 机制, 仅需对小维度矩阵训练, 便可在设备侧高效快速部署和后续

升级。对于如特高压线路极端短路情况、大型馈线母线多点温升异常、复杂谐波扰动下的间歇性跳闸等现场罕见或极端场景,结合数据增强和对抗样本生成策略,可以自动扩充电力装备故障工况训练集,进一步提高小模型对未知现场事件的诊断泛化水平。

3.3 大规模多参量传感器性能自校验技术

针对电力装备传感器本体状态监视与矫正的智能应用场景中,结合大模型的强表征和推理能力,可突破传统规则驱动、数据孤立分析等局限,系统实现对传感器工况的全周期监控与自适应校准。

首先,多通道传感器原始时序信号^[29]表示为:

$$X \in \mathbf{R}^{C \times T_{\text{seq}}} \quad (33)$$

式中: C 为输入信号通道数,如变压器分接头温度、电流、电压等; T_{seq} 为采样周期数,按典型运维周期将每通道信号 $X_{s_{\text{lice}}}$ 分割为长度为 l 的不重叠片段 $x_{s_{\text{lice}}}$, 获得:

$$X_{s_{\text{lice}}} = \{x_{s_{\text{lice}}}^i\}_{i=1}^{S_{\text{lice}}}, x_{s_{\text{lice}}} \in \mathbf{R}^l \quad (34)$$

式中: S_{lice} 为总片段数; i 为每一片段所取长度。并对各片段进行归一化:

$$\tilde{x}_{s_{\text{lice}}} = \frac{x_{s_{\text{lice}}} - \mu(x_{s_{\text{lice}}})}{\sigma(x_{s_{\text{lice}}})} \quad (35)$$

式中: μ 为原始数据的均值; σ 为原始数据的标准差。通过归一化来抵消由电力系统频率波动、温度日变化、大负荷切换等引入的统计偏移和背景噪声,确保监测结果真实反映传感器本体特性。

归一化后的每一片段通过时序特征编码网络提取隐含运行规律:

$$\hat{x}_{s_{\text{lice}}} = \text{Chronos}(\tilde{x}_{s_{\text{lice}}}) \in \mathbf{R}^{(l+1) \times d_{\text{ts}}} \quad (36)$$

式中: 编码维度 d_{ts} 反映不同电力装备传感信号特性的复杂性; $l+1$ 结构利于识别如故障分界、换挡跳变、重合闸等关键边界现象。特征进一步经非线性映射,实现特征空间的重组并对齐获得与历史故障标签、设备维保记录、运行工况文本描述等电力运维知识库一致的对齐:

$$\hat{a}_{s_{\text{lice}}} = W_2 \sigma_{s_{\text{lice}}} (W_1 \hat{x}_{s_{\text{lice}}} + b_1) + b_2 \quad (37)$$

式中: W_1 、 W_2 为可学习参数,可结合行业知识进行有监督预训练; b_1 、 b_2 为不同的偏差; $\hat{a}_{s_{\text{lice}}}$ 是与文本对齐后的传感器信号; $\sigma_{s_{\text{lice}}}$ 为选择不同电力干扰下强非线性信号对应的非线性激活函数,从而提升对特定故障的敏感度。

一旦检测到信号异常,类 DS 模型将利用归因

机制区分该异常究竟源自电力装备故障还是传感器本体异常。类 DS 模型将融合同类传感器间信号对比、与工况环境变量的关联规则、离群检测及历史相似事件回溯等信息,分类判别输出每一片段的异常归属概率,有效区分电力装备故障和传感器故障。

针对具体应用场景,模型根据多模态上下文动态优化判据,生成针对性判别策略,最大限度抑制误判、漏判的发生。如特定间隔、环境或运维阶段下的误差分布权重将被自动调整,使模型在潮流扰动频发、极端气象或老旧设备多的场站表现更稳健。

判别完成后,实现针对性异常处理。当判定为传感器本体故障时,系统将立即调用历史运行数据,并利用大模型丰富的泛化能力,综合同类工况正常信号、运维记录和环境特征,为异常片段推理生成自适应矫正方案。校正方式具体为:

$$\tilde{x}_{s_{\text{lice}}} = d_{s_{\text{lice}}} + g_{s_{\text{lice}}} x_{s_{\text{lice}}} + F(x_{s_{\text{lice}}}, f_{s_{\text{lice}}}, \dots) \quad (38)$$

式中: $d_{s_{\text{lice}}}$ 为补偿因子(如温漂校正); $g_{s_{\text{lice}}}$ 为动态增益(如互感器衰减修正); $F(x_{s_{\text{lice}}}, f_{s_{\text{lice}}}, \dots)$ 为插值、冗余融合或物理建模修正函数,均由大模型结合历史数据统计与当前上下文推理自动生成,使得异常数据可回归到可用水平,避免因硬件失效直接造成监控盲点。

相较于传统时序预测模型,类 DS 模型进行大规模多参量传感器自校验性能优化具有单类故障所需样本少、自适应矫正、推理鉴别能力强大的优势,以 GIS 的声光电热磁力的多种传感器矫正场景为例,传感器种类、型号繁多,现有历史数据无法支撑历史预测模型对于每一种传感器建立专属的预测,而类 DS 模型仅需少量样本即可学习到 GIS 传感器故障的关键特征,而无需大量的历史数据。

自适应矫正方面,类 DS 模型能够根据 GIS 设备的实时运行状态和上下文信息,为单一传感器动态生成针对性的矫正方案,使得异常数据能够回归到可用水平,避免因传感器失效直接造成监控盲点,而传统的时序预测模型在矫正过程中往往较为固定,缺乏对声光电磁热等传感器种类和复杂场景的动态适应性。类 DS 模型结合多模态上下文信息,动态优化判据,生成针对性的判别策略,最大限度抑制误判、漏判的发生,显著提升了 GIS 设备运维智能化和感知数据的业务可靠性,而传统时序模型只能分辨数据异常与否,无法分辨是 GIS 发生故障还是传感器在恶劣的电磁、高温、振动的环境下发

生损坏或者漂移。

4 挑战与展望

4.1 未来挑战

类 DS 模型凭借其独特的技术优势, 为数字化电力装备检测提供了新的选择方案与创新动力, 但在实际落地中仍面临多重挑战。

4.1.1 多模态数据处理困难与幻觉问题

电力装备状态检测涉及的设备运行文本信息、摄像头采集气象图像、局部放电传感器音频采集等多模态数据, 分散在发电侧、电网侧与用户侧, 训练模型的多模态数据格式与质量参差不齐、跨模态数据共享机制不完善, 可能导致模型决策偏差, 甚至出现模型生成与事实不符、逻辑断裂或脱离上下文的内容, 出现 AI “幻觉”。因此, 需要针对模态部署处理专家, 提取各模态关键特征信息进行加权融合, 将得到的复合数据投入训练模型。

多模态数据之间的处理转换涉及图像(红外热成像、仪表图像、无人机图像)、文本(电力装备巡检报告、运行日志)、音频(局部放电超声、电晕噪声)、视频(巡检视频、激光扫描视频)等多种形式, 而目前模型对于全面检测和处理电力装备多模态实时数据还存在困难。且将这些电力相关数据投入到数据集中进行训练时, 若模型过度依赖参数化记忆而缺乏动态更新能力, 可能会导致“答非所问”的 AI 幻觉问题, 训练数据中存在错误或片面性问题, 可能会被模型放大而产生严重偏差。

因此, 首先需要构建多模态处理单元, 集成各模态硬件检测单元(如神经网络处理器 NPU 检测光学图像、数字信号处理器 DSP 解析声学波形、现场可编程门阵列 FPGA 监测 SF₆ 气体等), 实现多模态数据全面检测, 对模型进行动态实时更新, 防止出现幻觉问题, 其次需要在模态信息输入端进行数据预处理, 将关键特征信息而非全部的原始数据投入下一训练环节, 不过度依赖参数化记忆, 最后实现多模态信息互补、多物理量耦合、多时空角度关联。构建电力装备数字孪生模型要求大数据模型融合电气、材料、热、力等多学科知识, 面对电力装备工况复杂、多源数据交叉错杂、多模态数据格式混杂等缺陷, 大数据模型训练广度和多模态泛化能力需要进一步研究与探索。

4.1.2 硬件处理设备制约

MoE 架构依赖大规模跨节点专家并行才能发

挥最优的推理吞吐与延迟, 需要配置显存内存超高的一体机, 而一些电力终端设备检测芯片采用低功耗嵌入式芯片, 如电流电压采集检测芯片仅为 KB 级内存, 复杂检测系统为 MB 级别及以上, 而类 DS 模型最小为 GB 级别, 在显存带宽与内存处理上无法满足要求。且在运行大数据模型时, 需要处理的参数量可能会超过电力检测设备的内存上限, 导致芯片无法加载完整模型, 限制了复杂调度场景的实时响应能力。

同时需要考虑电力装备所处的环境对 AI 硬件芯片的干扰, 如高压电网环境中的电磁干扰可能影响 AI 芯片的稳定运行, 需开发抗干扰的硬件适配方案; 高原地区的电力装备直接暴露在低温低气压环境下, 巨大的昼夜温差给 AI 芯片的材料强度带来挑战, 需选择范围广阔阈值大的制造材料等。

4.1.3 行业适配融合困难

电力系统固定的电网拓扑迭代速度低, 与类 DS 范式模型的高速迭代更新存在冲突。虽然理论上可实现电力系统数字孪生建模的推理优化, 但像变压器、输电线路、电缆等物理设备的制造成本高、更新周期慢, 可能造成硬件设备无法匹配数字优化方案的情况, 需要对针对设备实际性能配置进行数字化方案设计, 老旧设备增加轻量化 AI 模组实现低成本智能化, 新建设备考虑未来发展预留数字化方案部署空间, 进行数字化信息跨设备融合。

同时需要考虑类 DS 模型的高质量标注数据要求与电力装备真实故障样本稀缺之间的矛盾, 需要最大化利用真实样本, 构建样本学习局域网, 降低标注依赖, 并对非故障样本进行深度学习与模态转换, 扩大故障检测的可能性范围。

另外, 需要注意电力装备检测的实效性要求与智能芯片架构处理时间之间的兼容问题, 调整模型处理方式与现有电力装备检测系统响应能力相匹配, 调整优先级分配方式或增加过渡处理。

4.2 未来展望

国产大数据模型在电力行业这一国家基础性产业具有重要战略意义, 类 DS 范式模型在电力行业的未来发展方向需要深度融合其核心创新技术, 围绕专业化、轻量化、安全化进行。

4.2.1 推理专业化

未来, 为了提高模型推理能力与电气专业知识的契合度, 需要结合混合专家模型的动态专家任务

分配能力, 设置面向声光热力电等不同领域的专属专家进一步高效并行处理电力装备的多维度数据, 从而实现多物理量、多模态数据的融合分析。同时, 需要考虑如何实现故障状态快速预测与精准响应, 在电力系统实时调度、大规模电力装备检测系统数字孪生建模方面取得进一步的发展。

4.2.2 模型轻量化

GRPO、无辅助损失负载均衡等高效低成本的训练技术大大降低人工智能技术在电力装备上部署的算力开销, 减小了对硬件算力基础的依赖。知识蒸馏技术还可以将复杂电力 AI 模型轻量化部署至边缘设备, 在异常状态快速定位与自恢复策略生成方面有巨大应用潜力。未来, 可以推出适配电力边缘设备的轻量化蒸馏模型, 构建动态电力专业知识库共享机制, 强化大数据模型与物理设备系统的双向校准, 实现去中心化, 提高 AI 普及率。

4.2.3 信息安全化

在电力装备状态检测领域, “黑箱”模型和“AI 幻觉”问题对大数据模型技术落地带来一定挑战, 要满足电力系统对可靠性和安全性的要求, 需定制面向电力检测领域的专业化约束训练与约束机制。在保护模型机密性和数据隐私方面, 类 DS 模型能更好地遵循国家的信息安全政策和标准, 有效应对大规模语言模型在云环境中部署时面临的隐私和安全挑战。未来电力装备状态监测和数据管理可以依托国产大数据模型通过加密数据传输和访问控制等措施, 确保电力数据在采集、传输和分析过程中的安全, 有效保障信息安全, 确保电力系统稳定运行, 降低因外部因素导致的信息泄露风险。

5 结论

本文从类 DS 模型的发展现状、类 DS 范式在电力装备故障诊断中的基础理论与应用模式、未来面临的挑战与展望等方面进行了分析研究, 得到以下主要结论:

1) 类 DS 范式在数字化电力装备状态检测基础理论应用的可行性。类 DS 范式的长上下文理解能力、强推理能力、混合专家模型和多头注意力机制等优势特点能够很好地匹配电力装备状态检测基础理论故障机理复杂、多物理量耦合的场景, 本文认为通过 RAG 知识库技术和 LoRA 技术, 类 DS 范式能够达到专业的电力理论推理水平, 在电力装备状态检测的理论研究方面能够进行可靠、深入的内容

生成, 并拥有及时的反馈升级能力, 为数字电力装备状态检测的理论研究提供了新视角新思路。

2) 类 DS 范式在数字化电力装备状态检测工程技术应用的可行性。类 DS 范式的多专家模式、推理能力蒸馏保存、泛化学习与内容生成能力能够很好地匹配电力装备状态检测多参量传感、边缘部署和大规模传感器自校验要求, 本文认为通过预训练和蒸馏, 类 DS 范式能够在保护现场数据安全性的前提下, 减轻人工智能边缘部署的硬件压力, 提高现场诊断的可靠性, 增加大规模部署传感器的鲁棒性, 为电力装备数字化、智能化转型提供经济可靠的软硬件基础, 赋能数字化电力装备的转型升级。

3) 类 DS 范式投入状态检测应用仍存在挑战。由于目前类 DS 范式对于多模态的处理能力依赖预置的多模态处理模型, 而非原生的多模态接口, 类 DS 的多模态处理能力的经济性和稳定性仍有待提高。虽然类 DS 模型可以通过蒸馏得到小模型部署到低算力计算设备上, 但是其所需的显存内存等硬件, 在过去安装的电力装备上没有广泛部署, 并且可能面对严苛的电磁环境, 仍需探究如何在电力装备上经济、稳定地部署类 DS 模型; 虽然类 DS 模型具有小样本、无样本学习能力, 其性能表现仍与训练的数据质量和更新频率有关, 电力系统较低的迭代更新速度和真实状态检测样本的稀缺制约了类 DS 模型的行业匹配融合, 亟待孪生数字模型等解决方案。

参考文献 References

- [1] 江俊杰, 胡 军, 马国明, 等. 数字化电力装备专用传感应用需求与发展趋势[J]. 高电压技术, 2024, 50(8): 3271-3302.
JIANG Junjie, HU Jun, MA Guoming, et al. Application requirements and development trend of special sensors in digital electrical equipment[J]. High Voltage Engineering, 2024, 50(8): 3271-3302.
- [2] 杨 挺, 耿毅男, 郭经红, 等. 人工智能在新型电力系统智能传感、通信与数据处理领域应用[J]. 高电压技术, 2024, 50(1): 19-29.
YANG Ting, GENG Yinan, GUO Jinghong, et al. Applications of artificial intelligence in sensing, communication, and data processing in the new power system[J]. High Voltage Engineering, 2024, 50(1): 19-29.
- [3] 余 涛, 梁敏航, 罗庆全, 等. 新型电力系统专用传感与边缘智能关键技术及其展望[J]. 高电压技术, 2024, 50(8): 3324-3338.
YU Tao, LIANG Minhang, LUO Qingquan, et al. Key technologies and perspectives of specialized sensing and edge intelligence for new power systems[J]. High Voltage Engineering, 2024, 50(8): 3324-3338.
- [4] 赵俊华, 文福拴, 黄建伟, 等. 基于大语言模型的电力系统通用人工智能展望: 理论与应用[J]. 电力系统自动化, 2024, 48(6): 13-28.
ZHAO Junhua, WEN Fushuan, HUANG Jianwei, et al. Prospect of general artificial intelligence in power systems based on large language models: theory and application[J]. Automation of Electric

- Power Systems, 2024, 48(6): 13-28.
- [5] 陈艳波, 方哲, 张宁, 等. 基于大语言模型绿电预测和绿电交易的园区综合能源系统集群多目标协同运行方法[J]. 高电压技术, 2024, 50(7): 2849-2863.
CHEN Yanbo, FANG Zhe, ZHANG Ning, et al. Multi-objective collaborative operation method for park-level integrated energy system cluster based on large language model for green electricity prediction and trading[J]. High Voltage Engineering, 2024, 50(7): 2849-2863.
- [6] 张孝顺, 李锦诚, 郭正勋. 大模型辅助的大型海上风电场集电系统拓扑优化[J]. 高电压技术, 2024, 50(7): 2894-2905.
ZHANG Xiaoshun, LI Jincheng, GUO Zhengxun. Topology optimization of large-scale offshore wind farm collector systems based on large language models[J]. High Voltage Engineering, 2024, 50(7): 2894-2905.
- [7] 李有亮, 方林波, 杨子, 等. 类 ChatGPT 大语言模型在电力调度中的应用展望[J]. 电力安全技术, 2024, 26(5): 24-27.
LIU Youliang, FANG Linbo, YANG Zi, et al. Prospect on the application of ChatGPT-like big language models in power scheduling[J]. Electric Safety Technology, 2024, 26(5): 24-27.
- [8] 谢宏宇, 吴雪铸, 曾荣甫, 等. 基于大语言模型的电力故障归因分析与增强诊断策略[J]. 科技与创新, 2025(3): 151-153.
XIE Hongyu, WU Xuexiu, ZENG Rongfu, et al. Power fault attribution analysis and enhanced diagnosis strategy based on large language model[J]. Science and Technology & Innovation, 2025(3): 151-153.
- [9] 李莉, 时榕良, 郭旭, 等. 融合大模型与图神经网络的电力设备缺陷诊断[J]. 计算机科学与探索, 2024, 18(10): 2643-2655.
LI Li, SHI Rongliang, GUO Xu, et al. Diagnosis of power system defects by large language models and graph neural networks[J]. Journal of Frontiers of Computer Science and Technology, 2024, 18(10): 2643-2655.
- [10] 曹伟, 张莉, 郭静, 等. 基于大语言模型的低碳电力市场发展应用前景[J]. 智慧电力, 2024, 52(2): 8-16.
CAO Yi, ZHANG Li, GUO Jing, et al. Prospects for development of low-carbon electricity markets based on large language models[J]. Smart Power, 2024, 52(2): 8-16.
- [11] 江秀臣, 臧奕茗, 刘亚东, 等. 电力设备 ChatGPT 类模式与关键技术[J]. 高电压技术, 2023, 49(10): 4033-4045.
JIANG Xiuchen, ZANG Yiming, LIU Yadong, et al. Power equipment ChatGPT-type model and key technologies[J]. High Voltage Engineering, 2023, 49(10): 4033-4045.
- [12] LIU A X, FENG B, XUE B, et al. Deepseek-v3 technical report[J]. arXiv preprint arXiv: 2412.19437, 2024.
- [13] GUO D Y, YANG D J, ZHANG H W, et al. DeepSeek-R1: incentivizing reasoning capability in LLMs via reinforcement learning[J]. arXiv preprint arXiv: 2501.12948, 2025.
- [14] HE M G, LIU Y L, TAO S M, et al. R1-T1: fully incentivizing translation capability in LLMs via reasoning learning[J]. arXiv preprint arXiv: 2502.19735, 2025.
- [15] OLSON M L, RATZLAFF N, HINCK M, et al. Semantic specialization in MoE appears with scale: a study of DeepSeek R1 expert specialization[J]. arXiv preprint arXiv: 2502.10928, 2025.
- [16] SANE S. Hybrid group relative policy optimization: a multi-sample approach to enhancing policy optimization[J]. arXiv preprint arXiv: 2502.01652, 2025.
- [17] GLOECKLE F, IDRISI B Y, ROZIERE B, et al. Better & faster large language models via multi-token prediction[J]. arXiv preprint arXiv: 2404.19737, 2024.
- [18] 李秀芳. 深度知识蒸馏网络感知与学习分类[D]. 西安: 西安电子科技大学, 2024.
LI Xiufang. Deep knowledge distillation networks perception and learning classification[D]. Xi'an, China: Xidian University, 2024.
- [19] WANG L, GAO H Z, ZHAO C G, et al. Auxiliary-loss-free load balancing strategy for mixture-of-experts[J]. arXiv preprint arXiv: 2408.15664, 2024.
- [20] ZHANG Z Y, LUO X F, LIU T, et al. Proximal policy optimization with mixed distributed training[C]//2019 IEEE 31st International Conference on Tools with Artificial Intelligence (ICTAI). Portland, USA: IEEE, 2019: 1452-1456.
- [21] WANG C E, KANTARCIOGLU M. A review of DeepSeek models' key innovative techniques[J]. arXiv preprint arXiv: 2503.11486, 2025.
- [22] NARIMANI A, KLARMANN S. Integration of large language models for real-time troubleshooting in industrial environments based on retrieval-augmented generation (RAG)[C]//7th European Industrial Engineering and Operations Management Conference. Augsburg, Germany: IEOM Society International, 2024: 287-298.
- [23] SARITURK B, BAYRAKTAR R, ERDEM M E. Efficient learning content retrieval with knowledge injection[J]. arXiv preprint arXiv: 2412.00125, 2024.
- [24] WU Z Y, CHEN X K, PAN Z Z, et al. DeepSeek-VL2: mixture-of-experts vision-language models for advanced multimodal understanding[J]. arXiv preprint arXiv: 2412.10302, 2024.
- [25] 张若泉, 冉慧娟, 谢军, 等. 基于动态多模态融合的电力变压器故障诊断方法[J]. 绝缘材料, 2025, 58(5): 107-115.
ZHANG Ruoquan, RAN Huijuan, XIE Jun, et al. A fault diagnosis method based on dynamic multimodal fusion for power transformer[J]. Insulating Materials, 2025, 58(5): 107-115.
- [26] 张瑞佳, 马慧芳, 张映月, 等. 基于可泛化图知识蒸馏的油浸式电力变压器故障检测[J/OL]. 计算机工程, 2025: 1-8[2025-05-15].
<https://doi.org/10.19678/j.issn.1000-3428.0070580>.
ZHANG Ruijia, MA Huifang, ZHANG Yingyue, et al. Generalizable graph knowledge distillation for fault detection in oil-immersed power transformers[J/OL]. Computer Engineering, 2025: 1-8[2025-05-15].
<https://doi.org/10.19678/j.issn.1000-3428.0070580>.
- [27] KUNDU A, LIM F, CHEW A, et al. Efficiently distilling LLMs for edge applications[J]. arXiv preprint arXiv: 2404.01353, 2024.
- [28] MURALIDHARAN S, TURUVEKERE SREENIVAS S, JOSHI R, et al. Compact language models via pruning and knowledge distillation[C]//Proceedings of the 38th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2024: 1299.
- [29] LI Z C, DELDARI S, CHEN L Y, et al. SensorLLM: aligning large language models with motion sensors for human activity recognition[J]. arXiv preprint arXiv: 2410.10624, 2024.



JIANG Xiuchen
Ph.D., Professor



ZANG Yiming
Ph.D.
Corresponding author

江秀臣

1965—, 男, 博士, 教授

主要从事电力设备的数字化智能化状态检测相关研究

E-mail: xcjiang@sjtu.edu.cn

臧奕茗(通信作者)

1996—, 男, 博士, 助理研究员

主要从事电力设备的数字化智能化状态检测相关研究

E-mail: zangyiming@sjtu.edu.cn

收稿日期 2025-05-15 修回日期 2025-07-21 编辑 卫李静