

学校编码：11059
学号：22085400431

密级 公开

合肥大學

硕 士 专 业 学 位 论 文

基于多模态大模型的 电力巡检图像智能识别

**Intelligent Recognition of Power Inspection Images
Based on Multimodal Large Models**

王启其

校内导师姓名：谢成军 研究员
校外导师姓名：刘术娟 工程师
专 业 名 称：计算机技术
学位论文形式：应 用 研 究
论文提交日期：2025 年 03 月
论文答辩时间：2025 年 05 月

2025 年 5 月

摘要

随着电力系统规模的持续扩展，输电、变电等户外设备长期暴露于复杂环境中，绝缘子破损、金具锈蚀等缺陷频发，对电网的安全稳定运行构成严重威胁。传统人工巡检方式受限于环境复杂性与检测效率，难以实现缺陷的实时精准识别。深度学习技术在电力缺陷检测领域取得了一定进展，但普遍面临一个核心挑战：深度学习小模型难以有效融合图像和文字等多模态信息，导致人机交互性弱。

针对上述问题，本文提出了一种基于多模态大模型的电力巡检图像智能识别方法，通过跨模态图文交互的方式实现电力巡检图像智能识别，包括识别不同电力场景和缺陷。然而，多模态大模型在具体应用于电力领域时仍面临参数规模庞大、训练成本高、领域知识不足等关键难题。为此，本文围绕多模态大模型在电力巡检智能识别领域应用中的核心问题，开展了多方面的研究和实践，主要贡献如下：

（1）提出了一种基于多模态大模型微调的电力图像智能识别技术。针对电力场景复杂性高以及现有小模型交互能力有限等问题，构建了一个电力领域多模态大模型，并将其应用于电力图像的智能识别。首先，利用 YOLOv8 自动构建电力缺陷多模态数据集，增强模型在电力领域的图文知识表达能力；然后，融合低秩分解（Low-Rank Adaptation of Large Language Models, LoRA）和 Q-Former 对模型进行参数高效微调，以降低计算开销，提高模型的视觉-语义对齐能力；最后，验证模型在电力场景中的智能识别能力，与主流多模态大模型进行对比。实验结果表明，本文提出的技术在电力巡检智能识别任务上具有更优的准确率。

（2）提出一种基于扩散模型的电力缺陷数据扩展技术。针对电力缺陷数据难以采集、正样本数量少以及电力多模态大模型对数据量要求高等问题，提出一种基于扩散模型的电力缺陷数据扩展方法。将 ControlNet 与 Canny 边缘检测融入到扩散模型中，控制电力设备缺陷的整体结构；在保证生成图像结构合理性的基础上，利用训练好的多模态大模型 Qwen-VL-Max 提取真实电力场景图像的深层次语义特征；并结合 Prompt 工程，生成高质量、符合电力缺陷场景特征的合成图像。实验结果表明，

生成数据可进一步用于构建的电力多模态大模型微调，提升电力巡检任务的识别精度。

本文的研究为多模态大模型在电力领域的智能识别任务提供了案例，不仅可以实现跨模态交互与识别，还可以为其他行业在应用多模态大模型方面提供参考和技术支持。

关键词：多模态大模型；智能识别；LoRA；扩散模型；数据扩展

Abstract

With the continuous expansion of power systems, outdoor equipment such as transmission lines and substations is exposed to complex environments for extended periods. As a result, defects such as insulator damage and hardware corrosion frequently occur, posing serious threats to the secure and stable operation of the grid. Traditional manual inspections are limited by environmental complexity and detection efficiency, making real-time, accurate defect recognition challenging. Although deep learning has achieved some progress in power defect detection, a core challenge remains: small deep learning models struggle to effectively fuse multi-modal information such as images and text, resulting in weak human-computer interactivity.

In response to these issues, this work proposes an intelligent recognition method for power inspection images based on multimodal large models, which leverages cross-modal text-image interaction to recognize various power scenes and defects. However, when applied to the power domain, multimodal large models still face key challenges such as large parameter scales, high training costs, and insufficient domain knowledge. To address these core issues in the application of multimodal large models for intelligent power inspection, this study presents comprehensive research and practice with the following main contributions:

(1) Intelligent recognition of power images via fine-tuning of multimodal large models. To address the complexity of power scenes and the limited interactive capability of existing small models, a multimodal large model for the power domain—Power-VGLM—was constructed and applied to power image recognition. First, a power defect multimodal dataset was automatically constructed using YOLOv8 to enhance the model's capability in expressing visual and textual knowledge in the power domain. Next, Low-Rank Adaptation and Q-Former were integrated to efficiently fine-tune the model parameters, thereby reducing computational overhead and improving visual-semantic alignment. Finally, the model's intelligent recognition performance in power scenes was validated and

compared with mainstream multimodal large models. Experimental results indicate that the proposed approach achieves superior accuracy in power inspection image recognition tasks.

(2) Power defect data augmentation based on diffusion models. Given the challenges of acquiring power defect data, the scarcity of positive samples, and the high data requirements of multimodal large models, a diffusion-model-based power defect data augmentation method is proposed. In this approach, ControlNet and the Canny edge detection algorithm are integrated into the diffusion model to control the overall structure of power equipment defects. While ensuring that generated images maintain a reasonable structure, a pre-trained multimodal large model, Qwen-VL, is used to extract deep semantic features from real power scene images. Combined with Prompt engineering, high-quality synthetic images that accurately represent power defect scenarios are generated. Experimental results show that the augmented data can further improve the fine-tuning of the power domain multimodal large model, enhancing recognition accuracy in power inspection tasks.

This work presents a case for the intelligent recognition task of multimodal large models in the power sector. The proposed method not only enables cross-modal interaction and recognition but also provides a reference and technical support for the application of multimodal large models in other industries.

Key Words: Multimodal large models; Intelligent recognition; LoRA; Diffusion models; Data augmentation

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 电力巡检图像智能识别研究现状	2
1.3 大模型研究现状.....	4
1.4 图像生成技术研究现状.....	6
1.5 主要研究内容与章节安排	7
第 2 章 相关理论与基础	9
2.1 大模型技术.....	9
2.1.1 ChatGLM-6B 架构解析	9
2.1.2 Vision Transformer 架构解析	12
2.2 大模型微调技术.....	13
2.2.1 大模型微调基础知识.....	13
2.2.2 微调方法介绍.....	14
2.3 扩散模型与图像生成技术	15
2.3.1 扩散模型原理.....	15
2.3.2 ControlNet 框架基础.....	17
2.3.3 CLIP 模型	18
2.3.4 Canny 算法应用	19
2.4 本章小结.....	20
第 3 章 基于多模态大模型微调的电力图像智能识别技术	22
3.1 电力缺陷领域数据集制作	23
3.2 LoRA 微调设计.....	24
3.3 Q-Former 算法设计.....	25
3.4 多模态大模型构建.....	26
3.5 数据与实验.....	29
3.5.1 数据介绍	29
3.5.2 评估指标.....	31
3.5.3 实验参数设计.....	33
3.5.4 模型实验.....	33
3.5.5 实验分析与讨论.....	35
3.6 本章小结.....	38
第 4 章 基于扩散模型的电力数据扩展方法	40
4.1 基于扩散模型的电力数据扩展方法	40
4.1.1 LDMs 技术原理	40

4.1.2 多模态大模型提示词生成.....	41
4.1.3 ControlNet 与 Canny 算法控制	43
4.2 实验展示与分析.....	44
4.2.1 数据集介绍.....	44
4.2.2 实验设置与评价指标设计.....	44
4.2.3 对比试验.....	45
4.2.4 消融试验.....	46
4.2.5 实验总结.....	48
4.3 本章小结.....	48
第 5 章 总结与展望	50
5.1 总结.....	50
5.2 展望.....	51
参考文献.....	52

第 1 章 绪论

1.1 研究背景及意义

人工智能的迅猛发展，各行各业纷纷引入该技术，其中包括电力行业，也积极拥抱智能化升级。国家电网积极响应国务院发布的《新一代人工智能发展规划》^[1]，推动智能巡检技术的发展，提升电力系统安全性和稳定性。在电力领域中，“发、输、变、配、用”五个环节共同构成整个系统。其中，输电环节负责电力传输，变电和配电则涉及电能电压等级的调整和用户分配^[2]。这三个部分的正常运作对整个电力系统至关重要。在输电和配电场景中，电力塔和电力线长时间暴露在户外，可能导致安全隐患，如鸟巢、金具锈蚀和绝缘子破损^[3,4]。变电场景涉及各种电气设备，如测量仪表和接地装置，也可能出现破损和缺失^[5]。这些问题会极大地威胁电力的正常传输、调整和分配。对于输电、配电和变电等场景的缺陷，存在交叉但不相同的情况。因此，在实际工业环境中，通常需要进行两个过程，即电力场景的区分和不同场景缺陷的检测^[6,7]。目前，主要依赖人工定期巡检来捕捉电力领域的缺陷，这不仅存在潜在的威胁，还给巡检人员带来巨大的工作量，浪费了大量的资源，难以满足现代电网对精细化、智能化巡检的需求。

为了提升电力巡检效率，基于深度学习的目标检测模型已被引入电力缺陷检测任务，并在此领域取得了一定的成果^[8,9]，提升了电力检测的智能化。然而，目前的电力缺陷检测算法需要大量的人工标注缺陷，而小型的检测模型存在多、乱、交互性低、难以改进等问题，导致电力缺陷检测耗时耗力，难以进一步发展，影响了电力巡检智能识别的效率和发展。这些问题一直存在，随着深度学习和目标检测算法的发展，变得更加显著。

近两年来，多模态大模型的不断发展使人机交互和智能化领域迎来了快速的变革。不同于以往的深度学习模型，基于自然语言处理技术^[10]的大模型，如 GPT-4^[11]和 Qwen-VL-Max，通过统一编码视觉、语言等多模态信号，在零样本图文问答、场景推理等任务中展现出强大的认知能力，为垂直领域智能化转型提供了新范式。电力场景识别和缺陷识别作为一项电

力巡检至关重要的任务，也可以充分利用多模态大模型进行跨模态智能识别，进一步提升人机交互能力。然而，将通用多模态大模型迁移至电力领域面临诸多挑战。首先，现有模型预训练数据主要来源于自然场景，缺乏对电力专业标准和缺陷知识的理解，导致其无法准确识别绝缘子破损、金具锈蚀等专业缺陷，且生成的文本描述常偏离电力规程术语。其次，主流多模态大模型的参数量级普遍达到几十亿规模，直接进行全参数微调需要消耗千卡级别 GPU 集群资源，远超电力企业或学术机构算力预算；最后，多模态大模型对训练数据规模要求较高，且电力缺陷数据难以采集、正样本数量少，可能导致训练后的模型智能识别水平受限。

综上所述，多模态大模型对于电力领域智能识别具有重要意义。但其局限性也较为明显，为了克服上述这些挑战，本文提出了一种基于多模态大模型微调的电力图像智能识别技术，利用目标检测和分类算法自动构建电力缺陷多模态数据集，增强模型在电力领域的图文知识认知能力，融合高效微调方法和跨模态对齐方法，对大模型进行参数高效微调，以降低计算开销，提高模型的电力缺陷视觉-语义对齐能力，实现基于多模态大模型的电力图像智能识别任务。同时，提出一种基于扩散模型的电力缺陷数据扩展技术，将电力图像的轮廓特征融入到扩散模型中，控制电力设备缺陷的整体结构^[12]；在保证生成图像结构合理性的基础上，利用训练好的多模态大模型提取真实电力场景图像的深层次语义特征；并结合 Prompt 工程，生成高质量、符合电力缺陷场景特征的合成图像，进一步补充电力多模态大模型的数据量，提升智能识别能力。该工作为推动电力巡检图像智能识别任务的发展提供了重要的参考价值。

1.2 电力巡检图像智能识别研究现状

传统的电力巡检图像识别主要依赖经验方法和专家对电力缺陷检测任务的深入理解。电力巡检专业人员从图像中提取电力设施和设备的特征，如设备和缺陷的边缘、形状^[13]、颜色^[14]、纹理^[15]以及梯度直方图^[16]等，然后进行特征匹配和计算特征距离，以确定目标缺陷的位置。Dalal N 等^[17]针对复杂环境中低清晰度的绝缘子图像，采用多尺度小波变换技术，并结合滤波处理和特征提取等方法，对实验室构建的不同厚度覆盖冰绝缘子图

像进行对比实验，从而建立了现场采集绝缘子覆冰厚度的测量体系。这类传统方法在处理大量且复杂场景的电力巡检中普遍存在准确率低和效率低的问题，难以满足现代电力巡检图像识别向智能化发展的要求。

深度学习加速了电力巡检图像识别智能化的发展。基于卷积神经网络（convolutional neural networks, CNN）的图像识别算法于 2012 年取得突破性进展，在基于公共图像数据集分类任务中取得良好的效果^[18,19]。深度学习在电力缺陷检测中的应用主要包括单阶段检测算法和双阶段检测算法^[20]。其中，双阶段检测算法一般包括 Fast R-CNN，Faster R-CNN 等。金昊等人^[21]使用 Faster R-CNN 模型对高压电线缺陷进行了识别实验，利用 1917 张原始样本图片经数据增强扩增至 13419 张样本。实验结果显示，对于高压电线的断股和异物缺陷，Faster R-CNN 实现了 90% 以上的平均精确度（Average Precision, AP），而对损伤缺陷的识别 AP 也达到了 83%，三类缺陷综合的平均精确度（mean Average Precision, mAP）达到了 94%。Liang 等^[22]提出一种改进的 Faster R-CNN，设计了一个多类别缺陷识别系统，其以 ResNet-101^[23]为骨干模型应用于缺陷检测；而单阶段检测算法中，YOLO^[24]以及其改进算法较为常见。罗潇等人^[25]提出一种基于 YOLOv3 的目标检测算法，选用 ResNet18 作为主干网络结构，并构建了一个多尺度空间金字塔与主干网络融合，形成了深度融合的电网巡检绝缘子检测模型。该模型的 mAP 达到了 98.10%，比 Faster R-CNN 提高了 6.71%；每秒检测帧数高达 47.52 帧，分别是 R-CNN 和 Faster R-CNN 的 25 倍和 12 倍，所提的 YOLOv3 网络在识别精度和检测速度方面均具有更优表现。与传统方法相比，深度学习能够自动学习图像中的深层特征，具备更高的准确率、更快的处理速度和更高的安全性，极大地提升了智能化水平。

徐晓敏等人^[26]针对无人机在电力线路巡检过程中存在的安全性和效率问题，提出了一种基于智能图像识别的无人机电力线路安全巡检新方法。该方法首先采集无人机电力线路巡检图像并进行滤波处理，然后基于智能图像识别技术设计无人机线路巡检识别算法，最后采用最优全局概率搜索遗传算法规划无人机电力线路的安全巡检路径，实现了无人机电力线路的安全巡检。实验结果表明，该方法效果较好且可靠性高。

当前，深度学习模型已能满足电力巡检智能化的部分需求，尤其在缺陷识别精度和实时处理能力方面表现出色，但在人机图文交互等跨模态领域的应用仍存在不足，相关研究与实践亟待进一步深入。

1.3 大模型研究现状

针对多模态大模型在电力缺陷检测领域应用的研究尚不充分的问题，为应对这一任务，本节调研了多模态，尤其是视觉语言大模型的发展情况，包括各阶段的改进、存在不足以及当前状态，并选择和优化适用于电力缺陷领域的算法和模型。2017 年，Vaswani 等人^[27]提出的 Transformer 模型在自然语言处理领域引发了革命性变化，其首次引入的自注意力机制不仅在文本处理上取得显著成果，也在计算机视觉领域表现卓越，成为连接文本和视觉的重要桥梁。2020 年，Dosovitskiy 等人^[28]提出的 ViT（Vision Transformer）进一步推动了视觉大模型的发展，在图像分类等任务上展现出卓越性能，但在处理局部图像特征方面仍需改进。2021 年，Radford 等人^[29]提出 CLIP（Contrastive Language-Image Pre-training）模型，该模型将视觉和语言融合，能够对图像进行分类并理解文本描述，实现了视觉和语言的紧密统一，但在大规模数据集上训练需要大量算力资源。2022 年 Salesforce 提出 BLIP（Bootstrapping Language-Image Pretraining）^[30]，这是一个具备跨模态编码和解码能力的多模态框架，用于生成图像提示或描述。2023 年，Salesforce 提出 BLIP-2^[31]，该模型框架包含预训练的图片编码器、预训练的大语言模型和一个可学习的 Q-Former（Query Transformer），通过充分利用预训练的视觉和语言模型，提供了高质量的视觉表征和强大的语言生成能力，从而降低了训练成本。同年，基于自然语言处理技术的大模型 GPT-4 凭借强大的多模态图文问答能力问世，激发了多模态大模型的研究热潮，类似的模型还有 MiniGPT-4^[32]、InstructBLIP^[33]、LLaVA-v1.5-13B^[34]。然而，大部分模型的训练策略和权重参数详细信息并未公开，使得进一步研究面临困难。清华大学开源了 VisualGLM-6B^[35]，该模型支持图像、中文和英文的多模态对话。该模型使用 ChatGLM-6B 作为基础大语言模型，并通过训练 Q-Former 构建视觉模型与语言模型之间的桥梁。

当前，大模型技术正在与多个行业结合，推动着这些行业的变革式发展。

在智能驾驶领域，大模型与多模态融合技术已成为实现复杂路况感知的核心手段，尤其是在感知和场景理解能力以及决策能力方面。在感知和能力理解方面，CAVG（Cross - Attention Visual - Grounding）^[36]与 ELM（End - to - End Learning Model）^[37]组合了 BERT、EVA 等多个多模态大模型，基于低秩适配（Low-Rank Adaptation, LoRA）^[38]技术采用自动驾驶领域数据集进行微调，实现了场景描述、物体定位、事件记忆和预测的多功能。在决策能力方面，GPT-Driver^[39]和 DriveVLM^[40]等将感知模型的结果和图像作为大语言模型的输入，则通过整合视觉语义信息与驾驶指令文本，实现了从感知到决策的一体化控制。在医学领域，大模型应用涵盖了多种场景，如患者服务、医疗服务、医学研究等，在降低医疗行业成本的同时改善和提升医疗领域的服务质量和效率。医疗领域的应用聚焦于多模态数据的知识挖掘与辅助诊断。IvyGPT^[41]与 CareGPT^[42]通过整合医学影像报告、临床病历与诊疗指南等多源数据，并通过结合高质量的医疗问答实例进行训练和微调，提高了大语言模型在特定医疗场景中的应用能力。DoctorGLM^[43]通过使用中文医疗对话数据集对 ChatGLM-6B 大语言模型进行微调得到，取得了一定的应用效果。在法律领域，多模态大模型正重塑法律文书处理范式。LawGPT^[44]基于 ChatGLM-6B，通过使用法律领域数据集（包括法律领域对话问答和中国司法考试试题等预料）进行微调，提升了大模型在法律领域的基础语义理解能力，增强了大语言模型对法律内容的理解和执行能力。Lawyer LLaMA^[45]则首先在大规模法律语料上进行了系统的预训练，并借助 ChatGPT 收集了法律职业资格考试和法律咨询的数据集，通过该数据集对大语言模型进行微调，使法律大语言模型具备实际应用的能力。

在大模型的垂直领域应用实践中，不同行业基于自身数据特征与业务需求，展现出创新性的技术探索路径，为电力缺陷检测领域的大模型实践研究提供了重要的方法论启示。现有多模态大模型在常见领域图文问答方面表现出色，但直接应用于特定领域时可能出现回答错误和幻觉等问题

[46,47], 其原因在于缺乏该领域的图文知识。此外, 多模态大模型参数庞大且难以训练。为此, 本文提出构建特定领域的多模态数据知识, 增加电力缺陷领域图文知识, 融合低秩适应方法与 Q-Former 方法, 降低模型参数量的同时, 对齐电力图像与电力语义信息, 以减少图文问答中出现的错误和幻觉。

1.4 图像生成技术研究现状

图像生成技术已成为计算机视觉领域的重要研究方向。Goodfellow 等人^[48]在 2014 年提出的生成对抗网络 (Generative Adversarial Networks, GAN) 是该领域的里程碑式突破。GAN 通过生成器和判别器的对抗训练来实现图像生成: 生成器旨在合成逼真图片, 而判别器则负责区分真实图像与生成结果。尽管 GAN 在高质量人脸图像生成和艺术风格迁移等任务中取得初步成功, 但其训练过程中存在模式崩塌、不稳定性以及生成不可控等问题, 导致图像质量与多样性难以保证^[49-51]。

为了改善上述缺陷, 研究者相继提出多种改进方案。DCGAN^[52,53]、通过引入卷积架构提升了生成效果; WGAN (Wasserstein GAN)^[54-56]采用 Wasserstein 距离优化训练过程; StyleGAN^[57,58]则通过风格解耦实现细粒度控制。这些方法通过架构创新、训练策略优化和新型损失函数设计, 显著提升了图像生成质量, 特别是在高分辨率图像生成和图像风格转换方面展现了卓越的性能^[59,60]。然而, 现有 GAN 系列算法仍难以实现生成内容的精准控制, 在复杂场景生成任务中尤为明显^[61]。

自回归模型作为另一类重要生成方法, 通过序列化条件概率建模像素间依赖关系^[62]。代表性的自回归模型包括 PixelCNN^[63]和 PixelSNAIL^[64]等, 将图像分解为像素块进行顺序生成, 避免了 GAN 的对抗训练不稳定性, 在图像生成精度方面具有优势。其逐像素生成机制导致计算复杂度呈指数增长, 在高分辨率图像生成场景面临严重效率瓶颈, 这极大限制了其实际应用范围。

当前, 扩散模型 (Diffusion Models) 的突破性进展引发了广泛关注。Ho 等人^[65]提出 DDPM (Denoising Diffusion Probabilistic Models) 通过渐进式加噪-去噪框架革新了生成范式: 在正向过程中逐步破坏数据分布, 再

通过逆向过程学习噪声去除过程。相较于需要对抗训练的 GAN 和序列生成的自回归模型，扩散模型凭借训练稳定性和高保真生成能力，在复杂场景重建等任务中表现突出。然而，早期基于像素空间的扩散模型存在内存消耗大、生成速度慢的缺陷。对此，Rombach 等人^[66]提出潜在扩散模型（Latent Diffusion Models, LDMs），通过将扩散过程迁移到低维潜在空间，实现效率跃升。LDMs 采用两阶段训练框架：首先利用变分自编码器（VAE）将图像压缩为潜在表征，随后在潜在空间执行扩散过程。这种设计不仅将计算复杂度降低数十倍，还能通过潜在空间结构化特征实现对纹理、光照等细节的精准调控。Stable Diffusion^[67-69]是一种基于 LDMs 架构的生图技术，其进一步融合文本语义引导机制，在保持生成质量的同时实现跨模态可控生成，标志着可控图像生成技术的重大突破^[70]。

扩散模型的独特优势在于其高度可控的生成过程。与 GAN 的不可预测性不同，扩散模型可通过调节噪声添加、去除的迭代过程精确控制图像细节。这种特性不仅使其在图像生成任务中表现出色，更为数据增强提供了创新解决方案：传统方法在数据稀缺场景下难以生成多样化高质量样本，而扩散模型能通过可控噪声注入策略生成具有丰富语义变化的图像，有效缓解小样本学习中的数据瓶颈问题。

1.5 主要研究内容与章节安排

本研究以电力巡检图像的智能识别为核心任务，围绕多模态大模型研究和实践展开。针对深度学习方法在复杂场景下泛化能力弱、跨模态交互性差等问题，重点研究多模态大模型在电力缺陷识别中的创新应用，提出一种基于多模态大模型的电力巡检图像智能识别方法。为解决电力数据稀缺对多模态大模型性能的限制，设计一种基于扩散模型的电力数据扩展方法。章节安排如下：

第一章，绪论。介绍本工作的研究背景和意义，调研电力巡检图像智能识别发展现状，概述关于大模型的研究现状与图像生成重要技术的发展历程；最后，简要介绍本文的研究内容和章节安排。

第二章，相关理论与基础。主要介绍了多模态大模型的相关语言模型、视觉模型、微调基础知识和方法，介绍图像生成技术基础的知识，为后续

研究和改进做理论支撑。

第三章，提出了一种基多模态大模型微调的电力图像智能识别技术。针对多模态大模型存在参数庞大、难训练、缺乏电力缺陷领域图文知识等问题，提出相应改进方案。使用 YOLOv8 构建多模态电力缺陷领域中文数据集，丰富电力缺陷领域的图文知识。融合 LoRA 和 Q-Former 方法进行模型微调，降低模型参数量并提高视觉与语义特征的提取能力，实现视觉与语义信息对齐。实验表明，所提出的方法在电力缺陷领域的问答准确率显著优于现有模型，提升了缺陷检测效率与巡检智能交互性

第四章，提出一种基于扩散模型的电力设备缺陷数据扩展方法。通过生成多样化电力场景图像扩充数据集的规模与多样性，为大模型提供更为丰富的图文知识。本章基于扩散模型，使用多模态大模型 Qwen-VL 提取原始图像视觉特征，优化初始 Prompt，增添 ControlNet 与 Canny 算法控制局部目标轮廓，调控初始潜在变量与重绘幅度控制生成过程。实验结果表明，该方法显著提升数据集的完整性与多样性，并增强多模态大模型的缺陷识别能力。

第五章，总结与展望。针对本文的研究项目，提出了简洁而有价值的总结，展示了相关工作的创新性，同时探讨了未来研究的方向和内容。

第 2 章 相关理论与基础

本章围绕大模型技术、参数高效微调与可控图像生成三大方向展开。首先，解析语言大模型的动态上下文建模原理与视觉大模型的序列化表征机制；其次，介绍大模型微调背景及核心方法，包括 LoRA 的低秩分解原理与 P-Tuning 的提示向量优化机制；最后，阐述扩散模型的去噪生成理论，分析 ControlNet 的结构约束编码原理与 CLIP 的跨模态语义对齐方法。本章内容为第 3 章电力多模态大模型构建及第 4 章电力图像数据扩展技术提供理论与方法支撑。

2.1 大模型技术

当前人工智能领域的大规模预训练模型主要分为三大技术分支：大语言模型（Large Language Model, LLM）、视觉大模型（Vision Foundation Model, VFM）与多模态大模型（Multimodal Large Model, MLLM）。LLM 专注于文本模态的建模与生成，通过自回归机制实现自然语言对话功能^[71]；VFM 以视觉表征学习为核心，通过全局序列建模突破传统卷积神经网络的局部感知局限^[72]；MLLM 则通过跨模态语义对齐技术，构建视觉、语言等多模态的统一表征空间^[73]。在技术架构层面，MLLM 通常以 LLM 和 VFM 作为核心基座，融合跨模态编码器构建交互通道。本节主要从语言和视觉两个方向解析大模型的核心技术。本文选择 ChatGLM-6B^[74]作为 LLM，ViT 为 VFM。

2.1.1 ChatGLM-6B 架构解析

ChatGLM-6B 是基于 Transformer 架构的自回归生成式预训练模型，专为多轮对话系统设计。其核心目标是通过动态上下文建模生成逻辑一致且语义连贯的自然语言响应。相较于通用生成模型，ChatGLM-6B 在架构设计与训练目标层面进行了针对性改进：采用 Transformer 解码器结构，通过扩展注意力机制增强长序列对话历史建模能力，并引入角色感知编码机制以区分用户与系统的交互角色。在预训练阶段，该模型利用大规模对话语料学习对话状态跟踪能力，同时通过一致性约束损失函数降低逻辑矛盾生成概率，显著提升多轮对话的稳定性。作为生成式预训练模型，

ChatGLM-6B 的技术实现主要基于自回归生成机制与改进的 Transformer 架构。

自回归生成机制采用链式条件概率建模方法，通过逐步预测词元序列实现文本生成。模型根据历史词元序列计算当前时刻的条件概率分布： $P(x_t|x_{1:t-1})$ 。每个生成步骤将已生成词元作为输入，迭代预测下一个词元直至输出终止符。该机制通过上下文依赖建模确保生成文本的连贯性，尤其适用于多轮对话场景。与非自回归模型相比，自回归生成机制在对话响应质量上具有显著优势，但存在推理速度较慢的局限性。

多头自注意力机制（Multi-Head Self-Attention, MHSA）作为 Transformer 架构的核心组件，通过建立词元间关联矩阵实现上下文语义建模。其计算过程可分为三个核心步骤：首先，将输入序列分别映射为查询矩阵（Q）、键矩阵（K）和值矩阵（V），其中查询向量表征当前词特征，键向量编码上下文信息，值向量传递语义内容；其次，通过 Q 与 K 点积计算注意力权重矩阵，经 Softmax 归一化后与 V 矩阵加权求和；最后，通过并行多组注意力头的协同计算实现多粒度语义捕获。其过程如公式 2-1 所示。ChatGLM-6B 在此基础上引入角色感知编码，将对话参与方的身份信息融入注意力计算过程。

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

在公式 2-1 中， d_k 是键矩阵的维度， $\sqrt{d_k}$ 是缩放因子。然后，通过加权求和的方式，将上下文信息聚合到当前词的表示中，从而捕捉远程依赖。

ChatGLM-6B 通过多头自注意力机制，在同一层中并行执行多个独立的注意力操作，捕捉不同的语义关系。每个注意力头会聚焦于句子的不同部分，帮助模型理解复杂的上下文结构。在语言建模中，ChatGLM-6B 使用自回归语言模型来生成下一个词。它通过前面的词来预测下一个词的概率分布，逐步生成整句话。每一步生成时，ChatGLM-6B 模型依赖于之前生成的上下文，并通过自注意力机制了解前面的生成历史，确保生成的句子连贯且符合上下文逻辑。ChatGLM-6B 中的多头自注意力机制并行计算

多个不同的注意力头，每个头会关注输入序列中不同的部分。其允许模型捕捉多种不同的语义关系，如短距离依赖和长距离依赖。多头注意力的输出会通过拼接，然后输入到后续的网络层中进行进一步处理。多头自注意力的设计提高了模型在生成文本时对不同上下文的感知能力，特别适合处理复杂对话和长文本。总的来说，在 ChatGLM-6B 的对话生成中，多头自注意力机制能够帮助模型理解长对话中的上下文信息，确保每次生成的回答不仅基于最近的上下文，也能参考多轮对话的历史内容。上述对于生成语义连贯且逻辑清晰的对话非常重要。

前馈网络（Feed-forward Network, FFN）和位置编码（Positional Encoding, PE）是 Transformer 的基本组成部分，它们在 ChatGLM-6B 中同样扮演着重要角色，帮助模型处理非线性变换和序列顺序信息。前馈网络是每一层 Transformer 中的关键组成部分，用于对每个词的表示进行非线性变换。前馈网络的公式如 2-2 所示。

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2-2)$$

在公式 2-2 中，其中 W_1 和 W_2 是线性变换的权重矩阵， b_1 和 b_2 是偏置项。在 ChatGLM-6B 中，前馈网络可以进一步处理来自自注意力机制的输出，增强每个词的表征能力，使得模型能够捕捉更丰富的特征。关于位置编码，Transformer 架构不具备对序列顺序的内在感知能力，因此需要通过位置编码来引入序列信息。位置编码通过正弦和余弦函数将每个词的位置信息加入其表示中，帮助模型捕捉词序列中的顺序关系。

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (2-3)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (2-4)$$

在公式 2-3 和 2-4 中， pos 表示词在序列中的位置， i 表示嵌入维度。前馈网络和位置编码共同作用，确保模型能够有效处理每个词的上下文表示，并同时保留词在句子中的顺序信息。尤其在多轮对话中，位置编码帮助 ChatGLM-6B 更好地理解对话中的词序关系，使得回复更加自然流畅。

ChatGLM-6B 作为对话系统的生成模型，在标准 Transformer 架构的基础上做了一些针对性的优化，以提升其在多轮对话中的表现。对多轮对话的优化：ChatGLM-6B 通过改进上下文窗口机制，能够更有效地处理长对话和多轮对话。相比于传统的 Transformer 模型，ChatGLM-6B 能够保留更多的对话历史信息，使得在生成回复时，模型不仅能关注最近的对话，还能参考之前多轮对话的内容。这种优化有助于减少模型生成无关回复的概率，特别是在复杂对话场景下，ChatGLM-6B 能够生成更加一致和连贯的答案。

总体而言，ChatGLM-6B 通过任务驱动的架构优化与训练策略创新，为对话系统的工业化应用提供了高效解决方案。后续研究应重点探索动态知识注入机制和跨模态交互能力扩展，以进一步提升模型在实际应用场景中的实用价值。

2.1.2 Vision Transformer 架构解析

在多模态大模型的架构设计中，视觉编码器作为核心组件之一，其表征能力直接影响跨模态对齐效果。当前视觉大模型普遍采用基于 Transformer 的架构设计，其中 ViT 通过序列化建模突破了传统 CNN 的局部感知局限，成为视觉表征学习的代表性方案。




图 2-1 ViT 模型架构示意图

Fig. 2-1 Schematic diagram of the ViT architecture

ViT 是一种基于纯 Transformer 架构的视觉大模型，其核心思想是将图像建模为序列化数据以捕捉全局语义关联。与传统 CNN 依赖局部感受野不同，ViT 将输入图像分割为固定尺寸的图像块，通过线性映射将每个块转换为向量序列，并引入可学习的位置编码 PE 以保留空间信息。给定输入图像 $x \in \mathbb{R}^{H \times W \times C}$ ，其中 H, W, C 分别表示图像高度、宽度和通道数，ViT 将其划分为 N 个 $P \times P$ 图像块，并通过线性投影生成嵌入向量序列，计算公式如 2-5 和 2-6 所示。ViT 模型架构示意图如图 2-1 所示。

$$N = \frac{HW}{P^2} \quad (2-5)$$

$$z_0 = [p_1 E; p_2 E; \dots; p_N E] + E_{pos} \quad (2-6)$$

在 2-6 式中， z_0 为嵌入向量序列， $E \in \mathbb{R}^{P^2 C \times D}$ 为块嵌入矩阵， D 为预设的嵌入维度， $E_{pos} \in \mathbb{R}^{N \times D}$ 为位置编码。该序列随后输入至多层 Transformer 编码器，通过 MHSA 与 FFN 实现全局上下文建模，最终通过分类头或解码器完成下游任务。

相较于 CNN 的归纳偏置特性，ViT 通过自注意力机制实现全局长程依赖建模，在大规模数据集上展现出更强的表征能力，这一特性使其成为多模态大模型中视觉编码器的理想选择，为跨模态语义对齐提供高分辨率的视觉特征表示。

2.2 大模型微调技术

2.2.1 大模型微调基础知识

大模型在自然语言处理、计算机视觉领域取得了显著成果。大模型通常包含超数十亿参数，通过大规模预训练学习丰富通用知识。训练好的大模型通常缺少垂直领域的深度知识，直接应用到特定领域效果不好。大模型微调技术就是来解决此类问题。大模型微调一般分为全量微调（Full Fine-Tuning）和参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）。

直接进行全量微调应用于下游任务，面临显著的算力和数据瓶颈^[75]。Full Fine-Tuning 是对整个预训练模型的所有参数进行训练更新，以适应特

定下游任务。PEFT 仅对预训练模型的部分参数进行更新，或引入少量额外参数，降低计算和存储开销。对于 Full Fine-Tuning，从计算资源角度看，反向传播过程中需要计算所有参数的梯度，导致显存占用和训练耗时呈指数级增长，计算成本高昂。从模型稳定性角度看，过度调整底层通用表征可能引发灾难性遗忘，使模型丢失预训练阶段习得的通用知识^[76]。

2.2.2 微调方法介绍

传统全量微调方法因计算成本高、知识遗忘严重等问题逐渐被 PEFT 取代。PEFT 通过选择性调整模型的部分参数或引入轻量化适配模块，显著降低训练资源消耗，同时保持模型性能。本节重点说明两种主要 PEFT 方法的原理与使用场景：低秩适配（Low-Rank Adaptation, LoRA）与前缀提示微调（Prefix-Tuning, P-Tuning）。

机器学习中普遍存在低秩结构，许多算法都表现出一些内在的低秩特性。对于深度学习任务，尤其有过度参数化神经网络的任务，训练后的神经网络会具有低秩属性。LoRA 基于大模型参数更新矩阵的低秩特性，在保持预训练权值不变的情况下，通过增加旁路矩阵模拟全参数微调，间接训练网络中的一些密集层，是目前通用且效果显著的微调方法，也能与其他高效微调方法有效结合。LoRA 最显著的优点是大大降低模型训练参数量，训练的速度更快，使普通学术研究者和小型企业更加方便自主实验。通过在原始权重矩阵旁添加可训练的低秩旁路矩阵实现高效优化。该方法思想是，模型在适应新任务时，仅需对原始参数空间进行低维调整可捕获任务特征。具体地，LoRA 将权重更新矩阵 $W \in R^{d \times k}$ 分解为两个低秩矩阵的乘积，如公式 2-7 所示。

$$\Delta W = X \cdot Y \quad (2-7)$$

在公式 2-7 中， $X \in R^{d \times r}$ 和 $Y \in R^{r \times k}$ 为可训练的低秩矩阵， r 为分解的秩，且 $r \ll d$ 。通过这种分解，LoRA 将权重更新矩阵参数量从 $d \times k$ 减少到 $r \times (d+k)$ ，极大降低了计算和存储开销。

P-Tuning 通过优化输入端的软提示向量（Soft Prompt）隐式引导模型行为。与传统的硬提升（Hard Prompt）不同，软提示向量是可学习的连续

向量，能够更灵活地捕捉任务语义信息。该方法核心思想是将任务指令编码为可学习的提示词，使模型在不修改内部参数的情况下适应新任务，从而显著降低计算和存储开销。具体地，P-Tuning 在输入序列前添加一组可训练的提示向量 $P=[P_1, P_2, \dots, P_m]$ ，其中 P_i 为第 i 个提示向量， m 为提示向量。

输入序列 X_{input} 与提示向量拼接后形成新的输入，如公式 2-2 所示。

$$X_{new}=[P_1, P_2, \dots, P_m, X_{input}] \quad (2-8)$$

在公式 2-8 中， X_{input} 为原始输入。通过这种方式，P-Tuning 在不改变模型参数的情况下，仅通过优化提示向量即可引导模型生成与任务相关的输出。

LoRA 通过低秩分解算法，仅训练模型中的部分参数，而固定大部分参数，减少了需要训练的参数数量。P-Tuning 通过在模型中加入可训练的前缀，微调的时候，只调整优化这些前缀，固定大模型其他参数。LoRA 适应于低资源的应用场景，也减少了极大的训练时间。P-Tuning 适应于高度定制化任务，需要训练更多的参数，尤其是当任务信息需要通过前缀向量精确控制时，要训练前缀向量。

2.3 扩散模型与图像生成技术

2.3.1 扩散模型原理

扩散模型核心思想是通过逐步加噪与去噪实现数据分布的学习与生成。与生成对抗网络（GANs）相比，扩散模型在生成高质量、多样性图像方面表现出显著优势。

扩散模型的核心分为两个阶段：前向扩散过程与反向去噪过程。

前向扩散过程将原始数据 x_0 通过 T 步逐步添加高斯噪声，最终转化为纯噪声 x_T 。该过程定义为马尔可夫链，如公式 2-9。

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1-\beta_t} x_{t-1}, \beta_t I) \quad (2-9)$$

在公式 2-9 中， $q(x_t | x_{t-1})$ 表示 x_{t-1} 到 x_t 的转移概率， N 表示高斯分布， $\beta_t \in (0,1)$ 为预设的噪声调度系数，控制噪声添加速率， I 表示噪声的协方差。通过重参数化技巧，可直接从 x_0 计算任意时刻 t 的噪声状态，如公式 2-10。

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \varepsilon, \varepsilon \sim N(0, I) \quad (2-10)$$

在公式 2-10 中, $\alpha_t = \prod_{s=1}^t (1 - \beta_s)$ 为累计噪声衰减因子。当 $T \rightarrow \infty$ 时, $\alpha_T \rightarrow 0$, x_T 趋近于准高斯分布, 实现复杂分布向简单分布的转化。

反向过程通过神经网络学习逐步去除噪声, 从 x_t 重构原始数据 x_0 , 该过程定义为参数化的马尔可夫链, 如公式 2-11 所示。

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \sum_\theta(x_t, t)) \quad (2-11)$$

在公式 2-11 中, $p_\theta(x_{t-1} | x_t)$ 表示从 x_t 到 x_{t-1} 的转移概率, μ_θ 和 $\sum_\theta$ 为神经网络预测的均值和协方差矩阵。实际训练中, 通常通过优化变分下界 (Variational Lower Bound, VLB) 实现, 如公式 2-12 所示。

$$L_{VLB} = E_{t, x_0, \varepsilon} [\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2] \quad (2-12)$$

在公式 2-12 中, L_{VLB} 为变分下界函数, $E_{t, x_0, \varepsilon}$ 为对时间步 t 、原始数据 x_0 和噪声 ε 的期望, ε_θ 为噪声预测网络, 表示对噪声的估计, $\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2$ 为预测噪声与真实噪声之间的均方误差。目标是通过最小化预测噪声与真实噪声的差异, 学习数据分布的内在结构。

在训练阶段, 随机采样时间步 $t \sim u(1, T)$, 向输入图片注入噪声后, 训练网络预测噪声分量。在生成阶段, 从标准高斯分布采样 x_t , 通过 T 步迭代去噪, 最后逐步生成高质量图片, 过程如公式 2-13 所示。

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \varepsilon_\theta(x_t, t) \right) + \sigma_t z \quad (2-13)$$

在公式 2-13 中, x_{t-1} , x_t 分别表示第 $t-1$ 和 t 步的去噪结果, α_t 为单步噪声衰减因子, $\beta_t = 1 - \alpha_t$, $z \sim N(0, I)$ 为标准高斯噪声, σ_t 为噪声放缩系数, 控制去噪过程的随机性。最终得到去噪结果 x_0 , 即生成的高质量图片。

在上述过程, 随着扩散时间步数的增加, 原始图像逐渐退化为纯噪声, 这一过程模拟了物理世界中的扩散现象, 如墨水在水中扩散。前向扩散的数学本质是将复杂的数据分布逐步简化为易于建模的高斯分布。

反向去噪过程是扩散模型生成图像的关键阶段。该过程通过学习一个

噪声预测模型，逐步从纯噪声图像中恢复出原始图像。模型在每一步预测当前噪声图像的噪声成分，并根据预测结果逐步去除噪声，最终生成高质量的目标图像。与以往生成方法不同，扩散模型的反向过程是一个迭代式的渐进生成过程，每一步都依赖于上一步的结果。这种设计使得模型能够生成细节丰富、多样性高的图像。

扩散模型的训练目标是最小化噪声预测误差。在训练过程中，模型从随机时间步中采样噪声图像，并尝试预测其中的噪声成分。通过优化噪声预测误差，模型逐渐学会从任意噪声水平恢复原始数据分布。这种训练方式具有较高的稳定性，训练过程可以并行化处理，提高了训练效率。

2.3.2 ControlNet 框架基础

当前基于纯文本提示的文生图模型在实际应用中面临生成效果不可控的挑战。这主要源于自然语言在描述图像空间结构时存在的固有局限，虽然文本提示可以传达大致的语义内容，但难以精确表达物体布局、姿态、形状等细粒度视觉特征。为了获得符合预期的生成结果，用户往往需要进行大量提示词的反复调试，这一过程不仅效率低下，而且对专业经验要求较高。

ControlNet 是一种基于条件控制的生成模型框架，旨在增强扩散模型对生成过程的精确控制能力。其核心架构在预训练扩散模型的基础上，构建并行的轻量化控制网络，将边缘图、语义图等条件信息编码为多尺度特征映射，通过注意力机制与原始模型特征动态融合。具体地，控制网络采用残差卷积结构提取条件特征，在 U-Net 编码器的每个下采样层级进行特征注入，实现从全局结构到局部细节的精细化控制。该设计使得生成过程既保留基础模型的创造能力，又能严格遵循物理约束，如设备边缘轮廓、热力学分布等条件输入。

基于扩散模型的生图技术虽然在生成高质量图像方面表现出色，但其生成过程缺乏对特定任务，如图像修复、风格迁移等的精确约束。ControlNet 通过引入条件控制模块，将外部约束信息，如边缘图、语义图注入生成过程，使模型能够生成符合特定需求的高质量图像。

ControlNet 的训练过程分为预训练与微调两个阶段。在预训练阶段，

原始扩散模型在大规模图像数据集上训练，学习通用的图像生成能力。在微调阶段，控制网络在特定任务数据集上训练，学习将外部条件信息映射为生成控制信号。训练目标是最小化生成图像与目标图像之间的差异，同时确保生成图像符合条件约束。例如，在风格迁移任务中，ControlNet 通过引入风格图像作为条件信息，生成既保留内容图像结构又融合风格图像特征的输出结果。

在实际应用中，在图像修复任务中，ControlNet 可以通过引入掩码图（Mask）作为条件信息，生成细节丰富且与原始图像风格一致的修复结果。在风格迁移任务中，ControlNet 能够根据风格图像生成符合目标风格的图像，为艺术创作提供支持。ControlNet 还可以与其他技术，如 CLIP 结合，实现更精细的图像生成与控制。例如，在文本到图像生成任务中，ControlNet 可以根据文本描述生成对应的图像，为内容创作提供直观的视觉参考。

2.3.3 CLIP 模型

CLIP 是一种基于对比学习的多模态预训练模型，建立图像与文本之间的语义关联。与传统的单模态模型不同，CLIP 通过联合学习图像与文本特征，实现了跨模态的语义理解与生成能力。这种特性使其成为扩散模型的重要辅助工具，能够为图像生成任务提供高层语义引导。本节从模型架构、训练方法与应用场景三个角度，介绍 CLIP 的核心知识。

CLIP 的模型架构由图像编码器与文本编码器组成。图像编码器通常采用卷积神经网络，如 ResNet，或视觉 Transformer，如 GANs，用于提取图像的视觉特征。文本编码器通常采用 Transformer 架构，用于提取文本的语义特征。两个编码器将图像与文本映射到同一特征空间，通过对比学习优化特征对齐。CLIP 的训练目标是最大化匹配的图像-文本对的相似度，同时最小化不匹配对的相似度。该设计使得 CLIP 能够学习到图像与文本之间的语义关联。

CLIP 的训练方法基于大规模图像-文本对数据集。在训练过程中，模型从数据集中随机采样一批图像-文本对，计算图像特征与文本特征之间的相似度矩阵，并通过对比损失函数优化特征对齐。对比损失函数的核心思

想是提高匹配对的相似度，降低不匹配对的相似度。通过在大规模数据集上训练，CLIP 学习到丰富的跨模态语义知识，为下游任务提供强大的语义理解能力。

在图像生成任务中，CLIP 可以为扩散模型提供高层语义引导。在文本到图像生成任务中，CLIP 能够将输入文本描述映射为语义特征，指导扩散模型生成符合描述的图像。在图像编辑任务中，CLIP 可以通过修改文本描述 Prompt 实现图像的语义编辑，例如将“夏天”改为“冬天”以生成不同季节背景图像。CLIP 可以与其他技术，如 ControlNet 结合，实现更精细的图像生成与控制。

2.3.4 Canny 算法应用

Canny 算法^[77]是一种经典的边缘检测算法，旨在从图像中提取高精度的边缘信息。自 1986 年提出以来，Canny 算法因其高精度、低误检率与良好的抗噪性能，成为计算机视觉领域广泛使用的边缘检测工具。在扩散模型与图像生成任务中，Canny 算法通过提供低层视觉特征，如边缘信息，为生成过程提供结构约束。图 2-2 是一种最常见的 Canny 算法应用效果，左边是原图，右边是基于 Canny 的图像边缘特征提取结果图。

Canny 算法的核心思想是通过多阶段处理提取图像中的显著边缘。首先，算法使用高斯滤波器对输入图像进行平滑处理，以抑制噪声干扰。其次，计算图像的梯度幅值与方向，通过非极大值抑制保留局部梯度最大的像素点。然后，使用双阈值检测筛选出强边缘与弱边缘，并通过边缘连接将弱边缘与强边缘连接起来，形成完整的边缘轮廓。该多阶段设计使得 Canny 算法能够在保留图像主要结构的同时，有效抑制噪声与伪边缘。



图 2-2 基于 Canny 的图像边缘特征提取结果图

Fig. 2-2 Edge feature extraction results from images via Canny operator

Canny 算法的实现细节包括高斯滤波器参数选择、梯度计算方法与双阈值设置。高斯滤波器的标准差控制平滑程度，较大的标准差可以抑制更多噪声，但可能导致边缘模糊。梯度计算通常采用 Sobel 算子或 Prewitt 算子，用于估计图像的梯度幅值与方向。双阈值设置包括高阈值与低阈值，高阈值用于筛选强边缘，低阈值用于筛选弱边缘。通过合理设置这些参数，Canny 算法能够适应不同场景的边缘检测需求。

在图像生成任务中，Canny 算法可以为扩散模型提供低层结构约束。例如，在图像修复任务中，Canny 算法能够提取待修复区域的边缘信息，指导扩散模型生成与周围区域结构一致的修复结果。在风格迁移任务中，Canny 算法可以提取内容图像的结构边缘，确保生成图像在风格变化的同时保留原始内容的结构信息。Canny 算法还可以与其他技术，如 ControlNet 结合，实现更精细的图像生成与控制。

2.4 本章小结

本章系统构建课题研究的技术理论体系，围绕大模型技术、高效微调方法与可控图像生成三大核心模块展开。首先解析大模型基础架构，包括大语言模型 ChatGLM-6B 的动态上下文建模能力与视觉大模型 ViT 的全局序列化表征特性；其次探讨大模型垂直领域适配需求，阐述参数高效微调

的技术原理，重点剖析 LoRA 的矩阵分解特性与 P-Tuning 的连续向量引导机制；最后介绍可控图像生成技术栈，涵盖扩散模型的渐进式去噪框架、ControlNet 的结构约束注入、CLIP 的跨模态语义对齐以及 Canny 算法的边缘特征提取。上述理论与方法为后续模型的构建与优化提供了完整的技术支撑。

第3章 基于多模态大模型微调的电力图像智能识别技术

深度学习技术在电力缺陷检测领域取得了一定进展，但现有方法难以实现多模态信息的高效融合，主要包括文字信息和图片信息，导致人机交互性差。针对此问题，本章拟构建一个电力领域多模态大模型，并将其应用于电力图像的智能识别，通过跨模态图文交互的方式实现电力巡检图像的智能识别，包括识别电力场景、缺陷以及电力领域知识对话。然而，多模态大模型在电力领域应用时仍面临领域知识不足、参数规模庞大导致训练困难以及图文对齐困难等关键问题。为此，本章提出了一种基于多模态大模型微调的电力图像智能识别技术。首先，利用 YOLOv8 自动并快速地构建电力缺陷多模态数据集，以增强大模型在电力领域的图文知识表达能力；然后，融合低秩适配算法和 Q-Former，对模型进行参数高效微调，以降低计算开销并提高模型的视觉与语义的对齐能力；最后，通过实验验证模型在电力场景中的智能识别能力，并与相近参数规模下的主流多模态大模型包括 InstructBLIP、LLaVa-Med^[78]、Mini-GPT4、LLaVa-v1.5-13B 和 VisualGLM-6B 等进行对比。实验结果表明，本章提出的技术在电力图像智能识别任务上具有更优的准确率。图 3-1 展示了整个工作的框架。




图 3-1 基于多模态大模型微调的电力图像智能识别技术总体框架

Fig. 3-1 Overall framework for intelligent recognition of power images based on fine-tuning of multimodal large models

图 3-1 中，YOLOv8-MD 表示本工作中利用 YOLOv8 自动构建多模态数据集的过程；而 Power-VGLM 则是本章针对电力图像智能识别任务

而进行微调的多模态大模型。

3.1 电力缺陷领域数据集制作




图 3-2 基于 YOLOv8 构建多模态数据集过程

Fig. 3-2 Multimodal dataset creation process based on YOLOv8

多模态大模型的训练集通常包括三个主要组成部分：图像、提示和标签。人工标注图像需要仔细观察和总结缺陷，并以文字形式输出，过程繁琐、费时且低效。为了解决这一问题，本章提出了一种基于 YOLOv8 的算法，用于自动生成多模态数据集。YOLO 系列算法能够进行物体分类和检测，因其体积小、推理速度快、实现简单而被广泛应用于工业场景检测，因此也成为检测电力场景缺陷的热门选择。鉴于本研究的目标是场景分类和缺陷检测，同时尽力减少多模型算法的使用，本章选择 YOLO 作为分类和检测模型。

在 YOLO 算法系列中，YOLOv8 展示了较高的综合准确性。本章训练了五个 YOLOv8 模型：一个用于电力场景分类（命名为 YOLOv8-FenLei），以及四个用于不同场景的缺陷检测模型，分别针对输电、变电、配电和安全监控（安监）场景。这四个缺陷检测模型分别能够检测对应场景中的 13 类、7 类、13 类和 2 类缺陷。这五个模型在构建电力缺陷多模态数据集发挥了重要作用。

如图 3-2 所示，首先，通过手动设置问题，即提示 Prompt 设计，本章将 Prompt 表述为“这是一张什么场景的图片？请描述以下这张图片”。其次，输入图片 image。然后，利用训练好的 YOLOv8-FenLei 对图像进行分类，确定其类别，例如输电场景。随后，针对输电场景训练的缺陷检测

模型用来检测图像中的缺陷，获取每张图像的检测结果，包括正常与缺陷两种结果。最后，将场景分类结果与物体检测结果组合成完整的句子，生成所需的场景和缺陷描述信息标签。例如：“这是一张输电场景的图片，描绘了复合绝缘子损坏、正常的鸟类防护刺（防鸟刺）、鸟巢异物、锈蚀的防震锤等”。通过这种方式，有效地减少了人工标注文字问答的负担，同时保持了数据集的准确性和效率。该设计模块在后续实验部分（第 3.3.1 小节）中有具体成果展示。

3.2 LoRA 微调设计

多模态大模型，由于参数数量的庞大，全面微调所有参数以适应电力任务显然是不切实际的。本章采用 LoRA 微调多模态大模型，降低训练参数量，提高视觉语言大模型微调下游任务的算力可行性与多模态识别有效性，维持高质量的模型性能。




图 3-3 LoRA 原理图

Fig. 3-3 Schematic diagram of LoRA

图 3-2 为 LoRA 的实现原理图，A 与 B 是低秩矩阵，d 和 x 分别是模型初始权重矩阵的长和宽，h 为训练后的完整参数。其实现流程为：

- (1) 在原始预训练好的语言模型旁边增加一个旁路，做降维再升维的操作来模拟内在秩。

(2) 用随机高斯分布初始化 A ，用零矩阵初始化 B ，训练时固定预训练模型的参数，只训练矩阵 A 与矩阵 B 。

(3) 训练完成后，将 B 矩阵与 A 矩阵相乘后合并预训练模型参数作为微调后的模型参数。

下面是公式表示，对于预训练权重矩阵 $W_0 \in R^{d \times k}$ ， d 和 k 分别是权重矩阵的长和宽。用一个低秩分解来表示参数更新 ΔW ，即：

$$W_0 + \Delta W = W_0 + BA \quad (3-1)$$

其中 $A \in R^{r \times k}$ ， $B \in R^{d \times r}$ ，且 $r \ll \min(d, k)$ ， r 是实验过程设置的低秩。训练过程中冻结参数 W_0 ，仅训练 A 和 B 中的参数。如图 3-2 所示， h 为训练完整参数，对于 $h = W_0 x$ ，前向传播过程变为：

$$h = W_0 x + \Delta W x = W_0 x + BA x \quad (3-2)$$

在本章微调实验中，将 LoRA 模块加入到视觉模型与语言模型的注意力层。该过程存在两个关键参数，LoRA-range 和 LoRA-rank。前者用于调整模型中哪些层可以加入 LoRA 模块，后者表示矩阵 A 和 B 的秩的大小。随着多模态数据集的增大和内容的不断复杂化，适当扩大 LoRA-range 的范围、增大 LoRA-rank 的设定值，确保模型训练得到更有信息量的参数，提高微调效果。上述调整更好地适应复杂多变的数据特征，使模型在应对不断增长的信息时能够更加灵活和准确地捕捉关键信息，从而提高模型整体性能。

3.3 Q-Former 算法设计

视觉和语言是人类感知外部环境的两种主要方式。在电力缺陷的图像文本问答中，将来自异质模态的数据融合实现视觉与语义之间的对齐是一个挑战。目前，多模态模型主要采用 Transformer 架构，能够无缝融合来自不同模态的信息到大模型的特征空间，充分发挥 Transformer 在多模态场景中的优良性能。为了进一步提高多模态模型在电力缺陷领域的表现，本章引入了基于 Transformer 架构的 Q-Former 框架，用于将电力缺陷领域的视觉模型与大型语言模型连接。Q-Former 重点提取与电力场景文本内容

最相关的视觉表征。




图 3-4 Q-Former 原理架构图

Fig. 3-4 Schematic diagram of Q-Former

Q-Former 的示意图如图 3-4 所示。Q-Former 由两个 Transformer 模块组成：图像 Transformer 和文本 Transformer，共享自注意力层。图像 Transformer 与冻结的视觉模型 ViT 交互，主要从 ViT 的输出中提取图像特征。文本 Transformer 充当编码器和解码器。在图像 Transformer 中，使用可学习的参数通过自注意力层与文本交互，并通过交叉注意力层与图像信息进行交互。此过程仅生成可学习参数长度的特征，忽略视觉主体模型的参数，显著减少计算复杂度。

在实验过程中，Q-Former 通过设定可学习参数 Learned Queries，学习电力缺陷领域中视觉特征与语义特征之间的关系。选择对比损失函数对电力缺陷领域中的视觉特征向量与语义向量进行训练，Q-Former 实现了视觉特征与语义特征的对齐，提高了模型在电力缺陷领域的图像文本问答能力。

3.4 多模态大模型构建

本工作旨在构建一个能够识别电力场景、检测缺陷并进行缺陷知识问答的技术模型。基于 VisualGLM-6B，一个开源的多模态问答大模型，支

持中英文，并已具备大量基础知识且具有较好的图像描述能力。本章选择 VisualGLM-6B 作为基础模型。VisualGLM-6B 在 CogView 数据集上进行了训练，该数据集包含 3000 万条高质量中文图像文本对和 3 亿条经过筛选的英文图像文本对。这些数据对预训练模型，使其能够理解不同语言的图像和文本信息。通过结合第 3.1 节中创建的多模态数据集，并整合第 3.2 节的 LoRA 方法和第 3.3 节的 Q-Former 方法，最终构建了 Power-VGLM。此模型减少了训练参数的数量，同时提升了其在电力缺陷领域的图像文本对话能力。Power-VGLM 的原理结构如图 3-5 所示。




图 3-5 Power-VGLM 原理图

Fig. 3-5 Schematic diagram of Power-VGLM

整体框架分为三个关键部分，包括图像模型、Q-Former 与语言模型。在图像模型方面，选择预训练好的 Vision Transformer 用于图像特征提取。ViT 通过连续多层注意力机制，捕获具有局部和全局上下文的图片信息，并生成一组图片嵌入向量。Q-Former 提取对文本内容最具信息量的视觉表示。设定一系列可学习的参数 queries，学习视觉特征和语义特征之间的联

系，并通过训练视觉特征向量与语义向量的对比损失函数，实现了对齐视觉特征与语义特征的目标。然后，将 Q-Former 输出的特征输入到语言模型中，确保模型具有动态调整适应性和强大的学习能力。大语言模型 ChatGLM-6B 接收来自 Q-Former 的信息，包括语义信息的图片嵌入向量和问题（prompt）文本的嵌入向量。ChatGLM-6B 输出包含视觉信息的文字回答，从该文字回答中提取语义嵌入向量。该语义向量再次进入 Q-Former 部分，计算视觉特征向量与语义嵌入向量之间的对比损失，进一步对齐视觉特征和语义特征。主体设计旨在有机结合图像和文字信息，为后续任务提供细致和全面的输入特征，提高模型在复杂场景下的性能表现。

对于跨模态学习，在文本侧，ChatGLM-6B 模型检索文本侧 CLS 令牌，其包含具有全局语义特征向量。对于多模态数据集中每个电力图像中的每个查询 query，计算与文本侧 CLS 令牌的余弦相似度，并选择对应于最大余弦相似度的 query。该过程将图像与文本表示对齐，最大化它们的相互信息。获得的 query 用于基于图像的文本生成，其中该 query 和文本 CLS 标记为正训练样本，而所有其他对应关系被视为负样本。余弦相似度计算公式定义为公式 3-3。

$$\cos(C, D) = \frac{C \cdot D}{\|C\| \|D\|} \quad (3-3)$$

在公式 3-3 中， C, D 是两个向量， $\|C\|$ 和 $\|D\|$ 分别表示 C 和 D 的范数。向量 C 和 D 的内积如公式 3-4 所示。

$$C \cdot D = \sum_{i=1}^n c_i d_i \quad (3-4)$$

在公式 3-4 中， n 表示两个向量的维数， c_i 和 d_i 表示它们各自的元素。内积计算包括两个向量的元素相乘，然后是所有乘积的总和。公式 3-5 定义了训练期间使用的损失函数。

$$L = -\log \frac{\exp(\cos(q, k^+) / \tau)}{\exp(\cos(q, k^+) / \tau) + \sum_{j=1}^{K^-} \exp(\cos(q, k_j^-) / \tau)} \quad (3-5)$$

在公式 3-5 中， τ 是温度超参数，是一个标量， k^+ 和 k_j^- 表示正负样本，

q 表示上述提到的 query, K^- 是负样本的数量。

在本实验中,选择训练充分、具备丰富知识的视觉模型 Vision Transformer 与大语言模型 ChatGLM-6B。将 LoRA 模块加入到视觉模型与语言模型的注意力模块中。为了规避大量参数的再训练可能导致微调环境难以实现,并确保不影响已经完善的视觉检测和语义对话功能,冻结模型主体参数,仅对 LoRA 和 Q-Former 中的参数进行训练,这样有效地保留并调整关键部分的权重,满足在特定任务中的需求,同时最大程度地利用原模型的丰富知识,提高模型的适用性和性能。该策略有助于避免对整个模型进行耗时的重新训练,同时确保了实验的最终效果。

3.5 数据与实验

3.5.1 数据介绍

本研究涵盖了与电力行业相关的四个场景:输电、变电、配电和安全监控(安监)。拍摄的图像内容复杂,大多数是从高空使用无人机拍摄的,少部分是从地面拍摄的,分辨率均为 4500×3000 像素。输电、变电和配电场景的前景包括各种电力设备,如输电塔、电线杆、架空线路和电表。背景则包括自然景观,如天空、田野、山脉、河流和道路。主要任务是检测缺陷,如绝缘子破损,鸟巢异物等。安全监控场景的特点是存在工作人员,主要任务是确定他们是否佩戴了安全帽。图 3-6 展示了这四个典型场景的样本。

为了支持本章讨论的电力场景识别和缺陷检测等智能巡检识别任务,创建了一个多模态数据集。该数据集包括图像、提示和标签,涵盖了输电、变电、配电和安监等场景。训练图像的数量如表 3-1 所示,其中包括 13 种输电领域缺陷、7 种变电领域缺陷、13 种配电领域缺陷和 2 种安监领域缺陷。表 3-2 是一个纯对话数据集,后续有介绍。根据 3.1 节设计的基于 YOLO 的多模态数据集制作方法,得到了表 3-3 中的结果。

其次,本工作收集了一系列关于电力缺陷检测的规则手册,提供了对各种电力缺陷类型的详细解释,包括常见的缺陷类型,如绝缘子破损、防震装置锈蚀以及塔上的鸟巢等。提取了相关的知识文本,重点关注电力场

景中的重要缺陷类型。从互联网上获取了常规的电力知识，涵盖了电力设备、电力场景和电力安全的通用常识。经过初步筛选，确保其真实性后，编制了一套全面的电力知识文本。该数据集主要包括五类：一般电力知识、输电缺陷知识、配电缺陷知识、变电缺陷知识和安监缺陷知识。这些知识资源帮助电力专业人员更好地理解缺陷的类型和特征。使用 Chat-GPT 和开发的自动化处理脚本，对问答格式的语义数据进行了处理，包括删除冗余信息、修改不流畅的句子，并根据类别进行组织。数据集的分布如表 3-2 所示。



图 3-6 电力领域数据集展示

Fig. 3-6 Four types of scene datasets

构建的训练数据集采用多模态格式，包括图像、提示和标签。主要的训练目标是将提示与标签对齐。通过这种方法，当提出与电力缺陷领域相关的提示时，模型生成的答案可以尽可能与本章预先建立的领域特定知识标签对齐。这有助于减少模型生成结果的随机性，并提高模型回答的专业性和准确性。

表 3-1 多模态数据集训练集和测试集数量

Table 3-1 Multimodal dataset training and testing set quantities

类别	输电	变电	配电	安监
训练数量	1000	1000	1000	1000
测试数量	100	100	100	100

表 3-2 电力缺陷知识训练和测试集数量

Table 3-2 Power defect knowledge training and testing set quantities

类别	电力知识	输电	配电	变电	安监	总量
训练数量	100	100	100	100	100	500
测试数量	30	30	30	30	30	150

表 3-3 多模态数据集样例

Table 3-3 Multimodal dataset examples

图片	Prompt	Label
	这是一张什么场景的图片？ 请描述以下这张图片。	这是一张输电场景图片。图中描绘有输电铁塔正常，鸟巢异物，大金具-联扳正常，防重锤锈蚀等。
	这是一张什么场景的图片？ 请描述以下这张图片。	这是一张变电场景图片。图中描绘有表计破损，表计污秽等。
	这是一张什么场景的图片？ 请描述以下这张图片。	这是一张配电场景图片。图中描绘有杆塔正常，熔断器正常，绝缘子破损等
	这是一张什么场景的图片？ 请描述以下这张图片。	这是一张安监场景图片。图中描绘有工人，不戴安全帽。

3.5.2 评估指标

本章研究了大型模型的评估指标，重点关注基于大语言模型的视觉语言模型。通常，大型语言模型通过自动和人工评估进行评估。自动评估方法使用计算机算法和生成的指标来快速评估模型性能。常见的指标包括 BLEU^[79]、ROUGE^[80]和 BERTScore^[81]，这些指标基于测试集与真实答案之间的相似性。人工评估则依赖于专家的主观判断和评估，提供更详细和深入的分析。由于视觉模型可能会产生幻觉，即两张相似的图像在不同提

问方式下可能会导致截然不同的答案，甚至在同样的提问下回答也不相同，并且缺陷检测任务只需要答案中的关键词和问题匹配，因此对模型输出的完整句子与完整的真实答案的相似度比较可能无法反映实际情况。因此，本章选择了一种精心设计的人工评估方法作为主体评价方法，BLEU 和 ROUGE 作为辅助评价指标。首先介绍下设计的人工评估策略。为了公平评估本章提出的多模态大模型与其他模型的有效性，电力缺陷描述的评估分为两个步骤：电力场景分类和电力缺陷描述。在本研究中， $P_{\text{场景分类}}$ ， $P_{\text{电力缺陷}}$ 与 $P_{\text{缺陷知识}}$ 分别是衡量图片场景分类、电力缺陷的识别以及电力缺陷知识问答的平均准确度，计算公式如公式(3-6)、(3-7)和(3-8)所示。三个评估指标，范围为 0 到 1。

$$P_{\text{场景分类}} = \frac{n_{\text{场景}}}{N_{\text{场景}}} \quad (3-6)$$

$$P_{\text{电力缺陷}} = \frac{n_{\text{电力缺陷}}}{N_{\text{电力缺陷}}} \quad (3-7)$$

$$P_{\text{缺陷知识}} = \frac{n_{\text{缺陷知识}}}{N_{\text{缺陷知识}}} \quad (3-8)$$

在上述公式中， $n_{\text{场景}}$ ， $n_{\text{电力缺陷}}$ 和 $n_{\text{缺陷知识}}$ 分别表示正确分类的场景、正确捕获的缺陷和正确回答的缺陷知识问答的测试样本数量， $N_{\text{场景分类}}$ ， $N_{\text{电力缺陷}}$ 和 $N_{\text{缺陷知识}}$ 分别表示场景分类、缺陷捕获和缺陷知识问答的测试样本总数。由于大模型生成的结果具有一定的随机性和多样性，可能会导致结果描述的差异，因此制定了三条规则来定义模型在场景分类、缺陷识别和缺陷知识问答中的正确性：

(1) 在场景分类阶段，正确的情况定义为：大型模型的回答内容应包括与输电、变电、配电、安全监控及其相关描述的描述，并且应与图像中的场景类别一致。

(2) 在缺陷识别阶段，类别识别率定义为大模型识别的缺陷类别数量与图像中存在的总类别数量的比率。设置了四个类别识别率阈值，分别为 25%、50%、75% 和 100%。较高的阈值表示大模型需要识别图像中更完整的缺陷类别。当大模型的类别识别率大于或等于阈值时，视为正确，否

则视为错误。

(3) 在知识问答阶段, 正确的响应定义为: 大型模型提供的内容应准确描述与输电、变电、配电、安全监控等相关的问题, 否则视为错误。

3.5.3 实验参数设计

实验的硬件配置包括 Intel(R) Core(TM) i9-10900X 处理器、16 GB DDR4 内存和 NVIDIA GTX1066 显卡, 运行 Linux 操作系统的台式计算机。实验平台使用 PyTorch 框架。训练过程如下: 使用 ViT 和 ChatGLM-6B 的预训练模型权重初始化网络。加入 LoRA 模块, 层数从 0 到 27。Q-Former 连接 ViT 和 ChatGLM-6B, 学习率设置为 0.001, 批量大小设置为 1。

3.5.4 模型实验

首先, 本研究调查并评估了常用的多模态大型模型。模型被输入一张图像, 并被提问: “这是一张什么场景的图片? 请描述以下这张图片。”表 3-4 展示了图像和文本的测试结果, 表 3-5 以数值量化形式展示了结果。本章的调研和测试显示, VisualGLM-6B 在电力场景分类中表现最佳。因此, 本工作选择 VisualGLM-6B 作为基线模型。

为了验证第 3.1 节中提出的多模态数据集, 评估第 3.2 节中描述的 LoRA 微调算法的有效性, 并评估 Power-VGLM 在识别电力场景、检测缺陷和处理缺陷相关问答方面的能力, 本章进行了一系列实验。实验使用表 3-3 中的电力缺陷领域特定的多模态数据集, 并采用融合 LoRA 的 Q-Former 微调算法进行训练。实验中, LoRA-range 没有进行广泛测试, 固定在 0-27, 本工作设置了相对较高的层数, 从 0 到 27, 为了更好地学习到大量新的电力领域知识。关于 LoRA-rank, 本工作设置了一组不同参数的实验。

在测试过程中, 模型通过单轮对话形式进行测试。模型被输入一张图像, 并被提问: “这是一张什么场景的图片? 请描述以下这张图片。”

表格 3-6 是不同 LoRA-rank 值设置的结果, 当 LoRA-rank 设置为 12 时, 电力场景分类与缺陷检测准确率最高, 因此, 本工作选取 LoRA-rank 为 12 作为后续实验参数设置。表 3-7 是 Power-VGLM 模型和 VisualGLM-6B 的图像-文本问答测试结果。表 3-8 展示了对 400 张图像进行的图像-文本描述测试结果。表 3-9 展示了电力缺陷知识问答的结果, 表 3-10 详细展示

了 150 个问题的缺陷知识问答量化测试结果。表 3-11 展示了 Power-VGLM 和 VisualGLM-6B 的 BLEU-4 分数。表 3-12 展示了 ROUGE-L 分数对比。

表 3-4 不同多模态大模型调研测试结果

Table 3-4 Investigation and test results of different multi-modal large models

输入图片	
输入问题	这是一张什么场景的图片？请描述一下这张图片。
Ground truth	这是一张输电场景的图片，它描绘了防鸟刺，破损的绝缘子，和锈蚀的防震锤。
VisualGLM-6B	这张图片描绘了一个美丽的自然场景，一座高耸的输电塔位于田野之间。它由许多金属结构和玻璃组成，构成了一个独特的景观。周围是茂密的树木和广阔的草原，仿佛置身于大自然的怀抱之中。人们可以感受到一种宁静与和谐的氛围。
Mini-GPT4	这是一张城市街道的图片。你可以看到许多人在行走，有许多汽车和公共交通工具。城市的建筑物和树木也可以看到。
InstructBLIP	这幅图展示了一个位于农村地区中央的高层建筑的俯瞰图。建筑周围有绿色的田野和树木，为照片提供了一幅风景如画的背景。
LLaVA-v1.5-13B	这张图片是一个空拍的飞行视角，展示了一个巨大的电塔和一片空旷的农田。电塔高耸入云端，横跨整个场景，显示出它的庞大和壮观。农田占据了大部分画面，呈现出一片荒凉的景象，没有任何人或建筑物可见。

表格 3-5 模型图文描述测试定量结果表

Table 3-5 Quantitative results table for model Text-Image description testing

Model	$P_{\text{场景分类}}$	$P_{\text{电力缺陷}}$			
		25%	50%	75%	100%
VisualGLM-6B	23.25%	15.25%	13%	11%	5%
Mini-GPT4	15.75%	31%	24.25%	20.75%	9.75%
InstructBLIP	14.25%	29%	21.25%	20.25%	9.25%
LLaVA-v1.5-13B	15.25%	28.25%	23.75%	19.75%	9.25%
LLaVa-med	14.75%	27%	21.75%	16.25%	8%

3.5.5 实验分析与讨论

在测试常见多模态大模型时，观察到它们的答案存在冗余和范围过广的问题。观察表 3-4，例如，VisualGLM-6B 在场景识别方面表现良好，有效地描述了“高耸的输电塔”，但在描述具体电力设备方面缺乏细节。Mini-GPT4 将一片麦田误认为行人，错误地将场景识别为“城市街道”。InstructBLIP 的回答仅提到“高楼”和无关的“绿色田野和树木”，缺乏任何电力相关的描述。LLaVA-v1.5-13B 识别出了“电力塔”，并提供了总体上可接受的背景描述，但其回答过于冗余，且未包含“输电”等关键术语。

表格 3-6 不同 LoRA-rank 设置下的图文描述测试定量结果表

Table 3-6 Table of quantitative results for Image-Text captioning tests under different LoRA-rank settings

LoRA-rank	$P_{\text{场景分类}}$	$P_{\text{电力缺陷(50%)}}$
4	80.5%	40.5%
8	88%	47.50%
12	90.5%	50.75%
16	89%	50.25%
20	87%	46%

表 3-7 模型测试结果

Table 3-7 Model testing results


输入图片	
输入问题	这是一张什么场景的图片？ 请描述以下这张图片。
Ground truth	这是一张输电场景的图片，它描绘了防鸟刺正常，破损的绝缘子，和锈蚀的防震锤。
Power-VGLM(ours)	这是一张输电场景图片，图中描绘有输电塔正常，绝缘子破损，防鸟刺正常。
VisualGLM-6B	这张图片描绘了一个美丽的自然场景，一座高耸的输电塔位于田野之间。它由许多金属结构和玻璃组成，构成了一个独特的景观。周围是茂密的树木和广阔的草原，仿佛置身于大自然的怀抱之中。人们可以感受到一种宁静与和谐的氛围。

表 3-8 模型测试量化结果

Table 3-8 Quantitative results of model testing

Model	$P_{\text{场景分类}}$	$P_{\text{电力缺陷}}$			
		25%	50%	75%	100%
Power-VGLM(ours)	90.5%	60.25%	50.75%	31.75%	14.75%
VisualGLM-6B	23.25%	15.25%	13%	11%	5%

表格 3-9 电力缺陷知识问答结果

Table 3-9 Power defect knowledge question-answering results

问题	VisualGLM-6B	Power-VGLM(ours)
电力场景一般包括那些？	电力场景通常包括输电塔、电线和电缆，以及周围的景色。在乡村中，树木环绕着这些设备，为它们提供了自然的背景。此外，输电塔的高耸身姿可以吸引人们的目光，并产生独特的美感。	电力场景一般包括输电、变电、配电与安监场景。
输电场景有哪些缺陷？	输电场景存在的缺陷包括电缆老化、线路损坏和自然灾害等。电缆的老化会导致其电阻增加，从而影响电力传输效率；线路损坏则可能导致断路或短路等问题，危及设备和人员的安全。	输电场景缺陷包括杆塔类缺陷、附属设置类缺陷、接地装置类缺陷、绝缘子缺陷、大尺寸金具类缺陷、小金具类缺陷等。
输电场景中，大尺寸金具类缺陷有哪些？	大尺寸金具类缺陷是指在输电线路中常见的问题，如金具过大或过小、安装位置不当等。	大尺寸金具类缺陷包括防振锤滑移、防振锤偏斜、防振锤锈蚀、悬垂线夹偏移等。

表格 3-10 电力缺陷知识问答量化结果

Table 3-10 Quantitative results of power defect knowledge question-answering

Model	$P_{\text{缺陷知识}}$
Power-VGLM(ours)	61.33%
VisualGLM-6B	34.67%

表格 3-11 BLEU-4 分数对比

Table 3-11 BLEU-4 score comparison

Model	BLEU-4
Power-VGLM(ours)	0.4203
VisualGLM-6B	0.1526

表格 3-12 ROUGE-L 分数对比

Table 3-12 ROUGE-L score comparison

Model	Precision	Recall	F1
Power-VGLM(ours)	0.41	0.39	0.40
VisualGLM-6B	0.10	0.09	0.10

相比之下，观察表 3-7，本工作微调后的模型 Power-VGLM 在场景识别和相关描述方面表现出更高的准确性。它不仅正确识别了“输电场景”，还提供了图像中电力设备和缺陷的详细描述，如“绝缘子破损”和“防鸟刺正常”。微调后的多模态大型模型显著提高了场景识别和相关缺陷描述的精度，大大减少了不相关的背景信息。

观察表 3-7，Power-VGLM 提供了更规范和准确的答案。表 3-8 显示，Power-VGLM 在电力场景分类中的准确率达到 90.5%，并且在各种阈值下的缺陷检测中显著优于基线模型。这表明本研究中采用的多模态数据集和微调方法是有效的。表 3-9 表明，使用电力缺陷知识问答数据集进行微调后，相对于基线模型的答案，Power-VGLM 显然更合理准确，减少了大量冗余。表 3-10，表 3-11，表 3-12 的结果表明，与基线模型相比，电力缺陷知识问答准确率提高了 26% 以上。

综合实验结果和分析，Power-VGLM 在电力场景分类、电力缺陷检测和缺陷知识问答方面显著优于基线模型和常见的多模态大型模型。

3.6 本章小结

鉴于电力领域缺陷检测中场景的复杂性和缺陷类型的多样性，手动缺陷检测具有挑战性。现有的深度学习算法模型虽然多样，但交互性有限，从而限制了其改进。利用多模态大型模型帮助电力从业人员识别电力场景和缺陷，可以提高工作效率，提升电力巡检智能化。针对多模态大型模型参数庞大、训练困难以及缺乏领域图文知识等问题，本章提出了一种基于多模态大模型微调的电力缺陷图文问答技术。使用 YOLOv8 创建电力缺陷领域描述的多模态数据集，显著节省了时间和精力，并丰富了模型的电力领域图文知识。使用 LoRA 和 Q-Former 方法对语言和视觉模型进行微调，构建了电力多模态大模型 Power-VGLM。该模型在文本和视觉之间实现了

有效对齐，并在识别电力缺陷领域方面超越了许多现有的大模型。

总的来说，提出的多模态大模型在识别电力场景、缺陷检测和缺陷知识问答方面表现良好，优于许多常见的多模态大模型。该模型在一定程度上可以帮助电力从业人员在电力缺陷领域的工作，展示了多模态大型模型在实际应用中的潜力。

第4章 基于扩散模型的电力数据扩展方法

多模态大模型的性能高度依赖于大规模、高质量的标注数据，而电力缺陷图像数据集的正样本数量受限，难以支撑大模型的有效学习，导致其在复杂电力场景中的识别能力受限。因此，单纯依赖模型优化难以进一步提升识别效果，亟需从数据层面进行优化。近年来，扩散模型在数据生成与增强领域展现出巨大潜力，能够有效提升数据集的规模和多样性。为此，本章提出了一种基于扩散模型的电力数据扩展方法，旨在通过生成完整的包含电力缺陷的，并且多样化的电力场景图像，增强 Power-VGLM 的智能识别能力。本章基于扩散模型，利用多模态大模型 Qwen-VL-Max^[82,83]提取电力缺陷图片的关键语义特征^[84]，结合初始 Prompt，增添 ControlNet 与 Canny 算法以控制局部缺陷轮廓，从而精准调控生成图像的内容和质量。实验结果表明，该方法显著提高了电力领域数据集的生成质量和多样性，并有效增强了 Power-VGLM 在电力图像智能识别任务中的能力。




图 4-1 基于扩散模型的电力数据扩展方法流程框架

Fig. 4-1 A process framework for power data extension based on diffusion model

4.1 基于扩散模型的电力数据扩展方法

4.1.1 LDMs 技术原理

扩散模型近年来在图像生成和数据增强领域取得了显著进展。其核心思想是通过一个前向过程逐步将数据转化为噪声，再通过一个反向过程从噪声中恢复出数据。前向过程通过逐步添加高斯噪声，将原始数据分布转

化为一个简单的噪声分布；反向过程则通过学习噪声的逐步去除，从噪声中恢复出高质量的数据样本。扩散模型在图像生成任务中表现出色，能够生成高质量且多样化的图像，尤其适用于数据稀缺的场景。

在本章中，采用 LDMs 作为电力场景数据扩展的基础算法模型。先将通过变分自编码器（Variational Autoencoder, VAE）将图像转换到低维的潜在空间，再在潜在空间进行扩散过程，最后通过 VAE 解码器恢复为图像，提高生成效率和质量。

首先，VAE 将数据 x 编码到潜在空间，表示为潜在变量 z_0 ，公式表示为 4-1。

$$z_0 = E(x) \quad (4-1)$$

在公式 4-1 中， $E(x)$ 是 VAE 的编码器， z_0 是潜在空间的图像表示。然后，在潜在空间中进行扩散，公式表示为 4-2：

$$q(z_t | z_0) = N(z_t; \sqrt{\beta_t} z_0, (1 - \beta_t)I) \quad (4-2)$$

在公式 4-2 中，与基础扩散模型的像素空间扩散类似，但计算量更小， q 是数据在时间步 t 的条件概率分布， N 为正态分布， β_t 为噪声调度参数，控制每个时间步添加的噪声量，一般在 0 到 1 之间变化。 I 是单位矩阵，表示各维度噪声相互独立。接下来，从噪声中去噪还原潜变量，如公式 4-3 所示。

$$p_\theta(z_{t-1} | z_t) = N(z_{t-1}; \mu_\theta(z_t, t), \sum_\theta(z_t, t)) \quad (4-3)$$

在公式 4-3 中， $p_\theta(z_{t-1} | z_t)$ 表 z_t 到 z_{t-1} 的转移概率， μ_θ 和 $\sum_\theta$ 为神经网络预测的均值和协方差矩阵，最终可以得到生成后的 z_0 。然后，通过 VAE 解码器恢复图像，如公式 4-4 所示。

$$\hat{x} = D(z_0) \quad (4-4)$$

在公式 4-4 中， D 是 VAE 的解码器， $\hat{x}$ 是生成的图片。

4.1.2 多模态大模型提示词生成

为了确保生成的电力场景图像具有多样性和相关性，本工作尝试引入多模态大模型来生成有效的提示词。多模态大模型能够理解图像和文本之

间的关系，并生成与电力场景相关的文本描述。这些文本描述作为扩散模型的输入额外提示词，能够引导模型生成与电力设备、场景和缺陷相关的图像。

首先，选择多模态大模型 Qwen-VL-Max 来提取电力图像的视觉特征。使用 Qwen-VL-Max 对图像进行图文描述，并结合 Prompt 工程，生成与图像内容相关的文本提示词。这些提示词不仅包含场景的整体描述，还涵盖电力设备的具体细节，从而有效引导扩散模型生成高质量的电力场景图像。如图 4-2 所示，Qwen-VL-Max 可以提取出大部分图片的特征，包括颜色，形状和背景等。




图 4-2 Qwen-VL-Max 提取图像视觉特征简单示例

Fig. 4-2 Qwen-VL-Max Extracts Image Visual Features Simple Example

其次，为了进一步提升提示词的准确性，Qwen-VL-Max 提取的视觉特征要与初始图片特征（如“绝缘子破损”）进行合理拼接，并通过大模型润色，从而生成高质量的 Prompt。

为了扩展提示词的多样性和丰富性，本工作利用多模态大模型的文本生成能力，生成更多的提示词变体。例如，通过调整措辞或添加更多细节，生成适应于不同场合和季节的电力场景。这些扩展的提示词能够覆盖更多的电力场景和设备类型，从而确保生成图像的多样性。

最后，对生成的提示词进行筛选和优化，确保其与电力场景高度相关，避免生成无关或低质量的图像。

4.1.3 ControlNet 与 Canny 算法控制




图 4-3 基于 ControlNet 与 Canny 边缘约束的图像生成控制流程图

Fig. 4-3 Control flow diagram of image generation via ControlNet and Canny edge constraints

为了进一步控制生成图像的局部目标轮廓，本章引入了 ControlNet 和 Canny 算法。ControlNet 是一种基于条件控制的生成模型，能够根据输入的轮廓信息生成具有特定形状和结构的图像。Canny 算法则是一种经典的边缘检测算法，能够从图像中提取出目标的轮廓信息。

图 4-3 是本小节的算法设计流程。使用 Canny 算法从现有电力场景图像中提取目标的轮廓信息。Canny 算法通过多阶段的边缘检测过程，精确提取图像中的目标轮廓。对于输电场景中绝缘子图像，Canny 算法提取出绝缘子的结构轮廓，甚至破损的形状等。将提取的轮廓信息输入到 ControlNet 中，控制生成图像的局部目标轮廓。ControlNet 通过条件控制机制，结合 LDMs 能够根据输入的轮廓信息生成具有特定形状和结构的图像。

为了进一步优化生成图像的轮廓细节，调整 ControlNet 的参数，确保生成的图像在细节上与电力设备的真实结构相符。通过调整 ControlNet 的条件控制强度，能够生成更加精细的绝缘子结构或输电塔的金属支架细节。通过 ControlNet 与 Canny 算法的结合，能够有效控制生成图像的局部目标轮廓，确保其与真实电力场景高度一致。

4.2 实验展示与分析

4.2.1 数据集介绍

本章首先选取电力场景的常见的缺陷，即“绝缘子破损”来进行设计。为了确保实验的易观察性和有效性，选取一种常见的电力缺陷情况，绝缘子破损（缺失），样例图片如图 4-3 所示，中间缺失一小块。




图 4-3 绝缘子破损样例图

Fig. 4-3 Example images of insulator damage

4.2.2 实验设置与评价指标设计

实验的硬件配置包括 Intel(R) Core(TM) i9-10900X 处理器、16 GB DDR4 内存和 NVIDIA GTX1066 显卡，运行 Linux 操作系统的台式计算机。实验平台使用 PyTorch 框架。本章在进行实验时，用的是同一个基础生图模型，模型来源于扩散模型，使用的是 LDMs 框架。本工作的方法利用预先训练的稳态扩散模型，并采用了几种技巧模块：利用多模态大模型 Qwen-VL-Max 提取生成高质量的，含有大量图片视觉细节的 Prompt，结合图像初始 Prompt，称为 QwVLP 模块；利用 ControlNet 和 Canny 算法局部控制生成图片主体轮廓，本章设定称为 ConCan 模块；

本工作的目标是根据已有的图片生成主体变化不大的，完整的，多样性的图片。为了准确的评估生成图片质量，本工作用下面两个指标：

（1）电力研究者主观评价；电力研究者分析和评价 1000 组生成的图片，主要包括评判图片是否完整包括电力器件和缺陷，如果都合格即为正确，其中之一不合格为错误。

（2）实际应用效果；生成的图片，制作成多模态数据集，添加到多模态大模型 Power-VGLM 微调数据集中，观察大模型的效果有无提升。

4.2.3 对比试验

考虑到电力领域图片生成方面的研究还比较缺乏，本章选择了三种相关的常见图像生成方法进行对比分析：（1）Text-conditional Latent Diffusion Models 是一种最常见的以文本作为条件，生成符合文本描述的图像，本章记为 Text-LDMs。（2）Image-conditional Latent Diffusion Models，是以一张或多张图像作为条件，生成与条件图像相关的图像，本章记为 Img-LDMs。

（3）Image-conditional Latent Diffusion Models with ControlNet，以图片作为条件，结合 ControlNet 作为输入，本章记为 Img-LDMs-ControlNet。

图 4-4 直观地比较了本工作提出的方法和其他常见方法，一般分为文本引导和图像引导的图像合成。Text-LDMs 是基于文本引导扩散模型方法，没有使用电力缺陷图片作为底图生成，而是纯文生图，可以看出图片色泽和真实度还不错，但是生成出的不是常见的绝缘子破损，也证明了该扩散模型纯文字提示很难出现绝缘子破损的图片。另一类方法是基于图像引导的图像合成，Img-LDMs 是基于图片引导扩散模型方法，本工作种是添加文本和图像向量作为共同提示来控制生成，看出图片生成质量跟样例图有很大差异，但是图片的整体构图，主体物体的方向是上下指向，与 Text-LDMs 相比，和样例图结构更相似。Img-LDMs-ControlNet 是结合 ControlNet 模块，图片为 ControlNet 输入信息，可以得出，生成的绝缘子和样例图相似度较高，但细致观察，可以发现绝缘子的形状多样，表面不规整，有条纹，不够像样例图一样平滑，总体细节不够相似。本工作的方法保持了绝缘子整体的轮廓和破损位置的样子，绝缘子表面的平滑细节，保证了背景的重绘效果。表 4-1 与 4-2 中的定量比较结果也进一步说明了

本工作方法的有效性性。




图 4-4 常见算法对比效果展示

Fig. 4-4 Comparative effectiveness display of common algorithms

表 4-1 电力专业人员评估量化表

Table 4-1 Quantitative evaluation table by power professionals

方法	主观评价合格率
Text-LDMs	1.1%
Img-LDMs	7.3%
Img-LDMs-ControlNet	34.8%
Ours	71.3%

4.2.4 消融试验

在本小节，设置各种单一模块实验验证本工作不同模块的重要性：（1）直接修改基础 LDMs 模型，使用图像和文本作为输入信息，作为 Base。（2）为了分别评估 QwVLP 和 ConCan 对效果的影响，本章在基础上，构建单一模块进行实验。消融实验的结果如图 4-5 所示。观察 ConCan 模块实验，相对于 Base，绝缘子整体的轮廓绘制控制的更像原图，已经有大致的轮廓。观察 QwVLP 模块，相对于 Base，轮廓形状有提升，并且绝缘子的纹理更细致，整体更清晰且细节更多。融合两个模块的结果展示出轮廓更相似，绝缘子特征更明显，细节掌握的更好的特点。




图 4-5 消融实验结果图

Fig. 4-5 Ablation experiment results

本章在此方法上进行了大量实验，尝试生成不同背景的绝缘子破损图片，主要操作是修改初始 Prompt 中环境的部分，结合 Qwen-VL-Max 来丰富细节。实验制作出多样性的图片集，拓展了多模态大模型在电力领域的图文知识。该过程生成的图片集如图 4-6。



图 4-6 生成的多样性背景的电力图片集

Fig. 4-6 Power image dataset with diverse backgrounds

为了判断生成电力数据是否有效，本工作对先前构建的电力多模态大模型 Power-VGLM 进行微调实验。准备两批训练数据集，第一批数据集是 500 张真实图片，包含常见的绝缘子破损 400 张，正常的绝缘子 100 张，记为数据集 Nor，第二批数据集是该工作生成的 400 张破损绝缘子和 100 张正常的绝缘子组成，本章记为 AII。测试集为真实的 70 张常见破损的绝

缘子图片，30 张正常的绝缘子图片。微调设计和先前中的实验相同，为了实验过程和结果更加清晰，规定一张图片中最多只有一个绝缘子，无其他设备缺陷。评价规则和方法也与先前实验的 $P_{\text{电力缺陷}}$ 相同。实验结果如表格 4-2。

表 4-2 模型测试结果
Table 4-2 Model testing results

Model	$P_{\text{电力缺陷}}$
Power-VGLM	53%
Power-VGLM + Nor	63%
Power-VGLM + AII (ours)	62%
Power-VGLM + Nor + AII (ours)	72%

4.2.5 实验总结

观察表 4-1，可以得出，本工作构建的生图技术制作的“绝缘子破损”电力图片，完整性和有效性明显高于常见生图方案。观察表 4-2，本工作构建 Power-VGLM 在利用 AII 数据集微调后的电力缺陷识别率达到了和利用真实 Nor 数据集几乎持平的效果，在同时加入 Nor 和 AII 数据集之后，效果也是明显的提升，证明了本工作生成的数据集对于多模态大模型微调训练的有效性。

4.3 本章小结

针对电力缺陷数据难以采集、正样本数量少以及电力多模态大模型对数据量要求高等问题，难以支撑大模型的有效学习，导致其在复杂电力场景中的识别能力受限。单纯依赖模型优化难以进一步提升识别效果，亟需从数据层面进行优化。近年来，扩散模型在数据生成与增强领域展现出巨大潜力，能够有效提升数据集的规模和多样性。

本章提出了一种基于扩散模型的电力数据扩展方法，主要利用多模态大模型 Qwen-VL-Max 提取电力缺陷图片的关键语义特征，结合初始 Prompt，增添 ControlNet 与 Canny 算法以控制局部缺陷轮廓，从而精准调控生成图像的内容和质量。实验结果表明，该方法显著提高了电力领域数

数据集的生成质量和多样性，并有效提升了构建的多模态大模型 Power-VGLM 在电力设备缺陷检测中的学习能力，提高了模型智能识别能力。

总体而言，本章提出的电力数据扩展方法通过生成包含电力缺陷的多样化电力场景图像，有效扩充了电力领域数据集的规模与多样性，为多模态大模型提供了更为丰富的图文知识。

第5章 总结与展望

5.1 总结

本研究围绕着多模态大模型技术在电力领域的识别应用，研究了多模态大模型以及生图技术的方法，并针对大模型现有领域知识不足，参数大难以训练，图文难以对齐以及电力领域缺陷数据正样本少，难以大量获取等问题提出了两种创新性的技术方案：基于多模态大模型微调的电力图像智能识别技术和基于扩散模型的电力数据扩展方法。研究的主要目的是利用多模态大模型跨模态图文问答技术，提升电力巡检图像识别任务智能化，包括识别场景和缺陷。通过结合大模型微调优化与数据扩展增强，构建了“生成-标注-训练”的闭环技术体系。

首先，提出了一种基于多模态大模型微调的电力图像智能识别技术，构建了电力多模态大模型 Power-VGLM。首先，利用 YOLOv8 自动构建电力缺陷多模态数据集，以增强模型在电力领域的图文知识表达能力；然后，融合 LoRA 和 Q-Former，对多模态大模型进行参数高效微调，以降低计算开销并提高模型的视觉与语义的对齐能力；最后，通过实验验证模型在电力场景中的智能识别能力，并与相近参数规模下的主流多模态大模型进行对比。实验结果表明，本文提出的技术在电力图像智能识别任务上具有更优的准确率。

其次，提出了一种基于扩散模型的电力数据扩展方法。其旨在通过生成完整的包含电力缺陷的，并且多样化的电力场景图像，增强 Power-VGLM 的智能识别能力。本方法基于扩散模型，利用多模态大模型 Qwen-VL-Max 提取电力缺陷图片的关键语义特征，结合初始 Prompt，增添 ControlNet 与 Canny 算法以控制局部缺陷轮廓，从而精准调控生成图像的内容和质量。实验结果表明，该方法显著提高了电力领域数据集的生成质量和多样性，并有效增强了 Power-VGLM 在电力图像智能识别任务中的能力。

总体而言，本文的研究为多模态大模型在电力领域的智能识别任务提供了一个重要案例，不仅实现了跨模态交互与识别，还为其他行业在应用多模态大模型方面提供了参考和技术支持。

5.2 展望

未来的研究可从以下几个方面深入探索：首先，本文的 Power-VGLM 模型基于 6b 参数的大模型，随着大模型技术的进步，可以选择更大规模的基础模型，以提升模型对电力领域复杂场景和设备的处理能力。这将有效增强模型的知识储备和推理能力，提升其在电力图像智能识别中的表现。

其次，Prompt 工程在大模型应用中的重要性日益突出。未来的研究可以专注于优化 Prompt 设计，通过精细化的 Prompt 提示，提升大模型在电力场景中的实际应用效果。特别是在无需微调的情况下，通过合理设计 Prompt 来引导模型更准确地识别电力设备和缺陷，进一步提升模型的效果和泛化能力。

最后，数据集的扩展仍是关键挑战。为了提高模型的智能识别能力，需要构建更加多样化和精准的电力图像与文本数据集。未来可通过增强图文问答数据集的多样性，涵盖不同电力场景、设备类型及季节变化，来提升模型在多变环境下的适应性。同时，结合人工智能辅助标注等方式，快速高效地构建大规模标注数据集，将为模型训练提供重要支持。

综上所述，未来的研究应聚焦于大模型规模的提升、Prompt 优化以及数据集扩展，以进一步推动电力领域图像识别技术的发展。这将为电力智能识别系统提供 stronger 的推理能力，并为其他行业的多模态大模型应用提供借鉴。

参考文献

- [1] 庞博, 鲍志远, 杨明坤, 等. 基于 YOLOv5 的电力巡检图像缺陷识别研究 [J]. 四川电力技术, 2022, 45 (05): 48-53+94.
- [2] 王越. 输配电改革下电力企业成本核算体系研究[D]. 重庆大学, 2022.
- [3] 李朋磊. 基于深度学习的电力绝缘子缺陷检测与多缺陷分类研究[D]. 郑州轻工业大学, 2023.
- [4] 梁基重, 晋涛, 牛曙等. 基于 EMD-FFT 特征提取的 GIS 机械缺陷诊断方法研究 [J]. 电力科学与技术学报, 2023, 38 (03): 216-223.
- [5] 张珂, 王静, 邵健伟, 等. 变电站巡检机器人老旧表计识别性能提升 [J]. 电力安全技术, 2023, 25 (09): 55-59.
- [6] 吕强, 王伟, 马国强, 等. 电力设备巡检缺陷图像智能识别技术研究 [J]. 安徽师范大学学报(自然科学版), 2022, 45 (06): 545-552.
- [7] 周琪. 试论输配电及用电工程线路的安全运行措施 [J]. 模具制造, 2023, 23 (11): 286-288.
- [8] 许文涛. 基于无人机影像深度学习算法的输电线路缺陷智能识别技术研究 [J]. 机电信息, 2023, (20): 85-88.
- [9] 向昕玥. 电力作业违规行为的图像识别技术研究[D]. 湖南大学, 2022.
- [10] 赵春昊, 陈敏刚, 徐斯颖, 等. 自然语言处理系统测评及标准化研究 [J]. 信息技术与标准化, 2023, (10): 48-56+63.
- [11] 刘静, 郭龙腾. GPT-4 对多模态大模型在多模态理解、生成、交互上的启发 [J]. 中国科学基金, 2023, 37 (05): 793-802.
- [12] Croitoru F A, Hondru V, Ionescu R T, et al. Diffusion models in vision: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(9): 10850-10869.
- [13] Zhao Z, Liu N, Wang L. Localization of multiple insulators by orientation angle detection and binary shape prior knowledge [J]. IEEE Transactions on Dielectrics & Electrical Insulation, 2016, 22(6): 3421-3428.
- [14] Zhai Y, Wang D, Zhang M, et al. Fault detection of insulator based on saliency and adaptive morphology[J]. Multimedia Tools and Applications, 2017, 76: 12051-12064.
- [15] Wu Q, An J, Lin B. A texture segmentation algorithm based on PCA and global minimization active contour model for aerial insulator images [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2012, 5(5): 1509-1518.
- [16] Lowe D G. Object recognition from local scale-invariant features[C]//Proceedings of the

- seventh IEEE international conference on computer vision. IEEE, 1999, 2: 1150-1157.
- [17] Dalal N, Triggs B. Histograms of oriented gradients for human detection; proceedings of the 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05), F, 2005 [C]. IEEE.
- [18] 徐洪学, 汪安祺, 杜英魁, 等. 深度学习的基本模型及其应用研究[J]. 长春师范大学学报, 2020, 39(12): 47-54, 93.
- [19] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems, London, 2012: 1097-1105.
- [20] 臧国强, 刘晓莉, 徐颖菲, 等. 深度学习在电力设备缺陷识别中的应用进展[J]. 电气技术, 2022, 23(6): 1-7.
- [21] 金昊, 康宇哲, 齐希阳, 等. 基于 Faster R-CNN 的高压电线缺陷检测方法[J]. 计算机应用, 2019, 39(增刊 2): 97-102.
- [22] Liang H, Zuo C, Wei W. Detection and evaluation method of transmission line defects based on deep learning [J]. IEEE Access, 2020, 8: 38448-38458.
- [23] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [24] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [25] 罗潇, 於锋, 彭勇. 基于深度学习的无人机电网巡检缺陷检测研究[J]. 电力系统保护与控制, 2022, 50(10): 132-139.
- [26] 徐晓敏, 朱晓峰, 李江成, 等. 基于智能图像识别的无人机电力线路安全巡检方法[J]. 电力大数据, 2023, 26(2): 10-16.
- [27] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [28] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [29] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.
- [30] Li J, Li D, Xiong C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//International Conference on Machine

- Learning. PMLR, 2022: 12888-12900.
- [31] Li J, Li D, Savarese S, et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models[J]. arXiv preprint arXiv:2301.12597, 2023.
- [32] Zhu D, Chen J, Shen X, et al. Minigpt-4: Enhancing vision-language understanding with advanced large language models[J]. arXiv preprint arXiv:2304.10592, 2023.
- [33] Liu H, Li C, Li Y, et al. Improved baselines with visual instruction tuning[J]. arXiv preprint arXiv:2310.03744, 2023.
- [34] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. arXiv preprint arXiv:2304.08485, 2023.
- [35] VisualGLM (2023). <https://github.com/THUDM/VisualGLM-6B>.
- [36] Liao H, Shen H, Li Z, et al. Gpt-4 enhanced multimodal grounding for autonomous driving: Leveraging cross-modal attention with large language models[J]. Communications in Transportation Research, 2024, 4: 100116.
- [37] Zhou Y, Huang L, Bu Q, et al. Embodied understanding of driving scenarios[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 129-148.
- [38] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. arXiv preprint arXiv:2106.09685, 2021.
- [39] Mao J, Qian Y, Ye J, et al. GPT-driver: Learning to drive with gpt[J]. arXiv preprint arXiv:2310.01415, 2023.
- [40] Tian X, Gu J, Li B, et al. Drivevlm: The convergence of autonomous driving and large vision-language models[J]. arXiv preprint arXiv:2402.12289, 2024.
- [41] Wang R, Duan Y, Lam C T, et al. Ivygpt: Interactive Chinese pathway language model in medical domain[C]//CAAI International Conference on Artificial Intelligence. Singapore: Springer Nature Singapore, 2023: 378-382.
- [42] Wang R S, Zhou R Z, Chen H M, et al. WangRongsheng/ CareGPT[DB/OL]. [2024-04-12]. <https://github.com/WangRongsheng/CareGPT>.
- [43] Xiong H, Wang S, Zhu Y, et al. Doctorglm: Fine-tuning your Chinese doctor is not a herculean task[J]. arXiv preprint arXiv:2304.01097, 2023.
- [44] Nguyen H T. A brief report on lawgpt 1.0: A virtual legal assistant based on gpt-3[J]. arXiv preprint arXiv:2302.05729, 2023.
- [45] Huang Q, Tao M, Zhang C, et al. Lawyer llama technical report[J]. arXiv preprint arXiv:2305.15062, 2023.
- [46] Huang L, Yu W, Ma W, et al. A survey on hallucination in large language models: Principles,

- taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.
- [47] Chakraborty N, Ornik M, Driggs-Campbell K. Hallucination detection in foundation models for decision-making: A flexible definition and review of the state of the art[J]. ACM Computing Surveys, 2025, 57(7): 1-35.
- [48] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [49] Shen Y, Luo P, Yan J, et al. Faceid-gan: Learning a symmetry three-player gan for identity-preserving face synthesis[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 821-830.
- [50] Wang X, Guo H, Hu S, et al. Gan-generated faces detection: A survey and new perspectives[J]. ECAI 2023, 2023: 2533-2542.
- [51] Zhang X, Wang X, Shi C, et al. De-gan: Domain embedded gan for high quality face image inpainting[J]. Pattern Recognition, 2022, 124: 108415.
- [52] 唐贤伦, 杜一铭, 刘雨微, 等. 基于条件深度卷积生成对抗网络的图像识别方法[J]. 自动化学报, 2018, 44(5): 855-864.
- [53] 张承圣, 邵振国, 陈飞雄, 等. 基于条件深度卷积生成对抗网络的新能源发电场景数据迁移方法[J]. 电网技术, 2021, 46(6): 2182-2189.
- [54] Adler J, Lunz S. Banach wasserstein gan[J]. Advances in neural information processing systems, 2018, 31.
- [55] Cao J, Mo L, Zhang Y, et al. Multi-marginal wasserstein gan[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [56] Bouallegue G, Djemal R. EEG data augmentation using Wasserstein GAN[C]//2020 20th International Conference on Sciences and Techniques of Automatic Control and Computer Engineering (STA). IEEE, 2020: 40-45.
- [57] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 4401-4410.
- [58] Karras T, Laine S, Aittala M, et al. Analyzing and improving the image quality of stylegan[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 8110-8119.
- [59] Sauer A, Schwarz K, Geiger A. Stylegan-xl: Scaling stylegan to large diverse datasets[C]//ACM SIGGRAPH 2022 conference proceedings. 2022: 1-10.

- [60] Tov O, Alaluf Y, Nitzan Y, et al. Designing an encoder for stylegan image manipulation[J]. ACM Transactions on Graphics (TOG), 2021, 40(4): 1-14.
- [61] Saxena D, Cao J. Generative adversarial networks (GANs) challenges, solutions, and future directions[J]. ACM Computing Surveys (CSUR), 2021, 54(3): 1-42.
- [62] Tian K, Jiang Y, Yuan Z, et al. Visual autoregressive modeling: Scalable image generation via next-scale prediction[J]. Advances in neural information processing systems, 2024, 37: 84839-84865.
- [63] Van Den Oord A, Kalchbrenner N, Kavukcuoglu K. Pixel recurrent neural networks[C]//International conference on machine learning. PMLR, 2016: 1747-1756.
- [64] Chen X, Mishra N, Rohaninejad M, et al. Pixelsnail: An improved autoregressive generative model[C]//International conference on machine learning. PMLR, 2018: 864-872.
- [65] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [66] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.
- [67] Borji A. Generated faces in the wild: Quantitative comparison of stable diffusion, midjourney and dall-e 2[J]. arXiv preprint arXiv:2210.00586, 2022.
- [68] Zhang Z, Zhang Q, Li G, et al. DyArtbank: Diverse artistic style transfer via pre-trained stable diffusion and dynamic style prompt Artbank[J]. Knowledge-Based Systems, 2025, 310: 112959.
- [69] Zhang L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 3836-3847.
- [70] Shao M, Meng L, Qiao Y, et al. Latent code augmentation based on stable diffusion for data-free substitute attacks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025.
- [71] Yao Y, Duan J, Xu K, et al. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly[J]. High-Confidence Computing, 2024: 100211.
- [72] Xiang J, Wang X, Zhang X, et al. A vision-language foundation model for precision oncology[J]. Nature, 2025: 1-10.
- [73] Wu J, Gan W, Chen Z, et al. Multimodal large language models: A survey[C]//2023 IEEE International Conference on Big Data (BigData). IEEE, 2023: 2247-2256.

- [74] Zhang X, Zhang X, Yu Y. ChatGLM-6B fine-tuning for cultural and creative products advertising words[C]//2023 International Conference on Culture-Oriented Science and Technology (CoST). IEEE, 2023: 291-295.
- [75] 刘学博,户保田,陈科海,等. 大模型关键技术与未来发展方向——从 ChatGPT 谈起 [J]. 中国科学基金, 2023, 37 (05): 758-766.
- [76] 张铮,刘晨旭. 大模型幻觉: 人机传播中的认知风险与共治可能 [J]. 苏州大学学报(哲学社会科学版), 2024, 45 (05): 171-180.
- [77] Canny J. A computational approach to edge detection[J]. IEEE Transactions on pattern analysis and machine intelligence, 1986 (6): 679-698.
- [78] Li C, Wong C, Zhang S, et al. Llava-med: Training a large language-and-vision assistant for biomedicine in one day[J]. Advances in Neural Information Processing Systems, 2023, 36: 28541-28564.
- [79] Reiter E. A structured review of the validity of BLEU[J]. Computational Linguistics, 2018, 44(3): 393-401.
- [80] Schluter N. The limits of automatic summarisation according to rouge[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Association for Computational Linguistics, 2017: 41-45.
- [81] Zhang T, Kishore V, Wu F, et al. Bertscore: Evaluating text generation with bert[J]. arXiv preprint arXiv:1904.09675, 2019.
- [82] Wang P, Bai S, Tan S, et al. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution[J]. arXiv preprint arXiv:2409.12191, 2024.
- [83] Bai J, Bai S, Yang S, et al. A versatile vision-language model for understanding, localization, text reading, and beyond[J]. arXiv preprint arXiv:2308.12966, 2023.
- [84] Qwen-VL-Max(2024). <https://github.com/QwenLM/Qwen-VL>.