

基于 GRULLaMA 大模型的配电网运行状态 智能感知推演方法及应用

白晨阳¹, 倪天¹, 梅沁¹, 刘星晔¹, 陈烨², 王传君²

(1. 无锡广盈集团有限公司科技分公司创新研究院, 江苏 无锡 214000 ;

2. 南京工程学院计算机工程学院, 江苏 南京 211167)

摘要:针对新型源荷资源接入导致的配电网多源不确定性、多模态数据融合及状态推演难题,本文提出一种融合物理信息神经网络、时序建模、图卷积网络和多模态推理的 GRULLaMA 架构。通过构建 GRULLaMA 的多层次模块,实现电类量测、非电类气象/社会数据及碳类政策等多模态数据的时空特征融合。结合电力系统物理约束条件,构建数据驱动的配电网状态智能推演模型;并基于强化学习策略和正则化技术提升模型泛化能力和预测精度。仿真实验结果表明,相较于传统统计学方法和单一神经网络方法,该方法在源荷预测任务中的平均误差从 8.5% 降低至 2.8%,风险预判准确率从 83.5% 提升至 94.7%,转供操作时间从 2 小时减少至 5 分钟以内,有效提升了新型电力系统配电网智能化运行水平。

关键词:配电网;GRULLaMA;多模态融合;状态推演;物理信息神经网络

中图分类号:TM73

文献标志码:A

开放获取

文章编号:2096-4633(2025)10-0022-13

DOI:10.19317/j.cnki.1008-083x.2025.10.003

随着全球能源转型的深入推进和我国“碳达峰、碳中和”战略目标的提出,建设以新能源为主体的新型电力系统已成为电力行业发展的必然趋势^[1]。作为连接输电网与用户的重要纽带,配电网正面临着前所未有的技术挑战和发展机遇^[2]。海量分布式光伏、储能系统、电动汽车充电桩等新型源荷资源的接入,使得传统配电网从单向潮流的被动网络转变为双向潮流的主动网络^[3]。

配电网智能感知技术的发展可以追溯到 20 世纪 90 年代的配电自动化系统建设^[4]时期。早期的研究主要集中在基于 SCADA 系统的状态监测和故障定位技术^[5]。进入 21 世纪后,随着智能电网概念的提出,配电网状态估计和负荷预测技术得到了快速发展^[6-7]。然而,传统方法主要基于确定性模型

和统计学理论,难以有效处理新能源接入带来的随机性和间歇性问题^[8]。

近年来,人工智能技术在电力系统中的应用日益增多^[9]。深度学习方法(如循环神经网络、卷积神经网络等)在电力负荷预测、设备状态诊断等方面取得了显著成效^[10-11]。图神经网络技术的兴起为处理电网拓扑结构信息提供了新的思路^[12]。为科学计算领域带来了革命性变化^[13]。大语言模型(如 GPT、LLaMA 等)在自然语言处理和多模态理解方面展现出强大能力^[14-15]。然而,现有研究在配电网运行状态感知方面仍存在一些不足:首先多源异构数据融合能力不足,难以充分利用电类、非电类和碳类数据的协同价值^[16];其次缺乏对配电网物理约束的深度融合,预测结果可能违反电力系统基本定律。

基金项目:国网江苏省电力有限公司省管产业科技项目(JCWX2025014)。

Project supported by the State Grid Jiangsu Electric Power Co., Ltd. Provincial Management Industry Science and Technology Project (JCWX2025014)




图 1 总体框架

Fig.1 Overall framework

针对上述技术挑战,本文提出一种基于 GRULLaMA 融合大模型的配电网运行状态智能感知与推演方法^[17-19]。首先对电气类、非电气类及碳排放类等多模态数据进行统一建模与特征融合;鉴于各类数据在结构、语义和时空特性上的显著差异,然后采用差异化处理模块分别提取其多时空尺度下的关键特征,并通过特征融合模块引入多层次注意力机制,实现异构特征的深度融合,最终输出高精度的配电网状态推演结果。本方法的模型整体架构由两部分构成:模型管理与服务层和智能体与工具层。

本文主要创新贡献包括:构建融合时序建模(GRU)、图卷积神经网络(GCN)、多模态推理(LLaMA)和物理信息处理(PINN)的多模态深度学习架构;设计多层次注意力机制和物理约束优化策略;建立面向多业务场景的智能应用体系;在实际电网数据上验证了方法的有效性。

1 配电网运行状态数据采集与预处理

1.1 数据来源

本研究采用的配电网多源异构数据主要来源于多个业务系统,具体如下:

设备参数:来源于设备台账管理系统,包括线路阻抗参数、变压器容量、短路阻抗、额定电流等铭牌参数。

拓扑结构数据:包括静态拓扑信息和开关状态信息两部分。静态拓扑信息来源于生产管理系统,

涵盖线路走向、变压器连接关系、母线结构等固定连接关系;开关状态信息来源于配电自动化系统(DAS)的遥信数据,包括分段开关、联络开关及断路器的实时分合状态。基于上述两类数据,可动态构建节点邻接矩阵。

电气量测数据:来源于配电自动化系统与用电信息采集系统,包括各节点的有功/无功功率、电压、电流等实时量测值,采样间隔为 15 分钟。

非电气监测数据:来源于在线监测系统,包括变压器温度、环境温湿度、局部放电等状态监测量。

潮流与网损数据:基于实时量测数据,采用前推回代法计算各支路潮流分布和线路损耗,计算频率与量测数据同步更新。

1.2 数据采集与预处理组件

为提升配电网感知推演大模型在配电网状态智能感知与推演方面的精度,亟需构建高质量的多模态数据训练样本集。该样本集中的多模态数据可按类别划分为三类:电气类数据、非电气类数据以及碳类数据。

1.2.1 电气类数据

电气类数据是配电网状态推演的核心数据来源,其准确性、时效性和完整性直接决定了模型的可靠性和泛化能力。可从某电力企业电力数据中台获取变电站监测系统、配网自动化系统、智能电表与终端设备、分布式能源接入监测装置等数据,数据来源及内容见表 1。

表 1 电气类数据采集

Tab. 1 Electrical data collection

数据来源	主要数据项
变电站监测系统	实时电压、电流、有功、无功功率、功率因数。
配网自动化系统	配电线路的负荷数据、潮流计算结果、开关状态
智能电表与终端	用户侧电压、电流、功率、功率因数、电能质量
分布式能源接入监测装置	光伏、风电等分布式能源的发电功率、并网电压、电流波动

依据采集数据特性分析结果,将所采集数据分类别存储在不同类别数据库中并进行数据预处理操作,操作内容见表 2。

表 2 数据预处理操作

Tab. 2 Data preprocessing operations

类型	操作内容
时间对齐	基于 ISO8601 标准,对不同数据来源时间戳至标准时间格式
缺失值处理	基于线性插值、KNN、深度学习填补方法,修复丢失的数据点
异常值检测	利用统计方法、机器学习等多种方法进行异常值检测去除
数据标准化	对不同数据单位做归一化处理,提高模型训练效果
数据交叉验证	对比 SCADA、故障录波器的数据,验证采集数据一致性
历史数据比对	利用长期存储数据进行趋势分析,避免异常跳变

1.2.2 非电气类数据

为增强 GRULLaMA 大模型对配电网运行所处外部环境及社会经济因素的理解,进一步提升其状态推演精度与泛化能力,需系统性采集非电气量数据。在数据采集过程中,应融合供电区域的重要性等级信息,并据此对不同区域所获取的非电气量数据赋予差异化权重,以体现区域间在负荷特性、敏感性和保障优先级等方面的差异。

根据其影响配网状态的方式,归纳出表 3 的参数。

表 3 非电气类参数

Tab. 3 Non-electrical parameters

数据类别	数据内容
气象条件	温度、湿度、风速与风向、降水量、雷暴频率、太阳辐射强度、空气污染指数
地理信息	土地利用类型、建筑密度
用电行为	人口密度、产业结构
社会事件	节假日、大型体育赛事/演唱会/展会、突发灾害

通过定期离线导入方式,采集政府公告、新闻网站、社交媒体热点信息,获取节假日安排、大型活动计划、自然灾害、突发疫情等重大事件信息。数据来源及内容见表 4。

表 4 非电气类数据采集

Tab. 4 Non-electrical data collection

数据来源	数据内容
边缘设备感知	气象类数据采集
国网地理信息	配网地形、建筑密度、土地利用类型
政府网站	人口密度、城镇化率、产业结构、GDP 增长率
政府公告、新闻网站、社交媒体热点	节假日安排、大型活动计划、突发疫情等重大事件

由于非电气类数据种类多,内容繁杂,且大多数为非结构化数据,进行如表 5 所示的数据预处理操作。

表 5 非电气类数据预处理

Tab. 5 Non-electrical data preprocessing

预处理项	预处理内容
数据清洗	处理缺失值(插值、均值填充等)及纠正异常值(Z-score、箱线图分析等)
数据对齐	时序数据进行时间戳对齐
数据结构化	定义关键词,提取关键信息,形成键值对,以 json 格式存储,便于后续调用训练

1.2.3 碳类数据

碳类数据主要包括各级政府政策法规及电力市场机制现行规则,均对区域电网运行模式及负荷调

度优化有重要影响。包括:碳排放政策(限额/碳交易价格)、峰谷电价政策、电力市场机制。

通过定期分析政府政策文件、碳排放政策、分析电力交易中心数据获取上述信息,并由数据清洗、数据对齐、数据增强、数据结构化完成数据预处理操作,采用离线导入方式进行数据导入。

2 模型管理与服务层

2.1 GRULLaMA 模型结构

本文提出的 GRULLaMA 模型由四个核心模块组成:物理信息处理(PINN)模块、时序建模(GRU)模块、图卷积神经网络(GCN)模块和多模态推理(LLaMA)模块。各模块协同工作,实现对配电网运行状态的高精度感知与智能推演。

1) 物理信息处理(PINN)模块

PINN 模块通过将电网基本物理规律嵌入神经网络训练过程,确保预测结果的物理合理性。该模块主要包含功率平衡、电压、线路容量等物理约束条件。

功率平衡约束:

$$\sum_{i=1}^N P_{\text{gen},i} - \sum_{j=1}^M P_{\text{load},j} - \sum_{k=1}^L P_{\text{loss},k} = 0 \quad (1)$$

电压约束:

$$V_{\min} \leq |V_i| \leq V_{\max}, \forall i \in N \quad (2)$$

线路容量约束:

$$|I_{ij}| \leq I_{\max,ij}, \forall (i,j) \in L \quad (3)$$

其中, $P_{\text{gen},i}$ 为发电功率, $P_{\text{load},j}$ 为负荷功率, $P_{\text{loss},k}$ 为网损功率, V_i 为节点电压, I_{ij} 为线路电流。

将电网基本物理规律(如功率平衡、电压电流关系)嵌入神经网络训练,即利用神经网络对配网电流、电压等电气量进行短期推演,其训练过程还结合实际拓扑与运行特性反馈修正 GRULLaMA 大模型参数,从根本上保障推演的物理合理性。基本结构如图 2 所示。




图 2 物理信息神经网络

Fig. 2 Physics-based information neural networks

2) 时序建模(GRU)模块

专门处理配电网时序数据,通过门控机制捕捉时间依赖性。

$$\text{更新门: } z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad (4)$$

$$\text{重置门: } r_t = \sigma(W_r \cdot [h_{t-1}, x_t]) \quad (5)$$

聚焦电网时序数据(历史负荷、电流电压等)的时间依赖性,借助门控机制(更新门控制信息保留、重置门控制历史遗忘)迭代提取高价值特征,实现对分钟级波动、小时级趋势等多时空尺度状态的精准预测,为状态演化提供时间维度的关键支撑,基本结构如图 3 所示。




图 3 门控神经网络 (GRU)

Fig. 3 Gated neural networks

3) 图卷积神经网络(GCN 模块)

GCN 模块处理配电网拓扑结构信息,通过消息传递机制聚合邻域特征。

$$\mathbf{H}^{(l+1)} = \sigma \mathbf{D}^{-\frac{1}{2}} \mathbf{A} \mathbf{D}^{-\frac{1}{2}} \mathbf{H}^{(l)} \mathbf{W}^{(l)} \quad (6)$$

其中, $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}_N$ 为添加自环的邻接矩阵, $\tilde{\mathbf{D}}$ 为度矩阵, $\mathbf{H}^{(l)}$ 为第 l 层的节点特征矩阵。

以多馈线组静态拓扑图为输入,通过消息传递机制融合节点与边特征,将局部拓扑状态的空间影响传递至全局,深度刻画配网拓扑结构对状态的空

间关联效应,基本结构如图 4 所示。




图 4 卷积神经网络 (GCN)

Fig. 4 Graph convolutional neural network (GCN)

4) 多模态推理 (LLaMA 模块)

LLaMA 模块采用 Transformer 架构处理非结构化文本数据。

多头注意力机制:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(h_{\text{end},1}, \dots, h_{\text{end},h})W^Q \quad (7)$$

其中,

$$h_{\text{end},i} = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (8)$$

注意力计算:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (9)$$

专注于处理天气预报、节假日政策、碳交易规则等非电气类、碳类非结构化数据,形成多源异类信息的统一表征,为优化方案制定提供更全面的外部环境信息输入,基本结构如图 5 所示。




图 5 LLaMA 神经网络

Fig. 5 LLaMA neural network

2.2 数据类型及定义

1) 电气状态推演数据

包含配电网各节点和支路的电气量预测结果。节点电压预测给出未来时刻各母线的电压幅值和相角,支路电流预测提供各条线路的电流大小和方向,功率潮流预测则输出线路上的有功和无功功率分布。这些数据需满足电压在额定范围内、电流不超过热稳定限值等物理约束条件。

2) 多馈线组优化运行拓扑

输出最优的网络运行方式和开关配置方案。开关状态矩阵 S_{switch} 表示各开关的分合状态(0 表示断开,1 表示闭合),网络连接矩阵 A_{topology} 描述节点间的电气连接关系,联络线配置 L_{tie} 给出推荐的联络运行方式。系统自动寻找网损最小、电压分布最优的拓扑结构。

3) 负荷与电源预测数据

预测各节点的负荷需求和电源出力。包括用户侧的有功、无功负荷功率预测,分布式光伏、风电等新能源的发电功率预测,以及储能系统的充放电功率预测。这些预测考虑了天气、节假日、用电习惯等多种影响因素。

4) 风险预警数据

量化配电网运行中的各类风险。设备过载风险分四个等级:正常、关注、预警、危险,电压越限概率 P_{voltage} 计算节点电压超出安全范围的可能性,设备健康度 $H_{\text{equipment}}$ 评估变压器、开关等设备的运行状态。系统能提前 24~72 小时预警潜在风险。

5) 决策支持数据

为运行人员提供具体的操作建议。调度操作建议给出开关的具体操作序列和时机,负荷转移方案 T_{load} 指明故障时的供电恢复路径,维护计划建议 M_{maint} 基于设备状态预测提出最佳维护时间窗口。所有建议都经过安全性和经济性校验。通过上述推演数据,系统实现从被动监控到主动预测的转变,为配网调度、馈线组协调、负荷优化、故障预警等业务场景提供全方位的智能决策支持。

2.3 模型架构设计

为实现技术目标,GRULLaMA 大模型采用分层架构设计,各层次由独立模块协作完成配电网状态推演任务,具体包括数据输入层、模块化处理层、多时空尺度多模态特征融合层和输出层。模型结构如图 6 所示。




图 6 GRULLaMA 大模型结构图

Fig. 6 Structure diagram of the GRULLaMA large model

1) 数据输入层

物理信息神经网络(PINN)模块负责将配电网物理约束深度融合到数据驱动模型中。该模块的输入数据包括所有与配电网物理运行相关的量测和参数,具体包含节点电压幅值、有功/无功功率、支路电流、线路阻抗以及变压器变比等电气量数据,而非电气量的设备状态监测数据(如温度、局放)不纳入此模块处理。输入数据首先进行标准化处理,采用 Min-Max 归一化将不同物理量映射到 $[0,1]$ 区间,按式(10)归一化。

$$x_{\text{scaled}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (10)$$

其中, $x_{\min}$ 和 $x_{\max}$ 分别为历史数据的最小值和最大值,这一步骤确保了不同量纲的物理量在神经网络训练中具有相同的数值尺度。

2) 模块化处理层

在边界条件设置方面,本文考虑配电网运行的三类物理边界约束。一是电源节点边界条件,主变压器高压侧电压设为已知恒定值,功率平衡方程在该节点自动满足。二是负荷节点边界条件,已知量测的负荷节点功率注入 P 和 Q 作为边界条件施加。三是支路约束边界,线路电流不得超过热稳定极限,变压器容量不得超过额定容量。这些边界条件通过损失函数中的边界损失项强制满足,见式(11)。

$$\begin{cases} P_i = \sum_{j \in N(i)} V_i V_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij}) \\ Q_i = \sum_{j \in N(i)} V_i V_j (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij}) \end{cases} \quad (11)$$

其中, V_i 为节点电压幅值, θ_{ij} 为节点间相角

差, G_{ij} 和 B_{ij} 分别为导纳矩阵的实部和虚部。

3) 特征融合层

物理关系表达是 PINN 的核心,本文将配电网潮流方程作为偏微分方程(PDE)约束嵌入网络训练过程。具体而言,对于任意节点 i ,其功率平衡方程表示为多时空尺度多模态特征融合层融合各模块输出,实现时空与多源信息的深度整合。具体处理过程共有三个步骤。

步骤 1: 计算各子模块数据特征值

多模态注意力融合中首先通过自注意力机制计算各子模块数据特征的 Query, Key, Value。

$$Q_m = W_m^T H_m, K_m = W_m^K H_m, V_m = W_m^V H_m \quad (12)$$

其中, Q_m 表示各子模块数据特征第 m 个模态的特征矩阵, Q_m^T, W_m^K, W_m^V 为可训练参数。 $M \in \{\text{GRU}, \text{GCN}, \text{PINN}, \text{LLaMA}\}$

本文将来自不同子模块(GRU、GCN、PINN、LLaMA)的输出特征均视为独立模态。每个模态对应不同的数据来源、结构特征及统计分布。为统一建模,本研究将其记为第 m 个模态的特征矩阵 H_m ,并为其学习独立的 Query、Key、Value 映射矩阵 W_m^T, W_m^K, W_m^V ,从而在多模态注意力框架下实现跨模态信息的动态融合。

步骤 2: 计算各模态数据间注意力权重

$$a_{i,j} = \frac{\exp(Q_i K_j^T)}{\sum_j \exp(Q_i K_j^T)} \quad (13)$$

其中, $a_{i,j}$ 为不同模态间注意力权重。

步骤 3: 计算其他模态的影响

以电网拓扑特征数据(GCN)为主导模态,计算其他模态对他的影响。

$$H_{\text{fusion}} = H_{\text{GCN}} + \sum_{m \neq \text{GCN}} a_{\text{GCN},m} H_m \quad (14)$$

其中, H_{fusion} 为融合多模态数据特征。

4) 输出层

根据输入信息、输出配网状态推演数据,如多馈线组优化运行拓扑等,为配网调度、馈线组协调、负荷优化及故障预警等提供智能决策支持。接收多时空尺度多模态特征融合层的输出特征 H_{fusion} ,通过多个专门的预测头生成配网状态推演数据。具体实现过程如式(15):

$$\begin{aligned} Y_{\text{pred}} &= f_{\text{output}}(H_{\text{fusion}}) \\ &= \{Y_{\text{voltage}}, Y_{\text{current}}, Y_{\text{topology}}, Y_{\text{risk}}\} \end{aligned} \quad (15)$$

其中,各输出分量通过专门的全连接网络生成:

$$\begin{cases} Y_{\text{voltage}} = W_v H_{\text{fusion}} + b_v \\ Y_{\text{current}} = W_i H_{\text{fusion}} + b_i \\ Y_{\text{topology}} = \sigma(W_t H_{\text{fusion}} + b_t) \\ Y_{\text{risk}} = \text{softmax}(W_r H_{\text{fusion}} + b_r) \end{cases} \quad (16)$$

其中, W_v 、 W_i 、 W_t 、 W_r 分别为各任务特定网络的权重矩阵; b_v 、 b_i 、 b_t 、 b_r 分别为各任务特定网络的偏置向量, $\sigma(\cdot)$ 为激活函数, 用于拓扑优化; Softmax 也为激活函数, 用于风险评估。

2.4 源荷预测模块设计

源荷预测是 GRULLaMA 模型的核心应用之一, 直接利用多时空尺度多模态特征融合层输出的融合特征 H_{fusion} 进行精准预测。该模块专门针对配电网中的电源出力和负荷需求进行建模, 实现多时间尺度的预测能力。

2.4.1 预测模型输入设计

源荷预测模块以前文 1.3.3 节中的融合特征 H_{fusion} 作为主要输入, 该特征已经融合了 GRU 模块提取的时序特征、GCN 模块提取的拓扑空间特征、PINN 模块的物理约束信息以及 LLaMA 模块处理的非结构化多模态数据。具体输入构成如式(17):

$$\text{Input}_{\text{source-load}} = \{H_{\text{fusion}}, T_{\text{horizon}}, M_{\text{metadata}}\} \quad (17)$$

其中, H_{fusion} 为多模态融合特征, T_{horizon} 为预测时间范围参数, M_{metadata} 为辅助元数据(包括节点类型、设备容量等静态信息)。

2.4.2 分层预测架构

基于的丰富特征, 源荷预测模块采用分层预测架构, 包括负荷预测分支和电源预测分支。负荷预测分支专门处理用户侧负荷需求, 充分利用 H_{fusion} 中包含的历史负荷时序特征、气象数据影响、节假日社会活动等多模态信息。通过多层全连接网络将融合特征映射为各节点的负荷功率预测值。

2.4.3 电源预测架构

电源预测分支则面向配电网中分布式电源及常规电源的出力预测。该分支同样以融合特征 H_{fusion} 为主要输入, 重点利用其中包含的历史电源出力时序特征、气象与环境因素(如光照强度、风速、气温等)、运维工况信息, 以及 M_{metadata} 中的机组容量、接入位置等静态元数据。通过多层全连接网络将融合特征映射为各电源节点在不同时间尺度上的有功/无功出力预测值, 实现对光伏、风电等间歇性电源以及可控电源的统一建模与预测。为保证源荷预测结果的一致性, 电源预测分支的输出可与负荷预测分

支共同纳入功率平衡约束或联合损失函数中进行协同优化。

3 智能体与工具层

配电网运行状态感知推演系统的智能体与工具层包括五个应用组件: 配网健康度评估模块、多层次风险预警模块、多馈线组供电单元转供方案制定模块、停电计划校核及配网主动保障模块。

3.1 配网健康度评估模块

本文提出一种基于 GRULLaMA 模型推演结果的配网健康度评估方法。以大模型输出的配网状态推演数据为基础输入, 综合拓扑结构、运行工况、设备特性等多维度指标, 构建健康度评估体系并实现配网健康度的精准量化。

3.1.1 数据输入

1) 电气状态推演数据输入

节点电压预测序列: 用于计算电压偏差率和电压稳定性指标。

支路电流预测序列: 用于评估线路负载率和过载风险。

功率潮流分布: 用于分析功率传输能力和网损水平。

2) 设备状态推演数据输入

变压器负载率预测: 反映变压器运行状态和剩余容量。

设备健康度预测: 量化设备老化程度和故障风险。

开关动作频次预测: 评估开关设备的寿命损耗情况。

3) 拓扑结构推演数据输入

网络连接关系: 描述实时拓扑结构和连通性。

联络线运行状态: 评估网络冗余备用能力。

孤岛风险分析: 基于拓扑分析的安全性评估。

3.1.2 综合量化分析方法

1) 物理层指标量化体系

(1) 设备健康度综合评分

将变压器、电缆、开关等各类设备的健康状况进行加权综合。变压器健康度主要考虑负载率、温升情况和绝缘状态; 负载率超过 80% 开始扣分; 温升超过 65℃ 扣分。电缆健康度重点关注绝缘老化指数和载流能力退化情况。开关设备则侧重动作寿命损耗和接触电阻变化。

(2) 拓扑结构强度评估

基于 N-1 校验通过率、孤岛节点比例和联络线冗余度三维度,量化网络结构健壮性。N-1 校验通过率衡量网络安全裕度,即模拟每条线路停运后系统的供电能力;孤岛节点比例反映网络连通性;联络线冗余度体现备用转供能力。拓扑强度综合考虑这三个维度,形成网络结构健壮性的整体评价。

2) 运行层指标量化体系

(1) 供电质量评估

基于模型预测的电压序列,计算电压偏差率(偏离额定值的程度)、谐波畸变率和短时电压骤降频次。结合负载预测结果,评估馈线正向负载率的合理性、反向负载裕度的充足性,以及负载分布的连续性与均衡性。

(2) 可靠性量化分析

利用设备健康度预测结果和历史故障统计,推演各设备的故障率变化趋势。结合网络拓扑和负荷分布,计算平均停电时长和供电可靠率指标。通过时序分析识别可靠性的薄弱时段和关键风险点。

3.1.3 健康度综合评估模型

多层次权重融合机制将物理层和运行层指标按照不同权重进行融合,形成配网承载健康度总分。根据运行场景动态调整权重设置:正常期侧重运行层指标;在恶劣天气期提高物理层权重;在重大活动保电期则更关注运行层表现。

3.1.4 健康度量化评估算法

1) 基于 H_{fusion} 的综合健康度计算

配网承载健康度评估直接利用 GRULLaMA 模型输出的融合特征 H_{fusion} 和各项预测结果,构建多维度健康度量化模型。系统将健康度分解为设备健康度、运行健康度和结构健康度三个维度。

$$H_{\text{total}} = w_1 \cdot H_{\text{equipment}} + w_2 \cdot H_{\text{operation}} + w_3 \cdot H_{\text{structure}} \quad (18)$$

其中,权重系数根据运行场景动态调整:正常期 $w_1 = 0.3, w_2 = 0.5, w_3 = 0.2$;恶劣天气期 $w_1 = 0.5, w_2 = 0.3, w_3 = 0.2$;重大活动保电期 $w_1 = 0.2, w_2 = 0.6, w_3 = 0.2$ 。

2) 设备健康度精准计算

设备健康度基于 GRU 模块预测的设备状态参数和 PINN 模块的物理约束进行计算。对于变压器,重点考虑负载率预测、温升趋势和绝缘老化指数。

$$H_{\text{trans}} = (1 - \max(0, \frac{L_{\text{oad}} - 0.8}{0.2})) \times (1 - \max(0, \frac{T_{\text{emp}} - 65}{35})) \quad (19)$$

其中, L_{oad} 为 GRU 模块预测的负载率, T_{emp} 为温升预测值,当负载率超过 80% 或温升超过 65 °C 时开始扣分。电缆健康度主要基于绝缘老化速率和载流能力退化情况,开关设备则重点关注动作寿命损耗和接触电阻变化趋势

3) 运行健康度动态评估

运行健康度充分利用源荷预测模块的输出结果,实现供电质量和可靠性的动态评估。电压质量评估基于 GCN 模块预测的节点电压序列,计算电压偏差率和稳定性指标。

$$Q_v = \frac{1}{N} \sum_{i=1}^N \left(1 - \left| \frac{V_{\text{pred},i} - V_{\text{rated}}}{V_{\text{rated}}} \right| \right) \times (1 - C_{V,i}) \quad (20)$$

其中, $V_{\text{pred},i}$ 为第 i 个节点的预测电压, $C_{V,i}$ 为该节点电压变异系数。负载均衡度评估利用各馈线负载率预测结果,计算系统负载分布的均衡性和裕度充足性。

3.2 多层次风险预警模块

3.2.1 风险等级动态识别

基于健康度评估结果和 GRULLaMA 模型的状态推演数据,系统建立四级风险预警体系。风险等级计算融合当前健康度、变化趋势和预测偏差。

$$R_{\text{level}} = \alpha \cdot H_{\text{current}} + \beta \cdot \frac{dH}{dt} + \gamma \cdot D_{\text{pred}} \quad (21)$$

其中, $\alpha = 0.5, \beta = 0.3, \gamma = 0.2$ 为权重系数, dH/dt 为健康度变化趋势, D_{pred} 为预测偏差指标。风险等级划分:绿色 ($R_{\text{level}} > 0.8$)、黄色 ($0.6 < R_{\text{level}} \leq 0.8$)、橙色 ($0.4 < R_{\text{level}} \leq 0.6$)、红色 ($R_{\text{level}} \leq 0.4$)。

3.2.2 预警阈值自适应调整

预警阈值根据历史数据统计特性和季节性规律进行自适应调整。系统利用 LLaMA 模块处理的气象数据和社会活动信息,动态修正预警阈值:

在恶劣天气期间,设备过载预警阈值从 85% 下调至 75%;在重大活动保电期间,电压偏差预警阈值从 $\pm 5\%$ 收紧至 $\pm 3\%$ 。夏季高温期间,变压器温升预警阈值从 70 °C 下调至 65 °C。这种自适应机制确保预警系统在不同运行环境下的准确性和实用性。

3.2.3 多时间尺度预警策略

系统建立 24 小时、72 小时和 7 天三个时间尺度的预警机制。24 小时短期预警主要基于 GRU 模块的时序预测,重点关注负荷突变、设备异常等即时风险;72 小时中期预警融合气象预报和负荷趋势,提前识别恶劣天气影响和负荷高峰风险;7 天长期预警利用 LLaMA 模块的政策解读和活动规划,预判重大事件对电网的潜在影响。

3.2.4 智能预警决策支持

当系统识别到风险时,自动生成针对性地处置建议。对于设备健康度预警,系统基于设备劣化趋势预测最佳维护时间窗口;对于过载风险预警,系统调用转供优化算法生成负荷转移方案;对于电压质量预警,系统建议无功补偿调整和电压调节措施。预警信息通过多种渠道推送,包括调度席位告警、移动端推送、邮件通知等,确保运行人员能够及时响应。

3.3 多馈线组供电单元转供方案模块

3.3.1 主配网系统模型建立

基于状态推演结果制定转供方案前文节中 GRULLaMA 模型输出层生成的配网状态推演数据,为转供方案制定提供了关键的数据基础^[20],将多馈线组供电单元 DMS 的馈线开关,同主网 D5000 系统进行模型拼接,建立“主变-母线-馈线”多供电层次关系模型,以及站内母线联络关系模型、站外馈线联络关系模型。主配网系统模型如图 7 所示。




图 7 主配网系统模型拼接

Fig. 7 The main distribution network system model is spliced

3.3.2 多馈线组供电单元转供策略

由于目标设备与转供场景不同,系统主要采用两类转供策略:本层级基础带供、基于遗传算法的多层级联动优化转供。

其中,基于遗传算法的多层级联动优化转供方法针对配电网复杂转供场景,以多层次联络线路的开关状态组合为决策变量,构建网损最小化、电压偏差最小化和过载惩罚的多目标优化模型。该方法采用二进制编码方案表示开关分合状态,适应度函数

通过加权组合平衡系统网损、电压质量和设备承载能力三个关键指标,并设置违约惩罚机制确保电力系统约束条件满足。

在算法实现上,遗传操作采用锦标赛选择、单点交叉和位翻转变异策略,算法参数设置为种群大小 100、最大迭代代数 200、交叉概率 0.8、变异概率 0.01。为提升计算效率,系统采用多线程并行评估和 GPU 加速潮流计算。该算法能够同时考虑馈线级、母线级、主变级等多个层次的协调配合,相比传统逐级搜索方法,实现系统整体负荷分布的全局最优化,特别适用于大规模负荷转移和复杂故障恢复场景。当图 8 中“存在多条联络线路”判断为“N”时,说明本层级联络资源不足,流程自动跳转到“上级联络搜索”。系统按照“馈线级→母线级→主变级→跨站级”的层级递进顺序向上寻找转供路径,包括利用母线联络、主变负荷重分配或跨站支援等方式。若上级联络搜索仍无可行方案,则启动“应急预案”,如调用移动发电车、分层切负荷、申请相邻区域支援等。

本层级基础带供即通过目标线路的本层联络转移负荷,通过拓扑搜索获取目标线路的合理转供路径,优先选择负荷裕度满足要求的单一线路完成转供,按优先级规则筛选最优路径。流程图如图 8 所示。




图 8 本层级的线路带供流程图

Fig. 8 The line of this leve with a flow chart

基于遗传算法的多层级联动优化转供,通过智能优化算法实现复杂转供场景下的全局最优解。该方法将多层次联络线路的开关状态组合编码为染色体,以负荷均衡度、网损最小化、电压质量等为优化目标构建适应度函数。算法首先随机生成初始种群,每个个体代表一种开关状态组合方案;然后通过选择、交叉、变异等遗传操作不断进化。在进化过程中,系统严格校验每个方案的约束条件,包括功率平衡、电压限值、热稳定限额、网络连通性等,淘汰不满足约束的个体。经过多代迭代后,算法收敛到全局最优解,并输出最佳的多层级联动转供方案。相比传统的逐级搜索方法,该算法能够同时考虑馈线级、母线级、主变级等多个层次的协调配合,实现系统整体负荷分布的最优化。该算法特别适用于大规模负荷转移和复杂故障恢复场景,能显著提升转供方案的质量和系统运行的经济性。整体算法流程如图 9 所示。




图 9 基于遗传算法的多层级联动优化转供流程图

Fig. 9 Multi-level linkage optimization flow chart based on genetic algorithm

3.4 停电计划校核模块

基于 GRULLaMA 模型的预测能力,停电计划校核模块对计划性停电作业进行智能化校验和优化。利用负荷预测、天气预报、社会活动等多模态数据,该模块评估停电计划的合理性和影响范围。通过模拟停电期间的电网运行状态,预判可能出现的过载、电压越限等风险,并自动生成优化的停电时间

窗口和转供方案。

系统采用多约束条件校核算法,综合考虑负荷转移可行性、设备承载能力、天气条件和社会活动影响等因素多维因素,实现停电计划的精细化评估与优化。在负荷转移校核方面,系统基于 GRULLaMA 模型预测的负荷分布,对备用线路的承载能力进行验证,确保拟转移负荷不超过其安全容量。同时,时间窗口优化模块构建包含负荷影响、天气风险、社会影响和安全风险的综合目标函数,自动寻找最优停电时间窗口,最大程度降低停电影响。

智能校核流程由三个核心环节构成,比人工校核更具优势。

1) 计划解析与数据准备

自动识别停电范围与作业内容,调取相关历史运行数据、设备台账及多模态预测信息。

2) 多维度校核分析

从负荷转供能力、设备健康状态、外部环境条件及安全边界等多个维度开展联合校验。

3) 冲突识别与优化建议

一旦发现计划冲突(如容量超限、操作不可行或高风险时段),系统自动生成优化后的时间窗口建议及替代转供方案。

相较于传统依赖人工经验的校核方式,该模块能够融合更广泛的影响因子,提前识别潜在冲突,显著提升计划可行性,并将停电影响降至最低。

3.5 配网主动保障模块

配网主动保障模块实现从被动应急向主动防控的转变,基于“预测-预警-预控”三预联动机制构建全天候智能保障体系。系统利用 GRULLaMA 模型的状态推演和风险预警能力,提前识别设备老化、负荷增长、天气威胁等潜在风险,并制定预防性运维策略。其中,设备健康状态超前感知功能基于融合当前健康指标、环境参数、负荷水平及时间演化特征的劣化趋势预测模型,可实现故障发生前 24~72 小时的精准预警。

系统建立多维度风险评估矩阵,涵盖设备风险、负荷风险、天气风险、拓扑风险、运行风险和外部风险六个维度;采用 1~5 级量化评估方法计算系统综合风险等级。基于风险评估结果,系统实施分级预控机制:绿色(维持常规监测),黄色(加强监测并预置应急资源),橙色(主动调整运行方式启动预防性措施),红色(启动应急预案实施紧急保障)。智能资

源调度算法根据风险预警等级,自动匹配应急资源,在满足需求预测和时间约束的前提下,实现资源调度成本最小化。


在重大活动保电期间,系统提前 72 小时启动特级保障模式,自动生成 N-2 校验的保供方案,实时监控负荷变化并动态调整保障策略。针对恶劣天气,系统基于气象预报自动评估设备风险等级,预置抢修队伍和应急物资,启动防灾减灾预控措施。通过设备状态实时监测、负荷预测分析、应急预案智能匹配等功能,实现配网运行的主动安全管控,将故障风险消除在萌芽状态。

4 项目成效


4.1 提升源荷业务智能预测能力

通过融合 GRU 深度记忆网络对时序变化的精确建模、GNN 图神经网络对拓扑结构的空间感知能力以及 LLaMA 大模型对非结构化数据的语义理解优势,系统实现了多模态数据的协同特征提取与物理规律约束下的精准预测。

初步测试表明,相比基于统计学和单一神经网络的方法(源荷预测准确率为 92%~95%),本系统将源荷预测准确率提升至 95%~97.5%,结果如图 10(a)所示。尤其在分布式新能源高渗透率场景下,系统对光伏出力预测平均绝对百分比误差(MAPE)从传统方法的 8.5%降低至 5.2%,结果如图 10(b)所示。上述改进措施极大提升源荷业务预测的准确性、实效性和鲁棒性,为配电网精准调度和智能运维提供坚实基础。



(a) 预测准确率比较




(b) 预测误差比较

图 10 源荷业务预测精度比较


Fig. 10 Comparison of forecasting accuracy of source-load services

4.2 构建配电网健康度主动评估与风险预警体系

通过 GRULLaMA 大模型驱动的多维仿真与精准预测,实现配电网健康状态的全景式评估与动态监测,将传统被动式应对转变为数字孪生支撑下的主动预判。系统能够精准识别设备过载、谐波污染、电压偏移等潜在威胁,提前 24~72 小时预警高风险节点,实现从“事后处理”到“未雨绸缪”的事前管理模式转变。在应对重大活动保电与极端天气时,系统已实现平均故障响应时间缩短 42%,供电可靠率提升 1.28 个百分点,为配电网由被动适应向主动赋能转变提供了强大数智引擎。结果对比如图 11 所示。



(a) 风险预判准确率对比



(b) 故障响应时间对比

图 11 风险评估成效对比

Fig. 11 Comparison of risk assessment effectiveness

5 结论

本研究提出基于 GRULLaMA 大模型的配电网智能感知推演系统,通过多模态数据融合与物理约束嵌入,实现配网状态精准推演与主动决策支持。

1) 该系统融合 GRU(时序建模)、GNN(拓扑感知)、PINN(物理约束)与 LLaMA(多模态推理)四大核心模块,突破了传统模型“重数据轻物理”“重局部轻全局”的局限,这一创新架构能够实现电类、非电气类和碳排放类等多源异构数据的协同特征提取,并在物理规律约束下进行精确的状态推演,为配电网状态感知提供了“物理合理+数据可靠”的双轮驱动范式。

2) 目前,该系统已在某电网企业完成实际测试,验证了其技术可行性和实用性。特别是在以下四大核心应用场景中展示了显著的技术落地能力。提升了源荷业务智能预测能力,实现了配电网承载健康度主动评估与风险预警体系重构,提高了配电网调度调控的自动化与智能化水平。

3) 面向“双碳”目标与新型电力系统建设需求,配电网将呈现高比例新能源接入、高弹性负荷互动、高可靠性运行要求的“三高”特征。未来研究可从模型压缩与边缘部署、提高多灾害耦合推演能力、结合联邦学习技术,以及设计隐私保护机制等方面展开深入研究。

参考文献:

- [1] ACKERMANN T, ANDERSSON G, SÖDER L. Distributed generation: A definition [J]. Electric Power Systems Research, 2001, 57(3): 195-204.
- [2] PARHIZI S, LOTFI H, KHODAEI A, et al. State of the art in

research on microgrids: A review [J]. IEEE Access, 2015, 3: 890-925.

- [3] MAHMOUD M S, AZHER HUSSAIN S, ABIDO M A. Modeling and control of microgrid: An overview [J]. Journal of the Franklin Institute, 2014, 351(5): 2822-2859.
- [4] WANG H Z, LEI Z X, ZHANG X, et al. A review of deep learning for renewable energy forecasting [J]. Energy Conversion and Management, 2019, 198: 111799.
- [5] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations [J]. Journal of Computational Physics, 2019, 378: 686-707.
- [6] 张东霞, 苗新, 刘丽平, 等. 智能电网大数据技术发展研究 [J]. 中国电机工程学报, 2015, 35(1): 2-12.
ZHANG Dongxia, MIAO Xin, LIU Liping, et al. Research on development strategy for smart grid big data [J]. Proceedings of the CSEE, 2015, 35(1): 2-12.
- [7] 朱永利, 石鑫, 王刘旺. 人工智能在电力系统中应用的近期研究热点介绍 [J]. 发电技术, 2018, 39(3): 204-212.
ZHU Yongli, SHI Xin, WANG Liuwang. Recent research hotspot introduction on the application of artificial intelligence in power system [J]. Power Generation Technology, 2018, 39(3): 204-212.
- [8] 汤涌, 姚伟, 王宏志, 等. 电网仿真分析与决策的人工智能方法 [J]. 中国电机工程学报, 2022, 42(15): 5384-5406.
TANG Yong, YAO Wei, WANG Hongzhi, et al. Artificial intelligence techniques for power grid simulation analysis and decision making [J]. Proceedings of the CSEE, 2022, 42(15): 5384-5406.
- [9] 杨挺, 赵黎媛, 王成山. 人工智能在电力系统及综合能源系统中的应用综述 [J]. 电力系统自动化, 2019, 43(1): 2-14.
YANG Ting, ZHAO Liyuan, WANG Chengshan. Review on application of artificial intelligence in power system and integrated energy system [J]. Automation of Electric Power Systems, 2019, 43(1): 2-14.
- [10] 付泉泳, 秦骁, 张导, 等. 基于 GCN-Informer 模型的电力负荷短期预测 [J]. 电力大数据, 2024, 27(7): 22-34.
FU Quanyong, QIN Xiao, ZHANG Dao, et al. Short term forecasting of power load based on GCN-informer model [J]. Power Systems and Big Data, 2024, 27(7): 22-34.
- [11] 李思远, 国力, 许志元, 等. 基于多源报警信息贝叶斯网络与关联离散系数的配电网故障台区定位方法 [J]. 山东电力技术, 2024, 51(3): 45-54.
LI Siyuan, GUO Li, XU Zhiyuan, et al. Fault section location method of distribution network based on multi-source Bayesian network and associated discrete coefficient [J]. Shandong Electric Power, 2024, 51(3): 45-54.
- [12] 杜晓东, 赵建利, 刘科研, 等. 基于数字孪生的光伏高比例配电网过载风险预警方法 [J]. 电力系统保护与控制, 2022, 50(9): 136-144.

- DU Xiaodong, ZHAO Jianli, LIU Keyan, et al. Digital twin early warning method study for overload risk of distribution network with a high proportion of photovoltaic access [J]. Power System Protection and Control, 2022, 50(9): 136-144.
- [13] BOLOGNANI S, CARLI R, CAVRARO G, et al. Distributed reactive power feedback control for voltage regulation and loss minimization [J]. IEEE Transactions on Automatic Control, 2015, 60(4): 966-981.
- [14] LI Junnan, LI Dongxu, XIONG Caiming, et al. BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation [EB]. arXiv: 2201. 12086, 2022.
- [15] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and efficient foundation language models [EB]. arXiv: 2302. 13971, 2023.
- [16] Radford Alec, KIM Jong Wook, HALLACY Chris, et al. Learning transferable visual models from natural language supervision [EB]. arXiv: 2103. 00020, 2021.
- [17] KONG W C, DONG Z Y, JIA Y W, et al. Short-term residential load forecasting based on LSTM recurrent neural network [J]. IEEE Transactions on Smart Grid, 2019, 10(1): 841-851.
- [18] 汤奕, 崔晗, 李峰, 等. 人工智能在电力系统暂态问题中的应用综述 [J]. 中国电机工程学报, 2019, 39(1): 2-13, 315.
- TANG Yi, CUI Han, LI Feng, et al. Review on artificial intelligence in power system transient stability analysis [J]. Proceedings of the CSEE, 2019, 39(1): 2-13, 315.
- [19] 劳永钊, 吴任博, 肖健, 等. 基于同步相量测量的配电网电压暂降溯源系统设计研究 [J]. 南方能源建设, 2022, 9(1): 115-121.
- LAO Yongzhao, WU Renbo, XIAO Jian, et al. Research on voltage sag source-locating system design of distribution network based on synchronous phasor measurement [J]. Southern Energy Construction, 2022, 9(1): 115-121.
- [20] 朱卫卫, 朱清, 高文森, 等. 基于 5G 通信时延的配电网馈线自动化切换方法 [J]. 综合智慧能源, 2024, 46(5): 1-11.
- ZHU Weiwei, ZHU Qing, GAO Wensen, et al. Switching method for distribution network feeder automation system based on 5G communication delay [J]. Integrated Intelligent Energy, 2024, 46(5): 1-11.

收稿日期: 2025 年 7 月 14 日

作者简介:



白晨阳(1990), 男, 硕士, 高级工程师、高级技师, 研究方向为电力调度自动化、电力通信及智能系统。

(本文责任编辑: 秦健)

Intelligent Perception Deduction Technology and Application of Distribution Network Operation Status Based on GRULLaMA Large Model

BAI Chenyang¹, NI Tian¹, MEI Qin¹, LIU Xingye¹, CHEN Ye², WANG Chuanjun²

(1. Wuxi Guangying Group Co., Ltd. Technology Branch, Wuxi 214000, Jiangsu, China;

2. School of Computer engineering, Nanjing Institute of Technology, Nanjing 211167, Jiangsu, China)

Abstract: Aiming at addressing the issues of multi-source uncertainty, multi-modal data fusion, and state deduction in the distribution network caused by the integration of new energy sources and load resources, this paper proposes a GRULLaMA architecture. This architecture integrates physical information neural networks, time series modeling, graph convolutional networks, and multi-modal reasoning. By constructing the multi-level module of GRULLaMA, the temporal and spatial characteristics of multi-modal data, such as electrical measurements, non-electric meteorological/social data, and carbon policy-related data, can be integrated. Combined with the physical constraints of the power system, an intelligent, data-driven deduction model for the state of the distribution network is constructed. Based on reinforcement learning strategies and regularization techniques, the generalization ability and prediction accuracy of the model are improved. Simulation results show that, compared to traditional statistical methods and single neural network methods, the average error of the proposed method in source-load forecasting tasks is reduced from 8.5% to 2.8%, the accuracy of risk pre-judgment is increased from 83.5% to 94.7%, and the switching operation time is reduced from 2 hours to less than 5 minutes. These improvements effectively enhance the intelligent operation level of the distribution network in the new power system.

Keywords: distribution network; GRULLaMA; multimodal fusion; state deduction; physics-based information neural networks