

面向知识学习的电力科学大模型

陆超¹, 吴小辰², 刘迪¹

(1. 清华大学电机工程与应用电子技术系, 北京市 海淀区 100084;

2. 中国南方电网有限责任公司, 广东省 广州市 510700)

Exploration of the Evolutionary Trends of Large Scientific Models for Power Systems Oriented Towards Knowledge Learning

LU Chao¹, WU Xiaochen², LIU Di¹

(1. Department of Electrical Engineering, Tsinghua University, Haidian District, Beijing 100084, China;

2. China Southern Power Grid Co., Ltd., Guangzhou 510700, Guangdong Province, China)

ABSTRACT: The high volatility and nonlinearity of new power systems pose significant challenges to the accuracy and adaptability of mechanism-based analysis and optimization control methods. Data-driven machine learning methods have partially addressed these challenges but still suffer from weaknesses such as limited interpretability and reliability. Large models, which have shown preliminary capabilities in learning physical laws, offer a new pathway to tackling the complexities of power systems. Given the unique characteristics of power systems, such as spatiotemporal complexity and well-established mechanistic knowledge, it is imperative to explore the construction methodologies for domain-specific large models tailored to power systems. This paper first summarizes the development and capabilities of large model technologies, followed by an analysis of the core requirements for building specialized large models for power systems. Based on this, the key challenges in constructing large scientific models for power systems are identified. Finally, the paper discusses the development trends and prospects of scientific large models for power systems. Through this research, we aim to explore the fundamental requirements and construction methodologies for power system-specific large models, enabling them to extract underlying physical knowledge from massive data and establish a new paradigm for the intelligent operation of power systems.

KEY WORDS: new power systems; power science large models; physical knowledge learning

摘要: 新型电力系统高波动性、高非线性等特征给基于机理知识的电力系统分析与优化控制方法的准确性和适应性带来

了巨大的挑战, 数据驱动的机器学习方法在一定程度上解决了上述挑战, 但也存在可解释性及可靠性不强等弱点。初步展现出物理规律学习能力的大模型为解决电力系统复杂性问题提供了新路径。由于电力系统具有时空关联复杂、机理知识完善等独有特征, 需要探索电力系统专用大模型的构建方法。该文首先总结了大模型技术的发展历程与能力, 进而梳理了电力系统专用大模型构建的核心需求, 在此基础上提出了电力系统科学大模型构建面临的关键挑战, 最后对电力系统科学大模型的发展趋势进行总结与展望, 以期通过该文研究, 探索电力系统专用大模型的基本需求及构建路径, 使大模型可以从海量数据中学习背后的物理知识, 形成电力系统智能化运行的新范式。

关键词: 新型电力系统; 电力科学大模型; 物理知识学习

DOI: 10.13335/j.1000-3673.pst.2025.0961

0 引言

在我国“碳达峰、碳中和”的目标下, 电力系统的绿色化转型也在快速推进。可再生能源的大量渗透, 使得电力系统高波动性、高非线性的特征愈发显著, 给电力系统的分析与决策提出了更高的要求^[1-3]。与此同时, 人工智能技术在快速发展, 展现出了强大的认知与拟合能力, 尤其近几年大模型技术的发展与应用速度远超预期, 是解决上述问题的有效路径^[4]。习近平总书记也指出, “人工智能是新一轮科技革命和产业变革的重要驱动力量”。因此需要针对“双碳”目标下电力系统变革的需求, 探索人工智能技术支撑的电力系统智能化运行的新范式^[5-6]。

人工智能技术在电力系统中的应用已有大量的研究与探索, 早在 20 世纪末, 专家系统就开始在电力系统中应用, 这也是早期对电力系统智能化的探索。随着计算机技术的发展, 支持向量机^[7-8]、

基金项目: 中国南方电网有限责任公司创新项目(ZBKJXM20232035)。

Project Supported by Innovation Project of China Southern Power Grid Co., Ltd. (No. ZBKJXM20232035).

启发式算法^[9]等数据驱动的机器学习方法均被尝试应用在电力系统的认知、预测、优化控制等过程中,并取得了较好的效果^[10-11]。

自 2018 年 BERT(bidirectional encoder representations from transformers)模型提出并在自然语言处理任务中取得突破以来,大模型作为一种以大规模参数和数据驱动的人工智能技术范式,逐步成为人工智能发展的主流方向。2022 年 11 月底,OpenAI 公司推出了搭载 GPT-3.5 的 ChatGPT,其在自然语言理解与生成方面展现出前所未有的强大性能,标志着通用人工智能大模型进入快速发展阶段。随后,大模型技术迅速扩展至图像与视频生成、气象预测^[12-13]、蛋白质结构建模^[14]、药物分子设计^[15]等多个复杂领域,并取得了显著成果,表现出跨任务、跨模态的强泛化能力和知识迁移能力。

相较于传统人工智能方法,大模型依托海量参数与大规模数据训练,具备良好的涌现能力和复杂关系建模能力,已成为认知智能领域的重要突破方向。将大模型应用于新型电力系统,有望突破传统方法在高波动性、高非线性等场景下的感知建模和全局优化难题^[16-18],为新型电力系统的建设提供全新技术路径。

此外,大模型的涌现现象使其真正“理解”物理成为了可能,OpenAI 于 2024 年 2 月份发布的 Sora 就已经初步展现出了对物理规律的学习能力。同时,电力系统背后有非常完整的物理理论体系,如果大模型能够通过海量的数据,真正理解并学会数据背后的物理知识,则有望解决物理安全约束问题,发挥大模型性能优势的同时保障输出结果的安全可靠,实现电力人工智能质的突破^[19]。因此,如何将人工智能大模型应用于电力系统,提出基于人工智能大模型的电力系统智能化发展的新范式,需要进一步探索。

本文基于上述目标,首先根据新型电力系统运行优化本身面临的难题梳理新型电力系统对大模型技术的能力需求,进而分析大模型在电力系统中深化应用的核心挑战,最后从物理知识学习机理、电力专用大模型基础单元以及大模型应用架构几个层面提出电力系统专用大模型的发展趋势。

1 人工智能大模型的发展与能力分析

人工智能大模型是指一类拥有超大规模参数(通常在十亿个以上)、超强计算资源的机器学习模型。这些模型利用大数据和深度学习技术,通过在大规模数据集上进行预训练,具备了广泛的领域知

识和理解能力,能够在各种任务和领域中展现出强大的语言理解、生成和推理能力。相较于传统人工智能,人工智能大模型具有参数数量庞大、复杂性高、通用性强、多任务处理能力突出等独有特征。这些特征使得大模型在处理复杂和多样化任务方面表现优异,但也带来了巨大的资源消耗和训练难度。

1.1 人工智能大模型发展历程

在 1956 年的达特茅斯学院会议上,计算机专家约翰麦卡锡提出了“人工智能”一词,被认为是人工智能正式诞生的标志。1957 年, Frank Rosenblatt 发明了感知器,形成了一种简单的人工神经网络。1986 年, Hinton 在论文里论证了反向传播算法能有效提升神经网络的学习速度^[20],极大地提高了神经网络的学习效率,使得使用神经网络解决复杂的问题成为可能。2006 年 Hinton 提出深度信任网络(deep belief network, DBN)^[21-22],成为深度学习的起点,基于神经网络的人工智能开始进入快速发展阶段,并在图像识别等领域取得较好的效果。

2017 年, Google Brain 提出了 Transformer^[23],取代了 RNN(recurrent neural network)的架构,为大模型的发展奠定了模型基础。2018 年, OpenAI 发布的 1.17 亿参数的 GPT(generative pre-trained transformer)^[24]和 Google AI Language 发布的 3 亿参数的 BERT 模型^[25]奠定了大规模预训练的框架。在此基础上,大量的成果开始涌现, Google 团队在 2020 年 10 月提出了 CV(computer vision)领域应用的里程碑 Vision Transformer^[26], OpenAI 提出的 CLIP(contrastive language-image pre-training)则成为了大模型多模态应用的基础^[27]。2022 年 OpenAI 发布了 GPT 3.5,参数规模已经达到了 1750 亿,因其强大的能力,两个月内用户数量破亿,进一步加速了大模型的研究与应用。2023 年 3 月发布的 GPT 4 的模型参数达到了 1.8 万亿,模型性能显著提升,2024 年 5 月发布的 GPT 4o 则在多模态能力方面有了长足的进步。此外,2024 年 2 月 OpenAI 发布了 Sora,实现了高质量的文本生成,同时大模型开始展现出了对物理世界的理解能力。

自 2023 年起,人工智能大模型发展就开始步入精细化发展阶段,核心特征体现为效率革命与垂直领域深耕。在模型优化层面,以 DeepSeek 为代表的混合专家系统(mixture of experts, MoE)通过稀疏门控机制将参数量压缩至传统模型的 1/10,同时保持 95%的性能; 4-bit 量化技术使模型内存占用减少 75%,推理延迟降低至原 1/3;知识蒸馏技术如

TinyBERT 在 GLUE 任务上达到原始模型 96.8% 的性能。垂直领域定制化方面, BloombergGPT 基于 500 亿金融语料训练, 在 FIQA 金融问答任务中提升 18.7%; Med-PaLM M 通过医学知识注入, 在 MedQA 诊断任务中达到专家级准确率(92.3%)。

大模型在电力垂直领域也有了许多应用, 国家电网、南方电网等企业已推出电力专用大模型, 如国家电网研发的“光明电力大模型”在输变电设备缺陷识别中准确率达 92.7%, 南方电网的“大瓦特模型”实现负荷预测误差率低于 1.8%, 显著提升电网运行效率。但仍面临行业知识注入不足、大规模可靠决策能力较弱、输出结果可靠性不足等挑战。

除此之外, 大模型在 AI for Science 领域也取得了巨大的成功, 包括生物制药、材料研发、气象预测、结构设计等。DeepMind 提出的 AlphaFold 3 采用 Transformer+Diffusion 的结构, 实现了对蛋白质结构的准确预测, 华为盘古大模型^[28]和谷歌 GraphCast^[29]均实现了对天气的准确预测。此外, 大模型在偏微分方程求解方面也取得了理想的效果^[30]。

1.2 大模型的基础架构

大模型本质上是具有海量参数的深度学习模型, 目前的大模型多以 Google Brain 在 2017 年提出的 Transformer 结构为基础^[23], 一个完整的 Transformer 模块包含一个 Encoder 和一个 Decoder, 如图 1 所示。




图1 Transformer 基本架构^[23]

Fig. 1 Fundamental architecture of Transformer

每个 Encoder 包含一个多头注意力机制模块和一个全连接神经网络, 通过残差连接。每个注意力机制模块由查询 Q (query)、键 K (keys) 和值 V (values) 向量构成, 注意力机制的输出矩阵为

$$\text{Attention}(Q, K, V) = \text{soft max}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

式中: $\sqrt{d_k}$ 为缩放因子。上述注意力机制的输出实质上是对值向量 V 的加权, 而权重则由查询向量 Q 和键向量 K 相乘获得。为了防止平均化丢失各个子空间的信息, Transformer 采用了多头注意力机制如图 1(c) 所示。

在 Transformer 的基础上, 大模型发展出了 3 种架构: Encoder-Only、Decoder-Only 以及 Encoder-Decoder, 每种架构都有其独特的特点和适用场景。

Encoder-Only 架构仅集成了编码器组件, 一般适用于无需生成序列输出, 而仅需对输入进行深度编码与处理的单向任务。具体而言, 包括但不限于文本分类、情感分析等, 它们侧重于从给定的文本数据中提取关键信息、理解其深层含义, 并据此做出相应的判断或分类, 而非构建全新的文本序列。Encoder-Only 架构的设计初衷在于高效处理输入数据, 通过复杂的神经网络结构(如多层自注意力机制)专注于对输入信息的深刻理解与高效编码。其核心优势在于能够捕捉输入序列中的上下文依赖关系, 从而在无需生成响应文本的情况下, 实现对输入内容的全面解析与表征。目前 Encoder-Only 架构以 BERT 系列模型为代表, 在其基础上发展出了一系列的衍生模型, 包括 RoBERTa(robustly optimized bert approach)、ALBERT(a lite bert for self-supervised learning of language representations)等。

Decoder-Only 架构则仅包含解码器部分, 模型能够直接生成输出序列, 而无需经过编码器的中间表示过程。这使得 Decoder-Only 架构特别适用于需要生成文本或序列的任务, 如文本生成、机器翻译、对话系统等。此外, Decoder-Only 架构支持无监督预训练, 在预训练阶段模型可以通过大量未标注的文本数据学习语言的统计模式和语义信息, 构建出广泛的语言知识和理解能力。这种预训练方法不仅提高了模型的泛化能力, 还使得模型能够更好地适应各种下游任务。Decoder-Only 架构的代表性模型包括 OpenAI 的 GPT 系列(如 GPT、GPT-2、GPT-3 及 GPT-4 等)。这些模型通过堆叠多层 Transformer 解码器构建而成, 具备强大的语言生成和理解能力。在自动回答问题、文本摘要、对话生成等任务中取得了显著的效果。

Encoder-Decoder 架构同时包含编码器和解码器部分, 其基本原理在于通过编码器(encoder)将输入序列映射到一个高维表示空间, 再由解码器(decoder)基于该表示逐步生成输出序列。该架构的

特点在于其灵活性和通用性，能够处理不同长度的输入和输出序列，并在多种任务中展现出强大的性能，如机器翻译、文本摘要、语音识别等。3 种架构的对比如表 1 所示。

表 1 模型架构对比			
Table 1 Comparison of model architecture			
项目	Encoder-Only	Decoder-Only	Encoder-Decoder
典型模型	BERT, RoBERTa, DistilBERT	GPT-2, GPT-3	T5, BART, mT5
主要用途	自然语言理解(NLU)	自然语言生成(NLG)	自然语言理解和生成(NLU&NLG)
结构	仅包含编码器	仅包含解码器	同时包含编码器和解码器
输入处理方式	输入序列经过编码器进行编码	输入序列经过解码器进行生成	输入序列经过编码器编码，解码器解码
输出处理方式	通常输出固定长度的表示或分类	输出可变长度的生成序列	输出可变长度的生成序列
主要优势	擅长文本分类、情感分析、命名实体识别等任务	擅长文本生成、对话系统等任务	兼具理解和生成能力，灵活多样
训练数据	通常需要大量标注数据进行预训练	通常通过自回归生成进行预训练	需要双向(编码-解码)训练数据
双向性	双向(从左到右和从右到左)	单向(从左到右或从右到左)	编码器双向，解码器单向
自注意力机制	适用于自注意力机制	适用于自回归注意力机制	编码器和解码器均使用自注意力机制

1.3 大模型预训练与微调

大模型的训练效果直接决定了大模型性能的好坏，训练过程包括预训练和微调，如图 2 所示。其中，预训练是训练过程的一个特殊阶段，旨在让模型在一个广泛的数据集上学习到通用的特征或知识。预训练的目标是构建一个具备广泛能力的模型，为后续特定任务训练提供基础。这一过程通常采用自监督学习方式，如语言建模任务，模型通过预测句子中缺失的单词来学习语言的统计特征。




图 2 大模型预训练和微调架构

Fig. 2 Pre training and fine-tuning architecture for large models

Post-Pretraining 是在通用预训练模型基础上进行的额外训练，通常使用大量领域特定数据，目的是使模型更好地适应特定领域或任务。这一阶段的训练可以是监督学习或自监督学习，目标是在不过度专化到某个特定任务的同时，提高模型对特定领域的理解和表现。

微调是调整预训练模型参数以适应特定任务的过程。这通常涉及在特定任务数据集上继续训练模型，以优化模型在该任务上的表现。微调的核心思想是通过向模型“输入”更多信息，对模型的特定功能进行“优化”，从而提升模型在特定领域的性能，包括全微调(full fine-tuning)、部分微调

(repurposing)以及参数高效微调(parameter-efficient fine-tuning, PEFT)。

其中，全微调是指对整个预训练模型进行微调，包括所有层和参数。这种方法适用于预训练模型与目标任务差异较大的情况，需要较大的计算资源和时间，但通常能获得更好的性能。部分微调是在微调过程中只更新模型的顶层或少数几层，而保持底层参数不变。这种方法旨在保留预训练模型的通用知识，同时通过微调顶层来适应特定任务。部分微调需要较少的计算资源，但在某些情况下性能可能有所降低。

PEFT 旨在通过最小化微调参数数量和计算复杂度，提升预训练模型在新任务上的表现。PEFT 包括多种方法，如 LoRA、适配器调整(adapter tuning)、前缀调整(prefix tuning)和提示调整(prompt tuning)等。其中，LoRA 是通过在预训练模型的关键层引入低秩矩阵，实现模型行为的微调，而无需修改整个模型结构。LoRA 以其计算效率高和存储需求低著称，能够在不显著增加计算成本的情况下实现性能提升。适配器调整是通过在模型的每一层或选定层之间插入小型可训练网络(Adapter 模块)实现微调。这些 Adapter 模块具有较少的参数，仅针对特定任务进行训练，而预训练模型的主体参数保持不变。前缀调整是在模型的输入端添加可学习的前缀向量，作为对模型后续处理的一种引导或提示。这种方法不需要修改模型的内部权重，减少了训练负担。提示调整是设计或学习合适的文本提示(prompts)，将这些提示与输入数据结合，引导模型生成特定任务所需的输出。与直接调整模型参数不同，此方法通过改变输入来间接影响模型行为。

微调策略的选择取决于具体任务的需求、可用资源(如计算力和内存)以及对模型性能和效率的权衡考虑。例如，对于计算资源受限的情况，PEFT 技术能够提供有效的解决方案；而对于需要高度灵

活性和自适应能力的任务,全微调可能是更好的选择。

1.4 大模型的能力与局限

大模型本质上是一种大规模的深度学习模型,其生成过程可以看作是一种概率预测。以 GPT 为例,在推理阶段,输入文本首先被转换为模型理解的词嵌入形式,然后通过前向传播逐步生成下一个词,每个词的生成基于其前面词的条件概率分布。使用不同的采样策略(如贪婪搜索、Beam Search、Top-k 采样、Top-p 采样等)来控制文本生成的质量和多样性,通过这些策略依据概率选择最可能的词。最后,生成的词嵌入被转换回文本形式,并进行必要的格式化处理,以确保输出文本的连贯性和正确性,如图 3 所示。




图 3 GPT 生成过程

Fig. 3 GPT generation process

在上述框架下,大模型能够处理自然语言处理任务,如文本生成、问题回答和翻译,同时在计算机视觉领域也表现出色,能够高精度地进行图像分类与识别以及场景理解。但目前大模型的能力也存在一些局限,尤其在电力系统中的应用还有很多不足。

1) 可靠性不足与输出幻觉问题。

大模型的回答基于概率分布生成而非确定性规则,因此在面对电力系统的故障诊断、应急调度等业务中的输出可靠性难以保障。更为严重的是,大模型存在“输出幻觉”问题,即在缺乏事实支撑时依然会生成看似合理但实际错误的信息。这种现象在高安全、高稳定性要求的电力系统中具有极大风险,可能误导操作人员做出错误判断,带来系统性安全隐患。

2) 数学与逻辑推理能力有限。

电力系统中涉及大量复杂的数学建模与逻辑

推理任务,如最优潮流计算、负荷预测、状态估计等,这些问题通常包含多层约束、非线性函数和递归逻辑。尽管大模型可以模拟一定的推理过程,但其推理深度和精度远不能满足工程应用需求。尤其是在需要满足等式与不等式约束时,大模型往往表现不稳定,甚至输出逻辑自洽性差的结果,难以替代传统优化算法或专家系统。

3) 可解释性与可调试性差。

在目前的电力系统中,任何自动化系统的输出必须具备良好的可解释性和可追溯性,以保障系统运行的透明性和安全性。而大模型作为黑盒模型,其内部机制复杂,不具备清晰的决策路径,无法准确回答“为什么做出该判断”。同时,由于模型规模巨大,参数调整过程复杂,其调试成本高、反馈响应慢,难以实现工程级的定向优化。这严重制约了大模型在电力系统核心业务中的广泛部署。

4) 数据局限性显著。

大模型对训练数据质量极为敏感,而电力系统数据本身存在显著局限。一方面,数据主要采集自 SCADA、EMS 等系统,受限于采样频率、故障记录缺失及隐私保护等因素,导致数据质量参差不齐;另一方面,高质量标注数据获取成本高、专业性强,难以构建类似互联网领域的大规模、多样化语料。此外,电力系统为保障稳定运行,绝大多数历史数据反映的是正常工况,极端天气、设备故障、系统扰动等异常状态下的数据极为稀缺,导致样本分布极度不均衡。这种不均衡不仅限制了模型在训练阶段对少数类样本(如事故或极端事件)的学习能力,也容易造成模型对异常情况的识别偏差,影响其在实际应用中的泛化能力和鲁棒性。

5) 模型训练、部署与推理成本高。

当前大规模预训练模型的参数量通常达到数十亿级别,对算力资源和硬件平台提出了极高要求,训练过程往往消耗大量时间与能源。在电力系统中,大模型需处理海量、异构、多模态的输入数据,对 GPU 集群等高性能计算资源依赖明显,导致本地部署难以实现。虽然以 DeepSeek 等为代表的轻量化技术在一定程度上压缩了模型规模,降低了计算复杂度,但整体算力需求依然庞大,特别是在应对长时序、多变量预测任务时。此外,即便完成部署,推理效率仍是瓶颈。大模型通常需数秒才能输出一个结果,若涉及深度逻辑推理,耗时更长,远不能满足电力系统故障响应、稳定控制等关键业务对秒级乃至毫秒级响应时效的严格要求。因此,大模型在电力系统中的训练、部署与推理全过程,

面临着算力高、实施难、实时性差等多重挑战。

2 新型电力系统对大模型技术的能力需求

电力系统规模巨大、机理复杂且安全性要求严格,同时存在负荷预测、稳定分析、经济调度、安全控制等多种不同的分析与调节业务需求,新型电力系统“双高”特性给传统电力系统分析与优化控制方法带来了巨大的挑战。需要针对电力系统分析与控制实际面临的问题,结合大模型学习能力的本质,充分考虑电力系统各断面空间上物理联结关系以及时间上状态变化趋势,发挥大模型强学习能力的优势,构建能够真正理解电力系统底层物理轨迹并能够自我学习进化的电力系统专用大模型。

2.1 大模型技术在电力系统中的应用现状

大模型在电力系统中的应用现状呈现出快速发展与广泛渗透的态势,通过结合电力行业的专业知识与大数据处理能力,大模型已在电网运行监控、故障预测、资源优化配置、客户服务等多个领域进行了成功应用,也形成了一些应用成果,包括南方电网“大瓦特”大模型、国家电网“光明电力大模型”等。

当前电力系统大模型的发展主要呈现3类技术范式:其一,基于通用自然语言处理(NLP)与计算机视觉(CV)大模型的迁移应用(如华为盘古、百度文心),通过领域语料微调实现电力文本解析、图像识别等基础任务,但其架构未嵌入电力物理机理,应用多局限于客服交互、文档管理等非核心业务;其二,行业知识增强型模型(如国家电网千亿级参数的电力专用 NLP 模型),虽在设备知识库构建、敏感实体识别等任务中取得进展,仍难以处理高维时空动态数据;其三,以南方电网“大瓦特-驭电”为代表的领域专用架构,通过融合物理约束神经网络与自主求解器,创新性地实现神经网络对高阶微分代数方程的求解,潮流计算和稳定分析速度相比经典仿真提升 1000 倍,计算误差小于 1.5%,标志着电力大模型从技术套用向物理机理深度耦合的范式跃迁。

然而,大模型在电力系统预测、优化调度与安全控制等核心领域的应用仍显著不足。这一瓶颈源于三方面根本性矛盾:在数据模态层面,电力系统需处理连续时空变量(如全网同步相量测量数据),而 NLP/CV 模型本质面向离散符号或静态特征,缺乏动态物理状态建模能力。例如风电功率预测需融合气象场与电网拓扑的实时耦合关系,直接应用 CV 模型处理卫星云图难以捕捉时空关联机制。在

机理嵌入层面,通用 Transformer 架构依赖统计概率建模,但电力调度决策需严格满足微分代数方程约束(如潮流方程、暂态稳定判据),未嵌入物理算子的模型在安全边界计算中误差难以被保障,某些工况下的误差远超工程容忍阈值。在系统可靠性层面,电网控制需毫秒级确定性响应,而大语言模型的概率生成特性存在随机输出风险,难以满足 $N-1$ 故障下的快速校正要求,导致当前应用多停留于辅助决策或设备运维场景,如智能问答^[31]、设备诊断^[32]、自动巡检^[33]等。

2.2 多源因素影响下的源荷精准预测能力需求

早期的预测主要依赖于统计学的分析方法,如时间序列分析^[34-35]、回归分析法^[36-37]、灰色预测法^[38-39]及卡尔曼滤波法^[40-41]等,通过对历史负荷数据的数学处理来预测未来负荷。该类方法本质上是对时间序列特征的学习,因此在电源侧新能源出力预测和负荷侧用电需求的预测中,没有明显区别。这些方法在处理简单、稳定的预测任务时表现出色,但随着电力系统的复杂化和多元化发展,其局限性逐渐显现。在新能源出力预测方面,难以融入天气信息的影响;在负荷预测方面,对用户特性和温度等外部因素的影响也考虑不足,导致预测精度下降。

随着计算机技术的发展,人工神经网络^[42-43]、支持向量机^[44-45]和随机森林^[46-47]等人工智能算法开始被引入,可以将时序数据之外的特征作为算法的输入,如在进行负荷预测时考虑用户特性,在新能源预测时考虑光照、风速等影响,提高了源荷预测的精度和鲁棒性,但在处理大规模、高维数据时仍面临挑战。

深度学习技术的兴起极大地提升了预测算法的性能,推动了源荷预测的发展。卷积神经网络^[48-49]、循环神经网络(RNN)及其变体(如 LSTM、GRU)^[50-51]等深度学习模型在源荷预测中得到了广泛应用。同时,图神经网络也开始被用于处理电网拓扑结构中的源荷预测问题^[52-53]。上述方法能够自动提取多元数据中的复杂特征,处理时间序列数据中的长期依赖关系,进而提高整体预测性能。

在当前电力系统运行领域,风电与光伏出力的日前预测平均准确率已达 80%~90%区间,而针对数小时内、以 15min 为更新周期的超短期预测场景,其准确率可突破 90%。与此同时,在省级及以上规模的大电网运行体系中,日前负荷预测的准确率通常能达到 95%~98%以上的水平。预测精度的提升,为电力系统的调度优化、供需平衡管理及电网稳定性控制提供重要的决策支撑基础。

外部环境是影响新能源出力的重要因素,而市场化环境下,电力市场的交易情况又会影响负荷预测的准确性。目前已有研究开始尝试将气象数据纳入新能源的预测中,在负荷预测领域也开始考虑用电计划、节假日日程、负荷检修计划、电价信号等多维业务数据。但整体仍主要依赖于结构化数据的处理能力,对于非结构化或弱结构化数据的利用存在显著不足。现有方法在面对如降雨强度、云层遮挡等影响光伏出力的气象因素,或如重大社会事件、突发故障等对电力需求具有扰动效应的复杂情境时,往往难以有效建模与捕捉其非线性关联与潜在时空耦合特征,导致预测模型的适应性及泛化能力受限。

大模型技术的发展,使得人工智能模型具备了多模态数据的处理能力,理论上能够整合并处理来自不同模态的数据,从而更全面地揭示电力负荷变化的规律。因此,如何充分发挥大模型多模态数据处理的能力,结合电力负荷预测的实际情况,实现准确的负荷预测面临挑战。

2.3 时变非线性系统暂态稳定快速评估能力需求

传统的电力系统稳定分析主要依赖于详细的数学模型和仿真技术。时域仿真法通过逐步积分求解电力系统的动态方程,能够模拟各种扰动下的系统动态响应,提供高精度的稳定性评估^[54-55]。然而,这种方法计算量大且耗时长,限制了其在实时在线分析中的应用。频域分析法则通过线性化处理系统模型,利用频率响应函数进行分析^[56-57],适用于小扰动情况下的稳定性评估,但忽略了系统的非线性特性。

为了克服传统仿真方法的计算负担,基于模型的简化分析方法应运而生。能量函数法通过构建与系统稳定性直接相关的能量函数,分析系统在不同扰动下的能量变化,从而评估稳定性^[58-59]。这种方法计算量较小,但能量函数的构造依赖于具体模型和参数,通用性受限。直接法则通过计算系统雅可比矩阵的特征值来判断稳定性,具有计算速度快的优点,适用于大规模系统的初步筛选,但结果精度可能受到模型简化的影响。

随着大数据和机器学习技术的发展,数据驱动分析方法在电力系统稳定评估中崭露头角。统计学习方法和机器学习方法被广泛应用于电力系统稳定性分析。统计学习方法如支持向量机^[60-61]、决策树^[62-63]、随机森林^[64-65]等,在电力系统稳定评估中通过构建分类或回归模型,从大量数据中学习特征与稳定性之间的映射关系。这些方法计算效率高,

对于中等规模数据集具有良好的泛化能力,但在处理高维、非线性数据方面能力有限。

以卷积神经网络、循环神经网络等为代表的机器学习方法在电力系统稳定评估中展现了强大的非线性建模和特征提取能力^[66-69]。这些方法能够自动从原始数据中学习复杂的模式,并有效处理时序和高维数据。然而,机器学习模型通常需要大量高质量的数据进行训练,且模型可解释性较差,计算成本也相对较高。

在基础的机器学习的基础上,进一步发展出了深度学习模型,如深度信念网络^[70-71]、生成对抗网络^[72-73]等,在电力系统稳定评估中进一步提升了数据驱动方法的性能。通过构建更深的神经网络结构,这些方法能够捕捉数据中更加细微和复杂的特征,实现高精度的稳定评估。然而,深度学习模型的训练过程复杂且计算密集,对数据量和数据质量的要求也更高,同时模型的可解释性仍是一个挑战。实际应用中,需要综合考虑模型性能、计算资源、数据可用性等因素来选择合适的方法。

尽管数据驱动的暂态稳定分析方法在新型电力系统中展现出巨大潜力,但仍面临诸多挑战。首先,电力系统数据的高维、异构和噪声干扰使得数据预处理和特征提取变得尤为困难。其次,模型的泛化能力和实时性仍需进一步提升,以满足复杂多变的电网运行需求。此外,模型的解释性和可信度也是实际应用中亟待解决的问题。

人工智能技术的不断发展,尤其是大模型的出现,为解决这些挑战提供了新的思路。大模型通过集成更多的数据和知识,面向时变非线性的复杂系统,能够捕捉更复杂的电力系统动态特性,提高模型的预测精度和泛化能力。同时,大模型结合先进的优化算法和训练技术,可以在保证实时性的同时,提升模型的解释性和可信度,是解决“双高”电力系统稳定评估挑战的有效手段。

2.4 复杂电力系统优化调度及快速控制能力需求

在电力系统运行控制框架中,优化调度与快速控制构成闭环控制体系的核心环节,二者通过时空尺度耦合实现系统安全与经济性的协同优化。优化调度作为预防性控制层,基于长期预测模型构建经济-安全多目标优化函数,通过机组组合、潮流重构及备用容量配置等策略,在系统稳态运行阶段预先消除潜在风险并建立安全裕度,为实时运行提供准稳态基准;而快速控制作为紧急恢复层,依托广域测量系统实现故障后毫秒级动态响应,通过紧急切机、切负荷等手段,保障故障后电力系统各项指标

在安全裕度之内。二者形成分层递阶控制结构，优化调度奠定全局最优性基础，快速控制保障局部稳定性边界，共同维持电力系统在正常工况与扰动场景下的动态平衡。此闭环控制体系的有效性，特别是快速控制环节的精准触发与执行，高度依赖于对系统暂态稳定状态的快速、准确评估能力。

经典的电力系统调度主要依赖于数学优化方法，其中以等微增率法为代表。该方法通过计算各发电机组的边际成本，使得所有机组的边际成本相等，从而达到总运行成本的最小化^[74]。此方法计算简单直观，适用于传统电力系统中小规模机组的调度问题。然而，它难以考虑网络约束、发电机爬坡率限制等复杂因素，无法直接应用于现代大规模、复杂多变的电力系统。与之对应的早期快速控制主要依赖本地保护装置和简单的稳定控制器，响应速度依赖于硬件特性，缺乏全局协调。此时的暂态稳定评估主要依靠离线计算和预设规则，评估速度慢且难以适应在线变化，制约了快速控制的协调性与适应性。

随着电力系统规模的扩大和复杂性的增加，数学规划方法逐渐成为主流。线性规划通过将经济调度问题线性化，简化了计算过程，虽然可能因线性化而损失一定的精度，但仍能处理包含复杂约束的优化问题^[75-76]。动态规划则进一步考虑了时间因素，适用于需要分阶段决策的经济调度问题^[77-79]。这些方法提高了调度的精确性，但在处理大规模系统时，计算复杂度显著增加，实时性难以保证。在快速控制方面，广域测量系统的发展使得基于实时同步相量数据的快速稳定控制成为可能。基于上述数据的快速评估结果(如失稳模式识别、稳定裕度计算)，为广域快速控制提供了必要的决策输入，两者结合共同提升了系统应对扰动的能力。

为克服传统数学规划方法在计算复杂度和实时性方面的局限，启发式优化算法应运而生。遗传算法^[80-81]和粒子群优化算法^[82-83]等通过模拟自然进化或群体行为，实现全局搜索和自适应优化。这些算法不依赖于问题的具体形式，能够处理大规模复杂优化问题，且具有一定的鲁棒性。然而，它们的收敛速度较慢，容易陷入局部最优，且参数设置对结果影响较大，对环境变化的适应能力较差。

随着智能化技术的发展，模糊逻辑控制^[84-85]、专家系统^[86-87]等智能优化与控制方法被引入电力系统调度中。这些方法能够处理不确定性、非线性和复杂系统，具有学习和自适应能力，能够不断优化调度策略。模糊逻辑控制通过模糊集合理论处理

不精确信息，提高了调度的柔性和鲁棒性；专家系统则基于领域专家的知识 and 经验，实现高效的规则推理和决策支持。然而，这些方法依赖专家知识，对于新情况可能需要重新调整规则。

随着新型电力系统的建设，我国电力系统的运行特征逐渐由发电机主导转变为变流器主导，出现高非线性、低惯量、低阻尼等特征。为应对新型电力系统日益复杂多变的运行环境和更高的调度要求，数据驱动的深度强化学习方法开始被应用^[88-92]。其通过与环境交互学习最优策略，在处理高维、非线性、不确定性强的问题时表现出色，并具有强大的自学习和自适应能力。大模型得益于巨大的参数量，具有更强的特征提取能力和泛化能力，理论上能够更好地应对大规模复杂非线性电力系统的全局优化问题。但其需要大量的训练数据和高性能计算资源支持，且模型可解释性较差，需要进一步研究和改进以保证调度决策的安全性和可靠性。

3 大模型在电力系统中深化应用的核心挑战

尽管大模型已经在许多领域被成功应用，但将大模型技术应用于电力系统的运行控制，并真正解决新型电力系统面临的高波动性、高非线性等挑战，还有许多挑战需要被解决^[93]。相较于已有的大模型应用，电力系统具有系统规模巨大、存在较为完善的理论体系、业务种类繁多、安全性要求极高、不完全可观等特点，如表 2 所示。

表 2 大模型典型应用特性对比					
Table 2 Comparison of typical application characteristics of large models					
对比项	电力系统	语言处理	图像视频	蛋白质预测	天气预报
超大系统规模	✓	×	×	×	✓
理论体系完整	✓	×	×	✓	✓
业务类型复杂	✓	×	✓	×	×
安全要求极高	✓	×	×	×	×
不完全可观	✓	×	×	×	✓
多模态能力	✓	×	✓	×	✓

针对新型电力系统独有的特点，大模型技术在电力系统中应用还面临着复杂系统超高维空间的高效学习、不均衡不完备历史样本数据的处理、满足电力业务需求的可解释性提升以及业务决策结果的可靠性校验与保障方面的挑战。

3.1 复杂系统超高维空间的高效学习

电力系统是人类历史上最为复杂的人造系统，而目前我国电力系统发电装机总容量、非化石能源发电装机容量、远距离输电能力、电网规模等指标均稳居世界第一^[94]。仅一省的 110kV 以上节点数量就能达到数万乃至十数万，而低压配网的台区数量

就达到了几十万,终端用户及设备数量过亿。而随着新型电力系统的建设,可控对象也从以发电侧的集中式电厂为主扩展至包括各个电压等级的源网荷储多类设备,控制规模呈现指数级增长。

此外,电力系统各个节点间的相互作用关系也十分复杂,既有稳态的功率平衡经济调度问题,又有暂态的电压频率稳定问题。在空间上,我国西电东送的总体格局使得电力系统科学大模型需要考虑电能在全国范围内的调度;在时间上,既有毫秒级的电磁暂态问题,又有日、月、年度的运行方式优化与安稳整定等问题。此外,电力系统可再生能源出力 and 负荷需求还受环境、社会事件等外部因素影响,这进一步加剧了电力系统的复杂程度。因此,面向空间上覆盖全国,时间上跨越毫秒级到年度,受多元因素影响的大规模复杂电力系统,对电力系统专用大模型的处理性能提出了较高的要求。

3.2 电力系统理论知识与大模型融合范式

与自然语言处理、图像识别等典型大模型应用领域主要依赖纯数据驱动不同,电力系统具备高度成熟和系统化的理论知识体系,其运行规律可以通过电磁理论、潮流方程、稳定性分析模型等物理机制进行较为准确的描述。这一特性决定了电力系统模型在长期以来主要依赖于基于机制的解析建模方法,具备良好的可解释性与工程可验证性。

然而,随着新型电力系统的快速发展,分布式新能源、电力电子设备和智能负荷等新型元件的大规模接入,使得系统呈现出更强的非线性、更高的不确定性以及更复杂的动态耦合关系。传统机制模型在建模精度、适应性和可扩展性方面逐渐显现出局限性,特别是在高比例可再生能源、高频扰动响应及复杂故障演化等场景下,难以全面捕捉系统的实际行为特征。

因此,亟需构建融合电力系统理论知识与大模型数据驱动能力的新型建模范式。该范式旨在结合物理模型的可解释性与大模型在高维特征学习、多模态信息处理方面的强表征能力,实现对电力系统状态的精准刻画与对控制行为的高效预测与决策。这种融合不仅有助于增强模型的鲁棒性与可信性,还可在极端场景下提升对未知状态的泛化能力。

然而,该融合范式的构建仍面临诸多挑战。一方面,如何在深度模型中有效嵌入潮流约束、电气拓扑、安全稳定边界等物理知识,仍缺乏统一的建模框架;另一方面,如何在保持模型灵活性的同时保证其符合物理规律,实现对约束条件的严格满足,也亟需深入研究。此外,电力系统知识多样,

既包括可形式化的数学模型,也包括运行经验与调度策略等非结构化知识,如何构建统一的知识表示与融合机制,是实现高质量大模型训练的关键问题。

3.3 不完备不均衡历史样本数据处理

尽管电力系统在多年的运行中储存了大量的历史数据,但依然存在数据完备性、均衡性等问题。一方面,目前电力系统中大电网的信息采集主要基于 SCADA 系统的 RTU 和 WAMS 系统的 PMU。其中,RTU 的覆盖率较高,但其数据采集频率较低,无法及时获取电网运行的动态信息,并且 RTU 单元缺乏时钟同步能力。而 PMU 增加了相角测量,且具备 GPS 授时单元,可以实现几十毫秒的测量,但其覆盖率仍有待提升。在配电网侧,电力系统的信息主要依靠用电采集系统开展,同样面临采集频率较低的问题,同时由于配电网的信息量巨大,通常仅存储于本地,上级调度部门通常难以获得配电网的实时信息。因此,就电力系统本身而言,存在信息采集频率不足导致动态特性丢失、高频采集单元 PMU 的覆盖率不足、配电网终端信息与上级调度不同步等问题^[95],因此在设计电力系统专用大模型时,需要充分考虑上述数据问题。

此外,电力系统的运行还受环境、社会事件等外部因素影响,例如光照和风速等环境因素直接决定了光伏和风电的出力,而环境温度和社会事件则在很大程度上会影响负荷需求,这些数据的获取与对齐同样存在困难,并且其空间分辨率和时间颗粒度可能难以满足大模型训练的需求。

另一方面,电力系统中的数据多为常规运行数据,极端工况和故障数据极度缺乏。例如,在进行电力系统的安全稳定分析和优化控制时,需要针对 $N-1$ 故障乃至 $N-1-1$ 或 $N-2$ 故障下的系统运行状态进行分析,但实际运行中,故障状态下的数据极少,完全无法覆盖所有故障情况。目前的解决方法多基于电力系统仿真软件(PSASP、BPA 等)进行仿真分析,但仿真软件与真实环境之间又必然存在误差,这很大程度上会影响大模型的学习效果。因此如何解决电力系统专用大模型训练样本数量不足、分布不均衡、仿真系统与真实环境存在偏差等问题,也是面临的关键挑战之一。

需要特别指出的是,即便训练数据主要源于仿真环境构建,依托物理约束驱动的数据生成机制,人工智能模型依然能够深度剖析并提炼蕴含其中的物理法则及系统动态演化机理,进而构建具备物理可解释性的知识表征体系。凭借这一体系,模型得以系统掌握不同运行工况下电力系统的决策逻辑

辑范式，无论是常态下的经济优化调度，还是故障场景中的紧急控制，均可依据已习得的通用规律，在真实系统运行过程中快速精准地识别问题本质，并制定契合实际需求的有效控制策略。这种数据生成与模型训练模式，成功突破仿真数据与真实数据间的固有局限，为电力系统智能化决策与可靠运行提供了坚实的技术路径与理论支撑。

3.4 满足电力业务需求的可解释性提升

人工智能大模型，尤其是深度学习技术，展现出强大的表征能力，能够在电力负荷预测、故障诊断等复杂任务中有效捕捉数据中的非线性关系和复杂模式。然而，这种强表征能力往往以牺牲模型的可解释性为代价。复杂的模型结构，如多层神经网络，具有数以百万计的参数，使得其内部机制和决策过程呈现为“黑箱”，难以为人类用户所理解。人工智能大模型黑箱的特性使得输出结果难以被信任，需要提升模型的可解释性，提升模型的透明度：一方面帮助运行调度人员更清晰地理解模型的工作原理和预测依据，辅助其制定更加科学合理的决策；另一方面通过对可解释性强的模型进行深入分析和研究，可以发现模型存在的问题和不足，并进行相应的改进和优化，有助于不断提升大模型在电力系统中的应用效果和性能表现^[96]。

人工智能的可解释性在电力系统中也已经有了很多探索，在电网稳定性分析中，SHAP(Shapley additive exPlanation)、LIME(local interpretable model-agnostic explanations)等可解释性方法被广泛应用于解释深度学习模型的决策，帮助理解电网安全评估、暂态稳定性等复杂问题的模型预测结果^[97-98]。在可再生能源预测领域，SHAP、LIME等方法同样被用来分析特征重要性，并提高模型的可解释性^[99-100]。在负荷预测领域，SHAP、注意力机制等方法被用来解释深度学习模型的预测结果，使用户能够更好地理解模型预测和决策依据^[101]。

尽管可解释性技术在电力系统中已经有了很多应用尝试，包括基于物理方程约束建模、机理驱动的网络结构设计等机理融合的可解释性方法，以及基于SHAP值分析、局部近似模型构建等因果规律挖掘方法，但其在电力系统科学大模型中的应用还面临一系列的挑战，包括性能与透明度的平衡、标准化定义的缺失、解释质量的评估难题以及用户适应性等问题，均亟待解决。首先，这些方法通常是针对特定类型的数据或模型设计，缺乏对电力系统复杂性和多样性的充分考虑，难以处理电力数据中的时间序列特性和多变量耦合问题。其次，现有方

法大多基于统计特征或数据驱动的解释，未能有效融合电力系统的物理机理和工程经验，这导致解释结果无法与实际的系统运行状况相对应，从而限制了可解释性结果在实际决策中的参考价值。此外，电力系统中的许多应用场景对实时性有较高的要求，如动态调度和故障响应等，但现有可解释性方法计算复杂度较高，难以满足实时性需求，从而限制了其在关键任务中的实用性。

3.5 业务决策结果的安全可靠性保障

电力系统的运行控制业务种类繁多，既有系统状态的感知与预测，也有安全稳定性的分析与评估。在上述工作的基础上，需要进行运行方式编排、机组组合、经济调度等电力系统稳态的优化调节，还需要进行安稳整定、频率/电压稳定控制等电力系统暂态安全控制。而目前的大模型本质上是大规模的深度学习，如何实现优化决策还缺乏成熟的方法。此外，如何通过大模型的预训练和微调，使得电力系统专用大模型在各项业务上均有良好的表现，也是关键需求之一。

安全稳定是电力系统运行控制的基础需求，并且不同于图像视频处理、蛋白质预测、天气预报等领域的应用，电力系统不能容忍任何一次严重的错误，因为这可能导致停电事故，会造成严重的经济社会损失。

保障电力系统的安全运行，需要解决两个层级的挑战。第一，根据电力系统不同的运行方式和外界环境，电力系统安全稳定运行的区间不同，随着高比例可再生能源和高比例电力电子设备的接入，这一稳定区间愈发难以被准确获取，因此需要充分发挥大模型的能力准确评估各种工况下电力系统安全稳定运行的区间及裕度。第二，大模型的决策本质上是概率预测，在给定的等式/不等式约束下，很难保障大模型输出的结果能够严格满足约束条件，因此面向复杂的新型电力系统，如何获取不同运行方式下电力系统的安全运行边界，并保障大模型的输出结果满足安全约束至关重要。

4 电力系统专用大模型发展趋势

传统电力系统长期存在的非线性、强耦合等技术难题尚未完全解决。而新能源与新型负荷的大规模接入，使新型电力系统的动态特性更为复杂。从传统技术向新型电力系统的过渡涉及技术理念、架构、算法等多层面革新，而非简单线性过渡。探寻适应性技术成为关键，其中人工智能(AI)凭借强大学习分析能力，有望成为上述变革的核心驱动。然

而, AI如何精准适配新型电力系统多变场景、复杂时空关联及高可靠性要求仍需深入研究。

针对新型电力系统对大模型技术的能力需求和核心挑战, 应充分发挥大模型在物理规律学习方面的潜力, 构建融合机理知识的电力系统专用大模型, 探索大模型从通用数理统计向专业知识学习转变的学习范式, 从根本上解决海量不均衡样本、可靠性、可解释性等方面的关键挑战。

4.1 符合电力系统特点的大模型基础单元重构

大模型的基础单元指模型可以理解和生成的最小意义单位。在大语言模型中, 基础单元为 token, 可以是单词、单词的一部分(如子词)、字符或其他文本片段, 具体取决于所使用的标记化(tokenization)方案。由于在语言处理中, 主要关注上下文之间的关系, 将语料处理成一维的 Token 在语言处理领域取得了较好的效果。

但在视频处理和生成领域, Token 一维的基础单元难以表达视频各帧之间的时空关系, 因此以 Sora 为代表的视频生成大模型构建了视频生成的基础单元 Patch。Patch 的概念源于视觉 Transformer (vision transformer, ViT) 中的基础概念。在 ViT 模型中, 图像被分割成多个小方块(即 Patch), 每个 Patch 被视为模型处理的一个独立单元。Sora 引入了时空 Patch(spacetime patch)技术, 将视频视为一个具有时间维度的 Patch 序列。这种处理方式使得 Sora 能够同时捕捉视频的空间和时间信息, 从而生成更加连贯和逼真的视频内容, 也初步展现出了对物理规律的学习能力。而电力系统多个断面间的时序关联也与视频的 Patch 有相似之处, 在设计电力系统科学大模型的基础单元时, 可以进行参考, 如图 4 所示。




图 4 电力系统基础单元

Fig. 4 Basic unit of power system

除此之外, 大模型在天气预报领域的应用也设计了专用的基础单元。Google 的天气预报大模型则是按 0.25° 的分辨率将地球划分成了多个网格, 每个网格点代表一组地表和大气变量, 将其作为基础单元进行模型的训练^[29]。华为在天气预报大模型中设计了三维地球特定变换器(3D Earth-specific

Transformer, 3DEST)架构, 每个 3DEST 基础单元与标准的 vision transformer 的基础单元类似, 但针对地球几何特性进行了优化, 同时通过引入地球特定位置偏置将先验信息注入到深度网络中^[28]。对于电力系统的分析, 也有暂态、稳态等划分, 因此在电力系统的基础单元也可以在时间和空间上进行更加细致的划分, 以更好地帮助电力系统科学大模型学习物理知识。

综上, 目前大模型基础单元的设计根据需求的不同有所差异: 自然语言处理中一维的向量组合即可表达上下文关系; 而视频处理领域则需要构建时空块帮助大模型学习时空的关联; 天气预报领域则进一步将空间网格信息细化, 并融入先验知识, 进一步提升大模型的性能。因此, 也需要针对电力系统本身的特征设计合适的基础单元, 使得电力系统专用大模型能够展现出理想的性能。

借鉴上述经验, 在电力系统领域构建科学大模型时, 基础单元设计必须紧密结合电力系统的时空结构、工程物理规律及运行机制特征。与其他领域相比, 电力系统的基础单元构建面临更为复杂的结构性挑战:

首先, 电力系统具备典型的图结构特征, 系统由大量节点(发电机、变电站、负荷节点等)和边(输电线路、互联系统、变压器等)构成, 呈现强耦合、高维、动态变化的网络拓扑。基础单元应能够保留这种拓扑联结信息, 同时支持节点和边的属性建模, 如电压、电流、频率、负荷功率、功率潮流方向等, 这些电气属性是支撑调度控制、稳定性分析和优化运行的核心信息。

其次, 电力系统具有显著的时序相关性与物理演化特性。如负荷变化、电压波动、频率响应等现象都具有明确的时间演化规律, 模型需在基础单元层面具备高效建模时序动态的能力。这可借鉴视频建模中的时空 Patch 设计理念, 发展适用于电网断面时序结构的“时空块”单元, 用于捕捉不同运行状态下节点间动态关联和因果传播路径。

第三, 电力系统的拓扑结构具备动态变化特性。受负荷波动、设备检修、故障切除、调度操作等因素影响, 电力网络结构可能在小时甚至分钟级别发生改变, 基础单元设计需支持动态图建模能力, 能适应拓扑结构实时演化、拓扑切换与孤岛划分等复杂场景。

第四, 电力系统涉及多源多模态数据融合。除结构性电气数据外, 还包含如气象数据(风速、光照、温度等)、市场数据(电价、出清曲线)、地理信息(站

点位置、地形地貌)等多种异质数据, 这些信息对新能源预测、负荷建模、调度优化均起关键作用。因此, 电力系统大模型的基础单元应具备多模态信息集成能力, 可支持跨类型特征协同建模。

最后, 电力系统是一个高安全性、高可信度的工程系统, 基础单元还应具备良好的物理可解释性与专业一致性。这意味着, 设计时应尽可能保留物理含义明确的变量结构, 便于后续的可解释性建模、约束控制及安全验证。

4.2 面向知识学习的电力系统科学大模型范式

目前在自然语言处理和图像识别领域获得巨大成功的大模型技术本质上还是对海量数据的统计映射。而电力系统背后存在着相对完善的理论体系, 在训练过程中嵌入机理知识, 引导大模型通过海量数据学会背后的物理知识, 是解决大模型技术在电力系统中应用关键挑战的有效途径。尽管电力系统的拓扑和运行方式多种多样, 但背后遵循着相同的物理规律, 因此如果大模型学会了电力系统背后的物理知识, 理论上能够适应任何可能出现的场景, 不再需要对所有可能出现的场景进行训练, 有效解决系统复杂、极端或故障运行工况样本缺失的问题。同时, 由于大模型的决策结果遵循物理定理, 也极大提升了结果的可靠性和可解释性。

大模型通过数据学习背后物理知识也符合科学发现的范式。从科学研究的方法来看, 主要存在着牛顿范式和开普勒范式两种知识发现的方法^[102]。其中, 牛顿范式是一种基于第一性原理的研究方式, 其核心在于从最基本的层面理解事物, 发现物理世界的基本原理。这种范式强调理论推导和数学模型的构建, 通过定义相关变量、写下运动规则并定义边界条件, 从而构建出系统的相空间, 进而预测系统的行为。开普勒范式是一种数据驱动的研究方式, 它侧重于通过对观测数据的分析来寻找科学规律并解决实际问题。这种范式强调实验观

测和数据分析的重要性, 通过收集大量数据并运用统计方法进行处理, 从而揭示出隐藏在数据背后的科学规律。

目前电力系统的理论研究多基于牛顿范式, 即基于电力系统的物理机理模型和数学方程开展分析与优化, 其具有理论深刻、预测性强, 能够揭示事物的本质规律等优点。但随着电力系统规模的扩大和复杂性的增加, 建立精确的机理模型变得越来越困难, 模型复杂度高且计算量大。此外, 机理模型往往基于一定的假设和简化, 难以完全反映电力系统的实际运行情况, 特别是在新型电力系统中, 其适应性受到严峻挑战。同时, 在实时性要求较高的场合, 机理分析方法的计算速度可能无法满足需求。

针对上述挑战, 数据驱动的方法开始被关注。其能够直接利用电力系统的实时运行数据进行分析 and 决策, 具有较强的实时性。它不依赖于固定的物理模型, 因此能够更好地适应新型电力系统的变化。但数据驱动方法本质上是数理统计, 面临着可解释性不强、可靠性难以被保障的挑战。

大模型的出现使得上述问题的解决成为了可能。大模型有“能力涌现”现象, 即当模型突破某个规模时, 性能显著提升并表现出让人意想不到的能力, 包括语言理解能力、生成能力、逻辑推理能力等。这就使大模型有可能基于开普勒范式, 通过对海量数据的学习, 真正“理解”数据背后的物理知识。事实上, 目前已经有许多研究试图引导大模型学习逻辑知识, 如通过思维链(chain of thought, CoT)引导大模型分布解决数学问题。此外, 当输入数据包含足够的信息时, 大模型也有能力自主学习到物理规律, 如以 Sora 为代表的一系列视频生成大模型已经初步展现出了对物理规律的理解。因此, 可以在大模型的训练中融入机理知识, 帮助大模型真正理解电力系统, 如图 5 所示。




图 5 融合电力知识的大模型训练过程

Fig. 5 Training process of a large model that integrates power knowledge

对于电力专用大模型的研究与设计,不仅仅是发挥神经网络强大的非线性拟合能力提升某方面的优化性能,而是充分考虑电力系统背后的机理知识,从基础单元构建、模型结构优化、训练方法提升等多方面构建全新的电力系统专用大模型,使数据驱动的方法不再局限于数理统计领域,而是形成从数据到知识的自主学习的智能化方法新范式,发挥数据驱动强大学习能力的同时也能够有基础理论保障。

4.3 大小结合的电力系统专用大模型应用架构

大小结合的电力系统专用大模型应用架构是




图6 电力系统科学大模型应用架构

Fig. 6 Application architecture of power system science large model

在大小结合的架构中,大小模型的分级分类应用是一种有效策略,将不同的任务划分为多个层次,由小模型负责处理局部任务,而大模型则统筹更为复杂的总体任务。通过这种层次化的模型分解,电力系统可以在每个任务层面上充分利用模型资源,避免因数据规模和任务复杂度不匹配而导致的计算资源浪费或性能受限。

为了进一步优化模型规模与性能的平衡,知识蒸馏技术成为一种重要的工具。通过知识蒸馏,可以利用大模型的学习成果“教导”小模型,使小模型在保持较高性能的同时显著减小规模。这一过程中,大模型的知识在小模型中得以浓缩,实现模型轻量化的同时保留了大模型的决策能力,适用于电力系统中的局部任务和资源受限场景。

此外,模型压缩技术的引入也对大小结合的架构具有重要意义。通过剪枝、量化、Huffman 编码等方法,可以有效压缩大模型的计算和存储需求,形成更加轻量的小模型。在迁移学习的帮助下,这

实现智能电力系统高效运行的重要方式。电力系统业务具有高度复杂性和多样化的特性,并不是所有问题都适合直接采用大模型处理。许多电力系统场景中数据规模较小,计算需求相对较低,因此更适合应用小模型。小模型在处理如设备故障检测、短期负荷预测等局部任务上具备较高的计算效率和快速部署的优势;而大模型则在全局优化、长期负荷预测等复杂任务中表现更为突出。因此,合理构建融合大小模型的架构,可以使电力系统的智能应用在多种场景下实现精准适配与资源优化,如图6所示。

些经过压缩的小模型可以在小数据集上进行微调,进而适应电力系统的具体需求,不仅节省了资源,还避免了重新训练的高昂成本。

在实际应用中,通过大小模型结合的分布式部署可以进一步优化算力配置。小模型部署在边缘设备或前端节点上,负责实时的数据采集与初步处理;而大模型则集中于云端执行整体性任务,为电力系统提供全局优化支持。通过这种分层部署方式,电力系统既能实现模型资源的高效利用,又提升了整体系统的实时性与响应能力。

综上所述,大小结合的电力系统专用大模型应用架构,不仅可以在不同任务中充分发挥各自优势,还能提升模型在多场景下的适应性与稳定性。这一架构的设计为复杂的电力系统提供了灵活而高效的智能化解决方案,有助于推动电力系统的智能化、高效化发展。

5 结语

新型电力系统的高波动性和高非线性特征对

基于机理知识的分析与优化控制方法提出了严峻挑战。在此背景下,数据驱动的机器学习方法,尤其是大模型技术,展现了其在解决复杂电力系统问题上的巨大潜力,有望发挥大模型强大的学习能力,使数据驱动的智能方法能够通过海量的数据学会电力系统背后的机理知识,形成电力系统智能化发展的新范式。

但电力系统复杂的时空关联特征以及一些独有特征使得现有大模型技术的简单套用难以达到理想的效果。本文针对电力系统专用大模型的构建开展了深入探讨,首先从发展历程、基础架构、训练与微调、能力与局限等多个方面分析了人工智能大模型的特点,并针对电力系统的独特需求,进一步明确明确了电力系统专用大模型的核心需求,包括多源因素影响下的源荷快速预测能力、时变非线性系统暂态稳定快速评估能力、大规模复杂电力系统优化调度能力等。

进而,本文梳理了大模型在电力系统中深化应用的核心挑战,包括超高维空间高效学习困难、历史数据不均衡不完备、可解释性与可靠性难以提升等。最后,本文提出了电力系统专用大模型的发展趋势,指出大模型拥有学习物理知识的潜力,如果能引导大模型通过数据学习期背后的物理知识,则有望解决表征能力与可解释性的矛盾,形成电力系统科学大模型应用的新模式。期望通过本文的研究,为电力系统专用大模型的构建及相关技术的研究提供参考。

参考文献

- [1] 张智刚,康重庆.碳中和目标下构建新型电力系统的挑战与展望[J].中国电机工程学报,2022,42(8):2806-2818.
ZHANG Zhigang, KANG Chongqing. Challenges and prospects for constructing the new-type power system towards a carbon neutrality future[J]. Proceedings of the CSEE, 2022, 42(8): 2806-2818(in Chinese).
- [2] 谢小荣,贺静波,毛航银,等.“双高”电力系统稳定性的新问题及分类探讨[J].中国电机工程学报,2021,41(2):461-474.
XIE Xiaorong, HE Jingbo, MAO Hangyin, et al. New issues and classification of power system stability with high shares of renewables and power electronics[J]. Proceedings of the CSEE, 2021, 41(2): 461-474(in Chinese).
- [3] 杨胜春,吕建虎,郭晓蕊,等.适应新型电力系统发展的多元灵活资源优化调度建模和分析[J].电网技术,2024,48(8):3114-3121.
YANG Shengchun, LÜ Jianhu, GUO Xiaorui, et al. Modeling and analysis of multi flexible resource optimization scheduling for adapting to the development of new power systems[J]. Power System Technology, 2024, 48(8): 3114-3121(in Chinese).
- [4] IBRAHIM M S, DONG Wei, YANG Qiang. Machine learning driven smart electric power systems: current trends and new perspectives[J]. Applied Energy, 2020, 272: 115237.
- [5] 蒲天骄,赵琦,王新迎.电力人工智能技术研究框架、应用现状及展望[J].电网技术,2025,49(5):1751-1770.
PU Tianjiao, ZHAO Qi, WANG Xinying. Technology framework, application status and prospects on electric power artificial intelligence[J]. Power System Technology, 2025, 49(5): 1751-1770(in Chinese).
- [6] 孙华东,黄彦浩,李宗翰,等.大电网运行映像模型及关键技术研究[J].电网技术,2025,49(6):2197-2207.
SUN Huadong, HUANG Yanhao, LI Zonghan, et al. Research on operation mapping model and key technologies of large power grid[J]. Power System Technology, 2025, 49(6): 2197-2207(in Chinese).
- [7] ALIMI O A, OUAHADA K, ABU-MAHFOUZ A M. Real time security assessment of the power system using a hybrid support vector machine and multilayer perceptron neural network algorithms[J]. Sustainability, 2019, 11(13): 3586.
- [8] LIN Guoqian, LI Lingling, TSENG Minglang, et al. An improved moth-flame optimization algorithm for support vector machine prediction of photovoltaic power generation[J]. Journal of Cleaner Production, 2020, 253: 119966.
- [9] YUAN Guanghui, YANG Weixin. Study on optimization of economic dispatching of electric power system based on Hybrid Intelligent Algorithms (PSO and AFSA)[J]. Energy, 2019, 183: 926-935.
- [10] 郭凌旭,刘金波,段丽娟,等.电力调度元宇宙架构及关键基础技术验证研究(上):复杂系统设计原理及架构设计[J].电网技术,2025,49(3):1109-1120.
GUO Lingxu, LIU Jinbo, DUAN Lijuan, et al. Research on the verification of power dispatch metaverse architecture and key basic technologies(Part I): design principles and architecture design of complex systems[J]. Power System Technology, 2025, 49(3): 1109-1120(in Chinese).
- [11] 郭凌旭,齐晓琳,刘金波,等.电力调度元宇宙架构及关键基础技术验证研究(下):应用场景规划、原型系统设计与验证[J].电网技术,2025,49(4):1316-1326.
GUO Lingxu, QI Xiaolin, LIU Jinbo, et al. Research on the verification of power dispatch metaverse architecture and key basic technologies(Part II): application scenario planning, design and verify the prototype system[J]. Power System Technology, 2025, 49(4): 1316-1326(in Chinese).
- [12] 李练兵,高国强,吴伟强,等.考虑特征重组与改进 Transformer 的风电功率短期日前预测方法[J].电网技术,2024,48(4):1466-1476.
LI Lianbing, GAO Guoqiang, WU Weiqiang, et al. Short-term day-ahead wind power prediction considering feature recombination and improved transformer[J]. Power System Technology, 2024, 48(4): 1466-1476(in Chinese).
- [13] 赵雅婷,景超,张兴忠.基于多重注意力的双通道超短期风电功率预测[J].电网技术,2023,47(7):2887-2896.
ZHAO Yating, JING Chao, ZHANG Xingzhong. Dual-channel ultra-short-term wind power prediction based on multi-attention[J]. Power System Technology, 2023, 47(7): 2887-2896(in Chinese).
- [14] ABRAMSON J, ADLER J, DUNGER J, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3[J]. Nature, 2024, 630(8016): 493-500.
- [15] THIRUNAVUKARASU A J, TING D S J, ELANGO VAN K, et al. Large language models in medicine[J]. Nature Medicine, 2023, 29(8): 1930-1940.
- [16] 董昱,孙大雁,许丹,等.新型电力系统电力电量平衡的挑战、应对与展望[J].中国电机工程学报,2025,45(6):2039-2056.
DONG Yu, SUN Dayan, XU Dan, et al. Challenges, response and prospects for power balance in new power systems[J]. Proceedings of

- the CSEE, 2025, 45(6): 2039-2056(in Chinese).
- [17] 范越, 李永莱, 舒印彪, 等. 新型电力系统平衡构建与安全稳定关键技术初探[J]. 中国电机工程学报, 2025, 45(1): 14-24.
FAN Yue, LI Yonglai, SHU Yinbiao, et al. Preliminary study on key technologies of balancing and stabilizing of renewable-energy-dominated power system[J]. Proceedings of the CSEE, 2025, 45(1): 14-24(in Chinese).
- [18] MUTHER T, DAHAGHIA K, SYED F I, et al. Physical laws meet machine intelligence: current developments and future directions[J]. Artificial Intelligence Review, 2023, 56(7): 6947-7013.
- [19] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533-536.
- [20] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [21] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [22] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates Inc., 2017: 6000-6010.
- [23] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training [R/OL]. (2018-06-11) [2025-10-11]. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [24] DEVLIN J, CHANG Mingwei, LEE K, et al. Bert: pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis: Association for Computational Linguistics, 2019: 4171-4186.
- [25] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: transformers for image recognition at scale[EB/OL]. [2025-10-11]. <https://arxiv.org/abs/2010.11929>.
- [26] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[J]. PMLR, 2021, 139: 8748-8763.
- [27] BI Kaifeng, XIE Lingxi, ZHANG Hengheng, et al. Accurate medium-range global weather forecasting with 3D neural networks[J]. Nature, 2023, 619(7970): 533-538.
- [28] LAM R, SANCHEZ-GONZALEZ A, WILLSON M, et al. Learning skillful medium-range global weather forecasting[J]. Science, 2023, 382(6677): 1416-1421.
- [29] LI Ruichen, YE Haotian, JIANG Du, et al. A computational framework for neural network-based variational Monte Carlo with Forward Laplacian[J]. Nature Machine Intelligence, 2024, 6(2): 209-219.
- [30] 张金营, 王天堃, 么长英, 等. 基于大语言模型的电力知识库智能问答系统构建与评价[J]. 计算机科学, 2024, 51(12): 286-292.
ZHANG Jinying, WANG Tiankun, YAO Changying, et al. Construction and evaluation of intelligent question answering system for electric power knowledge base based on large language model[J]. Computer Science, 2024, 51(12): 286-292(in Chinese).
- [31] 闫炯程, 李常刚, 刘玉田. 数据驱动的新型电力系统安全风险预警综述[J]. 电网技术, 2024, 48(12): 4989-5002.
YAN Jiongcheng, LI Changgang, LIU Yutian. Review of data-driven security risk early warning research of the new-type power system[J]. Power System Technology, 2024, 48(12): 4989-5002(in Chinese).
- [32] 蔡常雨, 莫文昊, 王万国, 等. 基于生成对抗数据增强的输电设备可视频缺陷检测技术研究[J]. 电力信息与通信技术, 2023, 21(9): 38-43.
CAI Changyu, MO Wenhao, WANG Wanguo, et al. Research on visual defect detection technology for transmission equipment based on generative adversarial data proliferation[J]. Electric Power Information and Communication Technology, 2023, 21(9): 38-43(in Chinese).
- [33] 李道兴, 王晓辉, 李黎, 等. 面向电力无人机巡检图像分析处理的自动化深度学习系统: 架构设计与关键技术[J]. 电力信息与通信技术, 2024, 22(4): 38-54.
LI Daoxing, WANG Xiaohui, LI Li, et al. The architecture and key technologies of an automatic deep learning system for image analysis in UAV transmission line inspection[J]. Electric Power Information and Communication Technology, 2024, 22(4): 38-54(in Chinese).
- [34] PAPARODITIS E, SAPATINAS T. Short-term load forecasting: The similar shape functional time-series predictor[J]. IEEE Transactions on Power Systems, 2013, 28(4): 3818-3825.
- [35] YILDIZ B, BILBAO J I, SPROUL A B. A review and analysis of regression and machine learning models on commercial building electricity load forecasting[J]. Renewable and Sustainable Energy Reviews, 2017, 73: 1104-1122.
- [36] GOIA A, MAY C, FUSAI G. Functional clustering and linear regression for peak load forecasting[J]. International Journal of Forecasting, 2010, 26(4): 700-711.
- [37] ZHAO Huiyu, GUO Sen. An optimized grey model for annual power load forecasting[J]. Energy, 2016, 107: 272-286.
- [38] MI Jianwei, FAN Libin, DUAN Xuechao, et al. Short-term power load forecasting method based on improved exponential smoothing grey model[J]. Mathematical Problems in Engineering, 2018, 2018: 3894723.
- [39] SHARMA S, MAJUMDAR A, ELVIRA V, et al. Blind Kalman filtering for short-term load forecasting[J]. IEEE Transactions on Power Systems, 2020, 35(6): 4916-4919.
- [40] TAKEDA H, TAMURA Y, SATO S. Using the ensemble Kalman filter for electricity load forecasting and analysis[J]. Energy, 2016, 104: 184-198.
- [41] HERNÁNDEZ L, BALADRÓN C, AGUIAR J M, et al. Artificial neural networks for short-term load forecasting in microgrids environment[J]. Energy, 2014, 75: 252-264.
- [42] KUO Pinghuan, HUANG C J. A high precision artificial neural networks model for short-term energy load forecasting[J]. Energies, 2018, 11(1): 213.
- [43] VRABLECOVÁ P, EZZEDDINE A B, ROZINAJOVÁ V, et al. Smart grid load forecasting using online support vector regression[J]. Computers & Electrical Engineering, 2018, 65: 102-117.
- [44] YANG Ailing, LI Weide, YANG Xuan. Short-term electricity load forecasting based on feature selection and Least Squares Support Vector Machines[J]. Knowledge-Based Systems, 2019, 163: 159-173.
- [45] FAN Guofeng, ZHANG Liuzhen, YU Meng, et al. Applications of random forest in multivariable response surface for short-term load forecasting[J]. International Journal of Electrical Power & Energy Systems, 2022, 139: 108073.
- [46] MOON J, KIM Y, SON M, et al. Hybrid short-term load forecasting scheme using random forest and multilayer perceptron[J]. Energies, 2018, 11(12): 3283.
- [47] JALALI S M J, AHMADIAN S, KHOSRAVI A, et al. A novel evolutionary-based deep convolutional neural network model for intelligent load forecasting[J]. IEEE Transactions on Industrial Informatics, 2021, 17(12): 8243-8253.
- [48] ESKANDARI H, IMANI M, MOGHADDAM M P. Convolutional

- and recurrent neural network based model for short-term load forecasting[J]. *Electric Power Systems Research*, 2021, 195: 107173.
- [49] LIN Jun, MA Jin, ZHU Jianguo, et al. Short-term load forecasting based on LSTM networks considering attention mechanism[J]. *International Journal of Electrical Power & Energy Systems*, 2022, 137: 107818.
- [50] WU Lizhen, KONG Chun, HAO Xiaohong, et al. A short-term load forecasting method based on GRU-CNN hybrid neural network model [J]. *Mathematical Problems in Engineering*, 2020, 2020: 1428104.
- [51] LIN Weixuan, WU Di, BOULET B. Spatial-temporal residential short-term load forecasting via graph neural networks[J]. *IEEE Transactions on Smart Grid*, 2021, 12(6): 5373-5384.
- [52] SUN Chenchen, NING Yan, SHEN Derong, et al. Graph neural network-based short-term load forecasting with temporal convolution [J]. *Data Science and Engineering*, 2024, 9(2): 113-132.
- [53] BARBIERATO L, PONS E, BOMPARD E F, et al. Exploring stability and accuracy limits of distributed real-time power system simulations via system-of-systems cosimulation[J]. *IEEE Systems Journal*, 2023, 17(2): 3354-3365.
- [54] XIONG Liansong, LIU Xiaokang, LIU Yonghui, et al. Modeling and stability issues of voltage-source converter-dominated power systems: a review[J]. *CSEE Journal of Power and Energy Systems*, 2022, 8(6): 1530-1549.
- [55] SEGUNDO-RAMIREZ J, BAYO-SALAS A, ESPARZA M, et al. Frequency domain methods for accuracy assessment of wideband models in electromagnetic transient stability studies[J]. *IEEE Transactions on Power Delivery*, 2020, 35(1): 71-83.
- [56] LIU Wentao, KERKES T, DRAGICEVIC T, et al. Review of grid stability assessment based on AI and a new concept of converter-dominated power system state of stability assessment[J]. *IEEE Journal of Emerging and Selected Topics in Industrial Electronics*, 2023, 4(3): 928-938.
- [57] 刘晔, 沈沉. 交直流混联系统的能量函数构造方法综述与探究[J]. *中国电机工程学报*, 2022, 42(8): 2842-2853.
- LIU Ye, SHEN Chen. Review and research on construction methods of energy function for hybrid AC-DC power system[J]. *Proceedings of the CSEE*, 2022, 42(8): 2842-2853(in Chinese).
- [58] WANG Tong, WANG Xiaotong, LIU Guangmeng, et al. Neural networks based Lyapunov functions for transient stability analysis and assessment of power systems[J]. *IEEE Transactions on Industry Applications*, 2023, 59(2): 2626-2638.
- [59] HU Wei, LU Zongxiang, WU Shuang, et al. Real-time transient stability assessment in power system based on improved SVM[J]. *Journal of Modern Power Systems and Clean Energy*, 2019, 7(1): 26-37.
- [60] TIAN Fang, ZHOU Xiaoxin, YU Zhihong, et al. A preventive transient stability control method based on support vector machine[J]. *Electric Power Systems Research*, 2019, 170: 286-293.
- [61] GAO Han, CAI Guowei, YANG Deyou, et al. Real-time long-term voltage stability assessment based on eGBDT for large-scale power system with high renewables penetration[J]. *Electric Power Systems Research*, 2023, 214: 108915.
- [62] SINGH M, CHAUHAN S. A hybrid-extreme learning machine based ensemble method for online dynamic security assessment of power systems[J]. *Electric Power Systems Research*, 2023, 214: 108923.
- [63] 杨博, 陈义军, 姚伟, 等. 基于新一代人工智能技术的电力系统稳定评估与决策综述[J]. *电力系统自动化*, 2022, 46(22): 200-223.
- YANG Bo, CHEN Yijun, YAO Wei, et al. Review on stability assessment and decision for power systems based on new-generation artificial intelligence technology[J]. *Automation of Electric Power Systems*, 2022, 46(22): 200-223(in Chinese).
- [64] LIU Songkai, LIU Lihuang, FAN Youping, et al. An integrated scheme for online dynamic security assessment based on partial mutual information and iterated random forest[J]. *IEEE Transactions on Smart Grid*, 2020, 11(4): 3606-3619.
- [65] CUI Mingjian, LI Fangxing, CUI Hantao, et al. Data-driven joint voltage stability assessment considering load uncertainty: a variational Bayes inference integrated with multi-CNNs[J]. *IEEE Transactions on Power Systems*, 2022, 37(3): 1904-1915.
- [66] SHI Zhongtuo, YAO Wei, ZENG Linggang, et al. Convolutional neural network-based power system transient stability assessment and instability mode prediction[J]. *Applied Energy*, 2020, 263: 114586.
- [67] ZHANG Zhe, QIN Boyu, GAO Xin, et al. CNN-LSTM based power grid voltage stability emergency control coordination strategy[J]. *IET Generation, Transmission & Distribution*, 2023, 17(16): 3559-3570.
- [68] DENG Xuan, HU Yufan, JIA Yiyang, et al. Power system stability assessment method based on GAN and GRU - Attention using incomplete voltage data[J]. *IET Generation, Transmission & Distribution*, 2023, 17(16): 3692-3705.
- [69] LI Baoqin, WU Junyong. Adaptive assessment of power system transient stability based on active transfer learning with deep belief network[J]. *IEEE Transactions on Automation Science and Engineering*, 2023, 20(2): 1047-1058.
- [70] SU Tong, LIU Youbo, ZHAO Junbo, et al. Deep belief network enabled surrogate modeling for fast preventive control of power system transient stability[J]. *IEEE Transactions on Industrial Informatics*, 2022, 18(1): 315-326.
- [71] LI Yang, ZHANG Meng, CHEN Chen. A deep-learning intelligent system incorporating data augmentation for short-term voltage stability assessment of power systems[J]. *Applied Energy*, 2022, 308: 118347.
- [72] LI Yang, ZHANG Shitu, LI Yuanzheng, et al. PMU measurements-based short-term voltage stability assessment of power systems via deep transfer learning[J]. *IEEE Transactions on Instrumentation and Measurement*, 2023, 72: 2526111.
- [73] 丁涛, 黄雨涵, 张洪基, 等. 基于等微增率并计及机组功率约束的火电机组最优负荷分配精确解[J]. *中国电机工程学报*, 2024, 44(4): 1446-1459.
- DING Tao, HUANG Yuhuan, ZHANG Hongji, et al. Precision solution of optimal load dispatch of thermal units with power constraints based on equal incremental cost principle[J]. *Proceedings of the CSEE*, 2024, 44(4): 1446-1459(in Chinese).
- [74] 苑菲, 杨红英, 刘道伟, 等. 基于知识图谱的电网调度运行优化管理系统[J]. *电力信息与通信技术*, 2023, 21(3): 17-25.
- YUAN Fei, YANG Hongying, LIU Daowei, et al. Power grid dispatching operation optimization management system based on knowledge graph[J]. *Electric Power Information and Communication Technology*, 2023, 21(3): 17-25(in Chinese).
- [75] COSIC A, STADLER M, MANSOOR M, et al. Mixed-integer linear programming based optimization strategies for renewable energy communities[J]. *Energy*, 2021, 237: 121559.
- [76] WU Min, XU Jiazhu, ZENG Linjun, et al. Two-stage robust optimization model for park integrated energy system based on dynamic programming[J]. *Applied Energy*, 2022, 308: 118249.
- [77] HE Zhongzheng, WANG Chao, WANG Yongqiang, et al. Dynamic programming with successive approximation and relaxation strategy for long-term joint power generation scheduling of large-scale hydropower station group[J]. *Energy*, 2021, 222: 119960.
- [78] LI Fangyuan, GAO Lefei, ZHANG Yubo, et al. Hierarchical operation switch schedule algorithm for energy management strategy of hybrid

- electric vehicle using adaptive dynamic programming[J]. Sustainable Energy, Grids and Networks, 2023, 35: 101107.
- [79] LIU Shengchun, SONG Liying, WANG Tieying, et al. Negative carbon optimal scheduling of integrated energy system using a non-dominant sorting genetic algorithm[J]. Energy Conversion and Management, 2023, 291: 117345.
- [80] BABU V V, ROSELYN J P, SUNDARAVADIVEL P. Multi-objective genetic algorithm based energy management system considering optimal utilization of grid and degradation of battery storage in microgrid[J]. Energy Reports, 2023, 9: 5992-6005.
- [81] PAN Kui, LIANG Chuandong, LU Min. Optimal scheduling of electric vehicle ordered charging and discharging based on improved gravitational search and particle swarm optimization algorithm[J]. International Journal of Electrical Power & Energy Systems, 2024, 157: 109766.
- [82] GONG Mengting. Multi-objective optimal scheduling analysis of power system based on improved particle swarm algorithm[J]. Distributed Generation & Alternative Energy Journal, 2023, 38(5): 1609-1636.
- [83] CHEN Ludong, ZHANG Pengcheng, WANG Jie, et al. Fuzzy logic based optimization algorithm design for active distribution grid power balance scheduling strategy[J]. Journal of Electrical Systems, 2024, 20(9s): 698-704.
- [84] RODRIGUEZ M, ARCOS-AVILES D, MARTINEZ W. Fuzzy logic-based energy management for isolated microgrid using meta-heuristic optimization algorithms[J]. Applied Energy, 2023, 335: 120771.
- [85] XU Siyang, ZHU Jiebei, LI Bingsen, et al. Real-time power system dispatch scheme using grid expert strategy-based imitation learning[J]. International Journal of Electrical Power & Energy Systems, 2024, 161: 110148.
- [86] DU Sijun, DING Tao, XIAO Yang, et al. Real-time scheduling of high-penetrated renewable power systems: an expert knowledge and reinforcement learning hybrid approach[J]. IEEE Transactions on Power Systems, 2025, 40(2): 1545-1557.
- [87] LI Yang, BU Fanjin, LI Yuanzheng, et al. Optimal scheduling of island integrated energy systems considering multi-uncertainties and hydrothermal simultaneous transmission: a deep reinforcement learning approach[J]. Applied Energy, 2023, 333: 120540.
- [88] LU Yu, XIANG Yue, HUANG Yuan, et al. Deep reinforcement learning based optimal scheduling of active distribution system considering distributed generation, energy storage and flexible load[J]. Energy, 2023, 271: 127087.
- [89] ALABI T M, LAWRENCE N P, LU Lin, et al. Automated deep reinforcement learning for real-time scheduling strategy of multi-energy system integrated with post-carbon and direct-air carbon captured system[J]. Applied Energy, 2023, 333: 120633.
- [90] ZHANG Zitong, SHI Jing, YANG Wangwang, et al. Deep reinforcement learning based Bi-layer optimal scheduling for microgrids considering flexible load control[J]. CSEE Journal of Power and Energy Systems, 2023, 9(3): 949-962.
- [91] LEE S, SEON J, SUN Y G, et al. Novel architecture of energy management systems based on deep reinforcement learning in microgrid[J]. IEEE Transactions on Smart Grid, 2024, 15(2): 1646-1658.
- [92] 李智轩, 陈亦平, 雪映, 等. 多分区异步互联电力系统频率稳定分析与控制研究综述[J]. 电网技术, 2024, 48(12): 5003-5023.
- LI Zhixuan, CHEN Yiping, XUE Ying, et al. Frequency stability analysis and control of multi-area asynchronous interconnected systems: a review[J]. Power System Technology, 2024, 48(12): 5003-5023(in Chinese).
- [93] 《新型电力系统发展蓝皮书》编写组. 新型电力系统发展蓝皮书[EB/OL]. (2023-06-02)[2024-12-06]. <http://www.nea.gov.cn/download/xxdlxtfzlpzgk.pdf>.
- [94] WEINAN E. The dawning of a new era in applied mathematics[J]. Notices of the American Mathematical Society, 2021, 68(4): 565-571.
- [95] 周亮, 张晓娟, 邱意民, 等. 电力数据分类分级方法研究[J]. 电力信息与通信技术, 2023, 21(4): 25-30.
- ZHOU Liang, ZHANG Xiaojuan, QIU Yimin, et al. Research on power data classification and grading method[J]. Electric Power Information and Communication Technology, 2023, 21(4): 25-30(in Chinese).
- [96] KRUSE J, SCHÄFER B, WITTHAUT D. Revealing drivers and risks for power grid frequency stability with explainable AI[J]. Patterns, 2021, 2(11): 100365.
- [97] REN Chao, XU Yan, ZHANG Rui. An interpretable deep learning method for power system transient stability assessment via tree regularization[J]. IEEE Transactions on Power Systems, 2022, 37(5): 3359-3369.
- [98] WANG Huaizhi, CAI Ren, ZHOU Bin, et al. Solar irradiance forecasting based on direct explainable neural network[J]. Energy Conversion and Management, 2020, 226: 113487.
- [99] CHAIBI M, BENGHOULAM E M, TARIK L, et al. An interpretable machine learning model for daily global solar radiation prediction[J]. Energies, 2021, 14(21): 7367.
- [100] CHAKRABORTY D, ALAMA A, CHAUDHURI S, et al. Scenario-based prediction of climate change impacts on building cooling energy consumption with explainable artificial intelligence[J]. Applied Energy, 2021, 291: 116807.
- [101] WENNINGER S, KAYMAKCI C, WIETHE C. Explainable long-term building energy consumption prediction using QLattice[J]. Applied Energy, 2022, 308: 118300.
- [102] MACHLEV R, HEISTRENE L, PERL M, et al. Explainable Artificial Intelligence(XAI) techniques for energy and power systems: review, challenges and opportunities[J]. Energy and AI, 2022, 9: 100169.



陆超

在线出版日期: 2025-09-28。

收稿日期: 2025-07-01。

作者简介:

陆超(1977), 男, 教授, 研究方向为电力系统分析与稳定控制、电力人工智能技术等, E-mail: luchao@tsinghua.edu.cn;

吴小辰(1972), 男, 教授级高级工程师, 硕士, 研究方向为电力系统稳定分析及控制, E-mail: wuxc@csg.cn;

刘迪(1990), 男, 博士, 通信作者, 研究方向为电力系统优化调节、电力人工智能技术等, E-mail: kfliudi@mail.tsinghua.edu.cn。

(责任编辑 徐梅)