

DeepSeek 大模型在电力设备运维管理中的应用研究

毛腾蛟

(深圳供电规划设计院有限公司, 广东 深圳 518000)

摘要: 电力设备运维管理是保障电力系统安全稳定运行的核心环节, 传统方法在故障预测、检修优化及运行状态评估方面存在精准度不足的问题。为此, 分析了 DeepSeek 大模型的预训练与微调机制, 研究了其在电力设备运维管理中的多模态数据处理能力, 提出了基于 DeepSeek 大模型的电力系统故障溯源分析与预测性维护检修策略, 旨在提高设备故障预测精度、优化检修计划、降低非计划停运时间, 并提升运维供电可靠性。

关键词: DeepSeek 大模型; 运维管理; 故障溯源

中图分类号: TM732

DOI: 10.19768/j.cnki.dgjs.2025.22.031

Research on the Application of DeepSeek Large Model in Power Equipment Operation and Maintenance Management

MAO Tengjiao

(Shenzhen Power Supply Planning and Design Institute Co., Ltd., Shenzhen 518000, China)

Abstract: Power equipment operation and maintenance management is the core link to ensure the safe and stable operation of the power system. Traditional methods have insufficient accuracy in fault prediction, maintenance optimization, and operation status evaluation. This article analyzes the pre training and fine-tuning mechanism of the DeepSeek big model, studies its multimodal data processing capability in power equipment operation and maintenance management, and proposes a power system fault traceability analysis and predictive maintenance and repair strategy based on the DeepSeek big model, aiming to improve equipment fault prediction accuracy, optimize maintenance plans, reduce unplanned downtime, and enhance the reliability of operation and maintenance power supply.

Key words: DeepSeek big model; operation and maintenance management; fault tracing

0 引言

电力设备运维管理的智能化水平直接影响电力系统的安全性与经济性, 传统基于阈值设定和规则库匹配的运维方式难以满足现代电网对高精准度故障预测和高效检修策略的需求^[1]。随着人工智能技术的发展, DeepSeek 大模型凭借强大的预训练机制、跨模态数据处理能力及高效推理能力, 在电力设备运维管理领域展现出巨大潜力。本文引入 DeepSeek 大模型, 探索其在设备故障溯源、预测性维护优化及运维成本控制等方面的应用价值, 提升电力设备运维的智能化水平, 实现电力系统安全、可靠、经济运行。

1 DeepSeek 大模型特性

1.1 预训练与微调机制

DeepSeek 大模型依托大规模 Transformer 架构, 采用

收稿日期: 2025-03-15

作者简介: 毛腾蛟(1990—), 硕士研究生, 研究方向为电力工程
管理。

自回归和自编码相结合的预训练范式, 在海量电力设备运维数据集上进行无监督学习, 实现深层次特征抽取与多维度语义建模。预训练阶段根据自注意力机制建立电力系统设备运行状态、故障模式、维护记录之间的长程依赖关系, 使模型具备全局感知能力, 能够精准解析设备运行工况及潜在故障征兆。在电力设备运维管理场景下, DeepSeek 大模型基于梯度下降的参数优化策略实现端到端的深度神经网络训练, 提高模型的泛化能力与决策精准度。微调阶段依托领域自适应迁移学习, 针对输变电设备、配电设施、智能传感器等不同层级设备的运维数据构建专用语料库。采用差分学习率优化增量学习机制增强模型对特定设备运维场景的适应性, 使该模型能精准识别断路器、变压器、无功补偿装置等核心部件的劣化趋势及潜在失效模式。此外, 为提升模型对电网实时运行数据的适应能力, DeepSeek 大模型采用强化学习策略, 由状态-动作-奖励机制优化智能调度与故障诊断的决策路径。

1.2 多模态数据处理能力

DeepSeek 大模型具备多模态数据融合解析能力, 能高效处理电力设备运维管理中多源异构数据, 包括时序运行监测数据、红外热成像、局部放电信号、油色谱分析结

果、振动噪声特征及文本化运维记录。并基于跨模态注意力机制，建立遥测量、状态量、影像数据及语义信息间的关联映射，实现电气设备健康状态精准建模。在输变电设备运维场景中，模型融合 SCADA 系统、PMU 数据流、超声波局放检测信息，构建全景感知矩阵。由视觉 Transformer 提取热成像光谱特征实现母线接头、导体连接点温升异常检测，并结合频谱分析识别高频局部放电模式，提高故障诊断精度。

2 DeepSeek 大模型的应用

2.1 电力设备运维管理架构

DeepSeek 大模型在电力设备运维管理架构中采用层次化架构，涵盖数据采集层、数据处理层、数据存储层和平台展示层，形成从数据采集、预处理、分析存储到智能决策的全链路闭环，如图 1 所示。




图 1 电力设备运维管理架构

数据采集层由 DeepSeek 设备数据采集工具对输变电设备、配电终端、智能传感器及 SCADA 系统的多源异构数据进行实时采集。采集的数据类型覆盖设备运行状态、故障检测、事件触发信息及环境参数，包括变压器负载电流、绕组温度、铁心磁通密度、断路器合分闸时间、触头接触电阻、避雷器泄漏电流等关键运行参数^[2]。同时整合局部放电信号、红外热成像、油色谱分析及 SF₆ 气体分解物浓度等故障特征数据，并结合异常告警、继电保护动作记录、设备跳闸信息及温湿度、气压、风速等环境因素全面构建电力设备健康评估体系。

数据处理层依托 DeepSeek 设备运维数据流架构，采用 Kafka 消息队列作为高并发、高吞吐率的数据流转通道，实现大规模电力设备数据的高效流式处理。该层的核心计算由 DeepSeek 大模型计算中心承担，经过数据清洗、特征工程及实时流处理技术提升数据分析效率。数据清洗模块消除异常值，进行信号去噪及时序对齐，以保证数据质量。特征工程环节基于深度学习方法提取变压器负载预测、断路器开断特性分析、高频局部放电信号提取等设备运行特征，同时利用 Syslog 日志系统进行设备状态变化监测、异常模式分析及故障趋势预测，从而提高设备异常检

测的精准度^[3]。

数据存储层采用分布式存储架构，由电力设备运维数据库及 DeepSeek 数据分析存储节点构成，支撑大规模运维数据的存储、检索及分析。电力设备运维数据库存储历史运行数据、设备健康评估指标及故障事件记录，为运维策略优化提供长期数据支撑^[4]。DeepSeek 数据分析存储节点由高性能计算资源支撑深度学习模型训练与数据分析任务，优化设备异常检测及故障预测的计算精度。

平台展示层构建设备管理、角色管理、配置管理、用户管理及访问权限管理五大模块，由 DeepSeek 设备运维数据分析接口提供智能运维的可视化支持。设备管理模块负责变压器、断路器、避雷器、开关柜等设备状态的实时监控，基于 DeepSeek 智能故障预警系统进行设备运行趋势预测，及时识别潜在故障点并提供维护建议。

2.2 电力系统故障溯源分析

DeepSeek 大模型在电力系统故障溯源分析中融合时序数据建模、故障模式识别及深度因果推理，实现了复杂工况下的多层级故障链路追溯提高电网异常状态的精准诊断能力。该模型依托多模态数据处理能力集成 SCADA 系统遥测数据、PMU 同步相量测量、继电保护动作信息及主设备在线监测数据，构建高维故障特征空间，并采用深度强化学习优化故障传播路径推理机制^[5]。在故障溯源过程中，DeepSeek 大模型基于电力系统动态等值模型，采用广义阻抗矩阵求解故障电流注入量，则故障节点电压偏移量为：

$$\Delta V_i = Z_{ii} I_i + \sum_{j \neq i} Z_{ij} I_j \quad (1)$$

式中， ΔV_i 为故障节点 i 的电压变化量； Z_{ii} 为故障节点自阻抗； I_i 为故障电流； Z_{ij} 为节点 i 与 j 之间的互阻抗； I_j 为非故障节点的电流注入量。经过高维矩阵计算 DeepSeek 大模型可快速定位故障发生点，并结合电压骤降轨迹及短路电流分布评估故障传播趋势。

同时模型采用时序因果推理构建故障传播路径，定义故障影响系数矩阵 F 为：

$$F_{mn} = \frac{\sum_{t=1}^T |S_m(t) - S_n(t)|}{T} \quad (2)$$

式中， F_{mn} 为故障从节点 m 传播至节点 n 的影响强度； $S_m(t)$ 和 $S_n(t)$ 为时刻 t 节点 m 和节点 n 的状态变量； T 为总时间步长。该矩阵使 DeepSeek 大模型在电力系统故障溯源分析中实现高精度溯源决策，结合历史运维数据训练多层神经网络，提高复杂故障环境下的决策泛化能力，为电网调度提供精准的数据支撑。

2.3 预测性维护检修策略

DeepSeek 大模型在电力设备预测性维护检修策略中的应用，依托时间序列建模、深度状态估计及自适应健康评估，构建了全生命周期智能运维体系。在预测性维护模型中引入概率退化状态转移矩阵，定义设备健康状态 $\mathbf{H}(t)$ 随时间演化的马尔可夫过程为：

$$\mathbf{H}(t+1)=\mathbf{P} \cdot \mathbf{H}(t)+\varepsilon(t) \quad (3)$$

式中, $\mathbf{H}(t)$ 为时刻 t 设备健康状态向量; $\mathbf{P}$ 为状态转移矩阵; $\varepsilon(t)$ 为外部随机扰动因子。DeepSeek 大模型基于历史运维数据优化状态转移概率, 结合时间卷积网络(TCN)增强时序依赖建模, 实现电力设备健康状态的动态评估, 为检修策略优化提供数据支撑。

模型采用变分贝叶斯推理预测剩余寿命(RUL), 定义 RUL 为:

$$RUL = \int_t^{T_f} \exp\left(-\int_t^s \lambda(\tau) d\tau\right) ds \quad (4)$$

式中, T_f 为失效时间; $\lambda(s)$ 为时刻 s 的故障率函数。DeepSeek 大模型故障率随时间的动态变化, 并结合贝叶斯更新机制优化故障概率分布, 提高预测精度。在预测性维护决策优化中, 模型基于强化学习算法构建检修决策网络, 利用深度 Q 学习(DQN)动态调整维护周期, 结合设备健康状态、经济成本及电网运行风险评估, 最优控制检修时机。

3 测试与分析

3.1 测试环境

实验基于典型 110 kV 变电站, 选取主变压器(S11-M-10000/110)、SF₆ 断路器(LW36-126)、电流互感器(LZZBJ9-35)等关键电力设备作为研究对象, 模拟运行环境下的故障数据采集与运维策略优化。实验系统采用 DeepSeek 大模型构建预测性维护架构, 并部署于 NVIDIA A100 GPU 服务器, 结合 SCADA、DGA 油色谱分析、红外热成像等数据源进行多模态融合分析。传统方法选取基于门限预警的规则维护策略进行对比分析。

3.2 测试步骤

(1)数据采集: 采集主变压器绕组温度(75.32℃)、油温(68.21℃)、局部放电(36.87 pC), SF₆ 断路器气体压力(0.58 MPa)、触头电阻(68.79 μΩ), 电流互感器二次侧电流畸变率(2.63%)等运行数据。

(2)数据预处理: 采用小波去噪、异常值剔除及时序插值补全缺失值, 保证数据完整性。

(3)模型训练与优化: DeepSeek 模型基于历史运维数据进行预训练, 并在测试数据上微调, 优化健康评估权重。

(4)对比实验: 分别采用 DeepSeek 模型与传统门限策略进行预测性维护分析, 并对设备健康状态、检修次数及经济性指标进行评估。

(5)结果分析: 从故障预警准确度、检修时间优化、运维成本等方面分析 DeepSeek 模型的应用优势。

3.3 测试结果分析

测试结果见表 1, DeepSeek 大模型在故障预测准确

度、误报率、误判率以及非计划停运时间等方面均优于传统方法。从预测提前量来看, DeepSeek 大模型能够更早期识别潜在故障, 为检修规划提供充足时间; 在误报率和误判率方面, DeepSeek 大模型能更精准地识别设备运行状态, 减少无效报警, 提高维护资源的合理调度; 在非计划停运时间方面, DeepSeek 模型优化的预测维护策略能够有效减小设备突发故障对系统稳定性的影响, 提高供电可靠性; 从综合运维成本来看, DeepSeek 大模型由精准故障预测和优化维护计划, 显著减少了无效检修和紧急维修成本, 提高了整体经济性。

表 1 测试结果

设备名称	评价指标	DeepSeek 大模型	传统方法
主变压器	预测提前量/h	92.37	24.56
	误报率/(%)	1.38	6.92
	误判率/(%)	2.14	9.87
	非计划停运时间/h	3.79	17.61
SF ₆ 断路器	预测提前量/h	87.24	21.93
	误报率/(%)	1.52	7.68
	误判率/(%)	2.69	8.31
	非计划停运时间/h	4.21	19.83
电流互感器	预测提前量/h	98.76	28.49
	误报率/(%)	0.97	5.74
	误判率/(%)	1.85	10.42
	非计划停运时间/h	3.41	16.29

4 结语

本文围绕 DeepSeek 大模型在电力设备运维管理中的应用展开研究, 结合电力系统故障溯源分析和预测性维护检修策略, 构建智能化运维管理体系。实验结果表明, DeepSeek 大模型能够提升设备故障预测准确度、优化运维资源配置, 并缩短非计划停运时间, 显著增强电网运行的安全性与经济性。

参考文献

- [1]李继军.电力设备智能运维管理系统在高速铁路的研究与应用[J].电气时代,2025(2):125-128.
- [2]吴鹏.人工智能技术在电力设备运维中的应用及未来发展探析[J].现代工业经济和信息化,2025,15(1):273-275.
- [3]华军军.电力系统中电力设备健康管理 with 智能运维关键技术研究[J].电工技术,2024(S2):683-685.
- [4]管雅鹏.基于虚拟现实技术的电力设备运维培训模拟平台设计与实现[J].电气技术与经济,2024(11):203-205.
- [5]童剑峰, 琚红, 许赞.图像识别技术在电力设备运维中的应用研究[J].电力设备管理,2024(20):218-220.