

基于高级检索增强生成技术与多模态大模型的 电力应急演练应用研究

李文超, 蒲毅, 白洋, 艾夏冕, 朱跃

(云南电网有限责任公司红河供电局, 云南 红河哈尼族彝族自治州 661199)

摘要: 针对传统大模型在电力应急演练中存在知识滞后与幻觉等问题, 文章提出一种基于高级检索增强生成(Advanced Retrieval-Augmented Generation, RAG)的多模态大模型框架。通过构建电力应急多模态知识库, 结合多维向量检索、知识重构与跨模态融合机制, 实现动态信息获取与精准内容生成。实验表明, 该方法能高效准确地生成可解释的应急演练方案, 显著提升方案的实用性与可操作性, 为电力系统智能化应急响应提供技术支撑。

关键词: 多模态大模型; 高级检索增强生成; 应急演练; 电力行业

中图分类号: TP393 文献标识码: A

文章编号: 1009-3044(2025)34-0102-03

DOI: 10.14004/j.cnki.ckt.2025.1742

开放科学(资源服务) 标识码(OSID):



1 概述

1.1 研究背景与意义

电力行业是国家能源安全与社会稳定的重要支柱, 随着新能源大规模并网, 电力系统面临的风险日益复杂化, 对应急管理提出更高要求。新型电力系统安全风险呈现三大特征: 一是来源多元, 除设备故障外, 新能源处理随机性、电力设备稳定性问题及用户负荷不确定性显著增加风险维度^[1-3]; 二是传导快速且易连锁, 源网荷储耦合加深使局部故障易引发跨区功率失衡与保护误动^[4], 叠加通信、网络等外部风险, 易导致大范围连锁故障^[5]; 三是评估困难, 新能源与负荷的不确定性 & 系统形态的动态变化, 使传统确定性评估方法难以满足当前需求^[6]。

在此背景下, 应急演练亟须智能化升级。大模型技术展现出极大的应用潜力, 检索增强生成(RAG)技术能够提升内容专业性, 多模态模型增强了对复杂场景的理解。本文提出融合大模型、RAG与多模态技术的智能框架, 面向电力演练生成科学、实用的应急演练方案, 推动电力应急管理向数字化、智能化发展。研究遵循相关演练原则, 兼具理论价值与实践意义。

1.2 主要研究现状

大模型在电力应急演练中成效显著: 国网上海电力“光明电力大模型”的“AI大脑”, 在上海电网春季检修演练中, 调度员借主配融合负荷转供智能体, 3分钟完成35千伏变电站全站失电故障处置模拟, 故障感知达分钟级, 负荷转供方案编制缩至30秒内, 准确率接

近100%; 应急管理部“久安”大模型, 在“断路、断网、断电应急救援行动”演习中, 可监测铁塔离线率等数据、预警并预判灾情区域, 还能结合历史案例与应急预案生成并调整救援方案。二者均证明大模型能提升电力应急演练效率与准确性, 为应急处置提供支持。

1.3 研究目的与贡献

本文旨在构建电力行业多模态大模型驱动的高级RAG应急演练方案生成机制, 解决传统方案生成的系列问题。主要贡献为: 构建含多模态数据的行业应急演练知识库; 设计高级检索增强生成框架, 实现行业知识动态检索与跨模态融合; 提出多模态方案生成机制, 自动生成优质方案; 通过实验与案例分析, 验证了框架的有效性与实用性。

2 理论基础和相关研究

2.1 多模态大模型

传统LLM(Large Language Model, 大语言模型)工作原理分为分词、词嵌入、注意力机制、内容生成四步; 多模态大模型与之类似, 步骤为多模态输入处理、模态嵌入、跨模态对齐与融合、高层语义建模、内容生成。在应急演练方案生成中, 本文引入多模态大模型弥补单一文本模型的不足: 关联性上, 通过跨模态注意力机制匹配环境与指令, 生成贴合语境的步骤; 通用性上, 依托多模态生成机制输出多样化内容, 增强方案的灵活性与可操作性。此设计赋予应急演练知识跨模态特性, 使方案更贴近真实, 支撑应急决策与实战训练。

收稿日期: 2025-10-05

作者简介: 李文超(1975—), 男(傣族), 云南弥勒人, 高级工程师, 研究方向为应急管理; 蒲毅(1982—), 重庆人, 工程师, 学士, 研究方向为电气工程自动化; 白洋(1980—), 男, 云南石屏人, 工程师, 研究方向为应急保供电管理; 艾夏冕(1987—), 男, 云南通海人, 工程师, 学士, 研究方向为变电运行及应急防灾减灾; 朱跃(1990—), 男, 云南石屏人, 工程师, 学士, 研究方向为电气工程自动化。

2.2 高级检索增强生成(RAG)技术在应急演练方案生成中的应用

检索增强生成(Retrieval-Augmented Generation, RAG)是一种结合外部知识检索与生成式模型推理的框架。其基本思想是,在用户提出问题后,系统首先从知识库或外部文档中检索与问题相关的信息,再将检索结果与用户输入拼接,作为生成模型的额外上下文,从而提升答案的事实性与时效性。这种方法在一定程度上缓解了大模型知识更新滞后和“幻觉”现象,但其性能仍高度依赖于检索结果的质量,且在当前复杂知识任务中往往存在不足。

为克服传统RAG局限,研究者提出高级检索增强生成(Advanced RAG),其深度优化并耦合检索与生成环节:检索阶段,除关键词或向量匹配,还引入多模态检索、语义理解等技术精准筛选重构知识;生成阶段,模型可调用外部知识,还能借优化后的知识表示增强上下文理解与推理能力^[7]。最终生成结果连贯性不变,噪声与幻觉减少,事实性和专业性提升,能更好应对复杂知识密集型任务。




图1 RAG与Advanced RAG对比图

3 面向电力应急演练的Advanced RAG框架设计与实现

3.1 总体框架设计

电力应急演练方案的生成可划分为基于大模型的向量知识库的构建、多模态驱动的应急演练内容理解、多模态检索增强生成应急演练方案三个阶段。

1) 构建基于大模型的向量知识库:收集电力应急相关的多模态数据,利用大语言模型提取语义特征并通过向量模型转化为高维向量,形成结构化的综合知识库。

2) 应急内容理解与检索:将用户输入的口语化需求转换为专业描述,分词并向量化后,在向量库中检索匹配的多模态内容,经整理分析后作为生成输入。

3) 多模态检索增强生成:以用户问题和检索结果(文本、图像、表格等)为联合输入,通过大模型融合生成语义准确、结构完整、符合规范的应急演练方案,实现知识驱动的智能输出。

3.2 多模态应急知识库构建

本研究构建基于向量数据库的行业知识库,分为四个阶段:1) 数据预处理:原始数据含规程标准类文本、图像等,文本与表格经规则解析分块,图像及PDF

用OCR提内容并留图像特征;2) 向量化表示:文本用text-embedding-v1编码,图像与复杂文档用multimodal-embedding-v1转向量,部分数据先生成摘要,摘要与原文分别存储;3) 向量存储:以ChromaDB为底层库,设置三种方案——多模态数据统一嵌入存储、摘要与原文档分存并构建多向量检索器、集合统一管理并引入灵活检索配置;4) 索引与动态更新:知识条目有唯一doc_id,ChromaDB索引支持相似度高效检索,结合多向量路由实现粗细粒度联合匹配,系统支持动态更新,新数据可实时向量化入库。




图2 基于父子索引的多向量检索流程示意图

3.3 核心检索与重排序策略

针对电力应急场景中全局向量语义缺失与跨模态对齐难题,本文提出基于“子-父”文档结构与多向量集合的层次化多模态检索机制,通过融合文本与图像联合嵌入提升检索精度。该方法与医学中MMRAG^[8]具有共性。检索时,针对查询向量 $q \in R^d$,与同一文档的多个向量 $\{v_1, v_2, \dots, v_m\}$ 分别计算相似度,在检索过程中构造了一个加权相似度函数:

$$Score(q, D) = \alpha \cdot sim(q, v_s) + (1 - \alpha) \cdot sim(q, v_f) \quad (1)$$

式中: $\alpha \in [0, 1]$ 为可调参数,用于控制摘要与原文的权重分配, v_s 为摘要向量, v_f 为全文向量。当 $\alpha \rightarrow 1$ 时,系统偏向于快速召回,提升响应速度;当 $\alpha \rightarrow 0$ 时,系统偏向于精确匹配,提升结果质量。

在多模态检索结果得到后,系统还支持对候选集进行重排序。假设召回得到的候选文档集合为 $R = \{D_1, D_2, \dots, D_k\}$,则最终排序分数可形式化为:

$$RankScore(D_i) = \lambda \cdot Score(q, D_i) + (1 - \lambda) \cdot Rel(D_i, task) \quad (2)$$

式中: $Score(q, D_i)$ 为基于相似度的打分; $Rel(D_i, task)$ 为任务相关; λ 为权重因子。该机制使得排序不仅考虑相似度,还结合了任务上下文的匹配度,确保最终输入生成模型的内容更加契合实际需求。

3.4 多模态信息融合与生成机制

多模态数据融合通过整合来自不同模态的信息,充分发挥各模态在不同领域或视角下的优势,实现对同一对象的全面表征。其目标是将多源单模态信息集成到统一的紧凑表示中,构建能协同处理与关联多

种模态数据的模型^[9-10]。系统文本嵌入模型 $f_{text}(\cdot)$ 与图像嵌入模型 $f_{image}(\cdot)$ 将不同模态数据映射至统一向量空间 R^d 。设文本输入为 T , 图像输入 I , 则其向量表示为:

$$v_T = f_{text}(T), v_I = f_{image}(I)$$

(3)

其相关性可由余弦相似度度量:

$$sim(v_T, v_I) = \frac{v_T \cdot v_I}{\|v_T\| \cdot \|v_I\|}$$

(4)

这样, 即便输入来自不同模态, 也能进行相似度检索与匹配。

在本研究的系统实现中, 检索器采用了父子索引机制。该机制的核心思想是利用摘要向量作为父索引进行快速召回, 并通过唯一标识符 doc_id 回溯到原文或图像等子内容。其流程可描述为:

$$Retrieve(q) = \{D_j | v_s \in TopK(sim(q, v_s)), doc_id(v_s) = doc_id(D_j)\}$$

(5)

生成模型不仅利用文本知识, 还结合图像与表格摘要信息, 实现融合式答案生成。其过程可抽象为:

$$A = g(q, (v_T, v_I, v_s))$$

(6)

式中: $g(\cdot)$ 表示多模态生成函数, 输入为查询向量及多模态知识向量集合, 输出为答案或解决方案。

4 实验效果

本文实验旨在验证多模态大模型驱动的高级RAG框架在电力内容检索与生成中的效果, 重点考查以下几点: 多向量集合机制对电力规程、案例及图像等多模态信息检索覆盖率与精度的提升作用; 结合高级RAG技术的多模态大模型能否生成更完整、专业且可操作的应急演练方案; 优化后的检索配置与多向量索引机制在响应速度和精度间的权衡效果。

4.1 实验环境及参数配置

实验在 Windows 11 系统下进行, 硬件环境包括 16 核 CPU、64GB 内存, Python 版本是 3.11.9, CUDA 版本 12.0, 实验中使用到的大模型的超参数配置如下: 大语言模型的超参数配置为: max_tokens 设为 2000, temperature 设为 0.7, top_p 设为 0.9, learning_rate 设为 $2e^{-5}$; 多模态大模型的超参数配置为: context_length 设为 131072, token 设为 16384, 优化器 AdamW 的参数为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.98$ 、 $\eta = 1e^{-6}$, max_pixels 设为 4-16384。

4.2 实验结果与讨论

本研究以电网应急演练文档为主要测试材料, 比较了通义千问 Qwen-Max 模型与 Qwen-VL-Max 多模态模型在问题生成任务中的表现。实验设定涵盖了演练方案、事故处置流程、调度指令记录以及附带的电网运行图像资料。评价指标包括多样性、准确性, 并引入了 BLEU、ROUGE 等 NLP 评测指标, 设计了一个包含多个维度的专家评估量规, 邀请领域专家进行打分。

表1 问题生成评估表

性能对比	Qwen-Max	Qwen-VL-Max
多样性	28.5	31.0
准确性	52.0	55.5
BLEU	75.0	82.0
ROUGE	68.0	74.0
专家评分	78.0	85.0
总计	61.475	66.725

实验先将所有指标统一归一化到相同量纲(百分制), 再根据各指标重要性赋予对应权重, 最终计算加权综合得分。设多样性 15%, 准确性 25%, BLEU 20%, ROUGE 20%, 专家评分 20%。从表 1 中可以看出, 在相同的知识库和检索技术前提下, Qwen-VL-Max 在多样性、准确性、BLEU、ROUGE 以及专家评分方面均优于 Qwen-Max。这表明 Qwen-VL-Max 在处理多模态数据时具有更强的能力。

5 结论

本文针对电力行业应急演练痛点, 提出并实现基于多模态大模型的高级检索增强生成(Advanced RAG)框架。该框架融合多类数据构建动态更新知识库, 通过闭环机制提升应急方案生成效率与覆盖度, 缓解知识分散及人工依赖问题。框架具有通用性与可扩展性, 可迁移至多行业支撑应急管理智能化升级, 未来可结合多模态加权索引等进一步优化。此框架推动电力应急演练数字化智能化转型, 同时为其他行业提供参考, 对提升社会应急响应能力具有显著意义。

参考文献:

[1] 杨涛,周洪,魏凤,等. 新型电力系统下的电网安全挑战与对策研究[J]. 电力信息与通信技术,2024,22(8):18-26.

[2] 马骞,祁达才,李建设,等. 电网安全风险管理与实践[J]. 南方电网技术,2014,8(4):11-16.

[3] 胡博,谢开贵,邵常政,等. 双碳目标下新型电力系统风险评述: 特征、指标及评估方法[J]. 电力系统自动化,2023,47(5):1-15.

[4] 张浩楠,崔丽敏. 新型电力系统的气候风险适应性分析及展望[J]. 电力建设,2025,46(3):16-33.

[5] 闫炯程,李常刚,刘玉田,等. 数据驱动的新型电力系统安全风险预警综述[J]. 电网技术,2024,48(12):4989-5002.

[6] 姜力杨,盖晨昊,齐航,等. 数据驱动的电力系统动态安全评估研究综述[J]. 山东电力技术,2024,51(4):27-35.

[7] XU K H, ZHANG K, LI J Y, et al. CRP-RAG: a retrieval-augmented generation framework for supporting complex logical reasoning and knowledge planning[J]. Electronics, 2025, 14 (1):47.

[8] ZHAN Z F, WANG J, ZHOU S, et al. MMRAG: multi-mode retrieval-augmented generation with large language models for biomedical in-context learning[J]. Journal of the American Medical Informatics Association,2025,32(10):1505-1516.

[9] 高伟,汪悦,宋春涛,等. 基于多模态融合与图神经网络的用户精准感知系统研究[J]. 邮电设计技术,2023(6):30-35.

[10] 李学龙. 多模态认知计算[J]. 中国科学:信息科学,2023,53 (1):1-32.

【通联编辑:张薇】