

多模态大模型与 Gabor 变换的电力调度数据异常检测

李 芑

(国网南京市高淳区供电公司, 江苏 南京 211300)

摘 要: 由于现行的方法在电力调度数据异常检测场景中应用效果不佳, 不仅 ROC 曲线下的面积 (area under the curve, AUC) 值比较低, 而且漏检问题比较严重, 为此提出考虑多模态大模型与 Gabor 变换 (短时傅里叶变换) 的电力调度数据异常检测研究。利用 Gabor 变换对电力调度数据去噪, 并通过多模态大模型对电力调度数据融合, 识别检测异常数据, 实现考虑多模态大模型与 Gabor 变换的电力调度数据异常检测。经实验证明, 设计方法 AUC 值基本接近 1, 并且漏检率不超过 1%, 可实现对电力调度数据精准检测。

关键词: 多模态大模型; Gabor 变换; 电力调度数据; 异常检测

0 引言

随着智能电网的快速发展, 电力调度系统面临前所未有的复杂性和挑战性。作为电力系统的核心组成部分, 电力调度负责实时监控和优化电网运行状态, 确保电力供应的安全、可靠和高效。然而, 随着电网规模的扩大和新型能源的接入, 电力调度数据呈现爆炸式增长, 数据类型也从传统的数值型数据扩展到包含图像、视频、文本等多种模态的信息。如何从这些海量、多模态的数据中准确、快速地检测出异常, 成为保障电网安全稳定运行的关键所在。近年来, 电力调度数据异常检测受到研究领域的重视与关注, 相关学者与专家针对该课题展开研究与探讨, 并取得了一定的研究成果。

文献 [1] 提出基于支持向量机的检测方法, 利用支持向量机 (support vector machine, SVM) 在特征空间中构建最优超平面, 将正常数据与异常数据有效分隔。通过对调度数据进行预处理、特征提取, 训练 SVM 模型以识别数据中的异常模式, 实现异常检测。文献 [2] 提出基于 Boosting 集成框架的检测方法, 通过多层递进式训练模式,

利用基分类器初步判断, 构建平衡数据集训练次级分类器, 最终决策器对数据异常识别检测。

尽管电力调度数据异常检测技术得到了广泛的应用, 但是现行方法仍然存在一些不足和挑战, 为此提出考虑多模态大模型与 Gabor 变换的电力调度数据异常检测研究, 其创新点如下:

(1) 将 Gabor 变换应用于电力调度数据的去噪环节, 充分利用 Gabor 变换在时频分析中的优势。相比于传统的去噪方法, Gabor 变换能够更好地捕捉电力调度数据中的局部特征, 尤其是在非平稳信号的处理上表现出色。通过这种变换有效去除数据中的噪声, 提高后续异常检测的准确性。

(2) 利用多模态大模型对电力调度数据进行融合与异常识别。多模态大模型能够处理来自不同来源或不同特征的数据 (如时间序列、空间数据等), 并通过深度学习技术进行特征提取与融合。这种方法不仅提高了数据的利用率, 而且还增强模型对复杂异常模式的识别能力。

(3) 通过结合 Gabor 变换与多模态大模型, 显著提升异常检测的 AUC 值 (接近 1) 并降低漏检率 (不超过 1%), 表明该方法在电力调度数据异常检测中具有极高的准确性和鲁棒性。

1 基于 Gabor 变换的电力调度数据去噪

在智能电网数据采集网络中, 所采集的电力调度数据其中混杂着干扰性较强的高斯白噪声, 这些信息尚不能直接作为可靠样本用于检测电力调度数据异常状态。为提高数据异常检测的精确度并确保样本数据的可靠性, 首要任务便是有效消除这些状态信息中的噪声成分。为实现这一目标, 采用 Gabor 变换技术对电力调度数据去噪^[3]。Gabor 变换以时域和频域双周期扩展的时间序列为基础, 通过自适应滤波的归一化处理, Gabor 变换识别并消除噪声信号, 从而保留原始状态信息的真实性和完整性。在实际应用中, Gabor 变换消除状态信息噪声的过程主要包括两个核心步骤: 聚集性度量和自适应滤波降噪。

1.1 电力调度数据聚集性度量计算

通过聚集性度量, 评估噪声在电力调度数据信息中的分布情况和强度, 为后续的自适应滤波提供有力依据。为了量化电力调度数据聚集性, 首先计算电力调度数据的信息熵^[4]。信息熵作为一个衡量信息不确定性的指标, 在这里被用来评估电力调度数据中噪声的混乱程度^[5]。通过计算信息熵, 将状态信息按照熵值的大小进行重新排列, 从而识别出噪声干扰最为严重的部分, 其计算公式为:

$$\zeta = \frac{1}{2} \sqrt{\sigma_x^2 \kappa h} \quad (1)$$

式(1)中, ζ 表示电力调度数据信息熵; σ_x 表示电力调度数据的噪声标准差; κ 表示电力调度数据实时序列; h 表示受噪声干扰丢失的电力调度数据。接下来, 限制上界状态信息与下界状态信息的范围, 将它们约束在一个正态分布矩阵中^[6]。这个正态分布矩阵被视为目标降噪矩阵, 电力调度数据正态分布矩阵的表达式为:

$$D = \|h(X_1) + h(X_2)\|^2, \zeta_{\min} \leq \zeta(X_1, X_2) \leq \zeta_{\max} \quad (2)$$

式(2)中, D 表示电力调度数据正态分布矩阵; $h(X_1)$ 、 $h(X_2)$ 分别表示电力调度数据上界与下界之间的

数据样本; $\zeta_{\min}$ 、 $\zeta_{\max}$ 分别表示电力调度数据下界信息熵和上界信息熵^[7]。通过将矩阵映射至时频域空间, 获取该矩阵在时域和频域上的波段信息^[8], 电力调度数据时, 频域空间, 其公式表示为:

$$F = \frac{P_e - P_a}{\|e^{-1}\|} \quad (3)$$

式(3)中, F 表示电力调度数据时频域空间; P_e 、 P_a 分别表示电力调度数据时频掩蔽信号分量和时频域空间约束条件; e 表示电力调度数据噪声信号长度^[9]。通过映射获取电力调度数据正态分布矩阵在时域和频域上的波段特征, 以此度量电力调度数据时域波段和频域波段的聚集性, 其公式表示为:

$$C_s = E_t \cdot E_{t-1} (D - F)^r \quad (4)$$

$$C_p = \xi \times \frac{\varepsilon}{\Delta F D} \quad (5)$$

式(4)和式(5)中, C_s 表示电力调度数据时域波段的聚集性度量值; E_t 表示聚集性有效度量参数; E_{t-1} 表示时频域空间有效噪声分布面积; r 表示电力调度数据时域波段特征; C_p 表示电力调度数据频域波段的聚集性度量值^[10]; ξ 表示电力调度数据时频带宽度; ε 表示计量贡献值。

对电力调度数据聚集性的评估与度量过程中, 需要注意到数据的时间序列特性^[11]。时间序列数据往往具有自相关性, 即当前的数据值与之前的数据值之间存在某种关联。因此, 在计算信息熵和构建正态分布矩阵时, 应充分考虑这种自相关性, 以确保评估结果的准确性。此外, 针对电力调度数据的实时性要求, 需要设计一种高效的算法来快速计算上述公式, 以便在实际应用中能够及时获取噪声的分布情况和强度。这可能需要利用一些先进的计算技术和优化算法, 如并行计算、分布式计算等, 以提高计算效率。值得注意的是, 以上方法主要适用于电力调度数据的离线分析。对于在线实时应用, 可能需要结合其他技术, 如滑动窗口算法等, 以实现电力调度数据的动态监测和噪声抑制。

1.2 自适应滤波降噪

基于时域波段与频域波段聚集性度量的深入分析, 在目标降噪矩阵中巧妙地分配自适应滤波^[12], 自适应滤

波降噪的公式为:

$$x = \{C_s(\phi) - C_p(\phi)\}^2 \quad (6)$$

式(6)中, x 表示降噪后的电力调度数据; ϕ 、 φ 分别表示 Gabor 变换母小波和时频域空间内保留的有用数据。通过以上方法实现对电力调度数据 Gabor 变换。

2 基于多模态大模型的电力调度数据异常识别检测

考虑到电力调度数据来源于多个传感器, 数据模态存在差异, 为了获得更加精确和全面的信息, 将去噪后的多模态电力调度数据进行综合分析, 实现对电力调度数据二分类, 识别检测异常数据。因此, 利用多模态大模型将各类数据源的信息融入一个统一的框架内, 从而增强数据异常识别检测任务执行的效能和结果的准确性。在多模态大模型架构中, 针对每一个模态, 都能够在预训练模型坚实基础上, 借助数据集实施微调策略。该做法在充分利用预训练模型优势的同时, 确保两侧编码器均能良好地适应特定的数据集。

多模态大模型摒弃单模态大模型中的分类层, 选择在隐层维度上将隐层状态进行拼接。拼接得到的向量进一步通过一个线性层进行映射处理, 最终解决一个二分类问题。线性层将特征向量映射到一个全新的向量空间中, 学习到特定的权重参数^[13]。假设有一个模态电力调度数据输入 x 、另一个模态电力调度数据 y , 输入到多模态大模型中将两种模态电力调度数据编码为特征向量, 其公式表示为:

$$S_x = Wav2Vec(x) \quad (7)$$

$$S_y = BERT(y) \quad (8)$$

式(7)和式(8)中, S_x 、 S_y 分别表示编码的模态 x 电力调度数据和模态 y 电力调度数据; $Wav2Vec$ 表示模态 x 电力调度数据特征向量维度; $BERT$ 表示模态 y 电力调度数据特征向量维度。将 S_x 和 S_y 结合起来, 生成一个联合表示向量, 这可以通过一个结合函数表示:

$$v = f(S_x, S_y) \quad (9)$$

式(9)中, v 表示多模态电力调度数据联合表示向量; f 表示结合函数。在此基础上, 对多模态电力调度数据联合表示向量通过线性层映射, 其公式表示为:

$$v_* = Linear[f(S_x, S_y)] = Wv + B \quad (10)$$

式(10)中, v_* 表示映射后的多模态电力调度数据联合表示向量; W 表示线性层的权重; B 表示线性层的偏置。最终, 利用联合表示向量进行分类任务, 即电力调度数据正常、异常二分类, 其公式表示为:

$$P = sigmoid(W_T v_* + b_T) \quad (11)$$

式(11)中, P 表示电力调度数据为异常数据的概率; $sigmoid$ 表示激活函数; W_T 、 b_T 分别表示多模态大模型分类器的权重和偏置。通过以上将多模态电力调度数据融合, 识别检测电力调度数据, 实现考虑多模态大模型与 Gabor 变换的电力调度数据异常检测。

在融合多模态电力调度数据进行异常检测的过程中, 需考虑数据的时空特性。电力调度数据不仅包含来自不同传感器的模态信息, 还往往具有时间和空间上的关联性。因此, 在构建多模态大模型时, 可以进一步引入时空注意力机制, 以捕捉数据中的时空依赖关系。

此外, 为了提升模型的泛化能力和鲁棒性, 我们可以采用数据增强技术, 通过对原始数据进行变换和扩展, 生成更多的训练样本。这不仅可以增加模型的训练数据量, 还可以帮助模型得到更加丰富的特征表示, 从而提高异常检测的准确性。值得注意的是, 异常检测任务往往面临着数据不平衡的问题, 即正常数据远多于异常数据。为了解决这个问题, 可以在训练过程中采用重采样、代价敏感学习等技术, 以平衡不同类别数据的贡献, 从而进一步提高异常检测的效能。

3 实验论证

3.1 实验场景及数据集

为了验证本文方法的有效性与可靠性, 以某电力调度数据集为测试样本, 电力调度数据来源于某电网调度数据库, 数据集共包含 1000 个样本, 具体如表 1 所示。

表 1 电力调度数据

时间/h	区内发电量/kW·h	联络线送电量/kW·h	联络线受电量/kW·h
1	1251.62	568.14	624.54
2	2461.24	1032.51	1254.95
3	3125.57	1624.84	1748.51
4	4156.25	2162.14	2263.45
5	4986.71	2653.81	2864.19
6	6023.41	3035.25	3268.48

利用本文设计方法对该电力调度数据异常检测，实验环境设计，如表 2 所示。

表 2 实验环境

序号	项目	配置
(1)	CPU	Intel core i8 CPU
(2)	操作系统	Windows10
(3)	内存	16 GB
(4)	硬盘	128 GB
(5)	框架	1.1Python

在以上实验环境下进行电力调度数据异常检测。

3.2 实验流程及指标

将数据样本输入到式(1)~式(6)中进行 Gabor 变换，输入到多模态大模型中进行数据融合，多模态大模型参数设置，如表 3 所示。

表 3 多模态大模型参数表

序号	参数	设定值
(1)	模态数量	5
(2)	层数	10
(3)	头数	10
(4)	最大序列长度	216
(5)	隐层维度	110

通过多模态大模型数据融合，识别检测异常数据。为了使此次研究具有一定的参考性价值，在实验中将文献[1]提出的基于支持向量机的检测方法，文献[2]提出的基于 Boosting 集成框架的检测方法作为对照组。检测效果评价选择 AUC 和漏检率，AUC 为受试者工作特征曲线下面积，AUC 值越接近 1，则表示检测精度越高，通过对比三种方法 AUC 值和漏检率，评价本文方法检测精度。

3.3 实验结果与讨论




图 1 电力调度数据异常检测 AUC




图 2 电力调度数据异常检测漏检率

从图 1 可以看出，设计方法 AUC 最接近 1，最高可以达到 0.98，远远高于其余两种方法；从图 2 可以看出，设计方法漏检率不超过 1%，文献[1]提出的方法漏检率最高，超过 3%。因此实验证明，设计方法更适用于电力调度数据异常检测，可以实现对异常数据的精准检测。

4 结语

本文研究了多模态大模型与 Gabor 变换在电力调度数据异常检测中的融合应用，通过构建综合模型，有效提升了异常检测的准确性和效率。研究成果不仅验证了多模态数据融合与高级信号处理技术在电力系统监测中的潜力，也为未来智能电网的异常检测提供了新的技术路径。展望未来，计划进一步优化模型架构，提升其在复杂场景下的泛化能力。同时，将深入研究更高效的特征提取方法，以增强模型对异常模式的识别能力。此外，探索实时异常检测算法的实现，以及模型解释性的增强，将是未来研究的重要方向，以期为实现电力调度系统的智能化运维提供更全面和可靠的技术支持。

参考文献：

- [1] 刘震宇. 基于支持向量机的电力系统调度数据异常检测方法[J]. 自动化技术与应用, 2023, 42(6): 24-27.
- [2] 陈宇轩, 张耀, 徐杨, 等. 基于 Boosting 集成框架的新能源发电功率异常值检测方法[J]. 电网技术, 2023, 47(8): 3261-3268.
- [3] 王世杰, 邓捷, 胡勇, 等. 通信动力环境下电网运行状态在线自动监测技术研究[J]. 自动化与仪器仪表, 2023(8): 240-244.
- [4] Yunfei M, Yaqing Z, Hongjie J, et al. Day-ahead optimal scheduling of building energy microgrids based on time-varying virtual energy storage[J]. IET Renewable Power Generation, 2022, 17(2): 376-388.

- [5] 杨婕, 李泽辉, 马锴, 等. 基于小脑模型神经网络的温控负荷优化调度方法 [J]. 电力系统自动化, 2022, 46(10): 199-208.
- [6] 陈海鹏, 陈晋冬, 张忠, 等. 计及灵活运行碳捕集电厂捕获能耗的电力系统低碳经济调度 [J]. 电力自动化设备, 2021, 41(9): 133-139.
- [7] 王志南, 张宇华, 黄珂, 等. 计及多种柔性负荷的虚拟电厂热电联合鲁棒优化调度模型 [J]. 电力建设, 2021, 42(7): 1-10.
- [8] 孙毅, 张辰, 李泽坤, 等. 计及多区域用户差异化 PMV 的柔性负荷多功率级调控策略 [J]. 中国电机工程学报, 2021, 41(22): 7574-7585.
- [9] 杨挺, 张璐, 张亚健, 等. 基于信息熵计算模型的电力信息物理系统融合控制方法 [J]. 电力系统自动化, 2021, 45(12): 65-74.
- [10] 耿世平, 牛东晓, 郭晓鹏, 等. 计及多能源柔性负荷调度的微能源网多目标演化博弈 [J]. 电力建设, 2020, 41(11): 101-115.
- [11] Peng B, Xie Y, Seco-Granados G, et al. Communication Scheduling by Deep Reinforcement Learning for Remote Traffic State Estimation With Bayesian Inference [J]. IEEE Transactions on Vehicular Technology, 2022, 71(01): 4287-4300.
- [12] 林桂辉, 吴伟, 徐春华, 等. 基于信息熵理论的配电网多目标负荷调度模型设计 [J]. 电子设计工程, 2023, 31(1): 98-101, 106.
- [13] 陈家兴, 王春玲, 刘春明. 基于改进碳排放流理论的电力系统动态低碳调度方法 [J]. 中国电力, 2023, 56(3): 162-172.

作者简介:

李芄 (1998—), 女, 本科, 助理工程师。电网调度自动化。电子邮箱: xxxffidd123456@163.com。