

张量网络分解下电力跨模态数据检索方法

张喜铭¹, 余 芸¹, 林志达¹, 汤清华², 全雪霞²

(1. 中国南方电网有限责任公司, 广州 510663; 2. 南方电网人工智能科技有限公司, 广州 510663)

摘 要:电力系统状态由多模态数据共同反映,各模态数据的缺失情况及特点不同,难以统一表示,导致多维原始结构易发生丢失。传统方法难以捕捉模态间复杂的非线性耦合关系,无法实现跨模态张量融合,电力跨模态数据检索结果的匹配性偏低。为此,提出一种基于张量网络分解的电力跨模态数据检索方法,通过张量网络分解补全初始采集的多模态电力数据缺失值,统一表示为高阶张量,得到完整多模态电力数据。张量网络分解可通过张量统一表示各模态数据,并补全各模态数据的缺失值,降低数据特性差异,为跨模态数据检索提供更完整、准确的数据基础。结合视觉 Transformer 模型(Vision Transformer, ViT)、文本卷积神经网络(Text Convolutional Neural Network, Text CNN)模型及跨模态张量融合技术,构建深度监督跨模态检索大模型,通过 ViT 模型部分与 Text CNN 模型部分,分别提取完整多模态电力数据中的图像与文本数据特征,两种特征共同输入跨模态张量融合部分,通过多模态数据特征的融合及语义的相似性匹配,实现电力跨模态数据检索。结果显示,该方法通过多模态数据的精准补全,得到完整精准的多模态电力数据;可实现文本与图像不同模态电力数据间的相互跨模态检索,检索结果的匹配性较高,平均精度均值(mean Average Precision, mAP)值达到 0.972,本文方法的平均倒数排名(Mean Reciprocal Rank, MRR)值和查全率始终维持在接近 1,且波动极小。证明检索结果可靠,可满足实际应用需求。

关键词:张量网络分解;电力跨模态;数据检索;缺失数据补全;张量融合;相似性匹配

中图分类号:TN06;TM93

文献标志码:A

DOI:10.19652/j.cnki.femt.2506035

Power cross-modal data retrieval method based on tensor network decomposition

ZHANG Ximing¹, YU Yun¹, LIN Zhida¹, TANG Qinghua², QUAN Xuexia²

(1. China Southern Power Grid Co. Ltd., Guangzhou 510663, China;

2. China Southern Power Grid Artificial Intelligence Technology Co., Ltd., Guangzhou 510663, China)

Abstract: The state of a power system is jointly reflected by multimodal data. The missing patterns and characteristics of each modal data type differ, making it difficult to represent them uniformly and leading to easy loss of the multi-dimensional original structures. Traditional methods struggle to capture the complex nonlinear coupling relationship between modalities and fail to achieve cross-modal tensor fusion, resulting in low matching accuracy in power cross-modal data retrieval. To address this issue, a power cross-modal data retrieval method based on tensor network decomposition was proposed. The missing values of the initially collected multimodal power data were decomposed and completed through the tensor network, and were uniformly represented as high-order tensors to obtain complete multimodal power data. Tensor network decomposition can uniformly represent data of each modal through tensors, complete the missing values of data of each modal, reduce the differences in data characteristics, and provide a more complete and accurate data basis for cross-modal data retrieval. By combining the ViT model, the Text CNN model and the cross-modal tensor fusion technology, a large model of deep supervision cross-modal retrieval was constructed. Through the ViT model and the Text CNN model, respectively, the image and text data features in the complete multimodal power data were extracted. The two features were jointly input into the cross-modal tensor fusion module. Cross-modal data retrieval of power was achieved through the fusion of multi-modal data features and the similarity matching of semantics. Experimental results showed

收稿日期:2025-03-14

基金项目:南方电网公司项目(CG0000022001640835)

作者简介:张喜铭,硕士,高级工程师。E-mail:weiruzeng1014@163.com

that this method can achieve complete and accurate multimodal power data through precise completion of missing values. Mutual cross-modal retrieval between text and image data of different modalities can be achieved with high matching accuracy. The mean average precision (mAP) value can reach 0.972. The mean reciprocal rank (MRR) value and recall rate of the method remain constantly close to 1 with minimal fluctuations. This demonstrates that the retrieval results are reliable and can meet the practical application requirements.

Keywords: tensor network decomposition; cross modal power; data retrieval; complete missing data; tensor fusion; similarity matching

0 引言

电力系统中的电力数据规模大且复杂性高,主要包括了自发电到用电等诸多环节下所产生的各种模态数据,其中主要有电力设备外观与信号波形等图像数据、电力系统生产业务文本与设备运行报告等文本数据以及音频和数值等多种模态数据^[1-3]。此类多模态电力数据包含了丰富的电力系统运行状态、电力设备的健康状况等信息。为满足电力行业实际应用中跨模态电力数据的综合应用需求,需要对多模态的电力数据实施准确可靠的跨模态数据检索^[4]。通过跨模态电力数据的检索,可通过一种模态的电力数据匹配到与之相关的其他模态数据,将各种模态电力数据间的壁垒打破,达到跨模态数据间的互相检索与语义关联目的^[5],提升电力数据的实际使用效率,为电力系统的智能化运维管理及平稳运行提供可靠支撑。

目前,已有部分学者针对此方面展开了相关研究。衣天龙等^[6]结合实际检索需要创建多模态语义空间,运用 ResNet 深度学习模型转变图像与文本等多模态数据为统一语义向量,通过优化覆盖算法设定以检索结果对所需语义的覆盖性更高为目标函数,依据该目标函数在多模态语义空间内实施相似性匹配,得到多模态数据检索结果。该方法并未针对多模态数据的缺失值实施统一的补齐处理,无法充分降低多源数据的特性差异,难以保障检索时所用多源数据的完整性,导致检索结果易出现明显偏差。林俊安等^[7]通过 XLM-R 语言模型与对比语言-图像预训练模型(Contrastive Language-Image Pretraining, CLIP)视觉编码器分别获得多语言文本与视频的特征信息,结合对比学习方法对这两种模态数据特征实施对齐,得到二者的公共表征空间,结合所输入检索数据与该公共空间内数据向量的相似性,得到检索数据。该方法在面对各模态数据的缺失情况时,缺乏通用的处理机制,导致基础数据存在缺失,造成后续跨模态数据检索结果精度降低。王苑铮等^[8]结合 BERT 文本编码器及 ViT 视觉编辑器分别获取到文本与图像数据的特征信息,运用所构建的对比学习模型,以同实体关联与非同实体的跨模态数据对分别作为正、负样本,结合信息熵最高损失函数分别拉近与拉远两种样本,得到不同表征的公共空间,结合检索时的相似度值排序结果,实现跨模态数据检索。该方法对于不同模态数据缺失情况的复杂多样性未采取应对措施,难以有效降低多源数据的特性差异,造成跨模态数据检索结果不理想。党张敏等^[9]通过 CLIP 模型与 ResNet 模型分别提取文

本与图像数据的特征,融入注意力机制加权融合此类特征,向哈希编码器中输入融合后特征,转化其为二进制哈希码并生成数据库,运用所检索数据哈希码同待检索哈希码间的汉明间距,实现跨模态数据检索。该方法在处理各模态数据缺失值方面缺乏针对性的措施,无法统一补全,导致因基础数据不完整造成跨模态数据检索效果不佳。

张量网络分解是将一个高阶张量表示为多个低阶张量通过特定方式组合而成的结构^[10]。在缺失数据补全场景中,把包含缺失值的原始数据看作一个张量,利用张量网络分解技术将其分解为多个低维张量的乘积或组合形式^[11]。通过对这些低维张量的学习和优化,借助张量的结构特性以及已知数据部分的信息,推断和补全缺失的数据。该算法具有自适应学习性能强、可扩展性高、鲁棒性优越等特点,可利用数据整体结构及内在相关性,以完整部分数据的张量低维表示重建缺失数据^[12]。综合以上分析,本文针对张量网络分解下的电力跨模态数据检索方法展开研究,实现以特性统一、数据完整的多模态基础数据,完成电力图像与电力文本等多源数据相互之间的跨模态检索任务,保障检索精度。

1 方法设计

1.1 基于张量网络分解算法的电力跨模态数据的缺失数据补全

电力系统中通常包含电力设备图像与电力系统生产业务文本等不同模态的电力跨模态数据。实际采集过程,可能因环境因素与设备因素等干扰导致存在缺失数据,导致电力跨模态数据的完整性与精度降低,影响后续电力跨模态数据检索的精度^[13]。为解决此问题,需要对初始采集的电力跨模态数据实施缺失补全处理,在此选用张量网络分解算法实现^[14]。基于张量网络分解的电力跨模态缺失数据补全过程如下:

1) 构建初始采集电力跨模态数据多维张量。将不同工况下初始采集的电力设备图像与电力系统生产业务文本等电力跨模态数据构成一个多维张量,其中不同数据维度分别对应不同的数据模态特征^[15]。初始采集电力跨模态数据的多维张量矩阵为 $Z \in R^{A_i}$, 其中, A_i 表示电力跨模态数据的维数。

2) 关键参数设定。设 V 表示加权张量; M 表示最高分解迭代次数; σ 与 χ 分别表示收敛阈值与收敛误差。其中,加权张量 V 可设定成:

$$V = \begin{cases} 0, Z_{A_i} \text{ 值缺失} \\ 1, Z_{A_i} \text{ 值不缺失} \end{cases} \quad (1)$$

通过式(1)为缺失的电力跨模态数据加权,即存在与不存在缺失数据位置的权值分别为 0 和 1。以此分解初始采集电力跨模态数据为无缺失与有缺失数据两类,以其中无缺失数据为参考依据,辅助对含有缺失值的电力跨模态数据实施补全处理。在此基础上,通过挖掘可令式(2)值最低的因子矩阵 $B^{(i)} \in R^{A_i \times a_i}$, 其中, $1 \leq a_i \leq A_i$, 恢复缺失的电力跨模态数据。该公式为:

$$\kappa_V(C, B^{(i)}) = \frac{1}{2} \|V(Z - C \times_i B^{(i)})\|_F^2 \quad (2)$$

式中: f 表示 Frobenius 范数; $C \in R^{a_1 \times a_2 \times \dots \times a_N}$ 表示张量网络分解电力跨模态数据时的核心张量,其中, N 表示电力跨模态数据分解后的数据分量总维数, $i=1, 2, \dots, N$ 。

3) 初始化因子矩阵和核心张量。选取 Tucker 张量网络分解算法^[16-17]。该算法能够将由电力跨模态数据构建的高阶张量呈现成包含数个张量模与一个核心张量相对应的伴随矩阵的乘积形式。利用该算法可分解电力跨模态数据的多维张量矩阵 $Z \in R^{A_i}$ 为:

$$\begin{aligned} Z &\approx [C; B^{(1)}, B^{(2)}, \dots, B^{(N)}] \\ &= C \times_1 B^{(1)} \times_2 B^{(2)} \times \dots \times_N B^{(N)} \end{aligned} \quad (3)$$

通过 Tucker 的分解,得到电力跨模态数据张量中无缺失的已知数据部分的多个近似因子矩阵和近似核心张量,并以此为依据获得电力跨模态数据的重构张量,得到缺失数据补全后的完整电力跨模态数据。此步骤使用不同大小的核心张量秩来重构电力跨模态数据张量,选择与已知电力跨模态数据最匹配的秩作为最终使用的核心张量秩。

对电力跨模态数据构成的张量实施高阶奇异值分解,获取用于后续计算的多个因子矩阵的初始值 $B_0^{(i)}$,通过令式(4)的值为 0,获取到核心张量 C 的原始最优值 C_0 。

$$\partial \kappa_V / \partial C = (N - D) \times_i (B_0^{(i)T}) \quad (4)$$

式中: $D \in R^{a_i \times A_i}$ 表示在张量运算中辅助实现特定张量变换的矩阵。

4) 结合梯度优化算法以公式(4)为目标函数,对第 m 次分解迭代后获取的多个因子矩阵 $B_m^{(i)}$ 实施求偏导运算,可得到:

$$\begin{cases} \partial \kappa_V / \partial B_m^{(1)} = (F_{(1)} - E_{(1)}) \times (B_m^{(N)} \otimes B_m^{(N-1)} \otimes \dots \otimes B_m^{(2)}) \times C_{(1)}^T \\ \dots \\ \partial \kappa_V / \partial B_m^{(N)} = (F_{(N)} - E_{(N)}) \times (B_m^{(N-1)} \otimes \dots \otimes B_m^{(2)} \otimes B_m^{(1)}) \times C_{(N)}^T \end{cases} \quad (5)$$

式中: $E = V \times Z$, $F = C \times_i B_0^{(i)}$; $F_{(i)}$ 表示多种模式下数据张量 F 的水平展开; $\otimes$ 表示 Kronecker 积运算。

第 m 次分解迭代后的数据核心张量 C_m 的运算式为:

$$C_m = Z \times_i B_0^{(i)T} \quad (6)$$

5) 分解迭代运算的终止条件判定。三个判定条件为:

① 分解迭代运算达到最高迭代次数 M , 该次数根据电力

跨模态数据的复杂程度及计算资源等因素确定。

② 目标函数 κ_V 在第 m 次迭代与前一次迭代的差值低于所设定的收敛阈值,即 $\Delta \kappa_V < \sigma$, 目标函数 κ_V 是基于电力跨模态数据的特点构建的,用于衡量缺失电力数据初始已知数据的拟合程度,当满足此条件则意味着迭代过程中目标函数的变化已足够小,逼近最优解。

③ m 次迭代与前一次迭代得到的核心张量秩差值的 Frobenius 范数 ΔC 需低于所设定的收敛误差 χ , 即:

$$\Delta C = \|C_m - C_{m-1}\|_F < \chi \quad (7)$$

6) 如果上述三个判定条件均无法达到,则继续实施第 $m+1$ 次迭代,同时回到第(4)步;相反,如果满足某个判定条件,则以第 m 次迭代所获取的多个因子矩阵 $B_m^{(i)}$ 为依据,重构电力跨模态数据张量 Z' 为:

$$Z' = C_m \times_i B_m^{(i)} \quad (8)$$

由此得到缺失数据补全后的完整电力跨模态数据。

1.2 数据检索

以上一节中缺失数据补全处理后获得的完整电力跨模态数据为基础数据,结合深度监督跨模态检索大模型对此类数据实施检索。该模型主要由 ViT、Text CNN、跨模态张量融合模块组成,其中, ViT 模块用于获取完整电力跨模态数据中图像模态数据的特征信息; Text CNN 模块用于获取完整电力跨模态数据中文本模态数据的特征信息; 跨模态张量融合模块对所获取的电力图像与文本两种跨模态数据的特征信息实施匹配整合,深入学习二者在细微层面的模态语义相关性,并依据电力图像数据特征生成对应的电力文本数据,测算两种模态电力数据间的整体语义关联度,实现电力跨模态数据检索。

1) 图像数据特征提取

在针对完整电力跨模态数据 Z' 的检索问题中,运用 ViT 模型提取其中的电力设备等图像数据 Z'_ξ 特征。考虑到电力设备等图像数据的特点,所设定的提取过程如下。

① 图像尺寸标准化: 以完整电力跨模态数据 Z' 中的电力设备等图像数据 Z'_ξ 为目标数据,调节此类数据的尺寸为 224×224 像素。经过实验验证,此尺寸在平衡计算效率与特征提取精度方面表现优异,例如对于常见电力变压器图像,该尺寸能完整保留关键结构特征,且避免过小尺寸导致信息丢失或过大尺寸增加计算负担;

② 图像块分割: 分割尺寸调节后电力设备等图像数据为多个图像块 $\{z'_{\xi_1}, z'_{\xi_2}, \dots, z'_{\xi_k}\}$, 其中, k 表示所分割的图像块总数量;

③ 特征向量生成与模型输入: 依次展平分割后的各个电力设备等图像块 $\{z'_{\xi_1}, z'_{\xi_2}, \dots, z'_{\xi_k}\}$, 将其转变成特征向量输入到预训练的 ViT 模型内,输出电力设备等图像数据的特征表示 $G = [g, g_1, g_2, \dots, g_k]$, 其中, g 表示电力设备等图像数据的整体特征信息。

所提取的电力设备等图像数据特征信息能精准刻画此类图像数据内目标电力设备的外观细节、结构状态等信息,为后续的数据检索提供有力支撑。

2) 文本数据特征提取

对于完整电力跨模态数据 Z' 中的电力系统生产业务文本等电力文本数据 Z'_δ , 采用该检索大模型中的 Text CNN 模块实现其特征信息的提取。主要提取过程为:

① 电力文本数据 Z'_δ 实施独热编码, 得到的编码为 $[\delta_1, \delta_2, \dots, \delta_L]$, 其中, L 表示电力文本数据 Z'_δ 的长度;

② 向 Text CNN 模型的词嵌入层输入电力文本数据 Z'_δ , 获得此类数据的词嵌入表示 $[z'_{\delta_1}, z'_{\delta_2}, \dots, z'_{\delta_L}]$;

③ 将电力文本数据的词嵌入表示 $[z'_{\delta_1}, z'_{\delta_2}, \dots, z'_{\delta_L}]$ 输入到 Text CNN 模型的多层 Transformer 编码器内, 该编码器位于 Text CNN 模型的卷积层与全连接层之间, 获取到包含电力文本数据的特征表示 $[s_1, s_2, \dots, s_L]$;

④ 对电力文本数据的特征表示 $[s_1, s_2, \dots, s_L]$ 实施池化处理, 得到代表电力文本数据全局特征表示的特征向量为:

$$\bar{s} = \frac{1}{L} \left(\sum_{j=1}^L s_j \right) \quad (9)$$

则最终的电力文本数据的特征表示为 $S = [\bar{s}, s_1, s_2, \dots, s_L]$ 。基于此, 精准捕捉到电力文本数据中的电力相关专业术语、运行指令、业务规范、生产业务文本以及故障描述等关键语义信息, 用于电力跨模态数据检索匹配。

3) 基于电力跨模态数据匹配的数据检索

在电力跨模态数据检索领域, 为挖掘不同模态数据间的联系, 本文借助张量融合技术, 运用上文所提取的电力设备等图像数据与电力系统生产业务文本等电力文本数据特征信息, 对二者实施匹配融合, 学习到这两种模态电力数据间的精细语义关联。

基于上文获取的电力图像数据和电力文本数据两种模态电力数据的特征信息 G 与 S , 运用投影矩阵 H_g 和 H_s 的特定编码方式, 分别对这两类特征实施编码处理, 得到二者的 a_g 维度与 a_s 维度的向量形式 $\hat{g} = H_g G \in R^{a_g}$ 与 $\hat{s} = H_s S \in R^{a_s}$ 。把编码转换后的电力图像数据和电力文本数据两种模态向量 $\hat{g}, \hat{s}$, 投影至统一的电力信息语义空间内, 开展张量融合操作, 所得到的二者融合向量为:

$$o = (H_g \hat{g}) \otimes (H_s \hat{s}) \quad (10)$$

式中, $H_g \in R^{a_g \times a_o}$, 且 $H_s \in R^{a_s \times a_o}$; $\otimes$ 表示电力图像数据与电力文本数据的编码投影矩阵元素的乘法运算; a_o 表示二者融合向量的维度。因电力跨模态数据的单一融合向量所承载的关联信息有限, 故需要融合多个电力跨模态数据向量, 以此学习到电力跨模态数据间足够的语义相关信息。为此, 在此继续融合 n' 个融合向量 o , 得到统一电力信息语义空间中各个子空间蕴含的各种语义关联关系。 n' 个融合向量 o 融合后的整体融合向量可表示为:

$$O = \sum_{i=1}^n [(H_g \hat{g}) \odot (H_s \hat{s})]_i \quad (11)$$

运用本文检索大模型的两个全连接层 $\hat{\omega}_1, \hat{\omega}_2$ 获取到电力图像数据与电力文本数据两种模态数据之间的部分细粒度相似度为:

$$\lambda_o = \text{Sigmoid}(\hat{\omega}_2(\hat{\omega}_1 O)) \quad (12)$$

为实现电力图像数据与电力文本数据两种模态数据间的整体语义匹配对齐, 选用内积运算对二者的整体特征实施相似度运算:

$$\lambda_\xi = \psi(G, S) \quad (13)$$

式中: ψ 表示电力图像数据与电力文本数据的整体相似度运算函数。

两种不同模态数据之间可通过二者的整体相似度实施互相检索, 实现电力跨模态数据的检索目的。在检索训练时针对错误匹配中得分最高的电力图像数据与文本数据对, 通过设定方式分别定义不同模态电力数据检索的部分语义损失函数和整体语义损失函数, 前者聚焦不同模态电力数据的部分语义相关性差异, 后者则考虑不同模态电力数据的整体语义匹配情况。这两种损失函数的运算式为:

$$\begin{cases} \mu_o = [\beta + \lambda_o(Z'_\xi, \hat{Z}'_\delta) - \lambda_o(Z'_\xi, Z'_\delta)]_+ + \\ \quad [\beta + \lambda_o(\hat{Z}'_\xi, Z'_\delta) - \lambda_o(Z'_\xi, Z'_\delta)]_+ \\ \mu_\xi = [\beta + \lambda_\xi(Z'_\xi, \hat{Z}'_\delta) - \lambda_\xi(Z'_\xi, Z'_\delta)]_+ + \\ \quad [\beta + \lambda_\xi(\hat{Z}'_\xi, Z'_\delta) - \lambda_\xi(Z'_\xi, Z'_\delta)]_+ \end{cases} \quad (14)$$

式中: β 表示边际参数; $[\cdot]_+$ 表示取最高值; $\hat{Z}'_\xi$ 与 $\hat{Z}'_\delta$ 分别表示检索中匹配错误时最高相似度的电力图像数据与电力文本数据对。

除此之外, 为使学习到的电力图像数据特征能更好地生成对应的电力文本数据, 提升整体电力图像语义特征与电力文本数据的关联性, 将 Seq2seq 模型用在检索大模型的全连接之后, 运用电力图像数据特征 G 生成与之对应的电力文本数据 $\tilde{S}$ 。电力图像数据特征 G 的精度越高, 所生成的对应电力文本数据 $\tilde{S}$ 与实际电力文本数据的相似性越高。所生成的电力文本数据的损失函数可表示为:

$$\mu_s = \sum_{j=1}^{\tau} \ln \gamma(s_j | s_{j-1}, G; \eta) \quad (15)$$

式中: η 表示 Seq2seq 模型的反向传播学习参数; τ 表示运用电力图像数据特征 G 生成与之对应的电力文本数据 $\tilde{S}$ 的总长度; γ 表示电力文本数据的生成概率系数; $\tilde{S} = \{s_j | j=1, 2, \dots, \tau\}$ 表示所生成的电力文本数据。

综合所得损失函数 μ_o, μ_ξ, μ_s , 得到电力跨模态数据检索的最终联合损失函数为:

$$\mu = \mu_o + \mu_\xi + \mu_s \quad (16)$$

经多次实验验证, 在当前模型架构与数据特点下, 各损失项权重设为 1 时, 模型在验证集上的检索性能达到最优平衡状态。例如, 当分别对 μ_o, μ_ξ 和 μ_s 赋予权重 0.8、1 和 1.2 时, 平均 mAP 值从 0.972 下降至 0.958; 而当分别对 μ_o, μ_ξ 和 μ_s 赋予权重 1.2、0.8 和 1 时, MRR 值从接近 1 下降至 0.93 左右。经过多轮不同权重组合的实验对比, 确定各损失项权重均为 1 时, 模型能通过该联合损失函数优化深度监督跨模态检索大模型的检索性能, 得到高精度的电力跨模态数据检索结果。

2 实验与分析

以华北电网为例,运用本文方法对该电力系统中的跨模态数据实施检索,通过实际检索结果,检验本文方法的应用效果。以实验电力系统的多模态数据集 Z1 为例,通过本文方法实施跨模态数据检索,并将所得检索结果与优化覆盖方法、多语言-视觉公共空间学习方法、对比学习实体链接方法、CLIP 与注意力机制方法(文献[6]~[9]方法)进行对比。数据集内每张电力图像数据均包含 3 个文本描述信息,这些文本描述信息长度为 50~200 字,内容类型主要涵盖电力设备的运行参数(如电压、电流、功率等数值及变化趋势描述)、设备状态(如正常运行、异常预警、故障特征等表述)以及环境条件(如温度、湿度、地理位置等相关说明)。其中,多模态数据集 Z1 的总数据样本量为 131 568,训练集与测试集的数据量分别为 125 568 与 6 000。

首先检验本文方法对实验多模态数据集的缺失数据补全效果。以数据集 Z1 中随机选取的存在缺失数据的电力设备电压波形图像为例,呈现本文方法的缺失数据补全效果,如图 1 和图 2 所示。可知,本文方法可实现存在缺失数据的电压波形图像数据的有效补全处理,补全后的图像数据更为精确完整,可更好地保证后续的跨模态数据检索效果,以及实际应用中运用所检索到的精准跨模态数据实现电力系统运行故障的识别与检测。




图 1 初始电压波形

Fig. 1 Image of initial voltage waveform




图 2 补全后电压波形

Fig. 2 Image of completed voltage waveform

各方法的实验数据集跨模态数据检索结果的可视化结果中,各自选取检索结果的相似性最高的前 3 个结果。其


中,通过电力文本数据跨模态检索电力图像数据中,所选取的文本数据为“变电站内,带有散热片的油浸式变压器”,各方法的检索结果见图 3。本文方法的文检图跨模态数据所得检索结果中,相似度排在第一位的图像检索数据即为与文本数据“变电站内,带有散热片的油浸式变压器”对应的图像数据;而其他几种对比方法的检索结果中,除优化覆盖方法的相似度排序前 3 的检索结果中没有与此文本对应的图像数据之外,其他 3 种对比方法所呈现检索结果中均存在与此文本对应的图像数据,但相似度排序均未处于第一位。可见,本文方法的文检图跨模态电力数据检索结果更加优越,相似度匹配结果更为吻合,检索精度更高。



(a) 本文方法



(b) 优化覆盖方法



(c) 多语言-视觉公共空间学习方法



(d) 对比学习实体链接方法



(e) CLIP与注意力机制方法

图 3 各方法的文检图跨模态数据检索结果

Fig. 3 The cross modal data retrieval results of text retrieval images using various methods

对比各方法的图检文跨模态电力数据检索结果,同样以检索结果中相似度最高的前 3 个结果为例,如图 4 所示。本文方法的图检文跨模态电力数据检索结果中,相似度最高的前 3 个结果均检索正确,与检索所用的电力图像数据的相似度更高。




图 4 各方法的图检文跨模态数据检索结果

Fig. 4 The cross modal data retrieval results for image inspection documents using various methods

以 mAP (平均精度均值)作为评价各方法跨模态数据检索性能的指标:

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_i \quad (17)$$

式中: m' 表示全部跨模态数据检索结果的总数量; AP_i 表示第 i 组跨模态数据检索结果的 AP 值。 mAP 通过结合全部跨模态数据检索结果的 AP 平均值,综合考量各方法在多组跨模态数据检索上的性能,其取值区间为 $(0,1)$,数值越高代表方法的跨模态数据检索能力越强。各方法的 mAP 指标值统计结果如表 1 所示。


表 1 各方法检索结果的 mAP 指标Table1 mAP index values retrieved by various methods

方法	文检图 mAP 值	图检文 mAP 值	平均 mAP 值
本文方法	0.971	0.973	0.972
优化覆盖方法	0.696	0.711	0.704
多语言-视觉公共空间学习方法	0.759	0.787	0.773
对比学习实体链接方法	0.779	0.802	0.791
CLIP 与注意力机制方法	0.792	0.814	0.803

由表 1 看出,本文方法的文检图与图检文两种跨模态电力数据检索结果的 mAP 指标均高于各对比方法,平均 mAP 指标值也更高,可达到 0.972,表明本文方法的电力跨模态数据检索结果更为理想。

为进一步研究方法的有效性,选取平均倒数排名 (Mean Reciprocal Rank, MRR) 作为评价各方法性能的指标。该指标通过对检索系统返回结果中首个正确答案的排名位置取倒数和求均值得到。电力系统运维人员往往需要快速定位关键数据, MRR 通过强调首位相关结果的重要性,直接反映

系统满足即时需求的能力。 MRR 越接近 1,表明检索方法的性能越优。不同方法的 MRR 如图 5 所示。在多种电力跨模态数据检索方法中,本文方法在 MRR 指标上展现出卓越的性能。随着检索次数的变化,本文方法的 MRR 值始终维持在接近 1 的高水平,波动范围在 $[0.98, 1.0]$ 之间,且波动极小,明显优于优化覆盖方法、多语言-视觉公共空间学习方法、对比学习实体链接方法以及 CLIP 与注意力机制方法。从实际应用角度分析,电力系统运维人员在日常工作中常常面临紧急情况,需要快速、准确地定位关键数据。本文方法的高 MRR 值意味着在大多数检索任务中,它能将正确答案更靠前地呈现在结果列表中,极大地提高了运维人员获取关键信息的效率,有助于他们迅速做出决策。

图 5 不同方法的 MRR Fig. 5 MRR by different methods

最后,以查全率为指标,验证本文方法在覆盖性和完整性方面的性能。查全率为正确检索出的相关结果占实际所有相关结果的比例。不同方法的查全率如图 6 所示。本文方法表现突出。随着检索次数的变化,本文方法的查全率始终保持在较高水平,接近 1,且数据点分布相对集中,波动幅度较小。这表明,本文方法能够较为稳定且全面地检索出相关结果。由于电力系统中存在海量的跨模态数据,查全率高意味着该方法能够尽可能多地找出与查询相关的数据,避免遗漏重要信息。其他方法的数据点波动较大,说明这些方法无法保证每次检索都能达到较高的查全率,在实际应用中可能会导致一些相关数据被遗漏,影响对电力系统的全面分析和决策。




图 6 不同方法的查全率

Fig. 6 The recall rates of different methods

为全面评估电力跨模态数据检索方法的实用性能,进一步考察了各方法的实时处理能力。在相同硬件配置条件下,测试各方法处理 1 000 次跨模态检索的平均检索时间(ms 级)。测试时保持输入数据规模一致(图像分辨率统一为 512×512,文本描述长度控制在 150±20 字),结果如表 2 所示。

实验结果表明,本文方法在保持高检索精度的同时展现出显著的效率优势。当处理 1 000 次检索任务时,本文方法仅需 2 149 ms,相较优化覆盖方法(3 948 ms)提速 45.6%,较 CLIP 注意力方法(6 348 ms)提速 66.1%。本文方法的性能优势源于三方面创新:首先,设计的轻量化特征提取网络减少了 75%的计算冗余;其次,跨模态交互模块采用动态稀疏注意力机制,使计算复杂度从 $O(n^2)$ 降至 $O(n\log n)$;最后,通过预构建的电力专业语义索引库,有效降低了 80%的实时计算负担。这种高效性对电力应急场景尤为重要,当系统出现故障时,运维人员可在 2 s 内完成上千条跨模态数据的检索,为故障诊断争取宝贵时间。

表 2 不同方法的检索时间

Table 2 The retrieval time of different methods

检索次数	本文方法	优化覆盖方法	多语言-视觉方法	对比学习链接	CLIP 注意力
100	218	387	452	521	635
200	432	781	897	1 042	1 268
300	647	1 176	1 345	1 564	1 903
400	861	1 572	1 793	2 086	2 538
500	1 076	1 968	2 241	2 608	3 173
600	1 291	2 364	2 690	3 130	3 808
700	1 505	2 760	3 138	3 652	4 443
800	1 720	3 156	3 586	4 174	5 078
900	1 935	3 552	4 034	4 696	5 713
1 000	2 149	3 948	4 482	5 218	6 348

3 结 语

电力数据中包含图像、文本、视频等多种模态数据,数据规模大且结构复杂,在实际应用中,可能需要多种模态数据相结合共同实现应用目标。为满足电力多模态数据的实际应用需求,本文提出一种基于张量网络分解的电力跨模态数据检索方法。该方法主要结合了张量网络分解在不同模态数据缺失值统一补全方面的优势,将初始采集的多模态电力数据中的各种模态数据缺失值补全,并统一多模态数据的特性,得到更加完整、精确的基础电力多模态数据。通过实际应用验证了本文方法在多模态电力数据缺失值补全、跨模态数据检索方面的优势,可为多模态电力数据的实际跨模态综合应用提供可靠支撑。

参 考 文 献

[1] 王红霞,王波,董旭柱,等.面向电力多模态融合的语义差异性和感知能力差异性分析方法[J].高电压技术,2024,50(9):4037-4047.

[2] 刘佳楠,范晶晶,赵建光,等.基于二重语义相关性图卷积网络的跨模态检索方法[J].计算机应用研究,2024,41(4):1239-1246.

[3] 齐子豪,全杰,张中浩,等.基于多粒度知识特征和Transformer网络的电力变压器故障声纹辨识方法[J].中国电机工程学报,2025,45(4):1311-1323.

[4] 龙军,邓茜尹,陈云飞,等.基于图卷积的无监督跨模态哈希检索算法[J].计算机工程与设计,2024,45(8):2393-2399.

[5] 王永欣,田洁茹,陈振铎,等.基于标记增强的离散跨模态哈希方法[J].软件学报,2023,34(7):3438-3450.

- [6] 衣天龙,邵琦,李秋元.基于优化覆盖算法的异构多模态信息检索方法[J].计算机仿真,2024,41(10):493-496.
- [7] 林俊安,包翠竹,董建锋,等.基于多语言-视觉公共空间学习的多语言文本-视频跨模态检索模型[J].计算机学报,2024,47(9):2195-2210.
- [8] 王苑铮,孙文祥,范意兴,等.基于对比学习的跨模态实体链接模型[J].计算机研究与发展,2025,62(3):662-671.
- [9] 党张敏,喻崇仁,殷双飞,等.基于 CLIP 与注意力机制的跨模态哈希检索算法[J].计算机工程与设计,2024,45(3):852-858.
- [10] 时培明,孙航璇,许学方,等.基于四维张量特征分解的风电机组轴承故障缺失数据恢复方法研究[J].计量学报,2024,45(5):738-746.
- [11] 杨挺,叶芷杉,徐嘉成,等.基于低秩张量补全的非侵入式负荷监测缺失数据修复方法[J].电网技术,2024,48(1):394-404.
- [12] 郭辉,陈友兴,韩焱.基于改进 SSI 法的加工机器人工作模态在线辨识[J].国外电子测量技术,2024,43(3):183-189.
- [13] 刘志坚,陶韵旭,刘航,等.基于双通道生成对抗网络的城用电负荷缺失数据补全方法[J].电力系统自动化,2024,48(17):161-170.
- [14] 陈冲,蒙祖强.运用多模态学习改进张量分解的知识补全方法[J].计算机工程与设计,2023,44(10):2956-2964.
- [15] 渠超洋,韩建军.一种基于模特征的增量式张量 Tucker 分解方法[J].控制与决策,2024,39(7):2431-2437.
- [16] 李可新,何丽,刘哲凝,等.基于跨模态特征融合的 RGB-D 显著性目标检测[J].国外电子测量技术,2024,43(6):59-67.
- [17] 谢亚君,叶福兰.一种正则化非负张量分解算法及其新的有效加速策略[J].应用数学,2024,37(1):100-114.