

面向源网荷的智能化数据协同推断技术研究综述

张 辉^{1,2} 颜星雨^{1,2} 毛建旭^{2,3} 别克扎提·巴合提^{1,2} 杜 瑞^{1,2} 王耀南^{1,2}

摘 要 随着可再生能源并网比例的持续提升, 风电、光伏等新能源发电形式对电力系统的稳定性与调度智能化提出更高要求. 源网荷储一体化背景下, 如何高效利用多源异构电力数据实现精准预测与协同分析, 已成为关键问题. 近年来, 深度学习、大数据、大模型等技术推动智能化推断技术取得飞跃式进展. 本文首先结合深度学习技术, 对时间序列数据协同推断共性技术研究现状进行阐述, 重点分析趋势-季节性分解、频域建模、外生变量融合等关键方法, 分析基于不同架构的时间序列模型的研究现状. 其次针对源网荷智能化关键技术进行阐述, 进一步梳理源网荷系统中智能预测、状态评估与负荷调度等典型场景中的关键技术路径, 并对其具体应用场景进行分析. 最后, 结合日益复杂的电力系统背景, 对数据协同推断技术的发展方向进行展望.

关键词 源网荷智能化, 数据协同推断, 时间序列分析, 深度学习

引用格式 张辉, 颜星雨, 毛建旭, 别克扎提·巴合提, 杜瑞, 王耀南. 面向源网荷的智能化数据协同推断技术研究综述. 自动化学报, 2025, 51(11): 2387–2411

DOI 10.16383/j.aas.c250203 **CSTR** 32138.14.j.aas.c250203

A Review of Intelligent Data Collaborative Inference Techniques for Source-grid-load Systems

ZHANG Hui^{1,2} YAN Xing-Yu^{1,2} MAO Jian-Xu^{2,3} BIEKEZHATI Baheti^{1,2} DU Rui^{1,2} WANG Yao-Nan^{1,2}

Abstract With the continuous increase in the proportion of renewable energy integration, new energy generation forms such as wind power and photovoltaic systems have imposed higher requirements on the stability and intelligent dispatch of power systems. Under the integrated framework of source-grid-load-storage, how to efficiently utilize multi-source heterogeneous power data for accurate forecasting and collaborative analysis has become a critical issue. In recent years, technologies such as deep learning, big data, and large-scale models have driven rapid advancements in intelligent inference techniques. This paper first elaborates on the current research status of common technologies for collaborative inference of time series data, combined with deep learning techniques. Key approaches including trend-seasonality decomposition, frequency-domain modeling, and exogenous variable fusion are emphasized, alongside an analysis of time series models based on different architectures. Secondly, the paper discusses the key intelligent technologies for source-grid-load integration, further outlining critical technological pathways in typical scenarios such as intelligent forecasting, state assessment, and load scheduling within the source-grid-load-storage system, with detailed analyses of their specific application contexts. Finally, in light of the increasingly complex power system environment, prospects for the future development of data collaborative inference technologies are presented.

Key words Intelligentization of source-grid-load, data collaborative inference, time series analysis, deep learning

Citation Zhang Hui, Yan Xing-Yu, Mao Jian-Xu, Biekezhati Baheti, Du Rui, Wang Yao-Nan. A review of intelligent data collaborative inference techniques for source-grid-load systems. *Acta Automatica Sinica*, 2025, 51(11): 2387–2411

收稿日期 2025-05-08 录用日期 2025-08-04

Manuscript received May 8, 2025; accepted August 4, 2025

国家自然科学基金重点项目 (62433010), 科技创新 2030-“新一代人工智能”重大项目 (2021ZD0114503), 国家电网有限公司科技项目 (5700-202423229A-1-1-ZN) 资助

Supported by the Key Program of National Natural Science Foundation of China (62433010), the National Key Research and Development Program of China (2021ZD0114503), and the Science and Technology Project of State Grid Corporation of China (5700-202423229A-1-1-ZN)

本文责任编辑 温广辉

Recommended by Associate Editor WEN Guang-Hui

1. 湖南大学人工智能与机器人学院 长沙 410082 2. 湖南大学机器人视觉感知与控制技术国家工程研究中心 长沙 410082 3. 湖南大学电气与信息工程学院 长沙 410082

近年来, 节能减排成为发展的重要风向, 推动“双碳”目标的实现成为国家各能源行业的重要动力. 随着智能化时代的到来, 着力构建高效的能源体系受到世界各国的高度重视. 美国通过能源独立和安全法案, 明确了以电力和天然气为核心的智能能源系统研究的战略意义; 加拿大启动多个重要能

1. School of Artificial Intelligence and Robotics, Hunan University, Changsha 410082 2. National Engineering Research Center of Robot Visual Perception and Control Technology, Hunan University, Changsha 410082 3. College of Electrical and Information Engineering, Hunan University, Changsha 410082

源项目, 聚焦于社区级综合能源系统的技术攻关, 并计划在 2050 年实现低碳能源供给; 德国政府每年投资关注可再生能源利用、能效提升和能源安全, 而欧盟也较早地推进多个智慧能源及微电网相关项目; 此外, 我国发布的《能源发展“十三五”规划》等, 也明确了构建智能化电力体系的重要性. 现代能源系统正向多能源融合、源网荷高度集成的新模式转变, 源网荷储一体化及构建智能化电力系统成为支撑能源消纳、促进绿色发展的关键方案. 智能化推断技术作为支持源网荷储一体化能源系统的关键技术之一, 正日益成为提升能源系统灵活性和高效性的重要手段. 数据协同推断技术融合跨时间尺度和多维空间域的历史数据, 实现智能化“感知”的功能, 对时序模式进行深度挖掘与融合, 识别其潜在的周期性波动与突发事件, 为系统提供前瞻性的运行预判, 保障电力系统的安全性与稳定性.

随着机器学习、深度学习等技术的快速发展, 智能化协同推断技术的水平也呈现出飞跃式提升, 展现出更为卓越的预测与优化潜力. 如, 谷歌 DeepMind 的能源预测模型^[1]通过机器学习, 能源管理系统能够根据历史数据和实时信息在实际发电前 36 h, 预测风力输出, 并优化风能、太阳能等可再生能源的调度, 从而提高能源系统的效率与稳定性; 华为云盘古气象大模型^[2]将人工智能推断技术应用于天气预报领域, 该模型采用三维神经网络架构和分层时间聚合策略, 输出内容涵盖多项关键气象要素, 可作为风电、光伏发电量预测及电网负荷调度的输入特征, 为源网荷储一体化能源系统提供了高精度的气象输入保障.

当前, 节能减排任务日益艰巨, 灵活性需求逐渐增长, 驱动我国加快能源结构优化, 着力构建清洁低碳、安全高效的现代能源体系. 源网荷协同推断作为支撑智能化调度与安全稳定运行的关键环节, 面临诸多技术瓶颈. 源侧可再生能源波动性强, 荷侧需求响应则具有不确定性, 二者在多时空尺度上的强耦合关系难以建模. 此外, 电力系统中的多源异构数据语义层级差异大、更新频率不一, 带来多源异构数据融合与建模的挑战. 此外, 推断模型在具有较大差异性的不同区域、场景中泛化能力不足, 易出现过拟合、性能不稳定等问题, 难以在复杂系统中实现稳健推广. 随着大数据、大模型等新兴技术的快速发展, 为实现高精度时空协同推断提供了新的思路和发展契机. 因此, 结合智能化数据协同推断技术, 开展面向源网荷高度集成的综合能源系统的多时空尺度建模与推断研究, 有助于提高电网应对突发负荷变化与极端气候事件的能力, 为绿

色低碳发展提供有力技术支撑.

然而, 随着可再生能源在能源结构中占比不断攀升, 其固有的波动性与不确定性加剧了电力系统在负荷预测及电网稳定性方面的复杂性与挑战. 在实际工程中, 如何兼顾频率调节的精准性与系统运行的鲁棒性, 已成为智能化调度的核心问题. 针对这一点, Wen 等^[3]提出基于复合控制策略的频率调节方法, 用于源网负载系统的频率调节, 通过对频率的精准调控提升了可再生能源发电及电网运行的稳定性. 文献 [4] 则研究了在通信不确定性环境下的自适应共识鲁棒经济调度策略, 采用分布式调度算法, 在不同发电机组之间适当分配负载, 从而实现电力的最优调度, 为解决源网荷系统的频率与经济调度协同问题提供了新思路. 未来面向源网荷的数据协同推断技术将朝着多时空、多尺度、大模型的方向发展.

如图 1 所示, 本文内容安排如下: 第 1 节对数据协同推断共性技术及其共性架构进行概括; 第 2 节由源网荷关键技术出发, 介绍大数据协同推断技术在源端优化、网端检测以及负荷预测方面的具体实现; 第 3 节对源网荷智能化在典型应用场景中的实际运用进行深入剖析; 第 4 节则针对当前日益复杂的电力运行环境, 对未来源网荷智能化技术的发展趋势与挑战进行展望; 最后, 第 5 节对全文进行总结, 并提出未来研究方向.

1 数据协同推断共性关键技术

如图 2 所示, 数据协同推断技术综合考虑跨时间尺度和多维空间域的历史数据, 对数据的时间依赖性和变量相关性进行深度挖掘, 实现预测、分类、插值、异常检测等核心任务. 该技术通过融合多尺度时空数据信息, 在多个维度上共同推断出潜在的时空关系, 实现对复杂系统的建模与分析, 为源网荷智能化提供了丰富的数据洞察. 协同推断技术发展历程如图 3 所示, 传统的方法通过建立统计模型, 对时间数据进行分析. 然而, 随着场景的复杂化、数据的多样化, 传统方法逐渐无法满足精细化需求, 基于深度学习的方法应运而生^[5-6]. 近年来, 基于卷积神经网络^[7]和基于 Transformer 架构^[8]的模型, 已逐步成为解决时间数据协同推断中的复杂问题的核心技术^[9]. 卷积神经网络在时序数据的局部特征提取和复杂时空依赖建模中表现出了独特的优势, 而基于 Transformer 的时空建模方法则能够更好地处理长时间依赖性和多尺度的时序信息. 同时, 随着多模态数据的引入, 协同推断方法开始考虑不同类型数据间的互补性与一致性, 对外生变量和环境



图 1 文章总体架构

Fig.1 Overall structure of the article




图 2 数据协同推断技术

Fig.2 Data collaborative inference technologies

因素的智能融合也成为提升模型泛化能力和适应性的重要手段. 本节将重点介绍协同推断建模共性技术以及不同架构的时空数据协同推断模型.

1.1 协同推断与建模关键技术

1.1.1 时序分解技术

时序分解技术是数据协同推断的重要手段. 在复杂的场景中利用分解技术对原始时间序列进行结构化处理, 提取其潜在的周期性、趋势性与扰动成

分, 有效提升序列特征的清晰度与可建模性. 通过不同的分解方式, 系统地剖析时间序列在不同时间尺度下的动态特征, 为后续的多尺度建模、特征融合与任务适配提供精细的信息支撑. 该方法不仅能够增强模型对跨尺度结构的理解能力, 还为预测与异常检测等应用场景提供了更加稳定和可解释的数据基础. 常见的时间序列分解技术如图 4 所示, 包括趋势-季节性分解技术、基函数展开分解技术以及矩阵分解技术.




图 3 数据协同推断技术发展历程

Fig.3 Development history of data collaborative inference technologies




图 4 时间序列分解技术

Fig.4 Time series decomposition techniques

趋势-季节性分解技术. 趋势-季节性分解作为一种典型的序列结构化方法,旨在将原始时间序列拆解为长期演化趋势、周期性成分以及随机扰动信号等多个分量,以增强模型对潜在动态特征的理解与表征能力,可表示为:

$$X = \mathcal{T} + S + R \quad (1)$$

其中,趋势项 $\mathcal{T}$ 反映数据在较长时间尺度下的整体变化方向;季节项 S 用于描述固定周期内的重复性模式;扰动项 R 表示不可预测的随机波动或局部异常.

在传统建模范式中,该方法常借助滑动平均、低通滤波或指数平滑等数学工具,完成对时间序列的分离处理^[10],为后续的建模与推理提供清晰的子

结构支持.在深度学习方法中,Autoformer 模型^[11]首次将该分解机制嵌入 Transformer 模型架构,通过引入滑动平均池化与补零操作提取趋势信号,同时将残差部分建模为季节性成分,有效提高了模型在长周期建模与高频扰动刻画中的表现能力.基于此框架,研究者进一步提出多种结构优化策略:如 Crossformer 模型^[12]针对多变量时序预测中的跨维度依赖,采用维度片段嵌入将原始序列拆分为趋势与季节子序列,再通过双阶段注意力机制分别建模跨时间与跨维度交互,实现信息的分层解耦与融合;Tempo 模型^[13]则先采用局部加权回归方法对输入序列进行趋势-季节-残差三分量分解,再通过软提示将各分量映射至模型输入嵌入,并在提示微调阶段融合不同分量信息,实现对多领域时序数据的可

解释建模与强大零样本泛化能力。

当前, 趋势-季节性分解模块已被广泛视为深度时序推理中的核心结构单元^[14], 其分层解耦特性不仅增强了模型对复杂时间结构的辨识能力, 也显著提升了在预测、异常检测等任务中的建模稳定性与泛化性能^[15]。

基函数展开分解技术. 基函数展开分解技术通过构造可解释的数学基函数实现时序信号的层次化分解, 以前馈式层级结构为基础, 将时间序列表示为预定义函数空间的线性组合. 一般形式上, 可表示为:

$$X(t) = \sum_{i=1}^m \theta_i \phi_i(t) + \varepsilon(t) \quad (2)$$

其中, m 表示展开项数; $X(t)$ 表示原始时序信号; $\phi_i(t)$ 是预定义的基函数; θ_i 为待估参数; $\varepsilon(t)$ 为残差项. 在该类方法中, 建模过程通常采用残差传递机制, 在逐层迭代中依次剥离趋势、周期等关键结构, 实现建模复杂度与表示能力的有效平衡。

N-BEATS 模型^[16] 率先提出前向预测与后向分解相结合的双分支架构, 利用块式残差拟合机制逐层抽取时间序列的可解释成分. 该模型通过显式形式对趋势与季节性进行分解处理, 并将多层预测结果进行累加, 提升了对长期结构模式的拟合精度. 随后, N-HiTS^[17] 在 N-BEATS 模型基础上引入多频重采样机制, 通过子采样层增强输入的多频率分解能力, 同时设计分层插值操作适配不同时间分辨率下的信号结构, 有效解决了传统方法在跨尺度建模中的频率混叠问题, 在长周期气象预测等任务中取得突破性进展。

针对高维复杂时空序列建模问题, DEPTS^[18] 提出周期状态隐变量建模方法, 在残差学习框架中构建深度展开模块. 通过解耦观测信号与隐周期状态, 显式建模变量间的相位依赖关系. 基函数展开方法通过数学显式建模与深度学习、隐式学习的有机结合, 实现了时序信号的可解释分解与高效预测。

矩阵分解技术. 针对多变量时序, 通过将高维时空数据表示为低秩因子乘积, 实现跨变量关联模式的提取与特征解耦, 从而在压缩维度的同时保留主要信息, 提升下游预测与分析任务的效率^[19]。

令观测数据矩阵为 $X \in \mathbf{R}^{T \times C}$, 其中 T 为时间步长, C 为变量维度, 近似分解可表示为:

$$X \approx F X_b \quad (3)$$

得到特征矩阵 $F \in \mathbf{R}^{k \times C}$ 与时间基矩阵 $X_b \in \mathbf{R}^{T \times k}$. 其中秩 k 为预设的分解秩, 低秩近似在保持全局信息的同时剔除了冗余相关性, 显著降低了模型复

杂度。

为增强分解模型对时间依赖的刻画, 文献 [20] 在因子分解中引入自回归型时间正则器, 利用矩阵分解的可扩展性和正则化技术, 有效处理高维、缺失值多的时序数据, 在大规模预测任务中展现出超越传统方法的预测质量与计算性能. 进一步地, 研究者将空间自回归机制引入因子学习, 以同时建模时空依赖关系, 提升对未知传感器位置或空间网络的预测能力^[21]。

针对非平稳特征严重的高维时序, 文献 [22] 在分解框架中对时序因子矩阵施加差分与向量自回归过程, 实现保持低秩性质同时捕捉趋势与季节性变化, 验证了非平稳处理对现实数据建模的重要性. 此外, 文献 [23] 通过将矩阵分解与向量自回归过程统一到概率图模型中, 实现了对全局与局部时空一致性的联合建模, 在多维时序预测与不确定性估计中表现出较高的鲁棒性与可解释性。

近年来, 多元时序卷积与图模型的融合显著增强了矩阵分解的非线性表达能力. 如 DeepGLO 模型^[24] 将全局矩阵分解与时序卷积网络相结合, 实现在降低计算复杂度的同时提升准确度. 此外, SS-MF 方法^[25] 在传统分解结构中引入在线多模式季节性切换机制, 具备常数时空复杂度, 可在实时数据流中自适应捕捉突变与周期转移. 此类混合模型保留了矩阵分解的可解释性优势, 在电力负荷预测、交通流量等多元时序场景中展现了卓越的鲁棒性与泛化性。

然而, 矩阵分解在高维场景下的内存消耗仍是瓶颈. 特征矩阵 $F \in \mathbf{R}^{k \times C}$ 与基矩阵 $X_b \in \mathbf{R}^{T \times k}$ 的存储需求与时间步长 T 、变量维度 C 成正比, 常导致空间开销难以满足边缘计算或在线推理资源约束. 近期研究通过随机投影与流式更新策略显著缓解了内存压力. Cui 等^[26] 提出一种基于秩统计损失及核范数正则化的统一高维低秩矩阵估计框架, 在高维分解中显著降低峰值内存使用; Luan 等^[27] 提出一种基于张量分解的新型在线算法, 在保证高预测精度的同时实现更高效率的长期在线预测。

1.1.2 频域分析技术

频域分析技术将信号从时域映射到频域, 以频率成分的稀疏性和可解释性为基础, 将复杂时序信号拆分为具有不同频率的子分量, 实现跨尺度的特征表达与协同建模. 通过将原始信号从时域映射到频域, 模型能够更有效地提取不同频率层次的变化模式, 在处理长期依赖、季节性干扰及噪声抑制等方面表现突出。

基础频域变换技术. 傅里叶变换^[28] 作为经典的

频域分析工具, 能够将时序信号表示为一组正余弦波的加权组合, 擅长建模全局周期性模式, 已广泛应用于电力负荷与气象预测等任务中. 在此基础上, FITS 模型^[29] 引入低通滤波器以抑制高频噪声、保留低频趋势; FEDformer 模型^[30] 则通过随机采样策略平衡高低频成分, 并在深度框架中实现滤波器参数的动态优化. 然而, 由于傅里叶变换的全局性特征, 其对局部非平稳信号的建模能力存在一定局限性.

为克服上述不足, 小波变换^[31] 引入时频局部分析机制, 利用多尺度滤波器同时捕捉不同粒度下的趋势与扰动特征. SCINet^[32] 基于小波包分解构建树状结构, 以实现多尺度依赖关系的自适应建模. 此外, 经验模态分解^[33] 及其扩展方法以数据驱动方式将信号分解为一组内禀模态函数, 能够保留信号中的非线性与非平稳特征; 变分模态分解^[34] 则进一步在变分推理框架下实现固定频带的自适应分解.

时域频域建模技术. 频域建模技术旨在将时序数据的频率成分显式融入深度网络结构, 以增强对多尺度周期性特征的捕捉能力, 并提升模型在复杂非平稳场景下的泛化性能.

为提升频域方法对非平稳数据的适应性, 部分工作引入混合域或分层蒸馏策略. 如 FiLM 模型^[35] 在频域表示中引入低秩近似, 通过截断次要频率分量实现噪声抑制与特征压缩. 在频域与其他结构融合方面, ATFN 模型^[36] 在序列到序列框架中嵌入频域模块, 以捕捉复杂非平稳周期特征; TFAD 模型^[37] 基于时频卷积网络, 实现时域与频域表示的联合学习; STFNet 模型^[38] 对短时傅里叶变换后的频谱图进行卷积与池化操作, 获取更加稳定的局部频域特征; StemGNN 模型^[39] 则结合图傅里叶变换与离散傅里叶变换, 同步建模序列间的空间关联与时间依赖.

此外, 研究者们还致力于将频域信息与深度生成模型相结合. FreTS 模型^[40] 针对复数域数据设计多层感知机模块, 分别建模频域特征的实部与虚部. FCVAE 模型^[41] 在条件变分自编码器框架中并行融合全局与局部频谱特征. TSLANet 模型^[42] 则引入自适应谱块, 通过全局与局部滤波乘积捕获多尺度频域信息.

尽管频域方法在全局周期性检测与噪声抑制方面表现优异, 但是其对非平稳信号的适应性存在固有局限. 傅里叶变换的全局性质导致频谱泄漏与边界效应, 对突变或局部异常响应迟钝; 小波变换虽具有时频局部化能力, 但固定母小波难以兼顾多尺度突变化与长时记忆, 频带切换时易引发频谱

混叠^[33-34]. 为缓解这些限制, 可采用自适应时频分解结合智能调度策略. 例如, Xu 等^[43] 提出的虚拟电厂频率调节方案通过时频分解与储能优化协同, 实现了集成能源系统的高效频率恢复与资源调度; Xing 等^[44] 在直流送端系统中将电解铝负荷参与频率调节, 引入分层协同控制机制, 在多扰动场景下显著提升了频率稳定性和灵活性.

1.1.3 外生变量融合技术

在动态时序分析场景中, 有效整合外生变量已成为提升模型准确度和泛化能力的关键路径. 这类技术通过引入经济指标、气象参数、社会事件等有关外部驱动因素, 建立多维特征间的动态关联机制, 为解决复杂时空关联建模与概念漂移问题提供了新的方法.

传统线性统计模型, 如 ARIMAX^[45], 通过回归框架实现外生变量的因果建模, 然而, 其线性假设难以捕捉变量间复杂的非线性交互, 且无法处理长序列依赖关系.

针对非线性动态建模需求, DA-RNN 模型^[46] 创新性地构建了双注意力框架. 首先, 输入注意力层利用上一时刻的隐藏状态与各外生变量的特征表示, 通过非线性映射生成一组权重系数, 并对外生变量进行加权筛选, 从而自适应地突出最具驱动作用的因素. 其次, 将筛选后的外生变量向量与主序列特征共同输入时间注意力层, 在不同历史时刻之间分配注意力权重, 以同时捕捉短期波动与长期依赖.

此外, Transformer 架构的并行化优势与长程依赖建模能力, 为外生变量融合提供了更高效的实现路径. 近年来涌现的主要方法如表 1 所示. 交叉注意力机制作为外生变量融合的核心技术之一, 其本质在于解耦查询与键值来源, 允许主序列作为查询向量, 主动对外部变量中相关特征进行匹配与加权, 从而在输入模态不一致、尺度不统一的背景下, 有效解决了异构变量之间的关联建模问题. 部分 Transformer 变体在基础交叉注意力机制之上引入稀疏连接、自相关归纳偏置等结构设计, 以提升在长序列、多模态场景下的效率与泛化能力. Crossformer^[12] 采用二维分段嵌入保留主序列与外部变量间的局部结构, 在多个粒度上进行交叉特征提取; 先在各维时间内进行自注意力, 再在变量维度使用路由机制稀疏注意力, 显著提升变量间建模效率. 而 ExoTST^[47] 将历史外生与当前外生视为两种模态, 将外部因素嵌入不同模态空间, 通过交叉融合模块实现多模态注意力交互、聚合与再注入, 显著增强模型对外部导因的响应与适应能力. 此外, 在 Time-

表 1 基于交叉注意力的外生变量融合方法
Table 1 Cross-attention-based exogenous variable fusion methods

方法	核心机制	方法特点
Crossformer ^[12]	通过二维分段嵌入 (DSW embedding) 保留时空结构信息, 结合两阶段注意力 (TSA) 模块交替捕获跨时间与跨维度依赖	分层编解码结构以实现多尺度时空特征提取, 并通过参数共享降低模型复杂度
ExoTST ^[47]	将历史外生、当前外生与主序列视为三模态输入, 通过分层多头交叉注意力模块逐层融合	对缺失与噪声鲁棒性强, 动态整合多源异质驱动信号
TimeXer ^[48]	补丁级自注意力先行建模局部时序依赖, 再通过变量级交叉注意力引入外生变量	双流架构兼容局部与全局信息, 适应多模态输入与分布漂移
TGForecaster ^[49]	利用文本描述与数值序列共同作为查询与键值, 通过交叉注意力实现多模态融合	支持场景化预测, 增强模型可解释性与上下文感知能力
CATS ^[50]	舍弃自注意力, 仅保留未来-历史跨注意力机制, 以参数共享和可学习查询捕获预测依赖	架构简化, 参数与内存开销低, 长程预测精度优异

Xer^[48] 中, 主序列先通过局部补丁建模自身依赖关系, 再通过变量级交叉注意力对外生变量进行特征过滤与对齐, 采用全局内部变量补丁来有效地将外部序列桥接到内部时间补丁中, 提升模型对分布漂移与模态差异的鲁棒性。

在处理具有空间拓扑特性的外生变量时, 时空图神经网络通过联合建模时空相关性, 实现深度特征融合. AST-GCN 模型^[51] 将外部因素分为静态属性 (如道路结构、地理位置) 和动态属性 (如天气、节假日等). 通过引入属性增强模块, 将这些外部因素作为节点的附加特征融合到图卷积网络中, 从而提升模型对外部信息的感知能力, 增强了交通预测的准确性和可解释性. SPATIAL 模型^[52] 则构建一个跨变量的时空长短期记忆 (Long short-term memory, LSTM) 架构, 将邻域外生因素通过卷积长短期记忆单元引入预测过程. 该方法在环境数据预测任务中提升了时空一致性建模能力, 增强了模型对复杂时空动态的捕捉能力。

为进一步提升外生变量融合的鲁棒性与可解释性, 近年来, 研究者尝试在模型输入端引入因果图结构, 通过系统建模多源异构变量之间的因果关系, 将驱动因子与干扰噪声加以区分. 文献 [53] 在分布式及家庭级负荷预测中, 通过可解释的因果图神经网络架构提升了多变量依赖建模能力与预测准确性; 文献 [54] 则构建基于因果图卷积及微分方程的模型, 将因果发现嵌入时空神经微分方程中, 实现了变电站等复杂系统的中长期动态预测. 这类方法以结构化图表示方式整合外部信号, 通过因果路径约束提升特征选择的针对性, 避免非因果相关性的误导, 在大规模电力负荷和风电功率预测中已展示出了显著的精度提升和泛化能力^[55]。

目前, 外生变量融合技术已广泛应用于传感器网络、宏观经济预测等领域, 通过系统整合多源驱动信号, 提升模型预测性能. 随着多模态学习与因果推理技术的进步, 外生变量融合建模正朝着可解释、可溯源的方向发展, 为复杂系统的智能决策提

供关键技术支持。

1.2 协同推断共性技术骨干网络

1.2.1 神经网络协同推断模型

递归神经网络建模. 递归神经网络 (Recurrent neural network, RNN)^[56] 的结构特性使其擅长处理序列数据, 在自然语言处理^[57]、音频建模^[58] 等领域表现突出. 由于时间序列本身具有顺序性, RNN 的递归结构成为建模时间序列的理想选择^[59]. 然而, 传统 RNN 面临着梯度消失等问题, 限制了其在长序列中的表现. 为克服这些挑战, 长短期记忆网络^[60] 和门控循环单元 (Gated recurrent unit, GRU)^[61] 等改进型递归神经网络被广泛应用于时间序列建模. 如图 5 所示, LSTM 通过引入输入门、遗忘门和输出门的门控机制, 有效控制了信息流, 使得模型能够长期保留关键信息, 缓解了梯度消失问题, 适用于长时间依赖的建模任务; 而 GRU 则仅使用重置门和更新门, 以较少的参数实现类似的记忆能力, 提高了计算效率, 在资源受限的环境下表现优越. 在此基础上, DA-RNN^[46] 结合双阶段注意力机制与 LSTM, 实现自适应的时间序列信息提取. 该模型能够在每个时间步动态地选择相关的输入序列, 从而更精确地捕捉不同时间步的时空变化. Deep-AR 模型^[62] 则提出一种基于自回归递归网络的框架, 以 GRU 网络为核心, 不仅能够捕捉时间序列的季节性变化, 还能够学习协变量之间的依赖关系, 使得该模型即使在历史数据有限的情况下, 也能够




图 5 改进的 RNN 模型

Fig.5 Improved RNN models

进行有效的预测。

另一方面,研究者通过结合卷积操作与递归结构,构建递归卷积神经网络 (Recurrent convolutional neural network, RCNN) 模型,通过卷积进行特征提取,结合递归网络捕获时序信息,赋予了模型更强的时空建模能力,在捕捉长时间依赖性和多尺度特征方面展现了独特优势。如 LSTNet 模型^[63],通过将卷积层与递归结构相结合,在捕捉短期局部依赖关系的同时挖掘时间序列中的长期模式。

卷积神经网络建模. 卷积神经网络 (Convolutional neural network, CNN)^[64] 以其出色的局部特征捕捉能力在计算机视觉领域取得诸多成果,如图像分类^[65]、分割^[66] 以及目标检测^[67] 等。近年来,研究者将其迁移到时间序列领域^[68]。时空数据的语义信息主要隐藏在其时间变化过程中, CNN 能够有效提取这些局部时空特征,因此在时序数据建模中展示了显著的优势。如表 2 所示,现有的 CNN 架构时空协同推断模型主要包括 1D 和 2D 推断。

考虑到数据的时间连续性,许多方法已基于 1D 卷积操作进一步拓展了 CNN 的能力。时序卷积网络 (Temporal convolutional network, TCN)^[69] 是这类方法的代表之一,采用因果卷积的方式,使得模型在预测时只依赖于之前的数据,保持了自回归特性。此外, TCN 通过逐步扩大的膨胀卷积核堆叠,提升了感受野的范围,然而 TCN 在捕捉全局时间依赖关系时仍面临一定的挑战。

为解决这些局限性,文献 [70] 提出一种局部-全局卷积网络,结合不同类型的卷积核,从局部和全局两个角度同时建模时序数据的时间相关性。而文献 [71] 将传统 1D 卷积分解为深度可分离卷积和卷积前馈网络,分别独立处理时间维度和特征维度信息,进一步增强了传统 TCN 的表现,有效捕捉跨时间和跨变量的依赖关系。

另一方面, TimesNet^[72] 提出一种创新的 2D 变换策略,将 1D 时间序列数据转化为 2D 张量,结合不同的周期性估计,实现周期内和周期间的双重时空特征捕捉,增强了对复杂时间序列数据的建模能力。

在此基础上, Times2D 模型^[73] 进一步拓展了 2D 建模范式的表达能力,通过引入多分支 2D 卷积结构,从“局部时间-全变量”和“全时间-局部变量”两

个方向分别提取耦合特征,显著提升了对时序内部结构的建模深度。Times2D 将多变量时间序列重构为 2D 张量,并在每一层保持双向卷积流结构,不同卷积通路提取的特征随后通过互补融合模块进行集成,最终通过反卷积或展平操作复原为 1D 预测输出。相较于 TimesNet 仅在中间层引入 2D 结构, Times2D 在各个层级均保持 2D 结构建模优势,尤其适用于高维、多周期的能源负荷与气象类序列预测任务,展示出了更强的跨变量周期性捕捉能力和建模精度。

图卷积神经网络建模. 在多变量时间序列数据分析中,变量间的复杂非线性关系常常使得建模任务变得尤为艰巨。为解决这一问题,图神经网络 (Graph neural network, GNN)^[74] 逐渐成为时空建模领域的重要工具。通过将多变量数据表示为时空图, GNN 能够将每个变量视为图中的一个节点,捕捉邻近节点间的关系,并跟踪节点属性随时间的演变,从而有效地揭示数据背后的动态特性。作为一种强大的模型架构, GNN 通过利用图结构中的拓扑关系,提供了一种全新的方式来处理复杂的时空数据,在具有多维度和长时间跨度的数据分析中表现出显著优势。

根据图结构是否作为模型的输入,基于 GNN 的时空建模方法可以分为两类。第一类方法中,图结构通常是预先定义好的,这类方法通过固定的空间结构来建模时空数据的空间依赖性。如扩散图卷积模型 (图 6)^[75],将时间数据建模为有向图,利用扩散卷积操作来捕捉空间依赖性,同时结合递归神经网络来捕捉时间动态,从而实现时空依赖的建模。文献 [76] 则将图卷积网络与时间卷积相结合,通过图卷积捕捉交通传感器间的空间依赖性,再通过时间卷积捕捉时序依赖性,为时空建模提供一种精细化的分析框架。这些方法能够高效地提取时空数据中的规律,适用于空间结构较为明确的场景。

与此不同,第二类方法则侧重于自适应学习图结构,该类模型能够在没有预定义图结构的情况下动态地捕捉数据中的空间和时间关系。如文献 [77] 结合图卷积与扩张因果卷积,通过节点嵌入学习自适应的依赖矩阵,模型能够自动识别时空图数据中隐藏的空间依赖性;同样,文献 [78] 通过引入节点自适应参数学习和数据自适应图生成模块,能够在

表 2 CNN 架构时空协同推断模型
Table 2 Spatiotemporal collaborative inference model based on CNN architecture

技术	主要特点	代表文献
1D CNN	直接将时空数据视为 1D 序列,通过标准、扩张或因果卷积捕获局部特征和长程依赖	[79–81]
2D CNN	先将 1D 时空数据转换为 2D 张量,利用 Inception 块对信息进行融合,再将 2D 张量重塑为 1D 序列	[72]




图6 扩散图卷积模型结构

Fig.6 Diffusion graph convolution model structure

没有预定义图结构的情况下自动捕捉空间和时间依赖性; 文献 [39] 则通过引入图傅里叶变换与离散傅里叶变换, 将多变量时间序列数据转化到频域进行建模, 有效提升了模型在频域上的建模能力, 为处理高维、长时间跨度的时空数据提供了全新的视角。

1.2.2 基于 Transformer 架构的协同推断模型

随着 Transformer^[8] 模型的提出, 自注意力机制在机器视觉^[82]、语言处理^[83] 等领域取得突破性进展, 为电力时间序列建模提供了新的思路。研究者已经提出诸多基于其架构的变体^[6, 30] 应用于电力时空协同推断。

如图 7 所示, 现有的基于 Transformer 架构的数据协同推断模型可根据其骨干结构的不同, 划分为三种主要类别: 编码-解码器架构、仅编码器架构以及仅解码器架构。




图7 Transformer 骨干架构

Fig.7 Transformer backbone architecture

编码-解码骨干. 由于时空推断任务的模式, 编码-解码骨干成为时空数据分析建模的理想选择。该架构通过解码器中的自注意力和交叉注意力机制, 有效地融合了编码器提取的全局特征。通过自回归过程, 模型能够逐步生成预测值, 因此在时空推断任务中展现出显著的建模优势。近年来, 研究者针对编码-解码的高效时间数据协同建模进行了研究^[84]。然而, 其固有的架构在时空协同推断任务上仍存在局限性。自回归生成方式虽然有助于捕获时空依赖, 但也带来了推断过程的低效性, 每个时间步的生成需要依赖前一时间步的输出, 导致无法

一次生成整段序列, 显著增加了推理时间, 并累积了推理误差; 且注意力机制需要计算输入序列中每个时间步之间的全连接关系, 导致计算复杂度高, 限制了其在高频、长时间序列建模中的应用。此外, 多变量协同推断时传统的注意力机制往往难以全面捕捉变量间多层次、多尺度的依赖关系。

为克服这些限制, 研究者们提出了一系列改进的编码-解码器模型^[85]。针对编码-解码架构计算复杂度高问题, 许多方法基于注意力机制进行改进。Pyraformer^[86] 引入金字塔注意力模块, 在金字塔图结构中, 每个节点仅关注其邻近节点, 从而以多分辨率的方式描述时间序列依赖性, 显著减少了注意力计算的复杂度。Informer^[87] 模型提出稀疏注意力机制, 通过只允许每个查询 (Query) 关注关键的 u 个主导的键 (Key), 将传统的注意力机制计算复杂度 $O(L^2)$ 降低到 $O(L \log L)$, 显著提升了模型的推理效率。这一理念被文献 [88] 进一步探索, 结合 Informer 模型结构中的自注意力蒸馏模块和生成式推理解码器, 提出一种基于线性稀疏的多头自注意力模型, 相比先前的模型推理效果得到提升。

另一类模型则通过采用分块的标记尺度实现复杂度的优化。相较于将每个时间点进行标记, 分块标记方法将长序列分割成多个较小的时间段, 这类方法通过局部化处理来减少整体计算量, 同时保持序列的时序依赖性。Autoformer^[11] 是此类研究的开创性工作之一, 它引入一种自相关机制, 替代传统的逐点自注意力。自相关机制通过计算序列自相关来发现基于周期的依赖关系, 并通过时间延迟聚合来聚合相似的子序列, 采取序列分解的方法, 分别捕捉时间序列的短期波动和长期趋势, 显著提高了模型的计算效率。Preformer^[14] 继承了 Autoformer 的分段理念, 并在此基础上引入多尺度分段, 通过在多个不同长度时间段上计算相关性, 实现同时捕捉不同时间尺度下的依赖关系。Crossformer^[12] 则设计了维度分段嵌入来处理历史时间序列, 在建立跨变量维度依赖性的同时建立跨时间依赖性, 从而在兼顾计算复杂度的前提下, 有效解决了多变量协同建模问题。

仅编码骨干. 尽管编码-解码架构在时间序列预测中取得了显著进展, 但其固有的局限性也限制了进一步的发展。编码器与解码器的协作计算增加了整体模型的复杂性, 同时也限制了模型的可扩展性。这些问题促使研究者们探索更加高效的替代方案, 其中, 仅编码器和仅解码器架构因其简化的结构和针对性的优化而逐渐受到关注。这些架构通过减少多余的模型模块和计算步骤, 在提升模型效率

的同时,依然能够保留全局和局部的时间序列特征,成为时空数据协同推断领域的重要研究方向^[89]。

仅编码骨干摒弃了解码器模块,专注于通过多层编码器提取全局特征信息。由于没有解码器部分,该架构能够显著降低模型复杂度和计算成本,同时保留全局建模能力。目前主流的仅编码架构多采用掩码重建的方式进行建模,通过对部分时间段进行随机遮掩并训练模型重构这些被遮掩的片段,模型可以学习到时空数据的高层次特征。PatchTST^[90]是这类模型的代表之一,该模型将时间序列划分为子序列级的时间片段并支持多变量建模,每个通道被视为独立的单变量时间序列,各通道共享相同的嵌入和编码器权重,从而显著减少模型的参数量并提升计算效率。编码器生成的潜在表示通过展平操作和线性层转换为最终推断结果。

研究者汲取前者划分子序列时间段和掩码重建的方式,对大规模时空推断模型开展了进一步研究。文献[91]通过引入多尺寸时间段输入投影层和任意变量注意力机制,实现了应对复杂的时间序列变量;同时进行扁平化处理,把所有的变量视为一个单一序列来进行建模,实现了多变量建模。文献[92]则致力于时空推断的多样性问题,通过预训练及微调模型的方式,实现包括预测、分类、异常检测、插值等任务的统一,为时空协同推断提供了一个统一的大模型。

此外,编码器骨干的特征提取能力为多变量时空协同建模提供了新的方向。一类方法是对输入的标记尺度进行创新。如iTransformer^[93],不同于传统模型将多个变量的同一时间戳合并为单个标记,该模型将每个变量视为一个独立的标记,从而能够更加清晰地捕捉多变量之间的关联,并为每个变量学习更好的非线性表示。另外,倒转的结构设计减少了模型的计算复杂度,使其能够处理更长的时间窗口并降低内存消耗。另一类方法则引入交叉注意力机制捕获不同变量间的依赖性。如TimeXer^[48]模型,内生变量和外生变量分别通过不同的嵌入策略进行处理,通过自注意力和交叉注意力机制分别捕捉时序依赖和变量依赖,有效桥接外生变量的因果信息,显著提高了时空协同推断的准确性和泛化能力。

在仅编码骨干的基础上,部分研究进一步引入多模态增强机制,以提升模型的泛化能力和语义建模能力。如Time-VLM^[94]模型,设计了基于时间序列的主干网络,并融合冻结的语言模型与图像编码器所提取的文本语义和视觉感知特征,实现了跨模态特征融合。该模型具备良好的迁移能力与泛化性

能,为多模态时序建模领域提供了新范式。

仅解码骨干。仅解码骨干采用因果掩码机制,用于确保模型在生成序列时保持正确的时间顺序和因果关系。因果掩码的应用确保了每个时间步的推断只能依赖于当前时刻及之前时间步数据,无法访问未来的输入数据。通过确保每一步的推断只依赖于历史信息,因果掩码增强了模型生成过程的稳定性,避免了因未来信息引入不一致性而导致的错误。相较于编码器骨干主要通过自注意力机制提取全局特征,解码器架构采用因果掩码的方式,有助于捕获动态信息并更好地保持时空数据的因果关系^[95]。

大模型在自然语言处理任务中取得突破性进展,以GPT (Generative pre-trained Transformer)^[96]为代表的大模型成功驱动着时空协同推断仅解码骨干的研究与探索。一类研究着眼于训练大规模仅解码骨干的时空推断模型。如Das等^[97]提出的TimesFM是大规模时序模型的开创性模型之一,通过仅解码器结构灵活的切片和因果掩码机制以及较长的输出切片设计,高效地进行长时间范围的时间数据推断,且能够处理不同的上下文长度和推断任务。Timer模型^[98]则进一步探索了仅解码骨干的优势之处,通过使用仅解码器的自回归结构,结合大规模的时间序列数据集进行预训练,解决了传统时间序列模型在数据稀缺和任务复杂度高时的性能瓶颈。尽管这些模型在时空协同推断任务上取得了突破性进展,但在多变量时间数据中变量间的复杂关系没有得到充分挖掘,基于此,Timer-XL^[99]在Timer模型的基础上进行改进,提出了新的注意力机制,同时将多维时间序列建模为多个变量的下一个数据推断任务,捕获各序列之间的因果依赖关系,统一了单变量及多变量时空序列推断。

由于时空数据的有限性以及时空推断模型预训练方法的探索不足,时空协同推断的基础模型尚未完全发展,基于时间序列数据和自然语言相似的顺序表达,另一类研究则利用大规模语言模型 (Large language model, LLM) 来进行时空协同推断建模。如PromptCast模型^[100],将传统数值时序数据转化为自然语言格式的输入输出数据,通过句子到句子的方式进行推断;FPT模型^[101]则微调LLM的参数,使其适用于预测、分类、插值等多任务时空协同推断。

尽管LLM在自然语言处理领域表现出色,但电力时序数据的多尺度周期性、噪声与缺失以及严格的物理约束,给直接迁移带来了挑战。传统位置编码难以同时捕捉日、周、年等多级周期变化,数值时序与文本模态差异较大,导致注意力机制易忽略变量间的耦合关系;且如图8所示,存在LLM的模

型结构和生成方法不一致的问题,即用于自回归生成的仅解码器模型被转换为仅编码器的非自回归模型。此外,电力数据常伴随缺失和不均匀采样,基础 Transformer 对不规则序列的鲁棒性不足^[102]。为解决上述问题,AutoTimes 模型^[103]提出保留 LLM 的自回归特性,利用位置编码的方式将时间戳嵌入 LLM 中来增强时间序列的表示,同时将序列本身作为提示输入 LLM,充分发挥了自回归能力和大规模预训练模型的优势,在时空协同推断任务中取得了显著的性能提升。




图8 用于时序分析的自回归 LLM

Fig.8 Autoregressive LLM for time series analysis

2 源网荷智能化关键技术

经济的快速发展离不开能源的消耗,随着我国“碳达峰、碳中和”目标的推进,可再生能源在电力系统中的占比不断攀升^[103]。

能源系统形态正经历深刻变革。现代综合能源系统 (Integrated energy system, IES) 是这一变革的核心载体,其不仅包含电能,还广泛涉及热能、氢能、化学能等多种能源形式,并通过储能技术实现多能流的相互转换与耦合。这种多能流耦合特性使得 IES 的建模、分析与优化面临跨能级的复杂性。传统面向单一能源的独立建模与分析方法难以全面刻画 IES 中“源-网-荷”各环节的动态交互与耦合机理。由此,这类方法也难以以为系统安全性、经济性与运行效率提供准确的量化评估。因此,发展能够有效刻画多能流时空耦合关系的跨能级建模方法与高精度智能推断技术,是实现 IES 协同优化与智能运行的关键基础。据统计,2022 年中国光伏发电装机规模达 8741 万千瓦,占总装机量的 43.8%,并有逐年上升的趋势。源网荷储系统如图 9 所示。风光能源发电固有的间歇性和波动性给电力系统的安全稳定运行带来了挑战。在此背景下,实现源端的优化、网端的稳定性保障以及负荷的精准管理,成为推动双碳目标实现优化能源结构的重要任务。因此,本节将围绕源网荷智能化关键技术,重点对可再生能源智能推断技术、电网状态智能推断技术以及电力荷载智能推断技术进行阐述。



图9 源网荷储系统

Fig.9 Source-grid-load-storage system

2.1 可再生能源智能推断技术

在过去几年中,我国大力推进风能和太阳能发电建设,取得了显著的成效。根据国家能源局发布的《2024 年全国电力工业统计数据》^[104],截至 2024 年 12 月底,全国累计发电装机容量约 33.5 亿千瓦,同比增长 14.6%。其中,太阳能发电装机容量约 8.9 亿千瓦,同比增长 45.2%;风电装机容量约 5.2 亿千瓦,同比增长 18.0%。随着可再生能源比例的快速提升,弃风、弃光现象的普遍存在,风、光接入后产生的消纳问题成为制约可再生能源高效消纳的主要瓶颈。可再生能源智能推断可以为源网荷系统的协同调度提供依据。在可再生能源的智能推断中,时间尺度是影响预测精度和调度决策的重要因素。目前许多研究已根据不同的时间尺度将推断方法分为超短期推断、短期推断和中长期推断三类^[105]。

2.1.1 超短期推断

超短期推断主要针对未来分钟级、小时级的可再生能源发电量预测^[106],适用于电网的实时调度、短时负荷调整及需求响应策略等,对提升电网调度灵活性以及新能源消纳水平具有重要意义。由于超短期预测对数据的高时空分辨率要求较高,且风光功率具有显著的非线性和随机性,传统基于物理模型和统计模型的方法^[107]在计算复杂性以及对突发事件的响应能力上存在不足。因此,近年来,基于深度学习^[108]的超短期预测方法成为研究热点。

LSTM^[60]通过门控机制有效缓解了梯度消失和梯度爆炸问题,使其能够捕捉复杂的时间依赖关系,被广泛应用于超短期可再生能源预测。然而,传统 LSTM 模型在面对高度非线性和随机性的可再生能源数据时,仍存在一定的局限性。因此,许多研究基于 LSTM 网络进行改进。如文献 [109] 提出一种基于 CNN 和 LSTM 的超短期风电预测模型,利用 CNN 提取不同站点气象因子的空间相关特征向量和超短期气象特征的时间相关向量,进行时间序列

重构,作为 LSTM 的输入数据,实现了多步风电功率预测.所提出的模型具有更好的时空特征提取能力,能够更准确地预测风电场的功率.文献[110]则在前者的基础上,将自注意力时间卷积网络(Self-attention temporal convolution network, SATCN)与 LSTM 相结合,在 SATCN 之后使用 LSTM 进一步构建特征与输出之间的连接,以预测未来的超短时风电,相比 CNN-LSTM 模型预测准确率提高.此外,文献[111]将多任务学习和 LSTM 网络相结合,实现了对风电的高精度超短期预测.

另一类研究对数据的时空依赖性进行建模,通过图神经网络^[74]和注意力机制等方法提升超短期预测的准确性.如 Li 等^[112]提出时空有向图卷积神经网络,通过结合 Granger 因果关系建图及时间卷积网络提取时间特征,实现预测准确性提升.文献[113]则提出一种结合风电功率波动模式识别与时空图神经网络的超短期风电集群预测方法,根据波动模式选择对应模型进行预测,提高预测的精准度与鲁棒性,在复杂风电功率波动环境下具有较好的预测效果.结合注意力机制,文献[114]提出一种新的时空注意力图卷积网络模型,利用空间注意力机制聚合和提取原始风电数据的空间关联性,将提取的时空相关特征分别输入时间卷积网络和图卷积网络,进一步学习时空依赖性,实现预测效果的提升.

近年来,自注意力机制在超短期可再生能源预测中的应用取得了显著进展. Transformer 作为一种强大的时序建模工具,在多源数据融合和长期依赖关系建模方面表现优异.一些研究基于 Informer 模型进行超短期可再生能源预测,通过其高效的长序列建模能力和稀疏注意力机制提升计算效率和预测精度.例如,文献[115]提出 Informer 模型在风电预测中的应用,解决风电功率长时序的预测问题,从而降低空间复杂度、提高预测精度.文献[116]则结合 TCN 和 Informer 模型,从原始数据中提取更广泛的多样化特征.

此外,针对风光功率固有的强随机性和波动性特征,当前研究主要从提升模型鲁棒性与适应性两方面寻求突破.一方面,引入概率预测框架(如分位数回归、贝叶斯网络等)以量化预测不确定性,并结合集成学习与多模型融合策略增强对极端波动场景的适应能力.此外,通过混合策略结合多种方法的优点、模型间的互补性来提高预测的稳定性和鲁棒性.在复杂的风电数据环境下,融合多种方法能够有效应对多变的气象条件和功率波动,为超短期可再生能源预测提供了可靠的解决方案^[117].另一方面,采用滑动窗口机制与在线学习算法实现模型的动态

增量更新,有效跟踪数据分布的时变特性.在面向实时调度的应用场景中,模型复杂度与计算效率的平衡至关重要,研究趋势倾向于采用模型轻量化设计,如知识蒸馏、结构化剪枝以及部署高效推理架构,确保在满足严格时间约束的前提下完成高精度的超短期功率推断.

2.1.2 短期推断

典型的短期推断任务一般涵盖未来小时级和天级内可再生能源发电量的预测^[106].随着风能和太阳能装机容量的迅速扩展,其间歇性和波动性带来的弃风、弃光问题日益凸显.精准的短期推断成为应对这一挑战的关键手段.高精度的短期推断对于优化电网调度、最大化可再生能源的有效利用以及降低调度成本等至关重要.

传统机器学习方法,如支持向量机^[118]、线性回归^[119]、决策树^[120]等,曾广泛应用于短期发电预测.然而,在处理大规模、复杂且高度非线性风光发电数据时,传统模型在泛化能力和特征提取方面的不足导致其预测精度较低.由此,深度学习技术,凭借其强大的非线性建模能力和高效的特征学习机制,为短期推断提供了新的方向^[121].由于单一模型在短期发电预测中建模复杂非线性特征、捕捉多尺度时序模式方面仍存在局限性^[122],近期的研究趋势倾向于采用混合模型,以克服单一模型的不足.

一类研究结合模态分解技术与深度学习方法,通过经验模态分解^[33]或变分模态分解^[34]有效地将非线性和非平稳的时间序列数据分解成多个具有不同时间尺度的简化成分,从而揭示了数据的潜在规律和趋势.例如,文献[123]提出一种基于集合经验模态分解和分位数回归神经网络的风电预测模型,有效应对了风电数据的随机性和间歇性,提升了风电功率预测的性能.而文献[124]基于互补集成经验模态分解提出一种鲸鱼优化算法与核极限学习机相结合的混合预测模型来预测短期风电,通过互补集成经验模态分解将非平稳风电时间序列分解为一系列相对平稳的分量,降低了预测复杂度,并具有较小的重构误差.文献[125]则采用变分模态分解与 GRU 相结合的预测模型,应对风电的不确定性和多能源链复杂性带来的挑战.此外,为解决大规模分布式风电的波动性和随机性带来的安全威胁,文献[126]提出一种融合两层分解和深度学习的风电功率预测模型.通过完全集成经验模态分解对风电级数进行平滑处理,结合双向时间卷积网络提取与风速、风向和风功率序列相关的隐藏信息,并将获得的信息输入到由注意力机制优化的双向长短期记忆网络,以实现精准预测.

另一类组合模型结合 LSTM 和神经网络在建模时间序列依赖关系方面的优势展开研究. 其中 CNN-LSTM 结构是较为典型的一种方案^[127], 通过 CNN 提取局部时序特征, 而 LSTM 则捕捉长期依赖性, 使得该类组合模型在处理复杂、非线性时间序列数据时具备更强的预测能力. 另一种方案将 GCN 与 LSTM 结合^[122], 进一步拓展了 LSTM 在时间序列建模中的应用. GCN 构建节点间的图结构, 捕捉分布式风电场、光伏电站等空间相关的能源系统特征, 通过捕获空间依赖关系与时间动态特征, 使得模型表现出更强的空间建模能力.

此外, 基于注意力机制的深度学习模型也获得了广泛关注. 文献 [128] 指出, 基于注意力机制的模型在长距离依赖关系的建模上具有显著优势, 能够有效处理大规模可再生能源发电数据. 通过动态调整各时间步的重要性, 模型能够在处理多维度、高频率的时间序列数据时, 提供更加精确的预测结果.

2.1.3 中长期推断

中长期推断通常涵盖未来 1 至 7 天甚至更长时间的预测^[106]. 这类预测对于可再生能源电厂的维护调度、年度发电计划的制定等具有重要意义. 在风电和光伏电场建设后的长期运营管理中, 准确的中长期发电预测能够为电网调度和资源优化提供关键支持. 然而, 与超短期和短期预测相比, 中长期推断因时间跨度较长、受数据时效性和样本数量的限制较大, 使其研究相对较少.

传统的中长期预测方法多依赖于统计学模型和灰色预测模型^[129]. 灰色预测模型和其扩展模型, 通过在数据不足的情况下提供可行的解决方案, 广泛应用于可再生能源的增长趋势预测^[130]. 这些模型凭借其较低的数据需求和较强的适应性, 在中长期发电预测中取得了较好的应用效果, 然而传统灰色模型在处理非线性和动态数据变化中存在局限性. 针对这些局限性, 研究者们提出了改进的灰色预测方法^[131], 例如结构自适应离散灰色预测模型^[132]和带时间变异参数的灰色模型^[133], 这些模型在提高预测精度和应对系统变化方面表现出显著优势.

随着机器学习技术的发展, 基于深度学习的中长期预测方法也逐渐崭露头角. 文献 [134] 提出基于改进的 CNN-GRU 和 Informer 网络的中长期风电功率预测模型, 通过融合时间尺度降维和多头注意力机制, 在多个时间步长内优化预测精度. 此外, 研究者提出了融合马尔科夫链修正和熵值法的组合预测模型^[135], 用于新疆地区风电的中长期发电量预测. 模型通过综合多种算法优势, 能够有效克服单一模型的局限性, 提高预测结果的可靠性和实用性.

2.2 电网状态智能推断技术

电力设备的运行安全是电网可靠运行的基础. 随着新型电力系统建设的加速, 电网运行环境逐渐呈现出高比例新能源接入、多时空尺度交互以及电力电子设备密集化等特点. 在此背景下, 传统的基于阈值告警和人工巡检的故障检测手段已难以满足复杂工况下对精准感知的需求. 近年来, 相关研究主要聚焦于异常气象、设备老化及设备缺陷等因素引发的故障检测, 以人工智能为核心的智能检测技术在设备状态评估、故障诊断和预测性维护等方面表现出显著优势^[136].

2.2.1 极端气象条件智能推断

极端气象条件对电网设备的影响是电力系统安全稳定运行中的重要挑战. 随着气候变化的加剧, 极端天气事件对电网设施的冲击逐渐增大, 尤其是在高负荷或复杂气象条件下, 可能导致设备损坏、停运及大规模电力中断. 近年来, 越来越多的研究利用深度学习技术评估和预测极端气象对电网设备的影响, 为提高电网的抗灾能力和预警能力提供了新的思路^[137].

一类方法基于人工神经网络 (Artificial neural network, ANN) 对极端气象条件下的电网状态进行建模与预测. 以警告信息作为输入, 通过分析训练样本对未知的故障信息进行推断. 传统 ANN 方法主要依赖于气象特征和历史故障数据. 如文献 [138] 针对复杂特征问题, 结合遗传算法技术来选择最佳特征, 仅选择最重要的特征提供给 ANN 分类器. 然而, ANN 方法依赖于大量高质量数据进行训练, 计算复杂度较高, 且对罕见极端天气事件的泛化能力有限^[139]. 此外, 这类方法通常忽略了时序依赖性, 难以准确捕捉气象条件的动态变化对电网状态的影响.

针对时序依赖性问题, LSTM 被广泛应用于极端气象条件下的电网状态预测. Zhang 等^[140]提出一种基于 LSTM 与 SVM 相结合的电力系统线路跳闸故障预测方法. LSTM 通过处理大量时间序列数据, 捕捉电网在极端气象条件下的长时间跨度的时序特征, 以应对由气象变化引起的电网状态波动; SVM 用于分类处理, 结合 LSTM 网络的预测结果, 为电网运维人员提供更精确的故障预警.

针对数据的非线性问题, 小波变换^[31]被广泛用于特征提取. 通过将气象数据分解为不同频率的分量, 使 LSTM 更容易捕捉短期和长期趋势的变化, 以提高模型对时序信号的解析能力^[141].

此外, 近年来, 大规模气象预测模型为极端气象条件推断提供了新的视角. 目前, 主流 AI 气象大

模型如表 3 所示.

2.2.2 电力设备退化与隐性故障检测

随着电力系统的复杂性和规模不断增加, 电力设备的退化与隐性故障检测成为保障电网安全稳定运行的关键问题. 电机轴承磨损可能导致异常振动, 影响关键设备的运行效率, 甚至引发链式故障, 影响整个电网的安全运行. 传统的故障检测方法主要依赖于阈值告警和定期巡检, 难以应对高比例新能源接入、多时空尺度交互以及电力电子设备密集化等新型电力系统特点.

近年来, 基于深度学习的智能检测技术在设备状态评估、故障诊断和预测性维护方面展现出显著优势, 尤其是在处理长时间序列数据和复杂非线性关系时表现突出. 一类模型结合 LSTM 的时序处理能力, 例如, Li 等^[142]提出的混合神经网络框架结合一维卷积神经网络和 LSTM, 成功捕获了影响电池退化的多个变量之间的分层特征, 并实现了设备剩余使用寿命的精确预测. Luo 等^[143]提出的基于卷积注意力机制的双向 LSTM, 通过卷积神经网络提取输入信号的特征信息, 并结合注意力机制赋予输入数据不同的权重, 突出有效特征, 从而在长时间序列数据中捕获关键时频信息, 进一步优化了设备寿命预测的准确性. 为提高模型的泛化能力, Zhang 等^[144]提出基于双向门控循环单元和多栅极混合专家相结合的网络结构, 能够同时评估设备健康状况并预测设备剩余使用寿命.

传统的循环神经网络在多步递归预测中存在记忆长度有限、无法并行化以及对噪声数据敏感等问题. 此外, 这类方法主要依赖时间维度的信息, 难以有效捕捉电力设备间的空间依赖性, 限制了对复杂电力系统的建模能力. 因此, 近年来, 时空图卷积的模型逐渐受到关注. 如图 10 所示, 这类模型结合空间拓扑信息进行时空建模, 通过将时间序列数据转换为空间图结构来更好地捕获空间依赖性. 例如,

Jiang 等^[145]提出的电力时空图卷积网络, 通过结合图卷积网络和注意力机制, 实现了对电力设备长时间序列数据的高效处理. 此外, 自注意力机制作为一种新兴的深度学习技术, 能够动态调整输入数据的重要性权重, 从而更精确地捕捉关键特征. 在电力设备退化预测中, 自注意力机制与时空图卷积网络的结合进一步提升了模型的性能. 在此基础上, 文献 [146] 则提出基于移动网络大数据的注意力嵌入式矢量时空图卷积网络, 通过结合图数据模型和自注意力机制, 实现了长时间序列数据的高效预测. 该模型能够有效处理大规模电力设备运行数据, 并在设备剩余使用寿命预测中表现出较高的准确性和鲁棒性.

2.3 电力荷载智能推断技术

电力荷载智能推断技术是源网荷智能化关键技术的重要组成部分, 旨在通过先进的智能算法对电力负荷进行精准预测, 从而优化电力系统的供需平衡, 提升能源利用效率. 随着新型电力系统中新能源渗透率的不断提高, 负荷预测的准确性和实时性变得尤为重要. 负荷预测可根据不同的时间尺度分为超短期、短期、中期、长期预测四类.

2.3.1 超短期荷载预测

超短期荷载预测主要关注未来分钟级、小时级的电力需求变化, 具有较高的时空分辨率要求, 对于电网的实时调度、短时负荷调整及需求响应策略至关重要^[103]. 由于电力系统的波动性和可再生能源发电的不确定性, 传统的基于物理模型和统计模型的预测方法, 常常无法满足超短期预测所需的快速响应和高精度要求. 因此, 近年来, 基于深度学习的超短期预测方法成为了研究的热点, 研究主要集中在数据优化、混合策略以及模型架构创新三大方向.

信号分解技术是处理负荷序列非平稳性、实现数据优化的重要手段. 通过结合多种信号分解方法,

表 3 AI 气象大模型
Table 3 AI-based large-scale meteorological models

模型名称	模型结构	预测时效性	空间分辨率	预测范围
FuXi ^[147]	级联机器学习天气预报系统	中期 15 d	0.25°	6 h
FengWu ^[148]	多模态多任务 Transformer	中期 10.75 d	0.25°	6 h
GraphCast ^[149]	机器学习+图形神经网络	中期 10 d	0.25°	6 h
Pangu-Weather ^[2]	3D 多尺度 Transformer	短、中期 1 h ~ 7 d	0.25°	6 h
NowcastNet ^[150]	物理约束的深度生成模型	临近 3 h	20 km	10 min
SwinVRNN ^[151]	递归神经网络+Transformer	中期	5.625 0°	6 h
FourCastNet ^[152]	自适应傅里叶算子 Transformer	短、中期	0.25°	6 h
DLWP ^[153]	卷积神经网络	短、中期	1.9°	6 h




图 10 基于图卷积的电力设备状态检测模型

Fig.10 Graph convolutional network-based model for power equipment state detection

有效抑制了高频噪声的干扰^[154]。此外,变分模态分解和其改进版本也被应用于优化分解过程,增强了模型的稳健性和适应性^[155]。这些数据优化方法通过将负荷数据在时频域进行分解,有效解决了数据中的不规则波动,并提升了预测精度。

通过协同不同模型的优势,能够有效提升系统的鲁棒性。近年来,许多研究聚焦于混合模型。例如,文献[156]基于贝叶斯优化的卷积双向长短期记忆网络(CNN-BiLSTM),通过自动化搜索优化超参数,在电网负荷突变情况下取得了显著的误差降低效果。在此基础上,针对长序列依赖问题,文献[157]提出基于注意力机制的双向长短期记忆网络模型,通过集成多头注意力机制,赋予不同时间步不同的重要性,增强了模型对负荷尖峰和周期变化的响应能力。此外,针对负荷数据的多尺度特性,文献[158]提出将集合经验模态分解与多尺度卷积模块结合,在日内负荷预测中取得了较为优异的表现。

在模型架构创新方面,多尺度建模与时空特征融合被认为是提升预测精度的关键。通过引入CNN和GRU等模型,能够分别提取空间特征和捕捉时间依赖性。如,文献[159]提出的CNN-GRU混合网络能够在多种负荷场景下显著减少误差。此外,Transformer架构的引入进一步提升了时序建模的全局能力,能够在缺乏气象数据的情况下仍维持较高的预测精度^[160]。

2.3.2 短期荷载预测

短期荷载预测是优化电力系统调度、提升能源利用效率的核心技术,其核心挑战在于负荷序列的高波动性和用户行为的时空异质性。随着智能电表的普及和居民用电模式的多样化,传统基于统计或浅层机器学习的方法在处理个体用户负荷的复杂非线性特征时面临着精度不足的瓶颈。近年来,深度学习技术通过多层次特征提取和时空依赖建模,为短期荷载预测提供了新的突破方向。

Kong等^[161]通过LSTM编码用户历史用电序列的时序模式,结合日期、假日等外部特征,显著提

升了单用户负荷的预测精度。相较于传统反向传播神经网络,LSTM在捕捉用户日常行为规律方面展现出更强的鲁棒性,尤其是对具有周期性消费模式的用户,预测误差显著降低。然而,单一LSTM模型对跨用户的空间关联性缺乏建模能力,难以利用邻近用户负荷的潜在协同特征。

针对以上不足,图神经网络^[74]为空间建模提供了新的方向。如,Lin等^[162]提出的利用自适应图模型构建动态邻接矩阵,以节点嵌入技术自学习用户间的隐含关联强度。通过图卷积层聚合邻近用户的负荷特征,并结合扩张时序卷积提取多尺度时间模式,该模型在个体与聚合负荷预测中均实现显著提升。自适应邻接矩阵能够识别非地理关联用户的消费相似性。此类方法通过时空特征的协同优化,为高比例新能源接入下的负荷预测提供了新的范式。

针对多能源耦合与复杂时空关联问题,基于Transformer的架构通过自注意力机制能够实现全局时序依赖建模。Wang等^[163]提出的多解码器Transformer模型,采用一编码器-多解码器结构,将电力、冷热负荷的联合预测转化为多任务学习问题。编码器通过多头注意力提取多能源负荷的耦合特征,任务特定的解码器则结合外部注意力动态调整特征权重,从而在统一框架下实现不同能源负荷的精准预测。此类方法在系统级聚合负荷预测中表现优异,但对个体用户负荷的细粒度波动捕捉仍存在局限性。为进一步优化特征表示,Xiao等^[164]提出双向注意力机制,利用自注意力机制识别用户负荷序列内部的关键时段,而外部注意力则通过线性变换层学习不同用户负荷间的隐含关联。结合时序卷积网络的扩张因果卷积,该模型在保留长期历史信息的同时,通过注意力权重细化基线负荷曲线,显著降低了峰值负荷的预测误差。

2.3.3 中期荷载预测

中期荷载预测以数周至数月为时间跨度,需兼顾负荷趋势的稳定性与波动性特征,其预测结果对电力系统机组检修计划制定、燃料调度及中长期市

场交易具有重要指导意义. 然而, 中期负荷预测受温度敏感性降低、节假日用户行为变化等多因素耦合影响, 多源异构数据的时空尺度差异加剧了特征工程的复杂性. 针对上述问题, 研究者对多尺度及混合建模展开系统性研究.

LSTM 能够有效捕捉负荷数据的时间依赖性和长期趋势, 被广泛用于中期负荷预测. 然而, LSTM 存在对长期依赖关系的建模能力受限、对非周期性负荷波动的适应性较差以及对外部影响因素的刻画能力不足等局限. 针对这些问题, 研究者提出了多种改进策略. 如, 文献 [165] 提出一种双向 LSTM 混合模型, 使用随机森林和皮尔逊相关系数来选择特征, 结合前向 LSTM 和后向 LSTM 来提取语义特征, 实现长期依赖性捕捉; 为有效地提取深度特征和过滤噪声, 文献 [166] 提出一种基于多任务学习、卷积神经网络和 LSTM 的深度学习框架, 通过权衡主任务和辅助任务的相关训练数据, 所提出的混合深度学习网络模型解决了重复数据过多和卷积效果差的问题, 显著增强了模型的泛化性.

针对多尺度数据融合问题, Transformer 模型为中期荷载预测提供一种新的解决方案. 由于其自注意力机制能够捕捉长时间跨度的依赖关系, Transformer 在学习多尺度特征、建模复杂时序模式方面具有优势. 例如, 文献 [167] 提出一种结合 Transformer 和轻量级梯度提升决策树方法的功耗预测框架, 相较于 LSTM 方法实现了更准确的预测.

2.3.4 长期荷载预测

长期荷载预测通常针对未来一年至数年的电力需求趋势, 其预测结果对电网规划、发电机组容量配置及能源政策制定具有战略指导意义. 然而, 由于长期预测涉及复杂的社会经济变量、气候条件演变及能源结构调整等非线性因素, 所以传统人工神经网络在模型架构与训练方法上的局限性逐渐凸显, 为此研究者针对一系列改进方法进行了研究.

针对单一 ANN 模型仍面临梯度消失与局部最优问题, 难以充分表征长期预测中的多因素耦合效应, 混合模型通过集成多算法优势实现预测性能跃升. 自适应神经模糊推理系统将模糊逻辑与 ANN 结合, 通过模糊规则库量化社会经济变量与历史负荷的隐性关联, 其模糊推理层可有效处理长期预测中的不确定性^[168]. 支持向量机与粒子群优化的协同框架则通过核函数空间映射与参数全局寻优, 在降低预测方差的同时提高对长期趋势拐点的识别精度^[169]. 此外, 多元自适应回归模型凭借分段线性基函数的自适应组合, 在计算效率与预测稳定性方面展现出超越 ANN 与线性回归的综合优势^[170].

随着深度学习技术的突破, 基于深度神经网络的长期预测方法展现出更强的时序建模能力. 深度递归神经网络通过引入跨时间步的残差连接, 解决了传统 RNN 在长序列训练中的梯度衰减问题, 其堆叠式结构可逐层提取负荷数据的多尺度时空特征^[171]. LSTM 及其变体通过门控机制选择性记忆长期依赖关系, 结合注意力机制动态聚焦关键时间片段, 显著提升了模型对负荷周期性与趋势性成分的分隔能力^[172].

此外, 新兴方法基于 Transformer 的预测框架则利用自注意力机制建立全局时间依赖关系, 通过位置编码保留序列时序信息, 在超长期预测任务中表现出优异的抗噪声能力与计算并行性^[173]. 当前研究趋势表明, 长期荷载预测正朝着多模态数据融合、物理信息嵌入及元学习自适应方向演进, 以应对碳中和目标下能源结构转型带来的新型挑战.

3 源网荷智能化应用场景

随着“双碳”战略的深入推进, 智能化时空协同推断技术在能源系统各环节的应用场景持续拓展. 该技术通过多源数据融合与智能算法赋能, 在电力系统源网荷协同优化、分布式能源管理、需求侧响应等领域形成典型应用范式, 为构建新型电力系统提供关键技术支撑.

在此背景下, 深圳供电局推出了电力行业首个多模态预训练大模型——“祝融 2.0”. 该模型分别利用图像模型和语言模型, 将图像特征和文字特征提取后进行融合, 效果比传统图像单模态模型更好. 语言模型的加入使图像模型有了逻辑推理能力, 从而提高了判断的准确率. 通过融合海量的电力领域数据, 包括文本、图像、视频、语音、时序及网络拓扑信息, 赋予传统电网智能系统逻辑推理与自然语言表达能力. 借助“祝融 2.0”, 电力巡检系统不仅能够自动进行现场监测、数据记录、异常分析和预警, 而且具备了深入理解、推理和表达故障信息的能力, 使得电网安全隐患告警效率及识别准确率大幅提升.

在气象预测方面, 阿里巴巴达摩院发布“八观”气象大模型, 以自主研发的全球气象大模型为基础, 集成数学物理建模、时间序列预测与可解释性人工智能技术, 进一步开发出区域级高精度预报系统. 该系统融合了地面观测站数据、雷达与卫星影像、实时气象实况及开源地形信息等多源多模态输入, 以提升空间分辨率与预报精度, 支持逐小时网格化更新. 此外, 结合孪生网络与掩蔽自编码器来初始化模型参数, 使其能够在高波动性气象数据中学习

到更鲁棒的特征表示, 从而实现对复杂天气过程的精准模拟与预测. 其对温度、辐照、风速等关键气象指标预测性能实现大幅提升, 已在新能源比例较高的新型电力系统中率先落地. 该模型为电力调控提供了强有力的气象数据支撑, 多次有效预测极端天气事件, 确保了新能源发电功率与电力负荷的高精度预测. 这一成果不仅显著提高了电网运行调控的前瞻性与稳定性, 还为智能化调控方案的优化提供了数据依据.

在智能电网方面, 国家电网发布了“光明”电力大模型, 这一千亿级多模态行业大模型已在电网规划、运维、运行等多个领域取得突破性进展. 在电网规划中, 该大模型对 Transformer 基础架构进行优化, 增加了电力跨模态适配层, 通过特征向量化进行特征对齐. 在此基础上, 改进了混合注意力机制, 进一步对不同模态数据进行深度关联建模, 能够基于历史与实时气象、负荷和设备数据, 精准诊断过载风险, 优化网架结构, 辅助决策人员快速制定改进方案. 在电网运维方面, 通过对关键设备的状态数据和故障案例的深度学习, 实现设备“智慧体检”, 自动生成设备健康评估报告, 缩短评估周期, 提高运维效率. 南方电网推出的“大瓦特”电力大模型, 基于自主研发的算力芯片与训练框架从零构建, 现已在 80 余个典型场景中实现部署. 该模型支持聊天交互、信息查询与文本生成等多种功能. 在实际应用中, “大瓦特”显著提升了广西电网输电线路缺陷识别效率, 有效减轻了基层人员负担, 并推动负荷预测与巡检工作的深度智能化转型.

此外, 南方电网构建的 XS-1000D^[174] 抽水蓄能人工智能数据分析平台, 推动了抽水蓄能电站智能化运维模式创新. XS-1000D 平台集成了实时监控、数据治理、故障诊断和预测分析等功能, 融合水轮发电机组、变压器、调速系统等关键设备的振动、温度、电流等多源异构数据, 通过深度学习模型与智能推理引擎, 实现了设备状态的实时评估与异常趋势预测. 平台支持对抽水蓄能电站的充放电行为进行智能优化调度, 提升了电站辅助新能源消纳和电网调频调峰的响应效率, 为构建以新能源为主体的新型电力系统提供了有力支撑.

4 源网荷智能化技术发展趋势及挑战

随着能源结构向低碳化、智能化转型, 源网荷一体化协同优化成为新型电力系统的重要发展方向. 智能化推断技术依托人工智能、机器学习、大数据分析等手段, 对可再生能源发电特性、电网运行状态以及负荷特征进行精准推断, 实现源、网、荷之间的高效协同与优化配置. 在源侧, 可再生能源智能推断技术通过深度学习、统计建模等方法提高风光出力预测精度, 优化电源调度; 在网侧, 基于智能感知的电网状态推断技术可实时识别电网运行异常, 提高系统的安全性和韧性; 在负荷侧, 电力需求智能推断技术可优化负荷调控策略, 提升需求响应的精准度. 当前, 大数据、大模型等新兴技术快速发展, 以注意力机制为基础的时序大模型成为新一轮浪潮, 为源网荷智能化推断提供了新的契机. 未来源网荷智能化如图 11 所示.




图 11 未来源网荷智能化系统

Fig. 11 Future source-grid-load intelligent system

1) 多模态数据融合与智能推断优化. 源网荷系统涉及多种数据类型, 包括时间序列数据、图像监测数据、文本运维记录等, 这些数据在空间、时间及模态上存在异质性. 多模态数据融合技术通过深度特征提取、跨模态对齐及注意力机制优化, 实现不同数据源的协同推断, 提升智能化分析的全面性和精准度. 未来, 探索高效的多模态数据融合架构, 提升跨模态学习能力与数据质量感知能力, 将是智能化推断技术的重要研究方向.

2) 多时空、多尺度协同建模与模型优化. 源网荷系统中的数据呈现出复杂的时空分布和多能源耦合特性, 既包含瞬时波动又蕴含长期趋势. 这对时序推断模型提出了更高要求, 即, 如何在保证局部特征提取的同时捕捉全局关联, 并在不同时间、空间尺度及能源种类之间实现有效融合. 未来的发展趋势在于构建能够自适应调整输入数据预处理与特征抽取策略的多时空、多尺度模型架构, 通过优化模型结构、参数等, 使模型在面对多样化、异质性数据时仍能保持较高的鲁棒性和泛化能力.

3) 预训练大模型驱动的智能推断. 预训练大模型以大规模数据驱动的方式, 在时序预测、异常检测及优化控制等任务中展现出强大的泛化能力和迁移能力. 基于注意力机制的特征学习能力, 预训练大模型能够在复杂的源网荷电力场景中高效挖掘各环节的时序规律, 提高推断的精准度和适应性; 克服了数据驱动模型对特定场景和任务的依赖性, 使模型能够适应不同区域、不同时间尺度的电力系统变化. 有效构建大规模预训练模型体系, 提升跨模态数据融合、计算效率优化及模型可解释性, 将是未来源网荷智能化推断技术的重要发展方向.

4) 预训练模型应用挑战与优化方向. 面向电力系统特殊需求, 预训练模型应用需突破数据安全、物理规律嵌入不足以及多模态协同三方面技术瓶颈. 在数据安全维度, 可发展跨机构隐私计算框架成为保障电网敏感信息安全的前提; 在物理规律融合层面, 将可微分物理引擎集成至神经网络可确保推断结果符合能量守恒与潮流平衡约束; 针对多模态协同挑战, 可建立跨模态特征对齐机制弥合数值信号与文本记录间的语义鸿沟, 并通过生成-判别联合训练增强极端工况建模能力. 与此同时, 轻量化模型蒸馏与边缘计算技术的创新将成为解决现场资源约束的关键突破点.

5 结束语

随着“双碳”战略和低碳经济转型的深入推进, 能源系统正加速向多能源融合、源网荷储一体化协

同优化方向发展. 智能化数据推断技术, 依托深度学习、机器学习和大数据分析, 已在提升电力系统调度灵活性、优化资源配置和降低运营成本等方面展现出重要价值. 本文围绕源网荷场景下的智能化推断展开分析, 综述了多时空尺度数据驱动推断领域的研究进展, 重点探讨了源网荷背景下智能推断的关键方案, 结合典型应用案例, 总结了当前面临的挑战, 并展望了未来发展方向.

目前, 数据驱动的智能化推断技术在电力系统各环节已取得初步应用成果, 如基于多源数据的负荷预测、光伏功率推断、配电网运行状态评估等, 初步验证了在提升系统运行智能性方面的潜力. 然而, 实际应用中仍存在极端工况样本稀缺、大规模推断模型训练数据不足、模型在复杂环境下泛化性能不稳等问题, 制约了智能推断技术的进一步推广与落地.

未来, 面向源网荷协同场景, 需进一步突破多模态数据高效融合、跨模态知识迁移及多尺度建模等关键技术, 构建自适应异构时序数据特征重要性与相关性的融合框架. 通过引入领域自适应、对抗训练或元学习策略, 在大规模历史运行数据上预训练的深度模型参数高效迁移至现场工况, 并通过小样本微调实现对极端运行条件的快速适应, 提升推断系统在复杂环境下的适应性和准确性, 将成为智能化数据协同推断技术的重要发展方向.

References

- 1 Elkin C, Witherspoon S. Machine learning can boost the value of wind energy [Online], available: <https://deepmind.google/discover/blog/machine-learning-can-boost-the-value-of-wind-energy/>, July 10, 2025
- 2 Bi K F, Xie L X, Zhang H H, Chen X, Gu X T, Tian Q. Pangu-Weather: A 3D high-resolution model for fast and accurate global weather forecast. arXiv preprint arXiv: 2211.02556, 2022.
- 3 Wen G H, Hu G Q, Hu J Q, Shi X L, Chen G R. Frequency regulation of source-grid-load systems: A compound control strategy. *IEEE Transactions on Industrial Informatics*, 2016, 12(1): 69-78
- 4 Wen G H, Yu X H, Liu Z W, Yu W W. Adaptive consensus-based robust strategy for economic dispatch of smart grids subject to communication uncertainties. *IEEE Transactions on Industrial Informatics*, 2018, 14(6): 2484-2496
- 5 Rangapuram S S, Seeger M, Gasthaus J, Stella L, Wang Y Y, Januschowski T. Deep state space models for time series forecasting. In: Proceedings of the 32nd International Conference on Neural Information Processing Systems. Montréal, Canada: Curran Associates Inc., 2018. 7796-7805
- 6 Li S Y, Jin X Y, Xuan Y, Zhou X Y, Chen W H, Wang Y X, et al. Enhancing the locality and breaking the memory bottleneck of Transformer on time series forecasting. In: Proceedings of the 33rd International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates

- Inc., 2019. Article No. 471
- 7 Bai S J, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. arXiv preprint arXiv: 1803.01271, 2018.
- 8 Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, et al. Attention is all you need. In: Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, USA: Curran Associates Inc., 2017. 6000–6010
- 9 Wang Y X, Wu H X, Dong J X, Liu Y, Long M S, Wang J M. Deep time series models: A comprehensive survey and benchmark. arXiv preprint arXiv: 2407.13278, 2024.
- 10 Wen Q S, Gao J K, Song X M, Sun L, Xu H, Zhu S H. RobustSTL: A robust seasonal-trend decomposition algorithm for long time series. In: Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Honolulu, USA: AAAI, 2019. 5409–5416
- 11 Wu H X, Xu J H, Wang J M, Long M S. Autoformer: Decomposition Transformers with auto-correlation for long-term series forecasting. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. Virtual Event: Curran Associates Inc., 2021. Article No. 1717
- 12 Zhang Y H, Yan J C. Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
- 13 Cao D F, Jia F R, Arik S O, Pfister T, Zheng Y X, Ye W, et al. TEMPO: Prompt-based generative pre-trained Transformer for time series forecasting. In: Proceedings of the 12th International Conference on Learning Representations. Vienna, Austria: ICLR, 2024.
- 14 Du D Z, Su B, Wei Z W. Preformer: Predictive Transformer with multi-scale segment-wise correlations for long-term time series forecasting. In: Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Rhodes Island, Greece: IEEE, 2023. 1–5
- 15 Bandara K, Hyndman R J, Bergmeir C. MSTL: A seasonal-trend decomposition algorithm for time series with multiple seasonal patterns. *International Journal of Operational Research*, 2025, **52**(1): 79–98
- 16 Oreshkin B N, Carpov D, Chapados N, Bengio Y. N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. In: Proceedings of the 8th International Conference on Learning Representations. Addis Ababa, Ethiopia: ICLR, 2020.
- 17 Challu C, Olivares K G, Oreshkin B N, Ramirez F G, Canseco M M, Dubrawski A. NHITS: Neural hierarchical interpolation for time series forecasting. In: Proceedings of the 37th AAAI Conference on Artificial Intelligence. Washington, USA: AAAI, 2023. 6989–6997
- 18 Fan W, Zheng S, Yi X H, Cao W, Fu Y J, Bian J, et al. DEPTS: Deep expansion learning for periodic time series forecasting. In: Proceedings of the 10th International Conference on Learning Representations. Virtual Event: ICLR, 2022.
- 19 Xiong L, Chen X, Huang T K, Schneider J, Carbonell J G. Temporal collaborative filtering with Bayesian probabilistic tensor factorization. In: Proceedings of the 10th SIAM International Conference on Data Mining. Columbus, USA: SIAM, 2010. 211–222
- 20 Yu H F, Rao N, Dhillon I S. Temporal regularized matrix factorization for high-dimensional time series prediction. In: Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona, Spain: Curran Associates Inc., 2016. 847–855
- 21 Takeuchi K, Kashima H, Ueda N. Autoregressive tensor factorization for spatio-temporal predictions. In: Proceedings of the IEEE International Conference on Data Mining (ICDM). New Orleans, USA: IEEE, 2017. 1105–1110
- 22 Chen X Y, Zhang C Y, Zhao X L, Saunier N, Sun L J. Non-stationary temporal matrix factorization for multivariate time series forecasting. arXiv preprint arXiv: 2203.10651, 2022.
- 23 Chen X Y, Sun L J. Bayesian temporal factorization for multidimensional time series prediction. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, **44**(9): 4659–4673
- 24 Sen R, Yu H F, Dhillon I. Think globally, act locally: A deep neural network approach to high-dimensional time series forecasting. In: Proceedings of the 33rd International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2019. Article No. 435
- 25 Kawabata K, Bhatia S, Liu R, Wadhwa M, Hooi B. SSMF: Shifting seasonal matrix factorization. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. Virtual Event: Curran Associates Inc., 2021. Article No. 295
- 26 Cui X L, Shi L, Zhong W, Zou C L. Robust high-dimensional low-rank matrix estimation: Optimal rate and data-adaptive tuning. *The Journal of Machine Learning Research*, 2023, **24**(1): Article No. 350
- 27 Luan Z T, Sun D F, Wang H N, Zhang L P. Efficient online prediction for high-dimensional time series via joint tensor tucker decomposition. arXiv preprint arXiv: 2403.18320, 2024.
- 28 Sneddon I N. *Fourier Transforms*. New York: Dover Publications, 1995.
- 29 Xu Z J, Zeng A L, Xu Q. FITS: Modeling time series with 10k parameters. In: Proceedings of the 12th International Conference on Learning Representations. Vienna, Austria: ICLR, 2024.
- 30 Zhou T, Ma Z Q, Wen Q S, Wang X, Sun L, Jin R. FEDformer: Frequency enhanced decomposed Transformer for long-term series forecasting. In: Proceedings of the 39th International Conference on Machine Learning. Baltimore, USA: PMLR, 2022. 27268–27286
- 31 Farge M. Wavelet Transforms and their applications to turbulence. *Annual Review of Fluid Mechanics*, 1992, **24**: 395–458
- 32 Liu M H, Zeng A L, Chen M X, Xu Z J, Lai Q X, Ma L N, et al. SCINet: Time series modeling and forecasting with sample convolution and interaction. In: Proceedings of the 36th International Conference on Neural Information Processing Systems. New Orleans, USA: Curran Associates Inc., 2022. Article No. 421
- 33 Wu Z H, Huang N E. Ensemble empirical mode decomposition: A noise-assisted data analysis method. *Advances in Adaptive Data Analysis*, 2009, **1**(1): 1–41
- 34 Dragomiretskiy K, Zosso D. Variational mode decomposition. *IEEE Transactions on Signal Processing*, 2014, **62**(3): 531–544
- 35 Zhou T, Ma Z Q, Wang X, Wen Q S, Sun L, Yao T, et al. FiLM: Frequency improved Legendre memory model for long-term time series forecasting. In: Proceedings of the 36th International Conference on Neural Information Processing Systems. New Orleans, USA: Curran Associates Inc., 2022. Article No. 921

- 36 Yang Z J, Yan W W, Huang X L, Mei L. Adaptive temporal-frequency network for time-series forecasting. *IEEE Transactions on Knowledge and Data Engineering*, 2022, **34**(4): 1576–1587
- 37 Zhang C L, Zhou T, Wen Q S, Sun L. TFAD: A decomposition time series anomaly detection architecture with time-frequency analysis. In: Proceedings of the 31st ACM International Conference on Information & Knowledge Management. Atlanta, USA: ACM, 2022. 2497–2507
- 38 Yao S C, Piao A L, Jiang W J, Zhao Y R, Shao H J, Liu S Z, et al. STFNet: Learning sensing signals from the time-frequency perspective with short-time Fourier neural networks. In: Proceedings of the World Wide Web Conference. San Francisco, USA: ACM, 2019. 2192–2202
- 39 Cao D F, Wang Y J, Duan J Y, Zhang C, Zhu X, Huang C, et al. Spectral temporal graph neural network for multivariate time-series forecasting. In: Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2020. Article No. 1491
- 40 Yi K, Zhang Q, Fan W, Wang S J, Wang P Y, He H, et al. Frequency-domain MLPs are more effective learners in time series forecasting. In: Proceedings of the 37th International Conference on Neural Information Processing Systems. New Orleans, USA: Curran Associates Inc., 2023. Article No. 3349
- 41 Wang Z X, Pei C H, Ma M H, Wang X, Li Z H, Pei D, et al. Revisiting VAE for unsupervised time series anomaly detection: A frequency perspective. In: Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024. 3096–3105
- 42 Eldele E, Ragab M, Chen Z H, Wu M, Li X L. TSLANet: Rethinking Transformers for time series representation learning. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 494
- 43 Xu T, Wang R J, Meng H, Li M C, Ji Y, Zhang Y, et al. Grid frequency regulation through virtual power plant of integrated energy systems with energy storage. *IET Renewable Power Generation*, 2024, **18**(14): 2277–2293
- 44 Xing C, Xi X Z, He X, Deng C, Zhang M Q. Collaborative source-grid-load frequency regulation strategy for DC sending-end power grid considering electrolytic aluminum participation. *Frontiers in Energy Research*, 2024, **12**: Article No. 1486319
- 45 Box G E P, Jenkins G M, Reinsel G C, Ljung G M. *Time Series Analysis: Forecasting and Control (Fifth Edition)*. Hoboken: John Wiley & Sons, 2015.
- 46 Qin Y, Song D J, Chen H F, Cheng W, Jiang G F, Cottrell G W. A dual-stage attention-based recurrent neural network for time series prediction. In: Proceedings of the 26th International Joint Conference on Artificial Intelligence. Melbourne, Australia: IJCAI, 2017. 2627–2633
- 47 Tayal K, Renganathan A, Jia X W, Kumar V, Lu D. ExoTST: Exogenous-aware temporal sequence Transformer for time series prediction. In: Proceedings of the IEEE International Conference on Data Mining (ICDM). Abu Dhabi, United Arab Emirates: IEEE, 2024. 857–862
- 48 Wang Y X, Wu H X, Dong J X, Qin G, Zhang H R, Liu Y, et al. TimeXer: Empowering Transformers for time series forecasting with exogenous variables. In: Proceedings of the 38th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2025. Article No. 15
- 49 Xu Z J, Bian Y X, Zhong J Y, Wen X Y, Xu Q. Beyond trend and periodicity: Guiding time series forecasting with textual cues. arXiv preprint arXiv: 2405.13522, 2024.
- 50 Lu J C, Han X, Sun Y, Yang S H. CATS: Enhancing multivariate time series forecasting by constructing auxiliary time series as exogenous variables. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 1339
- 51 Zhu J W, Wang Q J, Tao C, Deng H H, Zhao L, Li H F. AST-GCN: Attribute-augmented spatiotemporal graph convolutional network for traffic forecasting. *IEEE Access*, 2021, **9**: 35973–35983
- 52 O' Donncha F, Hu Y H, Palmes P, Burke M, Filgueira R, Grant J. A spatio-temporal LSTM model to forecast across multiple temporal and spatial scales. *Ecological Informatics*, 2022, **69**: Article No. 101687
- 53 Miraki A, Parviainen P, Arghandeh R. Electricity demand forecasting at distribution and household levels using explainable causal graph neural network. *Energy and AI*, 2024, **16**: Article No. 100368
- 54 Wang Q P, Feng S B, Han M. Causal graph convolution neural differential equation for spatio-temporal time series prediction. *Applied Intelligence*, 2025, **55**(7): Article No. 671
- 55 Yang K Y, Shi F H. Medium-and long-term load forecasting for power plants based on causal inference and Informer. *Applied Sciences*, 2023, **13**(13): Article No. 7696
- 56 Elman J L. Finding structure in time. *Cognitive Science*, 1990, **14**(2): 179–211
- 57 Yin W P, Kann K, Yu M, Schütze H. Comparative study of CNN and RNN for natural language processing. arXiv preprint arXiv: 1702.01923, 2017.
- 58 Purwins H, Li B, Virtanen T, Schlüter J, Chang S Y, Sainath T. Deep learning for audio signal processing. *IEEE Journal of Selected Topics in Signal Processing*, 2019, **13**(2): 206–219
- 59 Wen R F, Torkkola K, Narayanaswamy B, Madeka D. A multi-horizon quantile recurrent forecaster. arXiv preprint arXiv: 1711.11053, 2017.
- 60 Hochreiter S, Schmidhuber J. Long short-term memory. *Neural Computation*, 1997, **9**(8): 1735–1780
- 61 Chung J, Gulcehre C, Cho K, Bengio Y. Empirical evaluation of gated recurrent neural networks on sequence modeling. arXiv preprint arXiv: 1412.3555, 2014.
- 62 Salinas D, Flunkert V, Gasthaus J, Januschowski T. DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 2020, **36**(3): 1181–1191
- 63 Lai G K, Chang W C, Yang Y M, Liu H X. Modeling long-and short-term temporal patterns with deep neural networks. In: Proceedings of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. Ann Arbor, USA: ACM, 2018. 95–104
- 64 LeCun Y, Bengio Y, Hinton G. Deep learning. *Nature*, 2015, **521**(7553): 436–444
- 65 Tan M X, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks. In: Proceedings of the 36th International Conference on Machine Learning. Long Beach, USA: PMLR, 2019. 6105–6114
- 66 Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

- Boston, USA: IEEE, 2015. 3431–3440
- 67 Ding M Y, Huo Y Q, Yi H W, Wang Z, Shi J P, Lu Z W, et al. Learning depth-guided convolutions for monocular 3D object detection. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA: IEEE, 2020. 11669–11678
 - 68 Liu C L, Hsiao W H, Tu Y C. Time series classification with multivariate convolutional neural network. *IEEE Transactions on Industrial Electronics*, 2019, **66**(6): 4788–4797
 - 69 Lea C, Vidal R, Reiter A, Hager G D. Temporal convolutional networks: A unified approach to action segmentation. In: Proceedings of the 14th European Conference on Computer Vision. Amsterdam, The Netherlands: Springer, 2016. 47–54
 - 70 Wang H Q, Peng J, Huang F H, Wang J C, Chen J H, Xiao Y F. MICN: Multi-scale local and global context modeling for long-term series forecasting. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
 - 71 Luo D H, Wang X. ModernTCN: A modern pure convolution structure for general time series analysis. In: Proceedings of the 12th International Conference on Learning Representations. Vienna, Austria: ICLR, 2024.
 - 72 Wu H X, Hu T G, Liu Y, Zhou H, Wang J M, Long M S. TimesNet: Temporal 2D-variation modeling for general time series analysis. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
 - 73 NematiRad R, Pahwa A, Natarajan B. Times2D: Multi-period decomposition and derivative mapping for general time series forecasting. In: Proceedings of the 39th AAAI Conference on Artificial Intelligence. Philadelphia, USA: AAAI, 2025. 19651–19658
 - 74 Scarselli F, Gori M, Tsoi A C, Hagenbuchner M, Monfardini G. The graph neural network model. *IEEE Transactions on Neural Networks*, 2009, **20**(1): 61–80
 - 75 Li Y G, Yu R, Shahabi C, Liu Y. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In: Proceedings of the 6th International Conference on Learning Representations. Vancouver, Canada: ICLR, 2018.
 - 76 Yu B, Yin H T, Zhu Z X. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. In: Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm, Sweden: IJCAI, 2018. 3634–3640
 - 77 Wu Z H, Pan S R, Long G D, Jiang J, Zhang C Q. Graph WaveNet for deep spatial-temporal graph modeling. In: Proceedings of the 28th International Joint Conference on Artificial Intelligence. Macao, China: IJCAI, 2019. 1907–1913
 - 78 Bai L, Yao L N, Li C, Wang X Z, Wang C. Adaptive graph convolutional recurrent network for traffic forecasting. In: Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2020. Article No. 1494
 - 79 Liu S, Ji H, Wang M C. Nonpooling convolutional neural network forecasting for seasonal time series with trends. *IEEE Transactions on Neural Networks and Learning Systems*, 2020, **31**(8): 2879–2888
 - 80 Wang Z G, Yan W Z, Oates T. Time series classification from scratch with deep neural networks: A strong baseline. In: Proceedings of the International Joint Conference on Neural Networks (IJCNN). Anchorage, USA: IEEE, 2017. 1578–1585
 - 81 Gao J K, Song X M, Wen Q S, Wang P C, Sun L, Xu H. RobustTAD: Robust time series anomaly detection via decomposition and convolutional neural networks. arXiv preprint arXiv: 2002.09545, 2020.
 - 82 Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X H, Unterthiner T, et al. An image is worth 16×16 words: Transformers for image recognition at scale. In: Proceedings of the 9th International Conference on Learning Representations. Virtual Event: ICLR, 2021.
 - 83 Radford A, Wu J, Child R, Luan D, Amodei D, Sutskever I, et al. Language models are unsupervised multitask learners. *OpenAI Blog*, 2019, **1**(8): Article No. 9
 - 84 Drouin A, Marcotte É, Chapados N. TACTiS: Transformer-attentional copulas for time series. In: Proceedings of the 39th International Conference on Machine Learning. Baltimore, USA: PMLR, 2022. 5447–5493
 - 85 Das A, Kong W, Leach A, Mathur S, Sen R, Yu R. Long-term forecasting with TiDE: Time-series dense encoder. arXiv preprint arXiv: 2304.08424, 2024.
 - 86 Liu S Z, Yu H, Liao C, Li J G, Lin W Y, Liu A X, et al. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting. In: Proceedings of the 10th International Conference on Learning Representations. Virtual Event: ICLR, 2022.
 - 87 Zhou H Y, Zhang S H, Peng J Q, Zhang S, Li J X, Xiong H, et al. Informer: Beyond efficient Transformer for long sequence time-series forecasting. In: Proceedings of the 35th AAAI Conference on Artificial Intelligence. Virtual Event: AAAI, 2021. 11106–11115
 - 88 Deng Wen-Li. Research on Travel Time Prediction Method Based on Improved Multi-head Attention Transformer [Master thesis], Harbin Institute of Technology, China, 2023. (邓文丽. 基于改进多头注意力 Transformer 的行程时间预测方法研究 [硕士学位论文], 哈尔滨工业大学, 中国, 2023.)
 - 89 Liang Y X, Wen H M, Nie Y Q, Jiang Y S, Jin M, Song D J, et al. Foundation models for time series analysis: A tutorial and survey. In: Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Barcelona, Spain: ACM, 2024. 6555–6565
 - 90 Nie Y Q, Nguyen N H, Sinthong P, Kalagnanam J. A time series is worth 64 words: Long-term forecasting with Transformers. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
 - 91 Woo G, Liu C H, Kumar A, Xiong C M, Savarese S, Sahoo D. Unified training of universal time series forecasting Transformers. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 2178
 - 92 Goswami M, Szafer K, Choudhry A, Cai Y F, Li S, Dubrawski A. MOMENT: A family of open time-series foundation models. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 642
 - 93 Liu Y, Hu T G, Zhang H R, Wu H X, Wang S Y, Ma L T, et al. iTransformer: Inverted Transformers are effective for time series forecasting. In: Proceedings of the 12th International Conference on Learning Representations. Vienna, Austria: ICLR, 2024.
 - 94 Zhong S R, Ruan W L, Jin M, Li H, Wen Q S, Liang Y X. Time-VLM: Exploring multimodal vision-language models for augmented time series forecasting. arXiv preprint arXiv:

- 2502.04395, 2025.
- 95 Tay Y, Dehghani M, Bahri D, Metzler D. Efficient Transformers: A survey. *ACM Computing Surveys*, 2022, **55**(6): Article No. 109
 - 96 Radford A, Narasimhan K, Salimans T, Sutskever I. Improving Language Understanding by Generative Pre-Training, Technical Report, OpenAI, USA, 2018.
 - 97 Das A, Kong W, Sen R, Zhou Y. A decoder-only foundation model for time-series forecasting. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 404
 - 98 Liu Y, Zhang H R, Li C Y, Huang X D, Wang J M, Long M S. Timer: Generative pre-trained Transformers are large time series models. In: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. Article No. 1313
 - 99 Liu Y, Qin G, Huang X D, Wang J M, Long M S. Timer-XL: Long-context Transformers for unified time series forecasting. In: Proceedings of the 13th International Conference on Learning Representations. Singapore: ICLR, 2025.
 - 100 Xue H, Salim F D. PromptCast: A new prompt-based learning paradigm for time series forecasting. *IEEE Transactions on Knowledge and Data Engineering*, 2024, **36**(11): 6851–6864
 - 101 Zhou T, Niu P S, Wang X, Sun L, Jin R. One fits all: Power general time series analysis by pretrained LM. In: Proceedings of the 37th International Conference on Neural Information Processing Systems. New Orleans, USA: Curran Associates Inc., 2023. Article No. 1877
 - 102 Tan M T, Merrill M A, Gupta V, Althoff T, Hartvigsen T. Are language models actually useful for time series forecasting? In: Proceedings of the 38th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2025. Article No. 1922
 - 103 Liu Y, Qin G, Huang X D, Wang J M, Long M S. AutoTimes: Autoregressive time series forecasters via large language models. In: Proceedings of the 38th International Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2025. Article No. 3882
 - 104 National Energy Administration. 2024 National electric power industry statistics [Online], available: <https://www.nea.gov.cn/20250121/097bfd7c1cd3498897639857d86d5dac/c.html>, July 10, 2025
(国家能源局. 2024 年全国电力工业统计数据 [Online], available: <https://www.nea.gov.cn/20250121/097bfd7c1cd3498897639857d86d5dac/c.html>, 2025-07-10)
 - 105 Raza M Q, Nadarajah M, Ekanayake C. On recent advances in PV output power forecast. *Solar Energy*, 2016, **136**: 125–144
 - 106 Rajagukguk R A, Ramadhan R A A, Lee H J. A review on deep learning models for forecasting time series data of solar irradiance and photovoltaic power. *Energies*, 2020, **13**(24): Article No. 6623
 - 107 Tsai W C, Hong C M, Tu C S, Lin W M, Chen C H. A review of modern wind power generation forecasting technologies. *Sustainability*, 2023, **15**(14): Article No. 10757
 - 108 Dai X R, Liu G P, Hu W S. An online-learning-enabled self-attention-based model for ultra-short-term wind power forecasting. *Energy*, 2023, **272**: Article No. 127173
 - 109 Wu Q Y, Guan F, Lv C, Huang Y Z. Ultra-short-term multi-step wind power forecasting based on CNN-LSTM. *IET Renewable Power Generation*, 2021, **15**(5): 1019–1029
 - 110 Xiang L, Liu J N, Yang X, Hu A J, Su H. Ultra-short term wind power prediction applying a novel model named SATCN-LSTM. *Energy Conversion and Management*, 2022, **252**: Article No. 115036
 - 111 Wei J Q, Wu X J, Yang T M, Jiao R H. Ultra-short-term forecasting of wind power based on multi-task learning and LSTM. *International Journal of Electrical Power & Energy Systems*, 2023, **149**: Article No. 109073
 - 112 Li Z, Ye L, Zhao Y N, Pei M, Lu P, Li Y L, et al. A spatiotemporal directed graph convolution network for ultra-short-term wind power prediction. *IEEE Transactions on Sustainable Energy*, 2023, **14**(1): 39–54
 - 113 Liu X Y, Zhang Y R, Zhen Z, Xu F, Wang F, Mi Z Q. Spatiotemporal graph neural network and pattern prediction based ultra-short-term power forecasting of wind farm cluster. *IEEE Transactions on Industry Applications*, 2024, **60**(1): 1794–1803
 - 114 Lv Y L, Hu Q, Xu H, Lin H Y, Wu Y F. An ultra-short-term wind power prediction method based on spatial-temporal attention graph convolutional model. *Energy*, 2024, **293**: Article No. 130751
 - 115 Wei H, Wang W S, Kao X X. A novel approach to ultra-short-term wind power prediction based on feature engineering and Informer. *Energy Reports*, 2023, **9**: 1236–1250
 - 116 Li Q, Ren X Y, Zhang F, Gao L, Hao B. A novel ultra-short-term wind power forecasting method based on TCN and Informer models. *Computers and Electrical Engineering*, 2024, **120**: Article No. 109632
 - 117 Yu M, Niu D, Gao T, Wang K, Sun L, Li M, et al. A novel framework for ultra-short-term interval wind power prediction based on RF-WOA-VMD and BiGRU optimized by the attention mechanism. *Energy*, 2023, **269**: Article No. 126738
 - 118 Zeng J W, Qiao W. Short-term solar power prediction using a support vector machine. *Renewable Energy*, 2013, **52**: 118–127
 - 119 Sánchez I. Short-term prediction of wind energy production. *International Journal of Forecasting*, 2006, **22**(1): 43–56
 - 120 Wang J D, Li P, Ran R, Che Y B, Zhou Y. A short-term photovoltaic power prediction model based on the gradient boost decision tree. *Applied Sciences*, 2018, **8**(5): Article No. 689
 - 121 Rahman M M, Shakeri M, Tiong S K, Khatun F, Amin N, Pasupuleti J, et al. Prospective methodologies in hybrid renewable energy systems for energy prediction using artificial neural networks. *Sustainability*, 2021, **13**(4): Article No. 2393
 - 122 Liao W L, Bak-Jensen B, Pillai J R, Yang Z, Liu K P. Short-term power prediction for renewable energy using hybrid graph convolutional network and long short-term memory approach. *Electric Power Systems Research*, 2022, **211**: Article No. 108614
 - 123 He Y Y, Wang Y. Short-term wind power prediction based on EEMD-LASSO-QRNN model. *Applied Soft Computing*, 2021, **105**: Article No. 107288
 - 124 Ding Y F, Chen Z J, Zhang H W, Wang X, Guo Y. A short-term wind power prediction model based on CEEMD and WOA-KELM. *Renewable Energy*, 2022, **189**: 188–198
 - 125 Chen H P, Wu H Y, Kan T Y, Zhang J H, Li H L. Low-carbon economic dispatch of integrated energy system containing electric hydrogen production based on VMD-GRU short-term wind power prediction. *International Journal of Electrical Power & Energy Systems*, 2023, **154**: Article No. 109420
 - 126 Zhang D D, Chen B A, Zhu H Y, Goh H H, Dong Y X, Wu T. Short-term wind power prediction based on two-layer decom-

- position and BiTCN-BiLSTM-attention model. *Energy*, 2023, **285**: Article No. 128762
- 127 Elizabeth Michael N, Mishra M, Hasan S, Al-Durra A. Short-term solar power predicting model based on multi-step CNN stacked LSTM technique. *Energies*, 2022, **15**(6): Article No. 2150
 - 128 Wu B R, Wang L, Zeng Y R. Interpretable wind speed prediction with multivariate time series and temporal fusion Transformers. *Energy*, 2022, **252**: Article No. 123990
 - 129 Deng J L. Introduction to grey system theory. *The Journal of Grey System*, 1989, **1**(1): 1–24
 - 130 He X B, Wang Y, Zhang Y Y, Ma X, Wu W Q, Zhang L. A novel structure adaptive new information priority discrete grey prediction model and its application in renewable energy generation forecasting. *Applied Energy*, 2022, **325**: Article No. 119854
 - 131 Wang Y, Wang L, Ye L L, Ma X, Wu W Q, Yang Z S, et al. A novel self-adaptive fractional multivariable grey model and its application in forecasting energy production and conversion of China. *Engineering Applications of Artificial Intelligence*, 2022, **115**: Article No. 105319
 - 132 Qian W Y, Sui A. A novel structural adaptive discrete grey prediction model and its application in forecasting renewable energy generation. *Expert Systems With Applications*, 2021, **186**: Article No. 115761
 - 133 Ding S, Li R J, Tao Z. A novel adaptive discrete grey model with time-varying parameters for long-term photovoltaic power generation forecasting. *Energy Conversion and Management*, 2021, **227**: Article No. 113644
 - 134 Ren Xin, Wang Yi-Mei, Wang Hua, Zhou Li, Ge Chang, Han Shuang. Two types of medium-long-term wind power forecasting methods based on improved CNN-GRU and Informer. *Modern Electric Power*, 2025, **42**(3): 542–549
(任鑫, 王一妹, 王华, 周利, 葛畅, 韩爽. 基于改进卷积-门控网络及 Informer 的两种中长期风电功率预测方法. *现代电力*, 2025, **42**(3): 542–549)
 - 135 Liu Da-Gui, Wang Wei-Qing, Zhang Hui-E, Qiu Gang, Hao Hong-Yan, Li Guo-Qing, et al. Application of Markov modified combination model mid-long term available quantity of electricity forecasting in Xinjiang wind power. *Power System Technology*, 2020, **44**(9): 3290–3296
(刘大贵, 王维庆, 张慧娥, 丘刚, 郝红岩, 李国庆, 等. 马尔科夫修正的组合模型在新疆风电中长期可用电量预测中的应用. *电网技术*, 2020, **44**(9): 3290–3296)
 - 136 Li Q Y, Deng Y X, Liu X, Sun W, Li W T, Li J, et al. Autonomous smart grid fault detection. *IEEE Communications Standards Magazine*, 2023, **7**(2): 40–47
 - 137 Deng X Z, Ye A S, Zhong J S, Xu D, Yang W W, Song Z F, et al. Bagging-XGBoost algorithm based extreme weather identification and short-term load forecasting model. *Energy Reports*, 2022, **8**: 8661–8674
 - 138 Hichri A, Hajji M, Mansouri M, Abodayeh K, Bouzrara K, Nounou H, et al. Genetic-algorithm-based neural network for fault detection and diagnosis: Application to grid-connected photovoltaic systems. *Sustainability*, 2022, **14**(17): Article No. 10518
 - 139 Chai E X, Zeng P L, Ma S C, Xing H, Zhao B. Artificial intelligence approaches to fault diagnosis in power grids: A review. In: *Proceedings of the Chinese Control Conference (CCC)*. Guangzhou, China: IEEE, 2019. 7346–7353
 - 140 Zhang S L, Wang Y X, Liu M Q, Bao Z J. Data-based line trip fault prediction in power systems using LSTM networks and SVM. *IEEE Access*, 2018, **6**: 7675–7686
 - 141 Branco N W, Cavalcá M S M, Stefenon S F, Leithardt V R Q. Wavelet LSTM for fault forecasting in electrical power grids. *Sensors*, 2022, **22**(21): Article No. 8323
 - 142 Li P H, Zhang Z J, Grosu R, Deng Z W, Hou J, Rong Y J, et al. An end-to-end neural network framework for state-of-health estimation and remaining useful life prediction of electric vehicle lithium batteries. *Renewable and Sustainable Energy Reviews*, 2022, **156**: Article No. 111843
 - 143 Luo J H, Zhang X. Convolutional neural network based on attention mechanism and Bi-LSTM for bearing remaining life prediction. *Applied Intelligence*, 2022, **52**(1): 1076–1091
 - 144 Zhang Y, Xin Y Q, Liu Z W, Chi M, Ma G J. Health status assessment and remaining useful life prediction of aero-engine based on BiGRU and MMoE. *Reliability Engineering & System Safety*, 2022, **220**: Article No. 108263
 - 145 Jiang Y C, Dai P W, Fang P C, Zhong R Y, Cao X C. Electrical-STGCN: An electrical spatio-temporal graph convolutional network for intelligent predictive maintenance. *IEEE Transactions on Industrial Informatics*, 2022, **18**(12): 8509–8518
 - 146 Jiang H, Li L X, Xian H R, Hu Y L, Huang H H, Wang J Z. Crowd flow prediction for social internet-of-things systems based on the mobile network big data. *IEEE Transactions on Computational Social Systems*, 2022, **9**(1): 267–278
 - 147 Chen L, Zhong X H, Zhang F, Cheng Y, Xu Y H, Qi Y, et al. FuXi: A cascade machine learning forecasting system for 15-day global weather forecast. *npj Climate and Atmospheric Science*, 2023, **6**(1): Article No. 190
 - 148 Chen K, Han T, Gong J C, Bai L, Ling F H, Luo J J, et al. FengWu: Pushing the skillful global medium-range weather forecast beyond 10 days lead. *arXiv preprint arXiv: 2304.02948*, 2023.
 - 149 Lam R, Sanchez-Gonzalez A, Willson M, Wernsberger P, Fortunato M, Alet F, et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, **382**(6677): 1416–1421
 - 150 Zhang Y C, Long M S, Chen K Y, Xing L X, Jin R H, Jordan M I, et al. Skillful nowcasting of extreme precipitation with NowcastNet. *Nature*, 2023, **619**(7970): 526–532
 - 151 Hu Y, Chen L, Wang Z B, Li H. SwinVRNN: A data-driven ensemble forecasting model via learned distribution perturbation. *Journal of Advances in Modeling Earth Systems*, 2023, **15**(2): Article No. e2022MS003211
 - 152 Pathak J, Subramanian S, Harrington P, Raja S, Chattopadhyay A, Mardani M, et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv preprint arXiv: 2202.11214*, 2022.
 - 153 Weyn J A, Durran D R, Caruana R, Cresswell-Clay N. Sub-seasonal forecasting with a large ensemble of deep-learning weather prediction models. *Journal of Advances in Modeling Earth Systems*, 2021, **13**(7): Article No. e2021MS002502
 - 154 Li K, Huang W, Hu G Y, Li J. Ultra-short term power load forecasting based on CEEMDAN-SE and LSTM neural network. *Energy and Buildings*, 2023, **279**: Article No. 112666
 - 155 Li W, Gao L, Zhuang Q Z, Shu X Y. Prediction of ultra-short-term wind power based on VMD-Transformer-SSA. In: *Proceedings of the International Conference on Energy and Electrical Engineering (EEE)*. Nanchang, China: IEEE, 2024. 1–6
 - 156 Shi H F, Miao K, Ren X C. Short-term load forecasting based on CNN-BiLSTM with Bayesian optimization and attention

- mechanism. *Concurrency and Computation: Practice and Experience*, 2023, **35**(17): Article No. e6676
- 157 Ren Jian-Ji, Wei Hui-Hui, Zou Zhuo-Lin, Hou Ting-Ting, Yuan Yong-Liang, Shen Ji-Quan, et al. Ultra-short-term power load forecasting based on CNN-BiLSTM-Attention. *Power System Protection and Control*, 2022, **50**(8): 108–116
(任建吉, 位慧慧, 邹卓霖, 侯庭庭, 原永亮, 沈记全, 等. 基于 CNN-BiLSTM-Attention 的超短期电力负荷预测. *电力系统保护与控制*, 2022, **50**(8): 108–116)
 - 158 Zeng W H, Li J R, Sun C C, Cao L, Tang X P, Shu S L, et al. Ultra short-term power load forecasting based on similar day clustering and ensemble empirical mode decomposition. *Energies*, 2023, **16**(4): Article No. 1989
 - 159 Li H Z, Liu H Y, Ji H Y, Zhang S Y, Li P F. Ultra-short-term load demand forecast model framework based on deep learning. *Energies*, 2020, **13**(18): Article No. 4900
 - 160 Zhang Q Y, Chen J H, Xiao G, He S Y, Deng K X. Transform-Graph: A novel short-term electricity net load forecasting model. *Energy Reports*, 2023, **9**: 2705–2717
 - 161 Kong W C, Dong Z Y, Jia Y W, Hill D J, Xu Y, Zhang Y. Short-term residential load forecasting based on LSTM recurrent neural network. *IEEE Transactions on Smart Grid*, 2019, **10**(1): 841–851
 - 162 Lin W X, Wu D, Boulet B. Spatial-temporal residential short-term load forecasting via graph neural networks. *IEEE Transactions on Smart Grid*, 2021, **12**(6): 5373–5384
 - 163 Wang C, Wang Y, Ding Z T, Zheng T, Hu J Y, Zhang K F. A Transformer-based method of multienergy load forecasting in integrated energy system. *IEEE Transactions on Smart Grid*, 2022, **13**(4): 2703–2714
 - 164 Xiao J W, Liu P, Fang H L, Liu X K, Wang Y W. Short-term residential load forecasting with baseline-refinement profiles and Bi-attention mechanism. *IEEE Transactions on Smart Grid*, 2024, **15**(1): 1052–1062
 - 165 Xu H S, Fan G L, Kuang G F, Song Y P. Construction and application of short-term and mid-term power system load forecasting model based on hybrid deep learning. *IEEE Access*, 2023, **11**: 37494–37507
 - 166 Zhang S Y, Chen R H, Cao J C, Tan J. A CNN and LSTM-based multi-task learning architecture for short and medium-term electricity load forecasting. *Electric Power Systems Research*, 2023, **222**: Article No. 109507
 - 167 Yang G, Du S H, Duan Q L, Su J. A novel data-driven method for medium-term power consumption forecasting based on Transformer-lightGBM. *Mobile Information Systems*, **2022**: Article No. 5465322
 - 168 Ammar N, Sulaiman M, Nor A F M. Long-term load forecasting of power systems using artificial neural network and ANFIS. *ARPJ Journal of Engineering and Applied Sciences*, 2018, **13**(3): 828–834
 - 169 Kazemzadeh M R, Amjadian A, Amraee T. A hybrid data mining driven algorithm for long term electric peak load and energy demand forecasting. *Energy*, 2020, **204**: Article No. 117948
 - 170 Nalcaci G, Özmen A, Weber G W. Long-term load forecasting: Models based on MARS, ANN and LR methods. *Central European Journal of Operations Research*, 2019, **27**(4): 1033–1049
 - 171 Taheri S, Jooshaki M, Moeini-Aghaie M. Long-term planning of integrated local energy systems using deep learning algorithms. *International Journal of Electrical Power & Energy Systems*, 2021, **129**: Article No. 106855
 - 172 Agrawal R K, Muchahary F, Tripathi M M. Long term load forecasting with hourly predictions based on long-short-term-memory networks. In: *Proceedings of the IEEE Texas Power and Energy Conference (TPEC)*. College Station, USA: IEEE, 2018. 1–6
 - 173 Wang K, Zhang J L, Li X W, Zhang Y X. Long-term power load forecasting using LSTM-Informer with ensemble learning. *Electronics*, 2023, **12**(10): Article No. 2175
 - 174 China Southern Grid Energy Storage. XS-1000D intelligent analysis system for equipment status of China Southern Grid Energy Storage released V2.0 [Online], available: <https://www.chu21.com/html/chunengy-33278.shtml>, April 30, 2025
(南网储能. 南网储能公司设备状态大数据智能分析系统 XS-1000D 正式发布 V2.0 版本 [Online], available: <https://www.chu21.com/html/chunengy-33278.shtml>, 2025-04-30)



张 辉 湖南大学人工智能与机器人学院教授. 2007 年获得湖南大学博士学位. 主要研究方向为数据分析, 图像处理和机器人控制. 本文通信作者.
E-mail: zhanghui1983@hnu.edu.cn
(**ZHANG Hui** Professor at the School of Artificial Intelligence and Robotics, Hunan University. He received his Ph.D. degree from Hunan University in 2007. His research interest covers data analysis, image processing, and robot control. Corresponding author of this paper.)



颜星雨 湖南大学人工智能与机器人学院硕士研究生. 2024 年获得江南大学学士学位. 主要研究方向为数据分析, 时间序列分析.
E-mail: yanxingyu@hnu.edu.cn
(**YAN Xing-Yu** Master student at the School of Artificial Intelligence and Robotics, Hunan University. She received her bachelor degree from Jiangnan University in 2024. Her research interest covers data analysis and time series analysis.)



毛建旭 湖南大学电气与信息工程学院教授. 2003 年获得湖南大学博士学位. 主要研究方向为数据分析, 信号分析和图像处理.
E-mail: maojianxu@hnu.edu.cn
(**MAO Jian-Xu** Professor at the College of Electrical and Information Engineering, Hunan University. He received his Ph.D. degree from Hunan University in 2003. His research interest covers data analysis, signal analysis, and image processing.)



别克扎提·巴合提 湖南大学人工智能与机器人学院博士研究生. 2020 年获得英国克兰菲尔德大学硕士学位. 主要研究方向为信号分析, 时间序列分析.

E-mail: bbiekezhati@hnu.edu.cn

(BIEKEZHATI Baheti Ph.D. can-

didate at the School of Artificial Intelligence and Robotics, Hunan University. He received his master degree from Cranfield University in 2020. His research interest covers signal analysis and time series analysis.)



杜 瑞 湖南大学人工智能与机器人学院博士研究生. 2020 年获得湘潭大学硕士学位. 主要研究方向为数据分析, 图像处理.

E-mail: durui@hnu.edu.cn

(DU Rui Ph.D. candidate at the School of Artificial Intelligence and

Robotics, Hunan University. He received his master degree from Xiangtan University in 2020. His research interest covers data analysis and image processing.)



王耀南 中国工程院院士, 湖南大学人工智能与机器人学院教授. 1995 年获得湖南大学博士学位. 主要研究方向为数据分析, 智能控制和图像处理.

E-mail: yaonan@hnu.edu.cn

(WANG Yao-Nan Academician at Chinese Academy of Engineering,

professor at the School of Artificial Intelligence and Robotics, Hunan University. He received his Ph.D. degree from Hunan University in 1995. His research interest covers data analysis, intelligent control, and image processing.)